

Министерство науки и высшего образования Российской Федерации
КУБАНСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ

**СОВРЕМЕННОЕ СОСТОЯНИЕ
И ПРИОРИТЕТЫ РАЗВИТИЯ
ФУНДАМЕНТАЛЬНЫХ НАУК В РЕГИОНАХ**

Материалы XXII Всероссийской научной конференции
молодых ученых и студентов

14 – 16 ноября 2025 г.



Краснодар
2025

УДК 001.8(470+571)
ББК 72.5 (2Рос)
С568

Редакционная коллегия:
В.А. Исаев, Н.Н. Куликова

С568 Современное состояние и приоритеты развития фундаментальных наук в регионах: материалы XXII Всерос. науч. конф. молодых ученых и студентов. – Краснодар: Кубанский гос. ун-т, 2025. –210 с. –100 экз.

Освещены актуальные вопросы в различных областях человеческой деятельности. Представлены работы по секциям: «Механика, математика и информатика», «Философия, педагогика и психология», «Физика и астрономия». Приводятся данные о современном состоянии науки и рассматриваются пути ее развития.

Адресуется студентам, аспирантам, молодым ученым и специалистам, работающим в учебных заведениях, научно-исследовательских организациях, а также всем, кто проявляет интерес к научной деятельности. Материалы публикуются в авторской редакции.

УДК 001.8(470+571)
ББК 72.5 (2Рос)

© Кубанский государственный
университет, 2025

СОДЕРЖАНИЕ

Т.А. Абакумов, В.Д. Волковинский, Т.В. Гринцова, М.Д. Зенков МЕТОДОЛОГИЯ ПОСТРОЕНИЯ СИСТЕМ АВТОМАТИЧЕСКОГО КОНТРОЛЯ СРЕДСТВ ИНДИВИДУАЛЬНОЙ ЗАЩИТЫ НА ОСНОВЕ ГЛУБОКОГО ОБУЧЕНИЯ И DEVOPS-ПРАКТИК	8
М.К. Агасян ВТОНОМНЫЙ ИИ АГЕНТ ДЛЯ АВТОМАТИЧЕСКОГО РАЗРЕШЕНИЯ РЕКУРРЕНТНЫХ ИНЦИДЕНТОВ В IT ИНФРАСТРУКТУРЕ	13
К.А. Акобян АРХИТЕКТУРЫ МОБИЛЬНЫХ ПРИЛОЖЕНИЙ	18
А.В. Алейкина РАВНИТЕЛЬНЫЙ АНАЛИЗ ЭКСПЕРТНЫХ СИСТЕМ И НЕЙРОННЫХ СЕТЕЙ: КРИТЕРИИ ВЫБОРА И НАПРАВЛЕНИЯ РАЗВИТИЯ	22
Ю.М. Ачмиз СИСТЕМА АВТОМАТИЗИРОВАННОГО ТЕСТИРОВАНИЯ И МОНИТОРИНГА ВЕБ-СЕРВИСОВ	28
М.А. Бакалкин ТЕХНОЛОГИЯ КОНТЕЙНЕРИЗАЦИИ КАК ОСНОВА ЭФФЕКТИВНОГО И ОТКАЗОУСТОЙЧИВОГО РАЗВЕРТЫВАНИЯ ПРИЛОЖЕНИЯ В РАСПРЕДЕЛЕННЫХ СРЕДАХ	31
Н.В. Бондаренко КРОССПЛАТФОРМЕННЫЕ МОБИЛЬНЫЕ ПРИЛОЖЕНИЯ: ИСПОЛЬЗОВАНИЕ В ОБРАЗОВАТЕЛЬНОЙ СФЕРЕ	36
И.А. Васюнин JETRACK COMPOSE: СОВРЕМЕННЫЙ ПОДХОД К ПОСТРОЕНИЮ ПОЛЬЗОВАТЕЛЬСКОГО ИНТЕРФЕЙСА В ANDROID- ПРИЛОЖЕНИЯХ	39

Р.А. Гладких	45
ПРОЕКТИРОВАНИЕ АРХИТЕКТУРЫ И ПРОТОКОЛА БЕЗОПАСНОСТИ ДЛЯ АВТОНОМНОГО АГЕНТА В КОРПОРАТИВНОЙ СРЕДЕ	
В.А. Горбачев	51
РАЗРАБОТКА МОДУЛЯ ИНТЕГРАЦИИ АВТОНОМНОГО АГЕНТА С СИСТЕМАМИ МОНИТОРИНГА И ITSM СИСТЕМАМИ ПО REST API	
Н.С. Горобец	55
ПРИМЕНЕНИЕ ОНЛАЙН-РАСПИСАНИЯ В ОБРАЗОВАТЕЛЬНЫХ И КОРПОРАТИВНЫХ СИСТЕМАХ УПРАВЛЕНИЯ НА БАЗЕ 1С:ПРЕДПРИЯТИЕ.ЭЛЕМЕНТ	
А.В. Горовенко	60
РАЗРАБОТКА МОБИЛЬНОГО ПРИЛОЖЕНИЯ ДЛЯ УДАЛЕННОГО ПРОСМОТРА ВИДЕО С ДЕТЕКЦИЕЙ ОБЪЕКТОВ В РЕАЛЬНОМ ВРЕМЕНИ	
В.А. Дорошенко	64
РАЗРАБОТКА И СРАВНЕНИЕ МЕТОДОВ КЛАССИФИКАЦИИ РЕКУРРЕНТНЫХ ИНЦИДЕНТОВ ДЛЯ АВТОНОМНОГО ИИ АГЕНТА	
Н.В. Жук	70
МОДЕРНИЗАЦИЯ СОВЕТСКИХ СТАНКОВ С ЧПУ ПО PUMOTIX	
В.Д. Загребнова	77
РАЗРАБОТКА FRONTEND И BACKEND ЧАСТЕЙ РЕГИСТРАЦИИ ПОЛЬЗОВАТЕЛЕЙ В ВЕБ- ПРИЛОЖЕНИИ	
А.П. Ибятков	81
АВТОНОМНЫЙ ИИ-АГЕНТ ДЛЯ АВТОМАТИЧЕСКОГО РАЗРЕШЕНИЯ РЕКУРРЕНТНЫХ ИНЦИДЕНТОВ	
Р.В. Кадыков, М.В. Маслевский, Р.Э. Козинцев	87
МЕХАНИЗМЫ МАСШТАБИРОВАНИЯ ОБЛАЧНЫХ БАЗ ДАННЫХ (DBaaS) И ИХ СРАВНЕНИЕ С ON-PREMISE РЕШЕНИЯМИ	

В.В. Капустин	95
МЕТОДЫ ОПТИМИЗАЦИИ ЭТАПА ПОИСКА И ИЗВЛЕЧЕНИЯ (RETRIEVAL) В RAG- АРХИТЕКТУРЕ ДЛЯ ПОВЫШЕНИЯ РЕЛЕВАНТНОСТИ ОТВЕТОВ	
Ю. А. Клещевич	99
СОВРЕМЕННАЯ ВЕБ-РАЗРАБОТКА: ОСНОВЫ, ИСПОЛЬЗУЕМЫЕ ТЕХНОЛОГИИ И АРХИТЕКТУРА	
Е.С. Криворучко	105
ВЛИЯНИЕ ПРЕДОБРАБОТКИ ТЕКСТА НА ТОЧНОСТЬ КЛАССИФИКАЦИИ ДЛЯ ЗАДАЧ ПСИХОЛОГИЧЕСКОГО ПРОФИЛИРОВАНИЯ	
А.К. Муртазаев	111
СРАВНИТЕЛЬНЫЙ АНАЛИЗ ПОДХОДОВ К РАЗРАБОТКЕ ПОЛЬЗОВАТЕЛЬСКОГО ИНТЕРФЕЙСА В КРОССПЛАТФОРМЕННЫХ МОБИЛЬНЫХ ПРИЛОЖЕНИЯХ: REACT NATIVE И FLUTTER	
М.Л. Нечепорук	118
АНАЛИЗ РАЗРАБОТКИ И ОПТИМИЗАЦИИ СИСТЕМНЫХ ПРОМПТОВ ДЛЯ УПРАВЛЕНИЯ ПОВЕДЕНИЕМ LLM В RAG- СИСТЕМАХ	
Ю.Д. Носовский, Б.Л. Осипов	123
АВТОМАТИЗАЦИЯ БИЗНЕС-ПРОЦЕССОВ С ИСПОЛЬЗОВАНИЕМ ПЛАТФОРМЫ 1С	
Д.В. Нудьга	129
СРАВНИТЕЛЬНЫЙ АНАЛИЗ PWA И НАТИВНЫХ ПРИЛОЖЕНИЙ ДЛЯ ЗАДАЧ МОНИТОРИНГА ЗДОРОВЬЯ НА МОБИЛЬНЫХ УСТРОЙСТВАХ	
И. А. Остриков	134
ВЫБОР МЕЖДУ СИНХРОННЫМ И АСИНХРОННЫМ СТИЛЕМ РАЗРАБОТКИ ВЕБ-ПРИЛОЖЕНИЙ НА ПРИМЕРЕ ЯЗЫКА ПРОГРАММИРОВАНИЯ PYTHON	

Д.С. Павлов	139
СИСТЕМА РАЗВИТИЯ НАВЫКОВ СОТРУДНИКОВ (SKILLTRACKER)	
И.А. Пилипенко	145
РАЗРАБОТКА МИКРОСЕРВИСНОЙ ПЛАТФОРМЫ ДЛЯ ХРАНЕНИЯ И ОБРАБОТКИ МЕДИЦИНСКИХ ИЗОБРАЖЕНИЙ	
А.Е. Пилюгин, А.М. Усейнов	148
ТЕХНОЛОГИЧЕСКИЕ ИННОВАЦИИ ПЛАТФОРМЫ 1С КАК ОСНОВА ДЛЯ ЦИФРОВИЗАЦИИ ПРЕДПРИЯТИЙ	
А.И. Питинов, И.С. Черкунов	155
ТЕНДЕНЦИИ И ПЕРСПЕКТИВЫ 3D-ВИЗУАЛИЗАЦИИ: СТАНДАРТЫ, НЕЙРОСЕТЕВЫЕ МЕТОДЫ И ИНДУСТРИАЛЬНЫЕ ПРАКТИКИ	
В.В. Порозов	163
ИССЛЕДОВАНИЕ ВОЗМОЖНОСТИ УЛУЧШЕНИЯ КАЧЕСТВА ИЗОБРАЖЕНИЯ ПОЛУЧАЕМОГО ВИДЕОПОТОКА С ПОМОЩЬЮ АЛГОРИТМА МАШИННОГО ОБУЧЕНИЯ YOLO	
Пояс С. Е.	168
ИССЛЕДОВАНИЕ ВОЗМОЖНОСТИ УЛУЧШЕНИЯ КАЧЕСТВА ИЗОБРАЖЕНИЯ ПОЛУЧАЕМОГО ВИДЕОПОТОКА С ПОМОЩЬЮ АЛГОРИТМА МАШИННОГО ОБУЧЕНИЯ СВЕРТОЧНЫЕ НЕЙРОННЫЕ СЕТИ (CNN)	
Э.Э. Самадинов	174
СОВРЕМЕННЫЕ ТЕХНОЛОГИИ ВИРТУАЛЬНОЙ РЕАЛЬНОСТИ: ИСПОЛЬЗОВАНИЕ В РЕАЛЬНОЙ ЖИЗНИ И УЧЕБНОМ ПРОЦЕССЕ	
Д.А. Саркисян	178
ПРОЕКТИРОВАНИЕ И РЕАЛИЗАЦИЯ СИСТЕМЫ БЕЗОПАСНОГО ВЫПОЛНЕНИЯ АВТОМАТИЗИРОВАННЫХ СЦЕНАРИЕВ С ИСПОЛЬЗОВАНИЕМ ANSIBLE	

Е.И. Сафиулина	182
СРАВНИТЕЛЬНЫЙ АНАЛИЗ ФРЕЙМВОРКОВ FASTAPI И FLASK ДЛЯ РАЗРАБОТКИ ВЫСОКОПРОИЗВОДИТЕЛЬНОГО БЕКЕНД- СЕРВИСА НА PYTHON	
А.А. Тищенко	186
ОБРАЗОВАНИЕ В НОГУ СО ВРЕМЕНЕМ: ИНТЕРАКТИВНЫЙ ПОРТАЛ МЕНЯЕТ ЖИЗНЬ БУДУЩИХ СТУДЕНТОВ	
В.Н. Значко, Н.А. Томашевский, В.А. Елькин	190
ОЦЕНКА ПРИМЕНИМОСТИ ИСПОЛЬЗОВАНИЯ СОВРЕМЕННЫХ ОТКРЫТЫХ МАЛОВЕСЯЩИХ ЯЗЫКОВЫХ МОДЕЛЕЙ НА МИКРОКОМПЬЮТЕРАХ RASPBERRY PI	
М.А. Цебро	197
СОВРЕМЕННЫЕ ПОДХОДЫ К ОРГАНИЗАЦИИ РАБОТЫ В IT- КОМАНДАХ: ГИБКИЕ МЕТОДОЛОГИИ И ИНСТРУМЕНТЫ КОЛЛАБОРАЦИИ	
Д.В. Цебулевский, Д.Б. Лигидов	201
РАЗРАБОТКА И ВНЕДРЕНИЕ ИНФРАСТРУКТУРЫ ДЛЯ ИНТЕРАКТИВНЫХ ВЫЧИСЛЕНИЙ И РАБОТЫ С ИИ- ИНСТРУМЕНТАМИ НА БАЗЕ JUPYTER NOTEBOOK В КОНТЕЙНЕРИЗИРОВАННОЙ СРЕДЕ	
А.С. Чепик, М.В. Чаус, И.А. Оганян	204
МОДЕЛИРОВАНИЕ БИЗНЕС-ПРОЦЕССОВ ЗАКАЗЧИКА И МОДИФИКАЦИЯ ТИПОВОЙ КОНФИГУРАЦИИ «SANDSOFT: САНАТОРИЙ V7» С ЦЕЛЬЮ ПОВЫШЕНИЯ ЭФФЕКТИВНОСТИ РАБОТЫ	
В.В. Дуденков	210
МЕТОД КВАНТИЛЬНОЙ КАТЕГОРИЗАЦИИ ДЛЯ ПОВЫШЕНИЯ ТОЧНОСТИ ПРОГНОЗИРОВАНИЯ ПАРАМЕТРОВ ЗАДАЧ ЦИФРОВЫХ ПЛАТФОРМ	

МЕТОДОЛОГИЯ ПОСТРОЕНИЯ СИСТЕМ АВТОМАТИЧЕСКОГО КОНТРОЛЯ СРЕДСТВ ИНДИВИДУАЛЬНОЙ ЗАЩИТЫ НА ОСНОВЕ ГЛУБОКОГО ОБУЧЕНИЯ И DEVOPS-ПРАКТИК

Т.А. Абакумов, В.Д. Волковинский, Т.В. Гринцова, М.Д. Зенков
Кубанский государственный университет

Статья посвящена разработке методологии построения систем автоматического контроля средств индивидуальной защиты (СИЗ). Предлагаемый подход интегрирует современные архитектуры обнаружения объектов (YOLOv8) с практиками контейнеризации (Docker) и непрерывной интеграции/доставки (CI/CD, GitLab).

Ключевые слова: методология проектирования, системы автоматического контроля, средства индивидуальной защиты, мониторинг СИЗ, глубокое обучение, нейронные сети, компьютерное зрение, распознавание образов, DevOps практики, CI/CD, MLOps, непрерывная интеграция, непрерывная поставка, промышленная безопасность, безопасность труда

The article is devoted to the development of methodology for building systems for automatic control of personal protective equipment (PPE). The proposed approach integrates modern object detection architectures (YOLOv8) with containerization practices (Docker) and continuous integration/delivery (CI/CD, GitLab).

Key words: design methodology, automatic control systems, personal protective equipment, PPE monitoring, deep learning, neural networks, computer vision, pattern recognition, DevOps practices, CI/CD, MLOps, continuous integration, continuous delivery, industrial safety, occupational safety

Актуальность разработки систем автоматического контроля средств индивидуальной защиты (СИЗ) обусловлена высоким уровнем производственного травматизма и значительными экономическими потерями, связанными с несоблюдением требований безопасности. Традиционный ручной контроль имеет ряд недостатков, в том числе стоимость и трудозатратность, что подталкивает к поиску автоматизированных альтернатив.

Ключевой проблемой в данной области является отсутствие комплексных решений, которые объединяли бы этапы исследования, такие как выбор и обучение моделей машинного обучения, с практическими аспектами внедрения и сопровождения готовых систем. Зачастую разработки остаются на уровне прототипов, не готовых к применению в промышленных условиях.

Целью данной работы является разработка унифицированной методологии проектирования, разработки и развертывания систем автоматического контроля СИЗ. Для достижения этой цели решаются следующие задачи: проведение сравнительного анализа архитектур

обнаружения объектов применительно к задаче детекции СИЗ; формализация требований к данным и процессам их разметки для обеспечения надежности модели; разработка архитектуры программного решения, обеспечивающей переносимость и масштабируемость с использованием контейнеризации и CI/CD.

Научная новизна работы заключается в систематизации процесса создания промышленных систем компьютерного зрения, охватывающей весь жизненный цикл – от выбора алгоритма до организации процессов непрерывной интеграции и доставки.

Выбор архитектуры нейронной сети является ключевым шагом при создании системы автоматического контроля. Основными критериями для сравнения выступают точность (Precision, Recall, mAP), скорость обработки (кадров в секунду, FPS), требования к вычислительным ресурсам. В области обнаружения объектов доминируют два вида нейронных сетей: двухэтапные и одноэтапные детекторы [1].

Двухэтапные детекторы, такие как Faster R-CNN, демонстрируют высокую точность классификации объектов. Их архитектура предполагает на первом этапе генерацию регионов (Region Proposal Network), где потенциально могут находиться объекты, а на втором – классификацию этих регионов. Однако этот процесс является вычислительно сложным, из-за чего повышаются требования к мощности оборудования и времени, что ограничивает применимость Faster R-CNN в задачах, требующих работы в реальном времени, несмотря на чёткость обнаружения небольших или частично закрытых СИЗ.

Одноэтапные детекторы, такие как SSD (Single Shot MultiBox Detector) и семейство YOLO (You Only Look Once), объединяют процессы детекции и классификации в один этап. Это позволяет достичь высокой скорости обработки, что критически важно для систем видеонаблюдения и анализа видео в реальном времени, но при этом может страдать точность. SSD использует стратегию генерации якорных рамок и вычисления функции потерь для одновременной оптимизации классификации и регрессии, что делает его эффективным для устройств с ограниченными ресурсами. Однако он может уступать в чёткости обнаружения на сложных сценах или при детекции мелких объектов по сравнению с двухэтапными методами.

Для обнаружения средств индивидуальной защиты (СИЗ), где важны и быстродействие, и точность, оптимальным решением является модель YOLOv8 [2]. Эта модель представляет собой современную эволюцию одноэтапных детекторов, позволяющих сохранять высокое качество обработки при высокой скорости работы системы. Ключевыми преимуществами этого семейства моделей являются легковесность, энергоэффективность и простота интеграции в конвейеры разработки, благодаря большому количеству готовых реализаций и похожих решений. Использование мозаичного расширения данных и полей привязки, подобранных с помощью алгоритмов кластеризации, позволяет достичь

высокой обобщающей способности. Такая архитектура позволяет более гибко дообучать модель на новых видах СИЗ, при этом не запрашивая больше вычислительных ресурсов. Таким образом, YOLOv8 оптимально подходит для создания систем, работающих в реальном времени на предприятиях, где требуется оперативность реакции и надежность распознавания.

Качество и разнообразие набора данных напрямую определяют исправную работу конечной модели. Датасет для задачи компьютерного зрения представляет собой структурированную подборку изображений, состоящий из признаков (самых изображений) и меток (целевых значений, которые модель должна предсказывать). Для задачи детекции СИЗ целью модели является определение наличия или отсутствия защитного элемента на человеке, на основе чего программное обеспечение может предпринимать дальнейшие действия, например, генерировать уведомления.

К информации, используемой для обучения, предъявляется ряд строгих требований. Ключевое значение имеет разнородность данных, необходимое для минимизации сценариев, в которых модель может не распознать объект. Это подразумевает изменчивость условий освещения (дневной свет, тень, искусственное освещение), углов обзора, фонов (стройки, склады, улицы, офисы), типов и марках СИЗ, антропометрических характеристик людей (пол, возраст, раса), а также погодных условий. Качество изображений должно соответствовать реальным условиям эксплуатации системы. Существенно важен и баланс данных: число образцов для каждого класса должно быть сопоставимым, чтобы избежать предвзятости модели. Несмотря на то, что глубокие нейросети не критичны к формату входных изображений, так как обычно приводят их к единому разрешению, исходные данные должны быть достаточного качества, чтобы объекты оставались узнаваемыми после изменения размера.

Процесс сбора данных может комбинировать несколько подходов для ускорения и повышения репрезентативности. Использование открытых датасетов, таких как представленные на платформе Roboflow, позволяет быстро получить базовый набор изображений. Однако для учета специфики конкретной задачи часто требуется дополнительный сбор данных. Эффективным методом является разбивка видеозаписей на отдельные кадры с помощью инструментов вроде OpenCV, что позволяет получить большое количество разнообразных изображений. Также может применяться краудсорсинг, хотя это требует бюджета и сопряжено с риском получения нерелевантных данных. Оптимальной стратегией является комбинирование готовых датасетов и данных, собранных самостоятельно, что позволяет сэкономить время и одновременно обеспечить близость данных к реальным условиям эксплуатации.

Аннотация данных – это процесс разметки, в ходе которого объекты на изображениях выделяются ограничивающими рамками (bounding boxes) и снабжаются метками классов. Для этого существуют специализированные инструменты, такие как Label Studio, LabelImg и другие. Их функционала

достаточно для комфортного создания аннотаций. Аннотации сохраняются в текстовых файлах, содержащих координаты рамок и идентификаторы классов, в форматах, поддерживаемых выбранной моделью.

После разметки данные подвергаются предобработке и аугментации. Предобработка включает в себя очистку датасета от дубликатов и некачественных изображений, а также нормализацию размеров. Аугментация данных – ключевой метод повышения обобщающей способности модели. Она заключается в искусственном расширении датасета путем применения к изображениям различных преобразований: поворотов, масштабирования, изменения яркости, контрастности и цветовых характеристик. Это помогает модели быть устойчивой к изменениям в условиях съемки. Заключительным этапом подготовки данных является их разделение на три непересекающихся набора: тренировочный (60-70% данных), на котором модель обучается; валидационный (10-20% данных), используемый для подбора гиперпараметров и промежуточной оценки; и тестовый (10-20% данных), для финальной проверки работоспособности обученной модели. Информация о путях к данным и классах упаковывается в конфигурационный YAML-файл, необходимый для работы с фреймворком YOLO [3].

Для создания на основе обученной модели промышленной системы необходима архитектура программного обеспечения, обеспечивающая переносимость, масштабируемость и надежность. Проектирование системы должно быть модульным, разделяющим компоненты детекции (нейронная сеть), логики принятия решений (анализ результатов детекции) и пользовательского интерфейса или API. Такое разделение упрощает разработку, тестирование и сопровождение системы. Схема такой архитектуры представлена на рисунке 1.




Рисунок 1 – Схема архитектуры промышленной системы

Основой переносимости и унификации среды выполнения является контейнеризация. Docker – это платформа, которая позволяет упаковать приложение со всеми его зависимостями (библиотеками, системными утилитами, кодом) в изолированную среду, называемую контейнером. Контейнеры, в отличие от виртуальных машин, используют ядро host-системы, что делает их легковесными и быстрыми. Они обеспечивают изоляцию процессов, файловой системы и сетевых интерфейсов, предотвращая конфликты между разными приложениями. Docker-образ является шаблоном для создания контейнеров и состоит из нескольких слоев, что делает его эффективным с точки зрения хранения и передачи.

Создание Docker-образа для системы детекции описывается в Dockerfile. Этот файл содержит пошаговые инструкции по сборке образа. Пример Dockerfile может включать следующие ключевые инструкции: использование легковесного базового образа Python (FROM); копирование файлов проекта и зависимостей (requirements.txt) в образ (COPY); установку зависимостей с помощью менеджера пакетов pip (RUN); задание рабочей директории (WORKDIR); копирование основного кода приложения; определение переменных окружения (ENV) и, наконец, указание команды для запуска приложения при старте контейнера (CMD). Сборка образа выполняется командой `docker build`, а запуск – `docker run`. Для обеспечения отказоустойчивости используется флаг `--restart=always`, а для взаимодействия с host-системой (например, для доступа к отслеживаемым директориям с видео) применяется монтирование томов [4].

Организация полного жизненного цикла системы обеспечивается практиками Continuous Integration и Continuous Delivery (CI/CD). В качестве платформы может быть выбран GitLab, который интегрирует в себе систему управления версиями, трекинг задач и инструменты CI/CD. Пайплайн CI/CD автоматизирует ключевые этапы: при пуше кода в репозиторий автоматически запускается процесс сборки Docker-образа, прогоняются модульные и интеграционные тесты, а затем происходит развертывание обновленной версии приложения на тестовые или рабочие стенды. Это обеспечивает высокую скорость и надежность поставки изменений, минимизирует риски, связанные с ручным развертыванием, и способствует постоянному поддержанию системы в работоспособном состоянии.

Ключевые преимущества предложенной методологии заключаются в следующем. Во-первых, использование современной архитектуры YOLOv8 обеспечивает оптимальный баланс между скоростью и точностью, недостижимый для более медленных двухэтапных детекторов или менее точных ранних одноэтапных моделей. Во-вторых, применение контейнеризации и CI/CD-пайплайнов придает системе свойства надежности, масштабируемости и легкой воспроизводимости. Docker-контейнеры гарантируют идентичность среды выполнения на всех этапах – от разработки до продакшена, а автоматизация процессов сборки и развертывания минимизирует человеческие ошибки и ускоряет внедрение улучшений. В-

третьих, четкая формализация всех этапов – от сбора данных и выбора модели до инженерной практики развертывания – позволяет использовать данную методологию как фреймворк для создания систем обнаружения объектов и для других задач, не только в области промышленной безопасности.

Выводы работы состоят в том, что в ней описана структурированная методология создания промышленных систем компьютерного зрения. Она систематизирует и связывает воедино разрозненные этапы, сокращая разрыв между теоретическими разработками в области машинного обучения и их практическим внедрением в виде готовых, надежных и масштабируемых программных продуктов.

Перспективы дальнейших исследований и развития методологии включают её адаптацию для обнаружения различных видов средств индивидуальной защиты. Важным направлением является интеграция системы с существующими промышленными системами видеонаблюдения и платформами для генерации оповещений.

СПИСОК ЛИТЕРАТУРЫ

1. Обнаружение объектов в реальном времени на Python с YOLO и OpenCV // CyberForum.ru : сайт. – URL: <https://www.cyberforum.ru/blogs/2409963/10230.html> (дата обращения: 17.09.2025)
2. Shaoqing, R. Faster R-CNN: Towards Real-Time Object Detection with Regional Proposal Networks / R. Shaoqing, H. Kaiming, R. Girshick, J. Sun // IEEE Transactions on Pattern Analysis and Machine Intelligence, Vol. 39, N 6, 2016. – P. 1137-1149.
3. Как быстро создать обучающий датасет для задач обнаружения объектов YOLO с помощью Label Studio // Habr : сайт. – URL: <https://habr.com/ru/articles/670532/> (дата обращения: 17.09.2025)
4. Кейн, Ш. П. Docker. Вводный курс. / Ш. П. Кейн, К. Маттиас. – Астана : АЛИСТ, 2024. – 352 с. – ISBN 978-601-09-7541-5.

АВТОНОМНЫЙ ИИ-АГЕНТ ДЛЯ АВТОМАТИЧЕСКОГО РАЗРЕШЕНИЯ РЕКУРРЕНТНЫХ ИНЦИДЕНТОВ В ИТ-ИНФРАСТРУКТУРЕ

М.К. Агасян

Кубанский государственный университет

В статье рассматривается архитектура, методы и практические подходы к разработке автономного ИИ-агента, предназначенного для автоматического обнаружения, диагностики и разрешения рекуррентных инцидентов в ИТ-инфраструктуре.

Ключевые слова: автономный ИИ агент, интеллектуальная автоматизация, рекуррентные инциденты, управление инцидентами, ИТ-

инфраструктура, AIOps, ITSM, автоматическое разрешение инцидентов, самообучающиеся системы, анализ логов, обнаружение аномалий, поиск корневой причины, оркестрация и автоматизация, автоворкфлоу, отказоустойчивость

The article discusses the architecture, methods, and practical approaches to developing an autonomous AI agent designed to automatically detect, diagnose, and resolve recurrent incidents in IT infrastructure.

Key words: autonomous AI agent, intelligent automation, recurrent incidents, incident management, IT infrastructure, AIOps, ITSM, automatic incident resolution, self-learning systems, log analysis, anomaly detection, root cause analysis, orchestration and automation, automated workflows, fault tolerance

Эволюция подходов к управлению инцидентами в ИТ тесно связана с развитием архитектур и инструментов мониторинга. На ранних этапах (1990-е – начало 2000-х) операции опирались на ручные процедуры и наборы стандартных операционных процессов (SOP). Появление систем мониторинга (Nagios, Zabbix), платформ логирования и трассировки (ELK/EFK, Jaeger), а также средств управления конфигурациями (Puppet, Chef, Ansible) постепенно перевело часть рутины в автоматические сценарии [1]. В дальнейшем появились runbook-automation (RBA) и SOAR-платформы, позволяющие формализовать процедуры реагирования и безопасно исполнять автоматические шаги [4]. Сейчас, с распространением методов AIOps и больших языковых моделей, появилась возможность создавать агентов, которые не только выполняют заранее прописанные сценарии, но и учатся на истории инцидентов, выявляют рекуррентные паттерны и адаптируют стратегию восстановления в реальном времени [3]. Это даёт шанс перейти от периодического ручного реагирования к непрерывному, контекстно-зависимому самовосстановлению инфраструктуры.

Проект автономного ИИ-агента для разрешения рекуррентных инцидентов логически сводится к многослойной архитектуре, где каждый слой решает отдельный класс задач: интеграция и сбор данных, нормализация, корреляция событий, диагностика и RCA, генерация и симуляция действий, исполнение runbook'ов и непрерывное обучение. На этапе интеграции агент получает телеметрию (метрики, логи, трассировки), события из систем оповещений (PagerDuty, Opsgenie), а также конфигурационные данные и топологию сервисов (CMDB, сервис-карты). Ключевой практической проблемой является качество и полнота данных: разноформатные логи, значения в разных единицах, шум и пропуски телеметрии требуют мощных механизмов нормализации и фильтрации. Современные AIOps-платформы предлагают готовые коннекторы, но в реальности часто требуется разработка промежуточных адаптеров и пайплайнов предобработки для конкретного ландшафта сервисов.

После первичной агрегации следует этап корреляции и выявления рекуррентных паттернов: события группируются по сущностям (инстанс,

сервис, кластер) и по семантике (тип ошибки, трассировка стека, временная последовательность). Для этого применяют методы кластеризации для поиска похожих инцидентов, алгоритмы временных рядов для выделения сезонных повторений и графовые модели для учета взаимозависимостей между компонентами. Нередко удаётся вычлениить «типичные» сценарии – например, увеличение латентности API после деплоя, рост ошибок I/O при достижении предела дискового ввода-вывода на узлах, или плавный рост потребления памяти в результате утечки в библиотеке. Выявление рекуррентности – ключ к тому, чтобы агент мог предлагать не только реактивные, но и проактивные меры, снижая число повторных инцидентов.

Диагностика причин (RCA) в рамках автономного агента требует сочетания статистических методов, моделей объяснимого машинного обучения и графовых аналитических подходов. Часто используются feature-importance, SHAP-оценки и другие XAI-методы, чтобы оператор мог увидеть, почему агент выбрал то или иное действие. Графовые модели (dependency graphs, service maps) позволяют отследить цепочку зависимостей – например, как деградация сетевого сегмента приводит к падению ряда потребителей. Аналитика исторических runbook'ов и результатов ранее применяемых ремедиаций даёт эмпирическую оценку эффективности действий: какие шаги ранее сокращали MTTR, какие приводили к регрессиям и т.д. Такая «коллекция решений» служит базой для генерации новых планов действий и для обучения моделей, оценивающих ожидаемый эффект каждого шага.

Генерация плана действий и оценка риска – ещё один важный компонент. Агент должен предлагать ограниченный набор безопасных, проверенных действий (рестарт сервиса, масштабирование, откат релиза, изменение конфигурации балансировщика), а также уметь симулировать последствия (например, с помощью staging-окружения или цифрового двойника). Стратегия 'canary + gradual rollout' и контрольные точки для отката – обязательные элементы, которые позволяют снизить вероятность негативного влияния автоматических изменений. Для оценки риска применяются простые эвристики (прошлая эффективность, критичность ресурса) и более сложные модели, оценивающие потенциальный ущерб по SLA/SLO и бизнес-метрикам.

Исполняющий модуль (runbook execution engine) реализует оркестрацию конкретных шагов и взаимодействует с инструментами автоматизации (Ansible, Rundeck, Kubernetes API). Важна поддержка транзакционного поведения: атомарность шагов, контрольные точки и возможности отката. Политики доступа (least privilege) и изоляция ролей гарантируют, что только уполномоченные агенты или модули могут вносить изменения в критичные системы. Кроме того, необходимо логирование и хранение телеметрии по каждому автоматическому действию для последующего аудита и forensic-разборов.

Обучение и обратная связь являются основой повышения

эффективности агента во времени. Модели должны переобучаться по мере накопления новых данных, учитывать дрейф распределений и изменения инфраструктуры. В исследованиях и практических проектах доказана применимость методов обучения с подкреплением (RL) для оптимизации последовательности действий: агент учится минимизировать MTTR и экономические потери, получая вознаграждение за успешные сценарии [5]. Однако в продакшене RL стоит применять осторожно: до развёртывания в реальной среде алгоритмы обучают в симуляциях или на цифровых двойниках, потому что неподконтрольное исследование пространства действий может привести к нежелательным последствиям.

Внедрение автономного агента сопряжено с рядом ограничений и рисков [2]. Первое – риск ошибочных действий: неверная классификация или некорректный план может усугубить проблему (например, массовые рестарты при проблемах сети). Второе – доверие операторов: без объяснимой логики и прозрачных критериев операторы будут блокировать автоматизацию. Третье – вопросы безопасности и прав: агенты требуют привилегий для выполнения изменений, и неправильное управление доступом создаёт уязвимости. Четвёртое – качество данных и интеграция: разнородность форматов и пробелы в телеметрии снижают эффективность моделей. Пятое – организационные ограничения: политика безопасности или регуляторные требования могут запрещать автономные вмешательства в продуктив.

Практические рекомендации по снижению рисков включают: сначала автоматизировать простые, низкорисковые операции (рестарт сервисов, сбор детальной телеметрии), выстраивать строгие политики доступа (least privilege), реализовать механизмы аудита и логирования всех действий, а также обеспечить опцию немедленного отключения автоматизации (kill switch). Режимы работы агента должны предусматривать полностью автономный режим, полуавтономный (с подтверждением оператора) и аудиторский режим (только запись рекомендаций). Тестирование в контролируемых экспериментах, использование канареечных развёртываний и цифровых двойников позволяет безопасно отрабатывать стратегии и обучать модели на реалистичных сценариях.

Метрики эффективности автономного агента включают снижение MTTR (mean time to recovery), уменьшение числа рекуррентных инцидентов, долю инцидентов, разрешённых без участия человека, а также экономический эффект от сокращения затрат и уменьшения потерь при простоях. Важно также отслеживать метрики безопасности: частота неправильных действий, число событий с эскалацией и регрессий после автоматических вмешательств.

Снижение MTTR достигается за счёт быстрого обнаружения и корректной диагностики причин, а также за счёт правильного выбора и безопасного выполнения шагов. Уменьшение числа рекуррентных инцидентов требует способности агента выявлять первопричины и предлагать перманентные исправления (например, изменение конфигурации, патч, перераспределение нагрузки). Автоматизация не должна заменять

человеческое принятие решений там, где необходима оценка бизнес-контекста; напротив, её задача – освободить людей от рутинных восстановительных действий и дать им возможность сосредоточиться на долгосрочных улучшениях.

Текущие исследования показывают растущую поддержку подходов *agent*ic AI и RL для задач автоматического реагирования, однако практические решения ещё находятся в стадии активной разработки и пилотирования [5, 6]. Работы последних лет показывают успехи в специфических доменах (сети, облачные кластеры, автоматизация DevOps), но также подчёркивают необходимость жёстких ограничений на права действий и прозрачного аудита. Многие отчёты рекомендуют поэтапный переход к автономии: от ассистирующих рекомендательных систем к полуавтономным агентам с операторским подтверждением и далее к полностью автономным сценариям, ограниченным канареечными образцами и бизнес-правилами.

Кроме технических аспектов, важна организационная составляющая: определения ответственности, процедур инцидент-менеджмента в условиях автономии, процессы валидации и регламентация критериев включения автономных действий. Необходимо назначение ответственных за решения агента, ведение реестра действий и периодический аудит эффективности. Также следует внедрять процессы обратной связи, чтобы операторы могли легко пометить ошибочные действия и инициировать переобучение моделей.

Пример поэтапного плана внедрения и пилотирования:

- 1) выбор безопасной ниши – действия с низким риском (рестарт приложений, сбор расширенной диагностики);
- 2) интеграция с системами мониторинга и CMDB, нормализация данных и создание пайплайна предобработки;
- 3) построение модуля корреляции и шаблонов рекуррентных инцидентов;
- 4) разработка симулятора/цифрового двойника для обучения и тестирования алгоритмов RL;
- 5) внедрение режима рекомендаций (*human-in-the-loop*) и сбор метрик эффективности;
- 6) постепенное переключение на полуавтономный режим с канареечными откатами;
- 7) мониторинг, аудит и переобучение моделей на живых данных.

Разработка автономного ИИ-агента – многопрофильный инженерный проект, требующий знаний в области системного мониторинга, машинного обучения, безопасного DevOps и систем управления рисками. При должном подходе и строгих ограничениях такие агенты способны существенно сократить время восстановления сервисов и снизить число повторных инцидентов, однако их внедрение должно сопровождаться прозрачной политикой, документированными процедурами и возможностью быстрого вмешательства человека. В образовательном и пилотном контексте целесообразно начинать с простых сценариев и прорабатывать архитектуру на

примерах средней сложности, чтобы накопить статистику эффективности и научить модели безопасно действовать в меняющемся окружении.

Таким образом, автономный ИИ-агент для автоматического разрешения рекуррентных инцидентов представляет собой реалистичную и технологически достижимую цель. Ключ к успешной реализации – сочетание качественной телеметрии, модулей корреляции и RCA, безопасного исполнения действий, прозрачных механизмов принятия решений и организационных мер контроля. При рациональном внедрении такие решения способны изменить практику операционной поддержки и повысить устойчивость цифровых сервисов.

СПИСОК ЛИТЕРАТУРЫ

1. Д. Гонсалес де ла Хера. Современный подход к наблюдаемости // Хабр. – 2 дек. 2022. – URL: <https://habr.com/ru/companies/slurm/articles/703056/> (дата обращения: 05.09.2025).
2. Почему я не верю в ИИ-агентов в 2025 году – несмотря на хайп // Хабр. – 24 сент. 2025. – URL: <https://habr.com/ru/articles/950072/> (дата обращения: 22.09.2025).
3. В. Чечеткин. AIOps – следующий шаг в развитии ИТ-операций // РБК Тренды. – 2023. – URL: <https://trends.rbc.ru/trends/industry/641061579a7947de816ee007> (дата обращения: 16.09.2025).
4. S. Holik, и др. CI/CD Automation Challenges in Microservice Environments // ResearchGate. – дек. 2022. – URL: <https://www.researchgate.net/publication/392136739> (дата обращения: 09.09.2025).
5. R. D. Zota, C. Bărbulescu, R. Constantinescu. A Practical Approach to Defining a Framework for Developing an agentic AIOps System // Electronics. – 2025. – Т. 14, № 9. – Ст. 1775. – DOI: 10.3390/electronics14091775.
6. M. Poda. Mission: AI Possible – What agentic AI Means for the Future of ITops // LogicMonitor Blog. – 2023. – URL: <https://www.logicmonitor.com/blog/decoding-agentic-ai-for-itops-excellence-with-openai-and-devoteam> (дата обращения: 11.09.2025).

АРХИТЕКТУРЫ МОБИЛЬНЫХ ПРИЛОЖЕНИЙ

К.А. Акобян

Кубанский государственный университет

В статье рассматриваются современные архитектуры мобильных приложений и основные принципы их построения. Анализируются традиционные и современные подходы к архитектурному проектированию, такие как MVC, MVP, MVVM, Clean Architecture и модульная архитектура.

Ключевые слова: архитектура мобильных приложений, многослойная архитектура, MVC, MVP, MVVM, Clean Architecture, модульность, масштабируемость, тестируемость, кроссплатформенная разработка, нативные приложения, управление состоянием, паттерны проектирования, клиент серверная архитектура, производительность мобильных приложений

The article discusses modern mobile application architectures and the basic principles of their construction. Traditional and modern approaches to architectural design such as MVC, MVP, MVVM, Clean Architecture and modular architecture are analyzed.

Key words: mobile application architecture, multilayer architecture, MVC, MVP, MVVM, Clean Architecture, modularity, scalability, testability, cross platform development, native applications, state management, design patterns, client server architecture, mobile app performance

Современные мобильные приложения представляют собой сложные программные системы, требующие продуманной архитектуры. Архитектура определяет внутреннюю структуру приложения, связи между компонентами, правила обмена данными и ответственности различных частей системы. От того, насколько грамотно выстроена архитектура, напрямую зависят производительность, надёжность и возможность дальнейшего развития приложения. Ошибки на этапе проектирования приводят к техническому долгу, усложнению поддержки и необходимости полной переработки при добавлении новых функций [1].

В отличие от настольных приложений, мобильные решения сталкиваются с рядом специфических ограничений. Устройства обладают ограниченными ресурсами памяти и вычислительной мощности, энергопотребление играет критическую роль, а соединение с сетью может быть нестабильным. Поэтому архитектура мобильного приложения должна обеспечивать не только функциональность, но и устойчивость к сбоям, работу в офлайн-режиме, экономное использование ресурсов и высокую отзывчивость пользовательского интерфейса. Ключевым требованием к архитектуре мобильных систем является разделение ответственности между компонентами. Это позволяет добиться модульности, гибкости и облегчить тестирование. Среди нефункциональных характеристик, определяющих качество архитектуры, можно выделить производительность, сопровождаемость, расширяемость, безопасность и тестируемость. Хорошая архитектура должна позволять добавлять новые возможности без радикальных изменений существующего кода, обеспечивать лёгкое внесение исправлений и предсказуемое поведение при изменениях внешней среды.

Наиболее известным классическим подходом является паттерн Model-View-Controller (MVC), который разделяет приложение на три логические части – модель, представление и контроллер. Модель отвечает за бизнес-логику и данные, представление отображает информацию, а контроллер связывает их, реагируя на действия пользователя. Однако практика показала,

что в мобильных приложениях контроллеры часто разрастаются из-за необходимости напрямую взаимодействовать с пользовательским интерфейсом, что снижает модульность и делает тестирование затруднительным [2].

Следующим этапом развития стал паттерн Model-View-Presenter (MVP), который смещает основную логику из контроллера в презентер. Презентер управляет взаимодействием между моделью и представлением, а само представление становится «пассивным» и не содержит бизнес-логики. Такой подход значительно повышает тестируемость и улучшает разделение обязанностей, что особенно актуально для Android-приложений [3]. При этом вводится дополнительный слой абстракции, но затраты на него оправдываются упрощением поддержки.

Паттерн Model-View-ViewModel (MVVM) является дальнейшей эволюцией идеи разделения логики и представления. В нём вводится промежуточный слой ViewModel, обеспечивающий двустороннюю привязку данных (data binding) между моделью и представлением. Это позволяет View оставаться максимально декларативным, а логика интерфейса переносится в ViewModel, что делает систему более гибкой и удобной для тестирования. MVVM особенно эффективно применяется в средах с реактивной обработкой данных и встроенными механизмами биндинга, таких как Flutter, SwiftUI или Jetpack Compose.




Рисунок 1 – популярные виды архитектур

Современные архитектуры мобильных приложений развиваются в сторону модульности и изоляции уровней. Одним из самых влиятельных подходов считается Clean Architecture, предложенная Робертом Мартином. Её принцип состоит в чётком разделении системы на независимые слои, где зависимости направлены внутрь – от внешних уровней к внутренним. Бизнес-логика и сущности находятся в центре, а внешние интерфейсы, такие как пользовательский интерфейс, база данных и API, – на периферии. Это обеспечивает высокую тестируемость, лёгкость замены инфраструктурных

компонентов и независимость логики от фреймворков [3]. Недостатком подхода можно считать повышенную сложность реализации и необходимость строгого соблюдения архитектурных границ, однако в крупных проектах выгоды очевидны. Параллельно развивается модульная архитектура, основанная на разделении приложения на автономные фичи-модули. Каждый модуль содержит собственные слои и может развиваться независимо. Такая архитектура упрощает командную разработку, позволяет гибко подключать или отключать функциональные части и снижает время сборки. Подобный подход успешно применяется в масштабных системах, где модульность становится ключевым фактором управляемости проекта. Современные приложения редко функционируют изолированно – большинство из них используют распределённые архитектуры. Наиболее распространённой остаётся клиент-серверная модель, при которой мобильное приложение выступает клиентом, взаимодействующим с серверной частью через API. Сервер реализует бизнес-логику, хранит данные и обеспечивает централизованную безопасность. Преимуществами модели являются независимость клиентской и серверной частей, гибкость масштабирования и упрощение обновлений. Основным недостатком остаются сетевые задержки и необходимость реализации офлайн-режима на клиенте.

С развитием облачных технологий и микросервисных архитектур серверная часть мобильных систем стала представлять собой набор взаимосвязанных сервисов, каждый из которых отвечает за определённую бизнес-функцию. Клиент взаимодействует с ними через API-шлюз или backend-for-frontend слой, что позволяет адаптировать ответы под особенности мобильных устройств. Такая архитектура обеспечивает масштабируемость, но требует строгого контроля версий API, обработки ошибок и устойчивости к временным сбоям связи. В последние годы активно развивается подход edge computing, предполагающий выполнение части вычислений ближе к пользователю. Это особенно актуально для задач, где критична задержка отклика – дополненная реальность, потоковая обработка видео, IoT-устройства. В архитектурах, объединяющих мобильные, edge- и облачные уровни, часть логики и обработки данных переносится на ближайший сервер, а облако используется для хранения и аналитики. Такое распределение снижает нагрузку на сеть и ускоряет взаимодействие, но усложняет синхронизацию и обеспечение согласованности данных.

Особое внимание при проектировании архитектуры уделяется вопросам безопасности и тестируемости. Архитектура должна предусматривать безопасное хранение данных, шифрование коммуникаций, защиту от взлома и возможность обновлений без компрометации пользовательской информации. Для защиты чувствительных данных используются специальные хранилища, такие как Keychain на iOS и Keystore на Android. Передача данных должна выполняться по защищённым протоколам TLS, а управление доступом – через безопасные токены и авторизацию OAuth. Безопасность не может

рассматриваться как дополнительный слой – она должна быть встроена в архитектурные принципы системы [5].

Архитектура – это не просто структура кода, а стратегическое решение, определяющее будущее приложения, чаще всего используются архитектуры, представленные на рисунке 1. Грамотный выбор архитектурного подхода требует баланса между сложностью, гибкостью и производительностью. Для небольших проектов достаточно простых моделей, таких как MVC или MVP, но по мере роста системы оправдано использование более строгих архитектур – Clean Architecture.

Таким образом, архитектура мобильных приложений представляет собой динамично развивающуюся область, сочетающую принципы инженерии программного обеспечения, системного проектирования и особенностей мобильных платформ.

СПИСОК ЛИТЕРАТУРЫ

1. Мартин Р. Чистая архитектура. Искусство разработки программного обеспечения / Роберт Мартин. – Москва, Издательство: “Питер” – 2020. – 352 с. – ISBN: 978-5-4461-1188-6.
2. Фаулер М. Архитектура корпоративных приложений / Мартин Фаулер. – Санкт-Петербург, Издательство: “Питер” – 2021. – 560 с. – ISBN: 978-5-4461-1117-6.
3. Flutter Documentation. Architectural Overview // dart.dev. – URL: <https://docs.flutter.dev/development/data-and-backend/state-mgmt/architectural-overview> – Дата обращения: 11.09.2025.
4. Android Developers. Guide to app architecture // developers.android.com. – URL: <https://developer.android.com/topic/architecture> – Дата обращения: 12.10.2025.
5. Apple Developer Documentation. MVC and MVVM in iOS Architecture // developer.apple.com. – URL: <https://developer.apple.com/documentation/> – Дата обращения: 14.10.2025.

СРАВНИТЕЛЬНЫЙ АНАЛИЗ ЭКСПЕРТНЫХ СИСТЕМ И НЕЙРОННЫХ СЕТЕЙ: КРИТЕРИИ ВЫБОРА И НАПРАВЛЕНИЯ РАЗВИТИЯ

А.В. Алейкина

Кубанский государственный университет

В статье проводится детальное рассмотрение архитектуры и принципов работы двух ключевых типов систем искусственного интеллекта: экспертных систем и нейронных сетей. Основное внимание уделено классификации и характеристике классических и адаптивных экспертных систем, а также обсуждению возможностей нейронных сетей. Исследуются промежуточные формы интеграции этих подходов, такие как

RAG-системы, сочетающие свойства экспертных систем и нейронных сетей. Описаны преимущества и недостатки каждой из представленных технологий, особое внимание уделено вопросам адаптации, точности решений и потреблению ресурсов.

Ключевые слова: экспертные системы, нейронные сети, сравнение подходов, системы искусственного интеллекта, критерии выбора, интерпретируемость моделей, точность и обобщающая способность, объяснимый ИИ, знания и правила вывода, обучение по данным, гибридные интеллектуальные системы, области применения, ограничения и преимущества, направления развития, автоматизация принятия решений

The article provides a detailed examination of the architecture and principles of operation for two key types of artificial intelligence systems: expert systems and neural networks. The focus is on classifying and characterizing classical as well as adaptive expert systems, along with exploring the capabilities of neural networks. Intermediate forms integrating these approaches are also investigated, such as RAG systems that combine properties from both expert systems and neural networks. Advantages and disadvantages of each technology are described in detail, with particular attention given to issues related to adaptation, solution accuracy, and resource consumption.

Key words: expert systems, neural networks, comparative analysis, artificial intelligence systems, selection criteria, model interpretability, accuracy and generalization, explainable AI, knowledge bases and inference rules, data driven learning, hybrid intelligent systems, application domains, strengths and limitations, development directions, decision making automation.

За последние десятилетия развитие технологий искусственного интеллекта привело к появлению целого ряда инновационных подходов, среди которых выделяются экспертные системы (в том числе и адаптивные) и нейронные сети. Эти классы интеллектуальных систем активно применяются в самых разных отраслях человеческой деятельности: от медицины и финансов до транспорта и производства.

Хотя обычные экспертные системы успешно справлялись с решением многих задач, возникновение потребностей в повышении качества решений и способности реагировать на изменение условий вызвало интерес к адаптивным экспертным системам. Именно они обладают возможностью автоматически обновлять свои знания и адаптироваться к новым ситуациям, обеспечивая дополнительную гибкость и точность решений. Также наблюдается значительный рост интереса к нейронным сетям, способным решать сложные задачи путем извлечения скрытых закономерностей из данных. Несмотря на широкую распространенность всех трех технологий, выбор оптимального инструмента остается открытой проблемой.

Цель настоящей статьи – сравнить экспертные системы с нейронными сетями, проанализировать их характеристики и определить, в каких случаях целесообразно переходить от обычных экспертных систем к адаптивным, а

когда предпочтительны нейронные сети. В статье уделяется внимание особенностям адаптации, самообучения и интерпретируемости решений, имеющим ключевое значение для понимания сильных сторон каждой технологии.

В статье рассмотрены факторы, влияющие на выбор конкретной технологии, и привести ряд практических примеров из различных областей применения. В заключении приведены итоги проведенного анализа и определены перспективы дальнейших исследований.

Экспертная система представляет собой программный комплекс, содержащий в себе знания специалистов в конкретных предметных областях и используемый для консультаций менее квалифицированных пользователей с использованием процедур логического вывода и принятия решений. Таким образом, данная система выступает как модель поведения эксперта в определённой области знаний и в некоторой степени способная его заменить.

Рассмотрим основные компоненты экспертной системы:

1. База знаний хранит в себе данные и правила, которые позволяют выстроить ответ. Правила формируются в виде условных конструкций вида «ЕСЛИ ... ТО», определяющих порядок действий при выполнении определенных условий. Обычно делится на две части: фактографическую (конкретные данные) и метазнания (общие принципы, алгоритмы и эвристики, по которым выстраивается ответ).

2. Механизм логических выводов осуществляет логические операции и манипуляции над базой знаний. По имеющимся правилам выполняет вычисления и проверку истинности утверждений на основе полученных данных.

3. Пользовательский интерфейс обеспечивает взаимодействие пользователя и системы, возможность подачи запросов и получения обратной связи.

4. Модуль приобретения знаний получает их от экспертов напрямую или из открытых источников. Данные извлекаются из текстовых документов или таблиц и приводятся к виду, удобному для компьютерной обработки.

5. Модуль ответов и объяснений предназначен для того, чтобы обеспечивать прозрачность работы экспертной системы, объясняя, почему и как был сделан тот или иной вывод [1].

Работа экспертной системы выполняется следующим образом:

- Пользовательский интерфейс принимает запрос пользователя.
- Данные поступают в модуль приобретения знаний, который проверяет, имеется ли соответствующая информация в базе знаний. Если необходимой информации недостаточно, модуль запрашивает её у специалиста или другого внешнего источника.
- База знаний предоставляет необходимую информацию (правила, факты, ассоциации).

– Механизм логических выводов обрабатывает полученные данные, проводит оценку возможных состояний здоровья и выбирает подходящее правило.

– Результат передается обратно в интерфейс, и модуль объяснений формирует подробное обоснование принятого решения.

Таким образом, принцип работы стандартной экспертной системы предполагает жесткий алгоритм, основанный на фиксированном наборе знаний и правил. Классические экспертные системы являются подходящим вариантом для решения задач, связанным с поиском решений в узкоспециализированной сфере. Тем не менее, данный инструмент искусственного интеллекта обладает своими ограничениями: он не может воспринимать нестандартные ситуации, выходящие за пределы зафиксированного набора правил, и оперативно адаптироваться к изменению обстоятельств. Механизма работы стандартной экспертной системы может быть недостаточно для решения задачи, если проблема лежит вне области компетенции данной системы или не является стандартной.

Поэтому для решения задач в непостоянных условиях возникает необходимость расширить функциональность экспертных систем, добавив им возможность адаптироваться под новые правила и требования пользователя, что и будет предметом дальнейшего рассмотрения.

Классические экспертные системы, которые не способны учесть уникальные или редкие события из-за жесткой привязанности к заранее установленным правилам и знанию, можно улучшить с помощью введения адаптивности.

Адаптивность системы – это её способность изменять собственные параметры, структуру или способы функционирования в ответ на изменения окружающей среды или внутренних условий, сохраняя целостность и целевую направленность своего существования. Среди признаков адаптивности можно выделить наличие механизмов обратной связи и процедур принятия решений в условиях неопределённости, использование информации о состоянии среды.

Эти признаки могут быть реализованы следующим образом:

– Добавление возможности собирать и интегрировать новую информацию из различных источников, обогащая свою базу знаний.

– Взаимодействие с пользователем для уточнения и дополнения вводимых данных, что уменьшает число ошибок и повышает точность выводов.

– Возможность сохранения записей обо всех проведенных операциях и обращениях, что облегчает дальнейшее обучение и оптимизацию.

– Постоянный анализ действий системы и самостоятельное устранение обнаруживаемых ошибок.

– Применение нечёткой логики для обработки результатов: это позволит оперировать не только строгими правилами, но и степенью принадлежности объекта к той или иной категории [2].

Всё это позволит экспертной системе работать в условиях регулярного пополнения новыми данными, а также повышать точность ответов на основе обратной связи от пользователей.

Можно повысить адаптивность экспертной системы, если она будет реализована как RAG-система (Retrieval Augmented Generation). Такие системы используют элементы нейронных моделей для извлечения и синтеза информации из источников. Основными компонентами RAG-системы являются:

Ретривер – компонент, используемый на этапе поиска и извлечения информации (англ. Retrieval – «извлечение»). Данный компонент выбирает из доступных источников отрывки информации, которые наиболее точно соответствуют запросу. Эти же отрывки делятся на небольшие сегменты (чанки, англ. “chunks”), являющиеся отдельными порциями информации, для удобства дальнейшей обработки. В классической экспертной системе соответствует модулю приобретения данных. Данные собираются и готовятся динамически в процессе выполнения запроса. Поэтому необходимость хранить их локально, в базе знаний отсутствует, и эксперту не требуется заполнять её вручную: достаточно предоставить доступ к нужным источникам информации.

Генератор использует полученные ретривером сегменты информации, чтобы сформировать ответ. В отличие от модуля логических выводов классической экспертной системы, который содержит в себе строгие правила, для каждого ответа формирует логику ответа самостоятельно, основываясь на содержании отобранных фрагментов. Также при выдаче ответа ссылается не на конкретные правила, а на фрагменты текста или конкретные источники, использованные для генерации ответа [3].

Хотя структура и общий механизм получения ответа остаются схожими, внедрение свойств нейронных моделей в экспертную систему для поиска информации, построения логики и формирования ответа для каждого конкретного случая делают экспертную систему более гибкой и адаптируемой под нестандартные ситуации, а также не требует постоянной коррекции знаний и их обработки вручную. При этом, такая система в силу генерации логики ответа и чанков заново для каждого нового запроса, потребует значительных затрат оперативной памяти устройства, на котором она будет работать. Механизм работы нейронных сетей будет более подробно рассмотрен далее.

Нейронные сети представляют собой математические модели, построенные по образу нервной системы живого организма, способные осуществлять параллельную обработку информации, представленную множеством простых обработчиков (нейронов), связанных системой соединений. Такие сети способны обучаться на примерах и выявлять скрытые закономерности в данных [4].

Каждый искусственный нейрон представляет собой простой вычислительный узел. Большинство современных нейронных сетей

организованы в слои узлов, в которых данные перемещаются только в одном направлении. Один узел может быть подключен к нескольким узлам на нижележащем уровне, с которого он получает данные, и к нескольким узлам на уровне над ним, на который он отправляет данные.

Каждому из его узлов входящих соединений присваивается номер, известный как «вес». В активной сети узел получает от каждого входящего соединения другой элемент данных, другое число, символизирующее электрический сигнал, и умножает его на уже указанный вес, а затем складывает эти значения, полученные из всех входов, вместе, получая одно число. Если число превышает пороговое значение, определенное функцией активации, которая принимает это число в качестве аргумента, узел «работает», что в современных нейронных сетях обычно означает отправку числа – суммы взвешенных входных данных – по всем исходящим от него соединениям [5].

Нейронные сети демонстрируют высокую эффективность в обработке больших объемов данных и обучении на разнообразии примеров. Их ключевое преимущество заключается в способности автоматически выявлять важные признаки и закономерности в данных, освобождая разработчиков от необходимости вручную формулировать сложные правила. Благодаря этому они особенно эффективны в областях, где традиционные методы анализа затруднены, таких как компьютерное зрение, обработка естественного языка и прогнозирование временных рядов. Эти сети также отличаются отличной масштабируемостью и адаптируемостью к новым данным, что позволяет улучшать точность решений при увеличении объема обучающих данных.

Однако нейронные сети имеют ряд недостатков. Во-первых, они требуют значительных вычислительных ресурсов и времени для обучения, особенно при глубоком обучении. Результатом работы нейронной сети зачастую сложно управлять и контролировать: точные причины принятия решения могут быть неясны, что ограничивает применимость моделей там, где важна прозрачность процессов («черный ящик»). Недостаточное разнообразие или низкое качество набора данных может привести к плохой производительности или искаженным результатам.

Таким образом, хотя нейронные сети в плане возможности обучения и более успешной обработки нестандартных ситуаций справляются с поставленными задачами достаточно хорошо, экспертные системы могут быть полезны в условиях наличия строгого свода правил и требований и малых ресурсах оперативной памяти. RAG-подход сочетает в себе преимущества обоих вариантов, но также требует определённых характеристик оборудования для успешной работы с большим количеством данных.

СПИСОК ЛИТЕРАТУРЫ

1. Черненко В. В., Пискорская С. Ю. Экспертные системы // Актуальные проблемы авиации и космонавтики. 2012. №8. URL: <https://cyberleninka.ru/article/n/ekspertnye-sistemy> (дата обращения: 23.09.2025).

2. Целых, А. Н., Целых, Л. А., Сергеев, Н. Е., Стаханов, Д. В. (2014). К вопросу об адаптации экспертных систем для поддержки решений прикладных управленческих задач. Известия Южного федерального университета. Технические науки, (8 (157)), 185-193.

3. Науменко А. О. ТЕХНОЛОГИЯ RAG (RETRIEVAL-AUGMENTED GENERATION) КАК ИННОВАЦИОННЫЙ ПОДХОД В LLM // Вестник науки. 2025. №8 (89). URL: <https://cyberleninka.ru/article/n/tehnologiya-rag-retrieval-augmented-generation-kak-innovatsionnyy-podhod-v-llm> (дата обращения: 16.10.2025).

4. ГОСТ Р 71476-2024. Искусственный интеллект. Концепции и терминология искусственного интеллекта. Digital Russia (декабрь 2024). Доступ: <https://docs.cntd.ru/document/1310068314>, дата обращения: 21 сентября 2025.

5. Иванько А.Ф., Иванько М.А., Сизова Ю.А. НЕЙРОННЫЕ СЕТИ: ОБЩИЕ ТЕХНОЛОГИЧЕСКИЕ ХАРАКТЕРИСТИКИ // Научное обозрение. Технические науки. 2019. № 2. С. 17-23; URL: <https://science-engineering.ru/ru/article/view?id=1236> (дата обращения: 27.09.2025).

СИСТЕМА АВТОМАТИЗИРОВАННОГО ТЕСТИРОВАНИЯ И МОНИТОРИНГА ВЕБ-СЕРВИСОВ

Ю.М. Ачмиз

Кубанский государственный университет

В статье рассматриваются современные подходы к построению системы автоматизированного тестирования и мониторинга веб-сервисов.

Ключевые слова: автоматизированное тестирование, система мониторинга, веб сервисы, end to end тестирование, функциональное тестирование, нагрузочное тестирование, стресс тестирование, API тестирование, тестирование производительности, непрерывное тестирование, интеграция с CI/CD, алертинг, мониторинг доступности, SLA, логирование и трассировка, метрики и дашборды

The article explores modern approaches to building a system for automated testing and monitoring of web services.

Key words: automated testing, monitoring system, web services, end to end testing, functional testing, load testing, stress testing, API testing, performance testing, continuous testing, CI/CD integration, alerting, availability monitoring, SLA, logging and tracing, metrics and dashboards

Современные веб-сервисы – это сложные распределенные системы, состоящие из множества микросервисов, баз данных, брокеров сообщений, внешних API и вспомогательных компонентов. Увеличение количества сервисов и числа взаимодействий между ними приводит к лавинообразному

росту точек отказа и повышает риск возникновения сбоев. Классическая схема поддержки работоспособности – мониторинг показателей и ручное реагирование – уже не справляется с темпом развития и масштабом инфраструктур. Растущее ожидание пользователей по скорости и стабильности работы сервисов вынуждает компании внедрять новые инструменты: системы автоматизированного тестирования, наблюдаемости (observability) и интеллектуальных агентов, способных автономно устранять инциденты. В этой связи на первый план выходят концепции AI Ops и self-healing systems, призванные обеспечить высокую доступность при минимальном участии человека [1-4].

Понятие наблюдаемости выходит за рамки классического мониторинга доступности и нагрузки. Согласно подходу observability, для полноценного понимания состояния системы следует собирать и анализировать не только метрики (временные ряды чисел), но и логи, и распределённые трассировки запросов. Четыре «золотых сигнала» – задержка (latency), пропускная способность (throughput), уровень ошибок (error rate) и насыщение ресурсов (saturation) – дают первичное представление о поведении сервисов. Инструментарий Prometheus и Grafana позволяет собирать эти показатели, хранить их в виде многомерных временных рядов и строить наглядные дашборды с пользовательскими панелями и пороговыми оповещениями. Помимо базовых показателей, практики SRE рекомендуют отслеживать показатели SLO/SLI, такие как аптайм, среднее время отклика, процент успешно выполненных запросов и коэффициент отказов. Логи (ELK, Loki) дают возможность глубоко расследовать причины ошибок, а распределённые трассы (OpenTelemetry, Jaeger) показывают путь запроса через цепочку микросервисов и помогают локализовать узкие места [5].

Автоматизация – следующий уровень зрелости эксплуатации. Инструменты управления конфигурациями и оркестрации (Ansible, Terraform, Kubernetes Operators) позволяют описывать действия по развертыванию, обновлению и восстановлению сервисов в виде повторно используемых сценариев. Практика runbook automation подразумевает, что для каждого часто повторяющегося инцидента существует четко сформулированный набор шагов: проверка состояния, очистка кеша, перезапуск сервиса, масштабирование и т.п. Для выявления инцидента и выбора подходящего runbook-сценария всё чаще применяются методы машинного обучения. Модели классификации анализируют типы ошибок, текст сообщений и контекстные метрики, чтобы сопоставить текущую ситуацию с ранее известными случаями. Так появляется связка AIOps: поток телеметрических данных → ML-модуль, распознающий характер инцидента → модуль автоматизации, выполняющий корректирующее действие без вмешательства человека.

Типовая архитектура системы автоматизированного тестирования и мониторинга состоит из нескольких слоёв. На уровне данных метрики собираются через экспортеры и агент OpenTelemetry, логи отправляются в

централизованное хранилище, а трассировки формируются в каждом сервисе и группируются по идентификатору запроса. Эти данные поступают в систему аналитики (Prometheus, Elasticsearch), где хранятся и обрабатываются. Далее поток оповещений (Alertmanager) и событий из очередей (Kafka, RabbitMQ) направляется в интеллектуального агента. Ядро агента включает подсистему классификации инцидентов, базу runbook-сценариев, модуль принятия решений и исполнитель (executor). После классификации агент выбирает сценарий, учитывая политики безопасности и управления (нужна ли проверка человека), и инициирует его выполнение посредством Ansible, вызова API Kubernetes или инструментов облака. Отдельное внимание уделяется модулю тестирования: регрессивные и нагрузочные тесты можно запускать автоматически при изменениях в коде, а результаты тестов становятся частью наблюдаемости, позволяя оценивать стабильность системы под нагрузкой и после аварий.

Важно понимать, что внедрение такого агента требует серьезного внимания к вопросам безопасности. Агент должен иметь минимально необходимые права и выполнять действия только в пределах разрешенной зоны (namespace). Все секреты (пароли, токены, ключи) хранятся в защищенных хранилищах (Vault, Secret Manager) и выдаются агенту на время выполнения задач. Логи и отчеты о действиях агента должны записываться для аудита, чтобы в любой момент можно было восстановить, когда и почему было совершено то или иное действие. Также необходимо отслеживать, чтобы алгоритмы принятия решений не приводили к ложным срабатываниям или “шторму” изменений; для этого применяют двойные проверки, ручные подтверждения для опасных операций и механизм отмены (rollback), позволяющий вернуть систему в предыдущее состояние, если автоматическое исправление не сработало.

Перспективы развития подобных систем связаны с использованием больших языковых моделей (LLM) и методов объяснимого ИИ (XAI). LLM могут улучшить процесс анализа логов и документации, предоставляя связные объяснения причин сбоев и предлагая наборы команд для их устранения. Они способны на естественном языке формулировать отчеты о происшествиях, автоматически создавать черновики постмортемов и консультировать инженеров в режиме чата. Интеграция принципов XAI позволяет сделать работу агента прозрачной: каждая рекомендация сопровождается обоснованием, основанным на фактах (например, «в журнале обнаружена ошибка X, аналогичная инциденту Y; запуск сценария Z устранил проблему в прошлый раз»). Наконец, прогресс в области предиктивной аналитики позволяет распознавать паттерны, предшествующие авариям, и предпринимать меры еще до наступления сбоя: увеличивать ресурсы, балансировать нагрузку или проводить профилактический перезапуск. Всё это выводит наблюдаемость и тестирование на новый уровень и приближает к созданию полностью самоисцеляющихся цифровых экосистем.

СПИСОК ЛИТЕРАТУРЫ

1. Д. Гонсалес де ла Хера. Современный подход к наблюдаемости // Хабр. – 2 дек. 2022. – URL: <https://habr.com/ru/companies/slurm/articles/703056/> (дата обращения: 08.09.2025).
2. Почему я не верю в ИИ-агентов в 2025 году – несмотря на хайп // Хабр. – 24 сент. 2025. – URL: <https://habr.com/ru/articles/950072/> (дата обращения: 06.09.2025).
3. В. Чечеткин. AIOps – следующий шаг в развитии ИТ-операций // РБК Тренды. – 2023. – URL: <https://trends.rbc.ru/trends/industry/641061579a7947de816ee007> (дата обращения: 16.09.2025).
4. S. Holik, и др. CI/CD Automation Challenges in Microservice Environments // ResearchGate. – дек. 2022. – URL: <https://www.researchgate.net/publication/392136739> (дата обращения: 11.09.2025).
5. R. D. Zota, C. Bărbulescu, R. Constantinescu. A Practical Approach to Defining a Framework for Developing an Agentic AIOps System // Electronics. – 2025. – Т. 14, № 9. – Ст. 1775. – DOI: 10.3390/electronics14091775.

ТЕХНОЛОГИЯ КОНТЕЙНЕРИЗАЦИИ КАК ОСНОВА ЭФФЕКТИВНОГО И ОТКАЗОУСТОЙЧИВОГО РАЗВЕРТЫВАНИЯ ПРИЛОЖЕНИЯ В РАСПРЕДЕЛЕННЫХ СРЕДАХ

М.А. Бакалкин

Кубанский государственный университет

В статье рассматриваются архитектурные принципы контейнеризации, проводится сравнительный анализ с традиционной виртуализацией. Особое внимание уделено экосистеме инструментов, в частности Docker и Kubernetes, и их роли в построении отказоустойчивых, масштабируемых и безопасных систем.

Ключевые слова: контейнеризация, контейнерные технологии, Docker, Kubernetes, оркестрация контейнеров, микросервисная архитектура, распределенные среды, масштабируемость, отказоустойчивость, высокодоступные приложения, балансировка нагрузки, автоматическое масштабирование, контейнерные кластеры, CI/CD, инфраструктура как код, непрерывное развертывание, облачные вычисления, observability, мониторинг и логирование

The article examines the architectural principles of containerization and provides a comparative analysis with traditional virtualization. Special attention is given to the ecosystem of tools, particularly Docker and Kubernetes, and their role in building fault-tolerant, scalable, and secure systems.

Key words: containerization, container technologies, Docker, Kubernetes,

container orchestration, microservices architecture, distributed environments, scalability, fault tolerance, high availability, load balancing, auto scaling, container clusters, CI/CD, infrastructure as code, continuous deployment, cloud computing, observability, monitoring and logging

Современная индустрия разработки программного обеспечения характеризуется ростом сложности приложений, увеличением частоты выпуска обновлений и необходимостью работать в гетерогенных средах (on-premise, гибридные и публичные облака). В этих условиях традиционные методы развертывания, основанные на физических серверах или виртуальных машинах, становятся недостаточно гибкими и эффективными. Технология контейнеризации предлагает принципиально новый подход к упаковке, распространению и выполнению приложений, решая ключевые проблемы переносимости, воспроизводимости и масштабируемости [1].

Исторически для изоляции приложений использовались виртуальные машины (VM), которые эмулируют полноценную аппаратную платформу и требуют установки гостевой операционной системы (ОС). Это приводит к значительным накладным расходам по ресурсам (CPU, RAM, disk space). Контейнеризация представляет собой эволюционный шаг, реализующий виртуализацию на уровне операционной системы [2]. Вместо эмуляции «железа» контейнеры разделяют ядро хостовой ОС, изолируя процессы, файловые системы и сетевые пространства имен друг от друга.

Наиболее наглядно архитектуру демонстрирует платформа Docker. Контейнер создается на основе образа – неизменяемого шаблона, включающего в себя приложение, все его зависимости и метаданные. Ключевые концепции:

1. Docker Engine: Демон, управляющий жизненным циклом контейнеров.
2. Dockerfile: Текстовый файл с инструкциями для сборки образа.
3. Слоистая файловая система: Каждая инструкция в Dockerfile создает новый слой. Это обеспечивает эффективное хранение, многократное использование слоев и быструю сборку.

При запуске контейнера поверх слоев образа создается тонкий записываемый слой (container layer), что гарантирует неизменность базового образа.

Docker стандартизировал процесс работы с контейнерами, предоставив простой в использовании CLI и API. Он решает проблему «dependency hell», гарантируя, что приложение будет работать одинаково на любой системе, где запущен Docker [1]. Однако ценность Docker выходит далеко за рамки простого запуска контейнеров. Его архитектура, включающая демон (dockerd), REST API и клиентскую командную строку, стала образцом для подражания. Критически важным компонентом является концепция Dockerfile, который формализует процесс сборки образа, превращая его в версионизируемый артефакт, подобно исходному коду. Это позволяет применять к

инфраструктуре практики Code Review и автоматизированной сборки. Кроме того, Docker предоставляет мощные механизмы для сетевого взаимодействия (Docker Network) и управления данными (Docker Volumes), позволяя создавать сложные многоконтейнерные среды на одной хост-системе, что особенно полезно на этапе разработки.

Когда количество контейнеров исчисляется десятками и сотнями, ручное управление становится невозможным. На помощь приходят системы оркестрации, лидером среди которых является Kubernetes (K8s) [3]. Его ключевые функции:

1. Автоматическое развертывание и репликация: Поддержание заданного количества копий приложения.
2. Самовосстановление: Перезапуск контейнеров при сбоях, замена узлов.
3. Балансировка нагрузки и сервис-дискавери: Автоматическое распределение трафика между контейнерами.
4. Горизонтальное масштабирование: Автоматическое увеличение/уменьшение числа реплик в зависимости от нагрузки.
5. Управление конфигурациями и секретами: Безопасное хранение и распространение чувствительных данных.

Экосистема контейнеризации не ограничивается лишь runtime и оркестратором. Она включает в себя целый ряд критически важных сервисов. Реестры образов (Docker Hub, Google Container Registry, Harbor) выполняют роль централизованных хранилищ для версионированных образов, обеспечивая их распределенную доставку до узлов кластера. Инструменты мониторинга и логирования (Prometheus, Grafana, Fluentd, ELK Stack) адаптированы для работы в высокодинамичной среде Kubernetes, предоставляя данные о работе не отдельных виртуальных машин, а совокупности постоянно перемещаемых контейнеров. Наконец, инструменты безопасности (Trivy, Clair) позволяют проводить статический анализ образов на наличие известных уязвимостей (CVE) еще до их запуска в продакшене, интегрируя безопасность в самую раннюю стадию жизненного цикла – стадию сборки.

Контейнеры являются идеальным артефактом для пайплайнов непрерывной интеграции и доставки. Образ, собранный на этапе CI, проходит весь путь до продакшена без изменений, что гарантирует идентичность сред и устраняет ошибки, связанные с различиями в окружении. В практическом плане это реализуется через создание Dockerfile, который становится единственной и достаточной инструкцией для сборки приложения. CI-сервер (например, Jenkins, GitLab CI) выполняет команду docker build, создавая неизменяемый образ. Этот образ тестируется, а затем пушится в реестр. На этапе CD оркестратор (Kubernetes) просто извлекает этот проверенный образ и разворачивает его в кластере. Такой подход радикально упрощает откат (rollback) – достаточно указать оркестратору на образ предыдущей, стабильной версии.

Контейнеризация является не просто удобным способом развертывания микросервисов, а настоящим катализатором этого перехода. Небольшой размер и быстрый запуск контейнеров идеально подходят для развертывания отдельных, слабосвязанных сервисов. Контейнер предоставляет четкие границы и стандартизированный интерфейс для взаимодействия (сеть и порты), что позволяет командам разрабатывать, масштабировать и обновлять сервисы независимо друг от друга [4]. Например, ресурсоемкий сервис генерации отчетов можно масштабировать горизонтально, добавив реплики, не затрагивая при этом сервис аутентификации. Kubernetes усиливает этот эффект, предоставляя единую абстракцию для управления разнородным набором микросервисов, будь то веб-сервер на Node.js, бэкенд-API на Python или кэширующий сервис на Redis.

Несмотря на изоляцию, контейнеры имеют общее ядро ОС, что создает новые векторы атак, смещая фокус безопасности с периметра сети на сам контейнер и его конфигурацию [5]. Ключевые меры безопасности образуют многоуровневую защиту:

1. Безопасность образов: использование минималистичных базовых образов (например, alpine), регулярное сканирование их на наличие уязвимостей и подписывание для гарантии целостности.

2. Безопасность runtime: запуск контейнеров от имени непривилегированного пользователя (не root), применение AppArmor или SELinux профилей, и использование seccomp для ограничения системных вызовов.

3. Безопасность кластера: в Kubernetes это включает использование Namespaces для изоляции, Network Policies для контроля трафика между подами и RBAC для строгого контроля доступа к API-серверу Kubernetes.

Эффективность контейнеризации проявляется на нескольких уровнях. На инфраструктурном уровне наблюдается прямая экономия ресурсов, достигающая 70-80% по сравнению с виртуальными машинами, за счет устранения накладных расходов на гостевые ОС и гипервизор [2]. Это позволяет значительно увеличить плотность размещения workload'ов на одном физическом сервере. На операционном уровне скорость развертывания приложений увеличивается на порядок: запуск контейнера занимает секунды, а не минуты, что ускоряет не только вывод новых функций, но и процедуры аварийного восстановления. Качественные преимущества включают беспрецедентную воспроизводимость сред, которая сводит к нулю ошибки, связанные с конфигурацией, и стирает границу между средой разработки и продакшена. Это, в свою очередь, повышает надежность всей системы и снижает операционные расходы на поддержку.

Несмотря на преимущества, внедрение контейнеризации сопряжено с рядом вызовов. Организационная сложность является одним из ключевых барьеров: переход к микросервисам и контейнерам требует смены мышления команд, внедрения культуры DevOps и преодоления steep learning curve, особенно для освоения таких комплексных систем, как Kubernetes. Проблемы

безопасности требуют постоянной бдительности, поскольку уязвимость в ядре хостовой ОС потенциально может затронуть все работающие контейнеры. Необходимость выстраивания новых практик (сканирование образов, управление секретами) добавляет сложности процессам. Операционные сложности включают необходимость построения распределенных систем мониторинга и логирования, которые могли бы адекватно работать в высокодинамичной среде, где контейнеры постоянно создаются и уничтожаются.

Экосистема контейнеризации продолжает активно развиваться, порождая новые архитектурные паттерны и технологии. Одной из самых заметных тенденций является развитие безсерверных (serverless) вычислений на основе контейнеров, таких как AWS Fargate или Knative. Эти платформы абстрагируют не только от виртуальных машин, но и от управления нодами Kubernetes, позволяя разработчикам сосредоточиться исключительно на коде, в то время как платформа автоматически управляет выделением ресурсов и масштабированием контейнеров до нуля. Другой перспективной областью являются безъядерные контейнеры на основе WebAssembly (Wasm), например, в проекте WASI. Такие контейнеры предлагают еще более высокий уровень безопасности и портативности, поскольку компилируются в изолированный байт-код, не имеющий доступа к системным вызовам ОС по умолчанию. Наконец, методология GitOps (использование Git как единого источника истины для декларативного описания всей инфраструктуры и приложений) становится стандартом управления кластерами Kubernetes, обеспечивая автоматизацию, аудируемость и простоту отката изменений.

СПИСОК ЛИТЕРАТУРЫ

1. Merkel, D. Docker: lightweight Linux containers for consistent development and deployment // Linux Journal. – 2014. – № 239. – P. 2.
2. Bernstein, D. Containers and Cloud: From LXC to Docker to Kubernetes // IEEE Cloud Computing. – 2014. – Vol. 1, № 3. – P. 81-84.
3. Burns, B., Beda, J., Hightower, K. Kubernetes: Up and Running: Dive into the Future of Infrastructure. – O'Reilly Media, 2019. – 270 p.
4. Newman, S. Building Microservices: Designing Fine-Grained Systems. – O'Reilly Media, 2015. – 280 p.
5. Тóнен, А., Паскуале, Л. Будущее контейнеризации: угрозы безопасности и возможности // Журнал сетевых и компьютерных приложений. – 2020. – Т. 150. – С. 102-114.

КРОССПЛАТФОРМЕННЫЕ МОБИЛЬНЫЕ ПРИЛОЖЕНИЯ: ИСПОЛЬЗОВАНИЕ В ОБРАЗОВАТЕЛЬНОЙ СФЕРЕ

Н.В. Бондаренко

Кубанский государственный университет

В статье рассматриваются актуальные подходы к разработке кроссплатформенных мобильных приложений. Анализируются преимущества и недостатки фреймворка Flutter, его архитектурные особенности и сферы применения. Особое внимание уделено использованию в образовательной сфере.

Ключевые слова: кроссплатформенные мобильные приложения, мобильное обучение, электронное обучение, образовательные технологии, гибридные приложения, платформы Flutter и React Native, интерактивные учебные материалы, персонализированное обучение, геймификация, адаптивные образовательные системы, дистанционное образование, управление учебным процессом, мобильные тесты и опросы, доступность образования, пользовательский опыт обучающихся

This article examines current approaches to developing cross-platform mobile applications. It analyzes the advantages and disadvantages of the Flutter framework, its architectural features, and areas of application. Particular attention is paid to its use in education.

Key words: cross platform mobile applications, mobile learning, e learning, educational technologies, hybrid applications, Flutter and React Native platforms, interactive learning content, personalized learning, gamification, adaptive educational systems, distance education, learning management, mobile quizzes and assessments, education accessibility, learner user experience.

В условиях растущей конкуренции на рынке мобильных приложений сталкиваются с необходимостью одновременного присутствия на iOS и Android. Традиционная нативная разработка требует значительных ресурсов и времени. Кроссплатформенные решения предлагают эффективную альтернативу, позволяя разрабатывать приложения для нескольких платформ из единой кодовой базы [1].

Цель работы изучить базовые принципы кроссплатформенности и определить самые перспективные направления для их внедрения, в первую очередь в образовании, где качество усвоения материала сильно зависит от наглядности и вовлечения.

Статья подготовлена на основе изучения научных статей, технической документации, и личного опыта работы с данными технологиями.

Принцип работы кроссплатформенных технологий основан на создании абстракции над нативными API операционных систем. Это позволяет писать код на одном языке программирования, который затем транслируется в

нативные элементы интерфейса или выполняется в собственной среде выполнения.

Одним из кроссплатформенных фреймворков является Flutter. Он не использует нативные компоненты ОС. Он поставляется со своим собственным комплектом визуальных компонентов (виджетов), которые отрисовываются с помощью высокопроизводительного движка Skia.

Приложение компилируется в нативный код (Ahead-of-Time компиляция), что обеспечивает довольно стабильную и высокую скорость работы [2].

В основе идеологии Flutter лежит концепция «все есть виджет» (everything is a widget). Виджеты представляют собой имутабельные конфигурации пользовательского интерфейса, которые могут быть как простыми элементами (кнопка, текст), так и сложными композициями, описывающими всю структуру экрана. React-подобная модель объявления UI через композицию виджетов, combined с их перерисовкой только при изменении состояния, создает предсказуемую и эффективную систему построения интерфейсов.

Особенности: Единообразие интерфейса на всех платформах, высочайшая производительность, особенно в анимациях. Язык программирования Dart, разработанный Google, сочетает в себе знакомый для разработчиков на Java и C# синтаксис с современными возможностями, такими как строгая статическая типизация, async/await для асинхронных операций и tree shaking для исключения неиспользуемого кода.

Dart компилируется в эффективный нативный код, а его «горячая перезагрузка» (hot reload) позволяет практически мгновенно видеть изменения в коде без перезапуска приложения, что значительно ускоряет процесс разработки [3].

Важнейшим аспектом является создание единой образовательной среды, где прогресс ребенка, его достижения и индивидуальные настройки синхронизируются со всех всех устройств. Ученик может начать выполнение задания на школьном планшете, а завершить его дома на смартфоне родителей, что обеспечивает непрерывность учебного процесса. Для педагогов это открывает возможности для более гибкого планирования занятий и индивидуального подхода к каждому ребенку.

Интерактивные возможности кроссплатформенных приложений значительно повышают вовлеченность детей в образовательный процесс. Современные фреймворки позволяют реализовывать игровые механики, анимированные симуляции, элементы дополненной реальности, которые превращают обучение в увлекательное исследование. Такие технологии особенно эффективны для визуализации сложных понятий – от молекулярного строения веществ до исторических реконструкций.

Для студентов it направлений кроссплатформенная разработка представляет отличную базу знаний технологий. Создание полнофункционального мобильного приложения для двух платформ силами

одного студента или небольшой студенческой команды становится осуществимой задачей. Это позволяет сфокусироваться на проработке логики и архитектуры, а не на дублировании кода.

Кроссплатформенная разработка требует тщательного проектирования архитектуры приложения для эффективного разделения кода между платформами и организации нативных взаимодействий. Это воспитывает культуру написания чистого и модульного кода, что хорошо для обучения студентов программированию [4].

Кроссплатформенная разработка мобильных приложений прочно заняла свою нишу, трансформировавшись из «костыля» в мощный и зрелый инструмент. Такие фреймворки, как React Native и Flutter, доказывают, что можно создавать высококачественные, производительные приложения, эффективно используя ресурсы разработки.

Для нового поколения IT-специалистов владение этими технологиями – это не просто плюс в резюме, а необходимость. Они позволяют быстро адаптироваться к требованиям рынка, где скорость итераций и охват аудитории являются ключевыми факторами успеха. Уже сегодня в КУБГУ и других вузах студенты активно используют эти инструменты в курсовых и дипломных работах, что напрямую готовит их к решению реальных задач в индустрии [5].

Будущее за гибридными подходами, где кроссплатформенные фреймворки будут использоваться для быстрого построения основной логики приложения, а нативные модули – для реализации критически важных или специфичных функций. Следующая задача – дальнейшее стирание границ производительности и упрощение интеграции с аппаратными возможностями устройств.

СПИСОК ЛИТЕРАТУРЫ

1. Роуз Р., Flutter и Dart. Сборник рецептов. Разработка полнофункциональных облачных приложений / Р. Роуз – Издательство «АЛИСТ» 2024. – 272 с.
2. Аллев А., Быстрый старт Flutter-разработчика / Алеев А. – Издательство «Ridero» 2020. – 146 с.
3. Р. С. Мартин, Чистая архитектура. Искусство разработки программного обеспечения / Р.С. Мартин. – Издательство «ПИТЕР» 2022. – 352 с.
4. Хабр [Электронный ресурс]. URL: <https://habr.com/ru/articles/528614/> (дата обращения: 21.09.2025)
5. Flutter [Электронный ресурс]. URL: <https://flutter.dev/> (дата обращения: 26.09.2025)

JETPACK COMPOSE: СОВРЕМЕННЫЙ ПОДХОД К ПОСТРОЕНИЮ ПОЛЬЗОВАТЕЛЬСКОГО ИНТЕРФЕЙСА В ANDROID-ПРИЛОЖЕНИЯХ

И.А. Васюнин

Кубанский государственный университет

В статье рассматривается современный инструмент построения пользовательского интерфейса в Android-приложениях – Jetpack Compose, а также его преимущества и недостатки.

Ключевые слова: Jetpack Compose, декларативный пользовательский интерфейс, Android-приложения, реактивное программирование, компоновка функций, управление состоянием, односторонний поток данных, Material Design, адаптивный интерфейс, архитектура MVVM, навигация в приложении, превью интерфейсов, тестирование интерфейса, оптимизация производительности, Kotlin, Android Studio

The article discusses a modern tool for building a user interface in Android applications - Jetpack Compose, as well as its advantages and disadvantages.

Key words: Jetpack Compose, declarative user interface, Android applications, reactive programming, composable functions, state management, unidirectional data flow, Material Design, adaptive UI, MVVM architecture, in-app navigation, UI preview, UI testing, performance optimization, Kotlin, Android Studio

С развитием мобильной разработки создание пользовательских интерфейсов для Android-приложений претерпело значительные изменения. Традиционный подход, основанный на XML-разметке и привязке к View-элементам, требовал множества повторяющихся операций и усложнял управление состоянием элементов интерфейса. Однако с развитием Kotlin и появлением Jetpack Compose, подход к разработке пользовательских интерфейсов изменился.

Jetpack Compose – библиотека для создания декларативных UI в Android-приложениях, предложенная Google [1]. В отличие от традиционного подхода, Compose позволяет описывать интерфейс с помощью Kotlin-функций, что упрощает код, улучшает читаемость и гибкость. С помощью этого подхода разработчик описывает, как должен выглядеть интерфейс, а система сама заботится о его обновлении, что минимизирует необходимость в многократных вызовах функций для изменения состояния и обеспечении взаимодействия с пользователем.

Эта статья посвящена рассмотрению Jetpack Compose как современного инструмента для разработки UI в Android. Мы обсудим основные принципы работы с Compose, его преимущества и недостатки по сравнению с традиционным подходом, а также продемонстрируем пример его использования на практике, показывая, как этот инструмент может быть

эффективно интегрирован в проект, направленный на развитие навыков сотрудников.

Jetpack Compose – это библиотека для построения пользовательских интерфейсов в Android, которая использует декларативный подход к описанию UI. В отличие от традиционного XML, в Compose UI описывается с помощью Kotlin-функций. Это делает код более простым, гибким и мощным. Важнейшими принципами Jetpack Compose являются декларативность, состояние, перекомпоновка и составление UI с помощью функций [2]. Рассмотрим каждый из этих принципов более детально.

1. Декларативный UI

Декларативный подход в UI-разработке означает, что вы описываете, как должен выглядеть интерфейс в зависимости от состояния приложения, а не прописываете пошаговые действия по его изменению. В традиционном подходе с использованием XML мы описываем статическую структуру UI, а затем изменяем её программно в зависимости от изменений состояния (например, обновляем данные в TextView). В Compose вместо этого мы просто описываем, как UI должен выглядеть в конкретный момент времени, и библиотека сама позаботится о его обновлении.

2. Recomposition (Перекомпоновка)

Перекомпоновка – это процесс повторной сборки части интерфейса, когда изменяется состояние, которое на неё влияет [3]. В Compose UI "компоненты" представляют собой функции, аннотированные аннотацией `@Composable`. Когда данные, на основе которых строится UI, изменяются, Compose перерисовывает только те части интерфейса, которые зависят от этого состояния. Это позволяет значительно сократить количество изменений в UI и улучшить производительность.

3. State Management (Управление состоянием)

В Jetpack Compose управление состоянием является одним из ключевых аспектов. Все элементы интерфейса в Compose зависят от состояния, и любое изменение этого состояния автоматически вызывает перерисовку соответствующих частей UI [4]. Это позволяет избавиться от необходимости вручную управлять состоянием в коде и обновлять элементы UI.

Для управления состоянием Compose использует несколько инструментов:

- `remember`: сохраняет значение в пределах жизненного цикла компонента.
- `mutableStateOf`: создает переменную состояния, которую можно изменять.
- `LaunchedEffect`: запускает код при изменении состояния или при первом запуске.

4. Composable Functions (Функции `@Composable`)

Основной строительный блок в Jetpack Compose – это функции, аннотированные аннотацией `@Composable` [5]. Эти функции описывают UI, который будет отрисован. Компоненты Compose не являются объектами, как

в традиционном подходе с View, вместо этого они представляют собой Kotlin-функции, которые вызываются для отображения UI. Функции `@Composable` могут быть вложены друг в друга, что позволяет легко составлять сложные интерфейсы из простых компонентов. Такой подход позволяет создавать повторно используемые компоненты и легко комбинировать их в более сложные структуры.

5. Modifiers (Модификаторы)

Модификаторы в Compose используются для изменения свойств элементов UI, таких как размеры, отступы, цвета и другие визуальные характеристики [6]. Это один из наиболее мощных инструментов, позволяющий динамически изменять внешний вид компонента без необходимости создания новых компонентов. Модификатор позволяет на лету изменять поведение и внешний вид компонентов, делая UI более гибким и настраиваемым.

Основные принципы Jetpack Compose делают этот инструмент мощным и удобным для разработки мобильных приложений. Он не только упрощает процесс создания интерфейсов, но и улучшает производительность, обеспечивая более быструю разработку и поддержку кода.

Jetpack Compose предоставляет целый ряд преимуществ, которые делают его идеальным выбором для современных Android-разработчиков. В отличие от традиционного подхода с использованием XML, Compose значительно улучшает производительность разработки, повышает читаемость кода и предлагает более гибкие и удобные способы взаимодействия с пользовательским интерфейсом. Рассмотрим основные преимущества Compose более детально.

1. Меньше шаблонного кода

Одним из основных преимуществ Jetpack Compose является значительное сокращение объема шаблонного кода. В традиционном подходе с использованием XML, для создания интерфейса необходимо писать множество разметки, настраивать и связывать компоненты вручную. Compose позволяет сделать это с помощью простых и лаконичных функций на Kotlin. Вместо того чтобы использовать несколько строк XML-кода и связать его с логикой в Activity или фрагменте, мы просто описываем, что должно отображаться, и Compose берет на себя все остальное. Это позволяет уменьшить количество кода и упростить поддержку приложения.

2. Лучшая поддержка архитектурных паттернов

Jetpack Compose тесно интегрирован с современными архитектурными паттернами, такими как MVVM (Model-View-ViewModel) и MVI (Model-View-Intent). Это особенно важно для крупных приложений и корпоративных решений, где управление состоянием и обновление UI являются ключевыми аспектами.

3. Горячая перезагрузка и предварительный просмотр

Одним из самых приятных преимуществ Compose является встроенная поддержка горячей перезагрузки и живого предварительного просмотра

интерфейса. Это позволяет разработчикам видеть изменения в интерфейсе в реальном времени, без необходимости перезапуска приложения.

Каждое изменение в Compose можно увидеть сразу, просто обновив код, что значительно ускоряет процесс разработки и тестирования.

4. Снижение сложности управления состоянием

Compose значительно упрощает управление состоянием интерфейса. В традиционном подходе мы часто сталкиваемся с необходимостью вручную обновлять элементы UI при изменении данных, что требует множества вспомогательных методов и может привести к ошибкам.

В Compose управление состоянием происходит через аннотации, такие как `remember`, `mutableStateOf` и другие. Эти инструменты автоматизируют процесс обновления UI, обеспечивая лучшую поддержку взаимодействия с пользователем и данные, связанные с состоянием.

5. Простота переиспользования UI-компонентов

В Jetpack Compose всё строится вокруг компонентного подхода. Это означает, что UI-компоненты становятся независимыми и легко переиспользуемыми. Вы можете создать одноразовый компонент и использовать его в разных частях приложения, изменяя только его параметры.

6. Интеграция с Kotlin DSL

Jetpack Compose использует возможности Kotlin DSL (Domain-Specific Language) для создания интерфейсов. Это означает, что интерфейсы описываются с помощью естественного, читаемого синтаксиса, что упрощает работу с UI.

С помощью Kotlin и его возможностей, таких как расширения и лямбда-функции, Compose позволяет создать очень гибкие и мощные UI компоненты. Например, использование `Modifier` в Compose напоминает декларацию стилей и внешнего вида компонентов, что позволяет избежать многократных вложений и улучшает структуру кода.

7. Тестируемость UI

Тестирование UI в традиционном подходе может быть сложным и трудоемким, особенно когда нужно тестировать различные состояния интерфейса. В Compose тестирование упрощается благодаря встроенным средствам для UI-тестирования.

С помощью `ComposeTestRule` можно легко создавать автоматические тесты для компонентов, что позволяет проверять их поведение и внешний вид без необходимости в сложных моках или заглушках.

Jetpack Compose предоставляет целый ряд преимуществ, которые упрощают и ускоряют процесс разработки Android-приложений. Эти преимущества включают меньший объем кода, улучшенную поддержку архитектурных паттернов, гибкое управление состоянием, горячую перезагрузку и предварительный просмотр UI, переиспользуемость компонентов, а также улучшенные возможности для тестирования. Всё это делает Jetpack Compose мощным инструментом для современных Android-разработчиков.

Несмотря на множество преимуществ, Jetpack Compose также имеет ряд недостатков и ограничений, которые важно учитывать при его внедрении в проект. Некоторые из этих проблем могут быть связаны с ограничениями самой библиотеки, а другие – с особенностями текущего состояния экосистемы Android и инструментов разработки. Рассмотрим основные из них.

1. Требования к версии Android Studio и Kotlin

Для полноценной работы с Jetpack Compose требуется версия Android Studio Canary или Beta. Стандартные версии не поддерживают все возможности Compose, что может быть неудобно для разработчиков, использующих стабильную версию IDE.

Кроме того, Compose тесно интегрирован с Kotlin и требует использования новейших версий Kotlin (например, Kotlin 1.5 и выше), что также может ограничить использование Compose в старых проектах, использующих более старые версии Kotlin.

Для разработки с Jetpack Compose необходимо постоянно обновлять как IDE, так и зависимые библиотеки, что требует дополнительных усилий от команды разработчиков и может вызвать проблемы совместимости с уже существующими кодовыми базами.

2. Новые проблемы с производительностью (в сравнении с XML)

Хотя Jetpack Compose предлагает много преимуществ, на ранних стадиях его использования были обнаружены проблемы с производительностью. В частности, в более сложных приложениях, где требуется большое количество компонентов и сложные UI, Compose может демонстрировать меньшую производительность, чем традиционный XML-подход.

Это связано с перекомпоновкой интерфейса. При изменении состояния Compose перерисовывает только те части, которые изменились, но если интерфейс слишком сложен или состояние неправильно организовано, это может повысить нагрузку на процессор.

3. Отсутствие поддержки некоторых сторонних библиотек

На данный момент Jetpack Compose не поддерживает все сторонние библиотеки, которые были оптимизированы для традиционного XML-UI. Особенно это касается библиотек для работы с графикой, анимацией, и сторонних UI-компонентов. Множество популярных библиотек на данный момент ещё не обновлены для поддержки Compose.

4. Меньшая зрелость и документация

Jetpack Compose, несмотря на активное развитие, всё ещё относительно молодой инструмент. Хотя его документация и примеры кода уже достаточно обширны, многие вопросы остаются нерешёнными, а некоторые возможности Compose всё ещё находятся в стадии активного тестирования и улучшения.

5. Трудности с миграцией существующих приложений

Миграция старых проектов с использованием традиционных XML-кодов на Jetpack Compose может быть достаточно сложной и трудоёмкой. Переход требует переписывания значительных частей кода и повторного

проектирования интерфейсов. Если приложение имеет большое количество экранов и элементов, перенос на Compose может занять много времени и ресурсов [7].

Кроме того, из-за изменений в структуре UI-компонентов, некоторым старым приложениям может понадобиться не просто миграция интерфейса, но и переработка архитектуры приложения, что требует дополнительных усилий. В идеале, на первых этапах стоит использовать Compose только для новых экранов или модулей, чтобы постепенно внедрять его в проект.

6. Ограниченная поддержка старых версий Android

Jetpack Compose был разработан с расчетом на Android 5.0 (API 21) и выше. Это означает, что приложения, использующие Compose, не будут работать на устройствах с более старыми версиями Android. В случае необходимости поддержки старых устройств, разработчикам может понадобиться использовать классический подход с XML для этих версий, что приводит к дополнительной сложности и необходимости поддерживать два параллельных подхода в одном проекте.

7. Проблемы с совместимостью компонентов

Jetpack Compose активно развивается, и хотя Google предоставляет все необходимые инструменты для его интеграции с другими компонентами экосистемы Android, на ранних стадиях реализации может возникать несколько проблем с совместимостью компонентов. Некоторые старые компоненты, такие как View или Fragment, могут работать не идеально при взаимодействии с Compose. Проблемы могут возникать также при интеграции с навигацией, анимациями и другими сторонними библиотеками.

Несмотря на множество преимуществ, Jetpack Compose имеет ряд недостатков и ограничений, которые разработчики должны учитывать при решении о его внедрении в проект. Однако, с учётом активного развития Compose и его совершенствования, можно ожидать, что эти ограничения будут постепенно устранены в будущих версиях.

Jetpack Compose представляет собой мощный и инновационный инструмент для разработки пользовательских интерфейсов в Android-приложениях [8]. Его декларативный подход, использование Kotlin и модульность компонентов значительно упрощают процесс разработки, повышают гибкость и читаемость кода. Одним из главных преимуществ является сокращение объема шаблонного кода и улучшенная интеграция с современными архитектурными паттернами, такими как MVVM и MVI. Возможность горячей перезагрузки и тестирования UI в реальном времени также способствует ускорению разработки и снижению сложности поддержания кода.

Однако, как и любой новый инструмент, Jetpack Compose имеет свои ограничения и недостатки, такие как требования к версии Android Studio, проблемы с производительностью в сложных приложениях и поддержка старых библиотек. Миграция на Compose также может быть трудоемким процессом для уже существующих проектов.

Тем не менее, с учетом активного развития Compose и его стремления к улучшению совместимости с другими инструментами и библиотеками, эти ограничения со временем будут преодолены. В будущем Jetpack Compose может стать стандартом для создания мобильных приложений, обеспечивая более эффективную и гибкую разработку, удобную интеграцию с Kotlin и поддержание современного подхода к проектированию UI.

СПИСОК ЛИТЕРАТУРЫ

1. Смит, Н. Основы JetPack Compose / Н. Смит. – СПб : БХВ-Петербург, 2025. – 688 с. – ISBN 978-601-12-3345-3.
2. Филлипс, Б.; Стюарт, К.; Марсикано, К. Android. Программирование для профессионалов. 4-е изд. / Б. Филлипс, К. Стюарт, К. Марсикано. – СПб : Питер, 2021. – 704 с. – ISBN 978-5-4461-1657-7.
3. Гриффитс, Д.; Гриффитс, Д. Head First. Программирование для Android на Kotlin. 3-е изд. / Д. Гриффитс, Д. Гриффитс; пер. Е. П. Матвеев. – СПб : Питер, 2023. – 912 с. – ISBN 978-5-4461-2016-1.
4. Данн, М.; Лоранс, П.-О.; Блейк Мик, Дж.; Хинчман-Домингес, А. Программирование на Kotlin для Android / М. Данн и др. – СПб : БХВ-Петербург, 2025. – 432 с. – ISBN 978-5-9775-0944-2.
5. Jetpack Compose – официальный раздел для разработчиков // Android Developers : [сайт]. – 2013. – URL: <https://developer.android.com/compose> (дата обращения: 08.09.2025).
6. Kotlin и Android (Jetpack/Compose): руководство // METANIT.COM : [сайт]. – 2009. – URL: <https://metanit.com/kotlin/jetpack/> (дата обращения: 12.09.2025).
7. Рекомендации по Jetpack Compose: от основ к масштабируемому UI // Хабр : [сайт]. – 2006. – URL: <https://habr.com/ru/articles/917196/> (дата обращения: 15.09.2025).
8. Полное руководство по написанию чистого кода Jetpack Compose // AppTractor : [сайт]. – 2014. – URL: <https://apptractor.ru/info/articles/polnoe-rukovodstvo-po-napisaniyu-chistogo-koda-jetpack-compose.html> (дата обращения: 24.09.2025).

ПРОЕКТИРОВАНИЕ АРХИТЕКТУРЫ И ПРОТОКОЛА БЕЗОПАСНОСТИ ДЛЯ АВТОНОМНОГО АГЕНТА В КОРПОРАТИВНОЙ СРЕДЕ

Р.А. Гладких

Кубанский государственный университет

В статье рассматриваются вопросы проектирования защищенной архитектуры и протоколов безопасности для автономных агентов, функционирующих в корпоративной среде. Предложены модели

взаимодействия, методы аутентификации, шифрования и управления доступом, обеспечивающие конфиденциальность, целостность и доступность данных.

Ключевые слова: архитектура безопасности, автономный агент, корпоративная среда, протокол безопасности, модель угроз, аутентификация и авторизация, управление доступом, zero trust модель, шифрование данных, журналирование и аудит, управление ключами, интеграция с IAM, управление уязвимостями, безопасность API, управление политиками, соответствие требованиям безопасности.

The article discusses the design of secure architecture and security protocols for autonomous agents operating in a corporate environment. Interaction models, authentication, encryption and access control methods are proposed to ensure confidentiality, integrity and availability of data.

Key words: security architecture, autonomous agent, corporate environment, security protocol, threat model, authentication and authorization, access control, zero trust model, data encryption, logging and auditing, key management, IAM integration, vulnerability management, API security, policy management, security compliance.

С развитием технологий искусственного интеллекта и интернета вещей автономные агенты становятся неотъемлемой частью корпоративных систем. Они используются для автоматизации бизнес-процессов, мониторинга, анализа данных и управления ресурсами. Однако их внедрение сопровождается рисками, связанными с утечкой информации, несанкционированным доступом и нарушением работы систем.

1. Архитектура автономного агента [1].

Архитектура автономного агента представляет собой сложную модульную систему, где большая языковая модель (LLM) выступает в роли центрального процессора, или "мозга", координирующего работу всех компонентов. Цель такой архитектуры – преобразовать статическую способность LLM генерировать текст в целенаправленное, последовательное и безопасное взаимодействие с окружающей средой (цифровой или физической) для достижения сложных задач.

Рассмотрим ключевые компоненты архитектуры подробнее.

1) Ядро агента: Большая Языковая Модель (LLM)

LLM является центральным процессором агента, ответственным за:

- рассуждение и декомпозицию: анализ высокой-level цели пользователя, её разбиение на последовательные, выполнимые шаги (подзадачи);
- планирование: формирование или корректировка плана действий на основе текущего контекста и результатов предыдущих шагов;
- принятие решений: выбор следующего действия или инструмента из доступного арсенала;

- синтез информации: обобщение информации из памяти и наблюдений для формирования целостного ответа или вывода.

Для работы в качестве "мозга" агента LLM используется в режиме few-shot обучения или манипулирования промптами, где системный промпт четко определяет ее роль, доступные инструменты и формат ответа.

2) Модуль Планирования и Исполнения

Этот модуль реализует основной цикл "Мысль-Действие-Наблюдение".

- планировщик:

на основе глобальной цели создает первоначальный план - упорядоченный список подзадач;

динамически адаптирует план при возникновении ошибок, неожиданных результатов или изменения условий. Например, если инструмент недоступен, планировщик должен предложить альтернативный путь.

- исполнитель:

ответственен за выполнение конкретного шага плана, выбранного ядром LLM;

взаимодействует с модулем инструментов, вызывая соответствующие функции/API на основе решения, принятого LLM.

3) Модуль Инструментов

Это "руки и ноги" агента, расширяющие его возможности за пределы текстовой генерации. Набор инструментов делает агента по-настоящему автономным. Типичные инструменты включают:

- поисковые системы: для получения актуальной информации из интернета;

- вычислители: для точных математических операций;

- интерпретатор кода: для написания, выполнения и отладки кода;

- API-клиенты: для взаимодействия с внешними сервисами (например, отправка email, управление календарем, работа с базами данных);

- специализированные модели: для анализа изображений, видео или аудио;

LLM не выполняет код напрямую, а генерирует запрос на вызов конкретного инструмента с правильными аргументами.

4) Модуль Памяти

Память является критически важным компонентом для поддержания контекста и обучения в ходе сессии. Она подразделяется на:

- кратковременная память:

хранит полную историю взаимодействия текущей сессии: цепочку мыслей, действия, наблюдения и результаты;

служит контекстом для LLM при принятии каждого следующего решения, позволяя агенту ссылаться на предыдущие шаги.

- долговременная память:

представляет собой векторную базу данных, где сохраняются ключевые факты, результаты и извлеченные уроки из прошлых сессий;

позволяет агенту "учиться на опыте" и использовать релевантную информацию при решении новых, схожих задач, без необходимости начинать с нуля.

5. Цикл работы агента

Взаимодействие компонентов происходит в рамках непрерывного цикла:

- ввод цели: пользователь ставит перед агентом сложную задачу;
- рассуждение и планирование: ядро LLM, используя контекст из памяти, анализирует цель и создает или обновляет план;
- действие: LLM решает, какой шаг выполнить следующим. Если требуется инструмент, она генерирует структурированный запрос на его вызов;
- наблюдение: исполнитель запускает инструмент и получает результат (наблюдение);
- синтез и запись в память: результат наблюдения добавляется в кратковременную память. LLM анализирует его в контексте всей истории и цели, чтобы решить: достаточно ли информации для перехода к следующему шагу или требуется уточняющий поиск;
- повторение: цикл (шаги 2-5) повторяется до тех пор, пока задача не будет выполнена или не будет достигнуто максимальное число итераций;
- финальный результат: агент возвращает пользователю итоговый результат и, при необходимости, сохраняет ключевые выводы в долговременную память.

2. Угрозы безопасности [2]

Основными угрозами для автономных агентов являются:

1) несанкционированный доступ - попытка получения контроля над автономным агентом или его компонентами без соответствующих прав доступа. К этой угрозе относятся: подбор учетных данных, эксплуатация уязвимостей ПО, социальная инженерия.

2) перехват данных - несанкционированный доступ к передаваемой или хранимой информации. К этой угрозе относятся: анализ сетевого трафика, компрометация каналов связи, кража данных из памяти.

3) изменение данных - несанкционированная модификация данных, команд или конфигурации агента. К этой угрозе относятся: изменение конфигурационных файлов, манипуляция данными сенсоров, модификация исполняемого кода.

4) отказ в обслуживании - нарушение доступности автономного агента или его компонентов. К этой угрозе относятся: перегрузка вычислительных ресурсов, атаки на сетевую инфраструктуру.

3. Протоколы безопасности [3-4]

Для защиты автономных агентов предлагается использовать следующие протоколы:

3.1. Протоколы аутентификации и авторизации.

- многофакторная аутентификация (MFA) представляет собой фундаментальный принцип обеспечения безопасности, требующий предоставления двух или более независимых доказательств идентичности. В контексте автономных агентов реализуется комбинация факторов:

Фактор знания - пароли, PIN-коды, секретные вопросы.

Фактор владения - аппаратные токены, смарт-карты, мобильные устройства.

Фактор наследия - биометрические характеристики (отпечатки пальцев, распознавание лица, голоса).

Фактор поведения - поведенческие биометрические шаблоны (динамика работы с клавиатурой, паттерны перемещения).

Для автономных агентов критически важным является реализация адаптивной аутентификации, при которой уровень строгости проверки зависит от контекста выполнения операций, оценки рисков и критичности выполняемых задач.

- протокол OAuth 2.0 и OpenID Connect. OAuth 2.0 обеспечивает делегированный доступ к защищенным ресурсам без раскрытия учетных данных пользователя. В архитектуре автономного агента данный протокол реализуется через:

Authorization Code Flow - для веб-приложений и сервисов.

Client Credentials Flow - для межсервисного взаимодействия.

Device Authorization Flow - для устройств с ограниченными возможностями ввода.

OpenID Connect расширяет функциональность OAuth 2.0, предоставляя уровень идентификации через стандартизированный механизм получения профилей пользователей.

3.2. Протоколы шифрования данных

- Transport Layer Security (TLS 1.3), представляет собой криптографический протокол, обеспечивающий защищенную передачу данных по сетям связи.

Основные особенности:

упрощенный handshake процесс;

обязательное использование Perfect Forward Secrecy;

удаление устаревших и небезопасных алгоритмов шифрования;

улучшенная производительность и безопасность.

- Internet Protocol Security (IPSec), обеспечивает безопасность на сетевом уровне модели OSI, предоставляя:

Authentication Header (AH) - аутентификацию и целостность пакетов.

Encapsulating Security Payload (ESP) - конфиденциальность, аутентификацию и целостность.

Internet Key Exchange (IKE) - управление криптографическими ключами.

3.3. Системы управления ключами

- Public Key Infrastructure (PKI), инфраструктура открытых ключей обеспечивает:

издание и управление цифровыми сертификатами;
создание центров сертификации (CA);
регистрационные центры (RA);
системы отзыва сертификатов (CRL/OCSP).

- Key Management Interoperability Protocol (KMIP), стандартизированный протокол для управления криптографическими ключами:

единый интерфейс для различных систем хранения ключей;
поддержка симметричных и асимметричных ключей;
управление полным жизненным циклом ключей.

- Hardware Security Modules (HSM), аппаратные модули безопасности обеспечивают: физическую защиту криптографических материалов, генерацию истинно случайных чисел, выполнение криптографических операций в защищенной среде.

3.4. Протоколы обеспечения целостности данных

- Цифровые подписи:

RSA-PSS - вероятностная схема подписи;

ECDSA - подписи на эллиптических кривых;

EdDSA - высокопроизводительные подписи.

- Коды аутентификации сообщений:

HMAC - хэш-коды аутентификации сообщений;

KMAC - коды аутентификации на основе Кессак;

Poly1305 - высокопроизводительные MAC.

- Контроль целостности программного обеспечения:

Secure Boot - верификация целостности при загрузке;

Measured Boot - измерение и регистрация состояния системы;

Remote Attestation - удаленная проверка целостности.

3.5. Протоколы мониторинга и аудита

- Security Information and Event Management (SIEM):

централизованный сбор и корреляция событий безопасности;

обнаружение аномального поведения;

реагирование на инциденты безопасности.

- протоколы сбора логов:

Syslog - стандартизированный формат системных логов;

CEF - Common Event Format для межплатформенной совместимости;

OCSF - Open Cybersecurity Schema Framework.

- протоколы обнаружения вторжений:

SNORT - сетевая система обнаружения вторжений;

Suricata - высокопроизводительная IDS/IPS;

YARA - идентификация и классификация вредоносного ПО.

СПИСОК ЛИТЕРАТУРЫ

1. Архитектура автономных систем на основе больших языковых моделей / К.Л. Джонс, М. Рихтер // Журнал искусственного интеллекта и его приложений. – 2022. – Т. 15, № 4. – С. 112-125.
2. Безопасность приложений и сервисов в эпоху искусственного интеллекта / А.И. Петров, В.С. Иванова // Труды международной конференции «Информационная безопасность и криптология». – 2023. – С. 45-52.
3. Криптографические протоколы для защиты данных в корпоративных сетях / С.М. Николаев, Т.П. Белова // Вопросы кибербезопасности. – 2023. – № 1(12). – С. 23-35.
4. Security Information and Event Management (SIEM): от теории к практике / А.В. Сидоров // Информационные технологии в бизнесе. – 2022. – № 3. – С. 88-95.

РАЗРАБОТКА МОДУЛЯ ИНТЕГРАЦИИ АВТОНОМНОГО АГЕНТА С СИСТЕМАМИ МОНИТОРИНГА И ITSM СИСТЕМАМИ ПО REST API

В.А. Горбачев

Кубанский государственный университет

Анализ современных систем мониторинга и ITSM-платформ с точки зрения предоставляемых REST API. Исследование архитектурных подходов к интеграции, модели данных, методам аутентификации и типовые сценарии взаимодействия для автоматизации управления IT-инфраструктурой и операционными процессами.

Ключевые слова: автономный агент, интеграционный модуль, системы мониторинга, ITSM системы, REST API, веб сервисы, JSON, управление инцидентами, управление изменениями, вебхуки, двусторонний обмен данными, корреляция событий, автоматическое создание заявок, синхронизация статусов, авторизация по токену, корпоративная интеграционная шина.

Analysis of modern monitoring systems and ITSM platforms from the perspective of their REST APIs. Research into architectural approaches to integration, data models, authentication methods, and typical interaction scenarios for automating IT infrastructure management and operational processes.

Key words: autonomous agent, integration module, monitoring systems, ITSM systems, REST API, web services, JSON, incident management, change management, webhooks, bidirectional data exchange, event correlation, automatic ticket creation, status synchronization, token based authorization, enterprise integration bus.

Современное управление IT-инфраструктурой требует тесной интеграции между системами мониторинга, отслеживающими состояние компонентов в реальном времени, и ITSM-системами, управляющими жизненным циклом инцидентов, изменений и услуг. Рост сложности распределённых и гибридных сред сделал невозможным ручное взаимодействие между этими платформами [1]. REST API (Representational State Transfer Application Programming Interface) стал стандартом для построения подобных интеграций благодаря своей простоте, масштабируемости и поддержке архитектурных стилей, независимых от языков программирования [2].

Системы мониторинга, такие как Zabbix и Prometheus, предоставляют API для извлечения метрик, событий и управления оповещениями. ITSM-системы, например, ServiceNow, предлагают API для создания, обновления и поиска записей в таблицах (инциденты, изменения, элементы конфигурации – CI). Эффективная интеграция этих систем позволяет автоматизировать процесс создания инцидентов на основе оповещений мониторинга, обновления статусов инцидентов при восстановлении служб и обогащения данных мониторинга информацией из CMDB (Configuration Management Database) [3].

Целью данного исследования является проведение сравнительного анализа REST API популярных систем мониторинга и ITSM, выявление общих паттернов взаимодействия, оценка возможностей и ограничений, а также формулировка рекомендаций по построению отказоустойчивых и безопасных интеграций.

REST API в рассматриваемых системах следует общим принципам: использование HTTP-методов (GET, POST, PUT, DELETE), кодов состояния HTTP для индикации результата и формата JSON для представления данных. Однако между системами существуют значительные различия в структуре эндпоинтов, моделях данных и механизмах безопасности [4]:

1. Zabbix использует архитектуру JSON-RPC с единым эндпоинтом `/api_jsonrpc.php`. Все операции выполняются через структурированные JSON-запросы, содержащие метод API, параметры и токен аутентификации. Модель данных строится вокруг объектов `host`, `item`, `trigger` и `event`, что обеспечивает централизованное управление [5].

2. Prometheus предлагает специализированный API для работы с временными рядами через эндпоинты `/api/v1/query` и `/api/v1/query_range` с использованием языка PromQL. Важной особенностью является отсутствие универсального API для управления конфигурацией, которая задается статически через YAML-файлы [6].

3. Nagios XI реализует традиционный RESTful подход с распределенными эндпоинтами для различных объектов (`/api/object/host`, `/api/object/service`). Это упрощает работу с API через стандартные HTTP-методы, но требует взаимодействия с множеством конечных точек [7].

В сегменте ITSM-систем архитектура API демонстрирует ориентацию на универсальность и глубокую интеграцию с бизнес-процессами:

1. ServiceNow предоставляет универсальный REST API через эндпоинты вида `/api/now/table/<table_name>`, где имя таблицы соответствует бизнес-сущности (`incident`, `cmdb_ci`). API поддерживает сложную фильтрацию, пагинацию и выбор полей, обеспечивая прямой доступ к данным [8].

2. Jira Service Management использует REST API на основе платформы Atlassian. Основные эндпоинты предназначены для управления запросами обслуживания (`/rest/servicedeskapi/request`). Для аутентификации применяется OAuth 2.0, что обеспечивает безопасное взаимодействие [9].

3. Zendesk реализует ресурсно-ориентированную архитектуру с отдельными эндпоинтами для тикетов (`/api/v2/tickets`), пользователей и организаций. API отличается предсказуемой структурой и тесной связью между бизнес-сущностями [10].

Для анализа возможностей API рассматривались ключевые операции, обеспечивающие интеграцию между системами. Основное внимание было уделено операциям чтения данных, которые включают получение списка активных проблем и алертов из систем мониторинга, а также выборку открытых инцидентов из ITSM-системы для анализа и сверки. Также детально изучались операции записи данных, в рамках которых реализуется автоматическое создание инцидента в ITSM на основе критического алерта из мониторинга и последующее добавление комментариев или обновление статуса по этому инциденту. Отдельно проводился анализ методов аутентификации для безопасного доступа к API, где сравнивались различные подходы, такие как использование API-ключей, протокола OAuth, Basic Auth и Session Token, с целью выбора наиболее подходящего и безопасного варианта.

Была разработана тестовая среда, в которой выполнялись автоматизированные сценарии взаимодействия между системами. Основные метрики включали *latency* операций, процент успешных запросов и сложность реализации типовых сценариев.

Анализ показал следующие результаты:

1. Универсальность и богатство функционала: наиболее полным и унифицированным является API ServiceNow, предоставляющий прямой доступ ко всем таблицам и бизнес-логике [8]. API Zabbix, несмотря на нестандартный JSON-RPC подход, также охватывает почти все функции системы [5].

2. Производительность: Prometheus API продемонстрировал наименьшую *latency* при запросах метрик (<50 мс), что обусловлено его ориентацией на чтение временных рядов. [6] Операции записи (создание инцидентов в ITSM) в среднем занимали 150-300 мс.

3. Сложность разработки: наибольшие усилия требуются для интеграции с Nagios XI из-за фрагментированности эндпоинтов и менее

последовательной модели данных [7]. JSM API имеет кривую обучения, связанную с пониманием специфичной для Atlassian модели данных [9].

4. Безопасность: все системы поддерживают шифрование TLS. ServiceNow и JSM предлагают наиболее зрелые модели OAuth 2.0 [8, 9], в то время как Zabbix и Nagios в основном полагаются на статические API-токены или аутентификацию на основе сессий [5, 7].

Проведённое исследование REST API систем мониторинга и ITSM показало, что, несмотря на общую приверженность принципам REST [2], между системами существуют значительные различия в архитектуре, модели данных и подходах к безопасности. Эти различия необходимо учитывать при проектировании интеграционных решений.

Универсальным паттерном является использование адаптерного слоя, который абстрагирует специфику API каждой системы и предоставляет единый интерфейс для бизнес-логики, что согласуется с современными подходами к разработке корпоративных приложений [4]. Для обеспечения надёжности критически важны механизмы повторных попыток (retry logic), обработки ошибок и мониторинга здоровья самого интеграционного канала.

Научная и практическая ценность работы заключается в систематизации знаний об API рассматриваемых систем и выработке рекомендаций, которые позволяют ускорить и удешевить разработку комплексных решений для автоматизации управления ИТ-услугами. Дальнейшие исследования могут быть направлены на анализ интеграций с использованием более сложных протоколов, таких как GraphQL, или в контексте гибридных и мультиоблачных сред.

СПИСОК ЛИТЕРАТУРЫ

1. Меньшиков В. В., Лапицкий В. И. Управление ИТ-услугами на основе ITSM: Стандартизация и автоматизация. – М.: ДМК Пресс, 2021.
2. Fielding, R. T. Architectural Styles and the Design of Network-based Software Architectures [Doctoral dissertation, University of California, Irvine]. – 2000.
3. Karwowski, A., & Zieliński, K. Integration of Monitoring and IT Service Management Systems for Automated Incident Handling // Journal of Network and Systems Management. – 2022. – 30(1). – P. 45-67.
4. Hohpe, G., & Woolf, B. Enterprise Integration Patterns: Designing, Building, and Deploying Messaging Solutions. – Addison-Wesley Professional, 2003.
5. Zabbix LLC. Zabbix 6.4 Documentation: API Reference. – URL: <https://www.zabbix.com/documentation/current/en/manual/api> (дата обращения: 12.09.2025).
6. Prometheus Authors. Prometheus Documentation: HTTP API. – URL: <https://prometheus.io/docs/prometheus/latest/querying/api/> (дата обращения: 15.09.2025).

7. Nagios Enterprises. Nagios XI Documentation: REST API. – URL: <https://assets.nagios.com/downloads/nagiosxi/docs/REST-API.pdf> (дата обращения: 16.09.2025).

8. ServiceNow, Inc. ServiceNow Developer Portal: Table API. – URL: https://developer.servicenow.com/dev.do#!/reference/api/rome/rest/c_Table_API (дата обращения: 12.09.2025).

9. Atlassian. Jira Service Management REST API Documentation (v3). – URL: <https://developer.atlassian.com/cloud/jira/service-desk/rest/v3/api-group-request/> (дата обращения: 15.2025).

10. Zendesk, Inc. Zendesk Developer Documentation: REST API. – URL: <https://developer.zendesk.com/api-reference> (дата обращения: 16.09.2025).

ПРИМЕНЕНИЕ ОНЛАЙН-РАСПИСАНИЯ В ОБРАЗОВАТЕЛЬНЫХ И КОРПОРАТИВНЫХ СИСТЕМАХ УПРАВЛЕНИЯ НА БАЗЕ 1С:ПРЕДПРИЯТИЕ.ЭЛЕМЕНТ

Н.С. Горобец

Кубанский государственный университет

Исследование внедрения онлайн-расписания на платформе 1С:Предприятие.Элемент для замены неэффективных инструментов планирования в образовательных и корпоративных структурах. Представлены подходы к модульной настройке системы, интеграции через API и адаптации пользователей. Практические кейсы подтверждают автоматизацию учета ресурсов, устранение конфликтов расписания и предоставление персонализированного доступа к актуальной информации.

Ключевые слова: онлайн расписание, системы управления на базе 1С:Предприятие.Элемент, образовательные организации, корпоративные информационные системы, управление учебным процессом, управление рабочим временем, автоматизация составления расписания, интеграция с электронным журналом, интеграция с кадровыми и ERP системами, веб интерфейс для пользователей, мобильный доступ, уведомления и оповещения, оптимизация использования ресурсов, аналитика посещаемости и загрузки.

A study of the implementation of online schedules on the 1C Enterpris.Element to replace inefficient planning tools in educational and corporate structures. Approaches to modular system configuration, API integration, and user adaptation are presented. Practical cases confirm the automation of resource accounting, the elimination of schedule conflicts and the provision of personalized access to up-to-date information.

Key words: online scheduling, management systems based on 1C:Enterprise.Element, educational institutions, corporate information systems, learning process management, workforce time management, automated timetable generation, integration with electronic gradebook, integration with HR and ERP

systems, web based user interface, mobile access, notifications and alerts, resource utilization optimization, attendance and workload analytics.

В условиях цифровизации вопросы автоматизации управления временем и ресурсами становятся особенно актуальными [1]. Существующие решения часто не справляются с динамическими изменениями и требуют значительных временных затрат на обновление. Образовательные и корпоративные организации сталкиваются с необходимостью эффективной организации занятий, встреч и распределения ресурсов, а традиционные способы ведения расписаний, такие как Excel или бумажные формы, не обеспечивают гибкости, оперативности и интеграции с другими сервисами. Существующие решения часто фрагментарны, не адаптированы к специфике организаций и требуют дополнительных затрат на сопровождение. В этих условиях централизованная система планирования становится критически важной. Онлайн-расписание на базе облачных технологий, таких как 1С:Предприятие.Элемент, обеспечивает доступ к данным в реальном времени, удобство взаимодействия пользователей и интеграцию с внутренними системами организации [1,7].

Цель работы – оценить эффективность внедрения онлайн-расписания на платформе 1С:Предприятие.Элемент. Актуальность исследования определяется необходимостью повышения эффективности управления временными ресурсами, сокращения трудозатрат и уровня цифровизации рабочих процессов. Применение таких решений позволяет автоматизировать планирование, снизить количество ошибок, обеспечить удобный доступ к информации для всех пользователей и создать основу для дальнейшего развития цифровых сервисов в организациях [2].

Процесс планирования и управления расписанием является неотъемлемой частью деятельности как образовательных организаций, так и корпоративных структур. В образовательной среде расписание обеспечивает согласованность учебного процесса, распределение занятий по аудиториям и преподавателям, а также равномерную нагрузку на студентов. В корпоративной сфере грамотное планирование позволяет координировать работу сотрудников, организовывать встречи и совещания, а также эффективно использовать ресурсы предприятия [3].

Современные тенденции цифровизации предполагают переход от традиционных инструментов планирования к онлайн-решениям. Это объясняется необходимостью поддержки гибридных форматов деятельности, обеспечением удалённого доступа к информации в режиме реального времени, интеграцией расписаний с системами управления персоналом, учебным процессом, проектами и ресурсами, а также возможностью оперативно изменять и актуализировать расписание, обеспечивая гибкость и адаптивность процессов [1].

Онлайн-расписания обеспечивают централизованное хранение данных, многопользовательский доступ с различными уровнями прав, интеграцию с облачными сервисами и мобильными приложениями, а также возможность

анализа и оптимизации процессов планирования. В современных условиях организации используют различные инструменты для ведения расписаний: традиционные, облачные сервисы общего назначения и специализированные корпоративные или образовательные системы. Наиболее распространёнными являются таблицы Excel и аналогичные программы, которые удобны и привычны пользователям, но при увеличении масштабов организации становятся малоэффективными, не обеспечивают коллективного доступа и плохо интегрируются с другими приложениями [2].

С развитием цифровых технологий получили широкое распространение онлайн-календари и планировщики, такие как Google Calendar, Microsoft Outlook и Яндекс.Календарь. Они обеспечивают базовые функции управления временем – создание событий, рассылку приглашений и напоминания – и отличаются доступностью и простотой внедрения. Однако такие сервисы не учитывают специфику образовательных и корпоративных систем, где важно управлять большими массивами данных, учитывать нагрузку на ресурсы и обеспечивать интеграцию с другими информационными системами.

В образовательной сфере применяются системы управления учебным процессом (LMS), такие как Moodle, Blackboard и Canvas. Они позволяют организовывать дистанционное обучение и часто включают модуль расписаний, но требуют значительных затрат на внедрение и настройку и не всегда соответствуют требованиям конкретных учреждений. В корпоративной среде применяются ERP и CRM-системы, которые позволяют управлять проектами, персоналом и ресурсами, однако модули расписаний в таких системах нередко ограничены в функциональности или сложны в эксплуатации для рядовых пользователей [3].

Платформа 1С:Предприятие зарекомендовала себя как мощный инструмент для автоматизации управленческих и учётных процессов в организациях различного масштаба. Однако для задач, требующих большей мобильности, облачного доступа и быстрого развертывания, рациональнее использовать более лёгкое решение – 1С:Предприятие.Элемент. Эта технология унаследовала концепцию экосистемы 1С, но ориентирована на разработку компактных веб и мобильных приложений с возможностью интеграции с существующими корпоративными системами.

Таблица 1 – Сравнение 1С:Предприятие и 1С:Предприятие.Элемент

Критерий	1С:Предприятие	1С:Предприятие.Элемент
Тип платформы	Устанавливаемая, серверная система с возможностью локального хранения данных	Полностью облачная платформа, работает через браузер
Назначение	Комплексная автоматизация бизнес-процессов и	Разработка лёгких веб и мобильных приложений,

	управления предприятиями	прототипов и онлайн- сервисов
Интерфейс и доступ	Классический 1С, требуется установка	Современный веб- интерфейс, доступ из любой точки
Разработка	Использует конфигуратор и язык 1С	Визуальный конструктор, упрощённый синтаксис сценариев
Интеграция	Глубокая интеграция с системами 1С и внешними сервисами	Поддержка API и взаимодействие с экосистемой 1С
Применение	ERP, бухгалтерия, CRM, кадровый учёт	Онлайн-расписания, учёт заявок, мини-CRM

Особый интерес представляет использование платформы 1С:Предприятие.Элемент. Данный сервис является облачным решением, ориентированным на разработку прикладных приложений и организацию совместной работы. Его преимущества: облачная инфраструктура – доступ из любой точки и с любого устройства; масштабируемость – возможность адаптации решения под потребности конкретной организации; интеграция с экосистемой 1С – взаимодействие с системами бухгалтерского учёта, управления персоналом и проектами; простота настройки – возможность разработки прикладных модулей без глубоких знаний программирования [1, 2].

Использование 1С:Предприятие.Элемент для реализации онлайн-расписания позволяет объединить гибкость облачных сервисов и функциональность корпоративных систем. Разработка основана на модульном подходе, включает базу данных расписаний, визуальный календарь, систему уведомлений и механизмы интеграции с другими модулями 1С и внешними сервисами через API. Облачная архитектура обеспечивает доступ к расписанию в режиме реального времени и работу с системой через веб-браузер и мобильные устройства [1].

Онлайн-расписание на базе 1С:Предприятие.Элемент обеспечивает удобное управление событиями, включая создание, редактирование и привязку к ресурсам, поддерживает групповые и индивидуальные расписания, гибко управляет правами доступа и интегрируется с календарями и почтой. История изменений фиксирует корректировки и позволяет восстановить расписание в случае ошибок. Применение платформы обладает масштабируемостью, универсальностью, облачной доступностью, интеграцией в экосистему 1С, экономичностью и простотой настройки и сопровождения [2].

В образовательных учреждениях система может использоваться для автоматизации учебных расписаний, учёта занятости преподавателей и

аудиторий, организации экзаменационных сессий, а для студентов и преподавателей – предоставлять индивидуальное расписание с уведомлениями об изменениях. В корпоративных структурах решение применяется для планирования встреч, распределения ресурсов, управления занятостью сотрудников и организации совместной работы, что особенно актуально при гибридном формате работы [1, 3].

Внедрение онлайн-расписания на базе 1С:Предприятие.Элемент повышает эффективность за счёт экономии времени, сокращения трудозатрат и улучшения взаимодействия между подразделениями. Сравнительный анализ показал, что после внедрения время на составление и корректировку расписаний сократилось на 30–40%, снизилось количество ошибок, пользователи получили оперативный доступ к информации, повысилась гибкость процессов. Для образовательных учреждений это обеспечивает автоматизацию распределения занятий и экзаменов, удобный доступ студентов к расписанию и анализ загруженности преподавателей. В корпоративных организациях система упрощает планирование встреч с учётом ресурсов, интегрируется с другими модулями 1С и поддерживает гибридный формат работы. Облачная архитектура обеспечивает масштабируемость и готовность к интеграции с аналитическими модулями, повышая эффективность управления и цифровую культуру организации [1, 2].

Несмотря на преимущества онлайн-расписания, в процессе внедрения могут возникнуть трудности. Пользователи могут сопротивляться новым технологиям из-за привычки к традиционным инструментам, что решается обучением, инструкциями и постепенным внедрением. Интеграция с существующими системами может быть сложной, поэтому рекомендуется использование стандартных API, настройка обмена данными и пилотное тестирование. При работе с расписаниями важно учитывать информационную безопасность, применяя защищённые каналы, разграничение прав доступа и многофакторную аутентификацию. Кроме того, пользователям может потребоваться техническая поддержка, что решается организацией службы поддержки и назначением ответственных администраторов [1, 3].

Исследование показало, что внедрение онлайн-расписания в образовательные и корпоративные системы управления актуально в условиях цифровизации. Традиционные инструменты, такие как Excel или бумажные формы, не обеспечивают оперативного обновления данных и коллективного доступа. Использование 1С:Предприятие.Элемент перспективно, так как сочетает гибкость, облачную доступность, масштабируемость и интеграцию с экосистемой 1С. Онлайн-расписание позволяет автоматизировать планирование, сократить трудозатраты, снизить количество ошибок и обеспечить удобный доступ к информации. Практическая значимость решения заключается в универсальности для образовательных учреждений и корпоративных организаций, а научная новизна – в рассмотрении 1С:Предприятие.Элемент как платформы для управления расписаниями [1, 2].

СПИСОК ЛИТЕРАТУРЫ

1. Официальный сайт платформы 1С:Предприятие.Элемент : [сайт]. – URL: <https://1s-element.ru/> (дата обращения: 03.09.2025).
2. Возможности облачных технологий 1С: [сайт]. – URL: <https://v8.1c.ru/platforma/oblachnye-tehnologii/> (дата обращения: 04.09.2025).
3. Автоматизация учебного процесса и онлайн-расписания : [сайт]. – URL: <https://antitreningi.ru/info/e-learning/avtomatizaciya-obrazovatelnyh-processov-dlya-onlajn-shkol/> (дата обращения: 04.09.2025).
4. Обзор автоматизации календарного планирования : [сайт]. – URL: <https://secrets.tbank.ru/blogi-kompanij/pro-avtomatizaciju-kalendarnogo-planirovaniya/> (дата обращения: 07.09.2025).
5. Цифровая трансформация: [сайт]. – URL: https://ru.wikipedia.org/wiki/Цифровая_трансформация (дата обращения: 08.09.2025).
6. Официальный сайт компании 1С: [сайт]. – URL: <https://1c.ru/> (дата обращения: 08.09.2025).
7. Сибел Т. Цифровая трансформация. Как выжить и преуспеть в новую эпоху / Томас Сибел. – Москва: Манн, Иванов и Фербер, 2021. – 256 с. – ISBN 978-5-00146-897-5.

РАЗРАБОТКА МОБИЛЬНОГО ПРИЛОЖЕНИЯ ДЛЯ УДАЛЕННОГО ПРОСМОТРА ВИДЕО С ДЕТЕКЦИЕЙ ОБЪЕКТОВ В РЕАЛЬНОМ ВРЕМЕНИ

А.В. Горовенко

Кубанский государственный университет

В статье рассматривается подход к разработке кроссплатформенного мобильного приложения, предназначенного для удаленного подключения к видеопотоку с IP-камер или других устройств. Ключевой особенностью приложения является интеграция алгоритмов компьютерного зрения, работающих непосредственно на мобильном устройстве, для детекции и классификации объектов в реальном времени. Описана архитектура приложения, включающая модуль сетевого подключения (RTSP-клиент), модуль декодирования видео и модуль компьютерного зрения на базе оптимизированной нейронной сети (YOLO). Особое внимание уделено решению задач визуализации результатов детекции – наложению bounding box и текстовых меток на видеопоток для таких классов, как "человек" и "домашнее животное".

Ключевые слова: компьютерное зрение, мобильное приложение, удаленный доступ, детекция объектов, RTSP, YOLO, TensorFlow Lite, кроссплатформенная разработка.

The article discusses an approach to the development of a cross-platform

mobile application designed for remote connection to a video stream from IP cameras or other devices. The key feature of the application is the integration of computer vision algorithms that work directly on a mobile device to detect and classify objects in real time. The application architecture is described, which includes a network connection module (RTSP client), a video decoding module, and a computer vision module based on an optimized neural network (YOLO). Special attention is paid to solving the problems of visualizing detection results – superimposing a bounding box and text labels on a video stream for classes such as "human" and "pet".

Key words: computer vision, mobile application, remote access, object detection, RTSP, YOLO, TensorFlow Lite, cross-platform development.

С распространением недорогих IP-камер и систем "умного дома" возможность удаленного наблюдения за жилыми помещениями, офисами и другими объектами стала массово доступной. Пользователи часто сталкиваются с необходимостью не просто видеть видеопоток, но и мгновенно получать визуальную информацию о происходящем, в частности, о появлении в кадре людей или домашних животных.

Традиционные подходы подразумевают либо постоянное наблюдение за видео, что не всегда удобно, либо использование облачных сервисов, которые анализируют видео и присылают уведомления. Однако облачные решения могут иметь задержки, требовать подписки и поднимать вопросы о конфиденциальности данных.

Альтернативой является перенос анализа на конечное устройство пользователя – смартфон или планшет. Современные мобильные процессоры, оснащенные акселераторами для машинного обучения (NPU, GPU), позволяют выполнять инференс оптимизированных нейронных сетей в реальном времени. Это открывает возможность создания приложений, которые, подключаясь к удаленной камере, не только отображают видео, но и в реальном времени выделяют и подписывают объекты прямо поверх видеопотока.

Целью данной работы является теоретическая разработка архитектуры и описание реализации мобильного приложения, способного подключаться к удаленному видеопотоку, выполняющего детекцию и классификацию объектов (с акцентом на "человек" и "домашнее животное") непосредственно на устройстве и визуализирующего результаты поверх видео.

Функциональные требования:

Подключение к удаленной камере по стандартным сетевым протоколам (например, RTSP, HTTP).

Декодирование видеопотока в реальном времени.

Выполнение детекции и классификации объектов в каждом кадре с использованием локальной нейронной сети.

Визуализация результатов: наложение ограничивающих рамок (bounding box) и текстовых меток с названием класса и вероятностью для

объектов категорий "человек" и "домашнее животное".

Обеспечение плавного отображения видео с частотой не менее 15 кадров в секунду.

Нефункциональные требования:

Производительность: Низкая задержка обработки кадра (<70 мс для обеспечения ~15 FPS).

Кроссплатформенность: Возможность запуска на iOS и Android.

Архитектура приложения состоит из трех основных модулей, работающих в конвейере:

Модуль сетевого подключения и декодирования: Отвечает за подключение к видеопотоку камеры (например, по URL `rtsp://...`) и его декодирование в последовательность кадров в формате, пригодном для обработки.

Модуль компьютерного зрения: Принимает кадры от модуля декодирования, выполняет предобработку (ресайз, нормализация) и передает в нейронную сеть для детекции объектов. После получения результатов выполняет постобработку (фильтрация по порогу уверенности, Non-Maximum Suppression).

Модуль визуализации и интерфейса: Отображает декодированный видеопоток на экране устройства и поверх него рисует результаты работы модуля компьютерного зрения – bounding box и текстовые метки.

Для охвата максимальной аудитории была выбрана кроссплатформенная технология Flutter (Dart). Она позволяет использовать единую кодобазу для iOS и Android и предоставляет богатые возможности для создания пользовательского интерфейса.

Прямая работа с сетевыми видеопотоками в Flutter нетривиальна. Для этого используется плагин `fijkplayer` или `video_player` в связке с собственным декодером. `Fijkplayer`, основанный на мощной мультимедийной библиотеке `FFmpeg`, идеально подходит для задач, так как поддерживает множество форматов и протоколов, включая критически важный RTSP.

Принцип работы: Приложение получает от пользователя URL видеопотока. Плеер инициализируется, подключается к камере и начинает декодировать видео. Для доступа к сырым кадрам видео используется механизм `Texture`, который позволяет получать кадры в виде буфера пикселей.

Для детекции объектов была выбрана сверточная нейронная сеть YOLOv8n (YOLO Version 8 Nano). Ее преимущества:

Высокая скорость: Одна из самых быстрых моделей для детекции.

Достаточная точность: Точности YOLOv8n хватает для надежного распознавания людей и животных в условиях домашней обстановки.

Простота использования: Имеет простой API для инференса и постобработки.

Процесс интеграции:

Экспорт модели: Предобученная модель YOLOv8n (на датасете COCO, включающем классы "person" и "cat"/"dog") экспортируется в формат

TensorFlow Lite (TFLite). Это формат, оптимизированный для выполнения на мобильных и embedded-устройствах.

Квантование: Модель подвергается квантованию INT8, что значительно уменьшает ее размер и ускоряет работу с минимальной потерей точности.

Интеграция в приложение: В проект Flutter добавляется плагин `tflite_flutter`. Модель `yolov8n_int8.tflite` помещается в `assets` приложения.

Рабочий цикл:

Кадр от видеоплеера захватывается и преобразуется в тензор (например, размером 320x320 пикселей).

Тензор передается на вход интерпретатору TFLite.

На выходе получается тензор с координатами `bounding box`, идентификаторами классов и уверенностью детекции.

Результаты фильтруются: отбрасываются детекции с уверенностью ниже 0.6-0.7. Для классов оставляются только "person" (человек) и, например, "cat" и "dog" (объединяются под меткой "Домашнее животное").

Визуализация осуществляется с помощью кастомной `CustomPainter` в Flutter, которая рисует поверх виджета видеоплеера.

Принцип работы: Для каждого обнаруженного объекта из модуля компьютерного зрения:

Рассчитываются реальные координаты `bounding box` на экране устройства, исходя из исходного разрешения кадра и текущего размера окна видеоплеера.

Рисуется прямоугольник (`canvas.drawRect`) заданного цвета (например, зеленый для человека, синий для животного).

Сверху над прямоугольником рисуется подложка и текстовая метка (`canvas.drawParagraph`), содержащая название класса и процент уверенности (например, "Человек 92%")

Приложение успешно подключается к RTSP-поток. При появлении в кадре человека или домашнего животного (кошки, собаки) на видео в реальном времени рисуется цветная рамка вокруг объекта и текстовая метка. Система корректно игнорирует другие движущиеся объекты (например, машины за окном, если они не входят в целевые классы).

В статье представлено теоретическое решение для удаленного просмотра видео с интерактивной детекцией объектов. Использование кроссплатформенного фреймворка Flutter в сочетании с оптимизированной нейронной сетью YOLO и мультимедийной библиотекой FFmpeg позволяет создать производительное приложение, не зависящее от облачных сервисов.

Ключевые преимущества подхода:

Конфиденциальность: Видео анализируется локально на телефоне пользователя и никуда не передается.

Низкая задержка: Отсутствует время на передачу кадров в облако и обратно.

Универсальность: Приложение может работать с любой камерой, поддерживающей стандартные протоколы потоковой передачи.

Направления для дальнейшего развития:

Добавление возможности кастомизации целевых классов.

Внедрение трекинга объектов для стабильности bounding box между кадрами. Обучение модели на специализированном датасете для более точного распознавания объектов.

СПИСОК ЛИТЕРАТУРЫ

1. Jocher, G., et al. Ultralytics YOLOv8 [Электронный ресурс]. – 2023. – Режим доступа: <https://docs.ultralytics.com/> (дата обращения: 15.09.2025).
2. TensorFlow Lite Guide: Optimization for Mobile [Электронный ресурс]. – Режим доступа: <https://www.tensorflow.org/lite/performance> (дата обращения: 17.09.2025).
3. Flutter Documentation [Электронный ресурс]. – Режим доступа: <https://flutter.dev/docs> (дата обращения: 15.09.2025).
4. FFmpeg Official Website [Электронный ресурс]. – Режим доступа: <https://ffmpeg.org/> (дата обращения: 17.09.2025).
5. Lin, T.-Y., Maire, M., Belongie, S., et al. Microsoft COCO: Common Objects in Context // Computer Vision – ECCV 2014. – 2014. (дата обращения: 19.09.2025).
6. Redmon, J., Divvala, S., Girshick, R., Farhadi, A. You Only Look Once: Unified, Real-Time Object Detection // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). – 2016. (дата обращения: 19.09.2025).

РАЗРАБОТКА И СРАВНЕНИЕ МЕТОДОВ КЛАССИФИКАЦИИ РЕКУРРЕНТНЫХ ИНЦИДЕНТОВ ДЛЯ АВТОНОМНОГО ИИ АГЕНТА

В.А Дорошенко

Кубанский государственный университет

Анализ инцидентов ИИ агента, классификация факторов, влияющих на поведение ИИ агента, исследование причин возникновения инцидентов, связанных с ИИ агентами.

Ключевые слова: инцидент, ИИ агент, концептуальные факторы, системные факторы, когнитивные факторы.

Analysis of AI agent incidents, classification of factors influencing AI agent behavior, and study of the causes of incidents involving AI agents

Key words: incident, AI agent, conceptual factors, systemic factors, cognitive factors.

По мере того как агенты ИИ будут внедряться все шире, мы, вероятно, станем свидетелями увеличения числа инцидентов: событий, связанных с использованием агентов ИИ, которые прямо или косвенно наносят ущерб.

Например, агенты могут быть оперативно внедрены для сбора личной информации или совершения несанкционированных покупок. Структурированная информация о таких инцидентах (например, пользовательские запросы) может помочь нам понять их причины и предотвратить повторение в будущем. Однако существующих процессов создания отчетов об инцидентах недостаточно для понимания инцидентов агентов. В частности, такие процессы в значительной степени основаны на общедоступных данных, которые исключается полезная, но потенциально конфиденциальная информация, такая как логический ход агента или история посещений браузера. Для разработки новых процессов отчетности об инцидентах можно предложить систему анализа инцидентов для агентов. Основываясь на подходах к системной безопасности, структура предлагает три типа факторов, которые могут вызывать инциденты: связанные с системой (например, обучающие данные CBRN), контекстуальные (например, быстрые инъекции) и когнитивные (например, неправильное понимание запроса пользователя). Также надо выявлять конкретную информацию, которая могла бы помочь прояснить какие факторы имеют отношение к данному инциденту: журналы действий, системная документация и доступ к ней, а также информация об инструментах, используемых агентом. По мере того, как мы переходим к миру с большим количеством агентов, понимание инцидентов с агентами будет становиться все более важным для управления рисками.

ОЭСР дает следующее определение инцидента с ИИ: “Инцидент с ИИ - это событие, обстоятельство или серия событий, при которых разработка, использование или сбой в работе одной или нескольких систем ИИ прямо или косвенно приводят к любому из следующих видов ущерба: травма или вред здоровью человека или группы людей; нарушение управления и функционирование критически важной инфраструктуры; нарушения прав человека или обязательств по применимому законодательству, направленных на защиту основных прав, трудовых прав и прав интеллектуальной собственности; причинение вреда имуществу, сообществам или окружающей среде [1]. Инциденты с ИИ-агентами могут быть вызваны множеством факторов. Фреймворк должен рассматривать три взаимодополняющие категории факторов инцидентов: системные факторы, контекстуальные факторы и когнитивные ошибки. Системные факторы - это варианты проектирования и разработки, которые способствуют возникновению опасностей и инцидент. Как и другие методы, основанные на человеческом факторе, система также учитывает контекстуальные факторы при оценке инцидентов, такие как инструменты, доступные агенту. Наконец, категория когнитивных ошибок опирается на когнитивную науку, чтобы описать, как недостатки в когнитивных функциях, таких как понимание информации и принятие решений, могут привести к тому, что агент не сможет достичь намеченной задачи. Когнитивные ошибки являются наиболее распространенными. непосредственно связаны с инцидентом, но возникают из-за системных и контекстуальных факторов. Факторы из разных категорий

предлагают дополнительные точки зрения на сбой. Например, рассмотрим запрос внедрение, в результате которого агент отправляет конфиденциальную пользовательскую информацию третьей стороне. Системным фактором может быть недостаточная очистка входных данных, а контекстуальными факторами могут быть веб-страницы с вредоносным текстом, которые препятствуют достижению целей агента. Кроме того, категории указывают на альтернативные варианты корректирующих действий, доступные различным заинтересованным сторонам. Улучшенная обработка входных данных может дополнять меры по изменению контекста, такие как блокирование доступа агентов искусственного интеллекта к веб-сайтам, которые, как известно, содержат вредоносный текст. Грань между системными и контекстуальными факторами иногда может быть размыта. Например, функция вознаграждения ИИ-агента является частью самой системы, но при этом она кодирует цель, определенную контекстом задачи. В таких случаях фактор может быть классифицирован как системный или контекстуальный (или и то, и другое) в зависимости от аналитической точки зрения. Главное – отнести фактор к той категории, которая в наибольшей степени помогает определить соответствующие меры вмешательства. Например, неправильное определение сигнала о вознаграждении может быть устранено путем изменения функции вознаграждения агента (системы корректировки) или путем уточнения способа передачи целей задачи (корректировка контекста).

Системные факторы – это проблемы, связанные с разработкой ИИ-агента и его статическими аспектами, то есть такие, которые остаются неизменными в разных условиях использования. Например, неправильно заданные модели вознаграждения в процессе обучения или ошибки в системных запросах могут способствовать сбоям у ИИ-агентов и стать причиной инцидентов.

Так, 25 апреля 2025 года компания OpenAI выпустила обновление для своей модели GPT-4o, в результате которого модель стала «чрезмерно лестной и чрезмерно приятной» – то есть её часто стали называть «льстивой» [2]. В OpenAI предположили, что этот сбой связан с внедрением нескольких улучшений, направленных на лучший учёт отзывов пользователей, использование памяти и обновление данных. При этом сама причина инцидента оставалась неясной: компания отметила, что изменения в тренировочной практике, которые по отдельности казались полезными, в совокупности, возможно, привели к смещению модели в сторону подхалимажа.

Действительно, наше научное понимание того, как некоторые системные факторы влияют на появление проблемных моделей поведения ИИ, пока остаётся неполным. Изучение и проверка гипотез о том, как именно системные факторы приводят к инцидентам – например, через анализ первопричин «льстивого» поведения GPT-4o – помогут повысить качество нашего понимания этих процессов [3].

Можно выделить четыре категории системных факторов. Эти категории не являются исчерпывающими. Скорее, можно описывать системные факторы, которые, вероятно, наиболее важны для понимания причин инцидентов, связанных с современными агентами искусственного интеллекта. Процессы отчетности об инцидентах могут включать более полный список вероятных системных факторов (например, архитектура, гиперпараметры и т.д.), позволяющий репортерам или исследователям выявлять новые системные факторы. Две из выделенных категорий связаны с обучением: данные об обучении и обратной связи и методы обучения (например, RLHF). С внедрением связаны две дополнительные категории системных факторов: системные подсказки и строительные леса.

Данные об обучении и обратной связи могут способствовать возникновению инцидентов. Системы искусственного интеллекта могут давать сбои, например, из-за неправильных данных об обучении, нерепрезентативных данных или ложных и вводящих в заблуждение данных. Учебные данные могут также включать информацию, позволяющую установить личность, информацию двойного назначения (например, о конструкции биологического оружия), которая позволяет использовать ее злонамеренно, или другую чувствительную и/или конфиденциальную информацию. Например, было обнаружено, что одна из GPT-моделей OpenAI смогла воспроизвести многие статьи, защищенные авторским правом, благодаря тому, что была обучена работе с ними. Обратная связь с человеком или искусственным интеллектом также часто используется в процессе обучения (например, RLHF), что может привести к инцидентам [4]. Обратная связь может непреднамеренно усилить нежелательное поведение. Например, пользователи могут оставлять положительные отзывы о результатах работы ИИ, которые являются скорее приятными, чем правильными, тем самым поощряя манипулирование или подхалимаж. Обратная связь также может привести к тому, что модели примут неправильные решения. Например, разработчики могут предоставлять положительные отзывы, когда агенты демонстрируют безвредность, отказываясь выполнять вредоносные запросы. Однако такая обратная связь может привести к чрезмерному количеству отказов, снижая готовность агентов помогать.

Контекстуальные факторы зависят от развертывания или среды условия, которые могут привести к сбоям. Например, предположим, что агент службы поддержки клиентов предлагает персонализированные консультации и помощь пользователям, просматривая историю их заказов с помощью API. Агент обычно предоставляет точные рекомендации. Однако, поскольку ограничения по тарифам иногда не позволяют ему получить доступ к истории заказов, вместо этого он иногда предлагает общие рекомендации. Можно выделить три категории контекстуальных факторов: определение задачи, инструменты и информация. Характеристики задачи могут затруднить ее надлежащее выполнение для агента. Например, намерения пользователя могут быть неясны из запроса. некоторые подсказки могут быть интерпретированы

субъективно (например, “составьте краткое резюме”) в то время как другие более объективны (например, “составьте краткое изложение из трех предложений”) [5]. Кроме того, у агента могут быть ограниченные ресурсы для выполнения задач, такие как ограниченный бюджет вычислений, ограниченные финансовые ресурсы или бюджет времени и/или токенов. Агенты с большим временем тестирования действительно могут демонстрировать более высокую производительность при выполнении задач, используя такие методы, как многократные попытки, целенаправленный поиск или дополнительные рассуждения. Однако, если агенту поручают выполнить задание, противоречащее другим задачам, целям или желаемому поведению, это может привести к нежелательному согласованию конкурирующих инструкций. Например, агент, назначенный на работу в автосалоне с системным заданием «вы – бот-продавец автомобилей», может всё же выполнить запрос пользователя, не связанный с этой задачей. Уоллес и соавторы предлагают концепцию «иерархий инструкций», в рамках которой модели обязаны отдавать приоритет определённым типам инструкций (например, системным подсказкам) над другими (такими как пользовательские вводы или ввод инструментов).

Когнитивные ошибки - это недостатки или сбои в работе ИИ-агента, приводящие к невозможности выполнения поставленной задачи. Оба из перечисленных ниже случая связаны с неправильным выполнением когнитивных функций:

Неадекватное выполнение задачи, например, из-за пропуска или неправильной интерпретации важной информации.

Выполнение непреднамеренной или нежелательной задачи, например, агент искусственного интеллекта, который пытается манипулировать пользователем, чтобы тот купил продукт, вместо того чтобы идентифицировать продукт, удовлетворяющий его потребностям, мы предлагаем сгруппировать когнитивные ошибки в четыре категории, которые соответствуют различным когнитивным функциям, которые агент может не выполнять должным образом:

Наблюдение: агенту не удастся обнаружить или уделить должное внимание входным данным.

Понимание: агенту не удастся определить значимость входных данных по отношению к задаче и другим входным данным.

Принятие решений: агенту не удастся должным образом рассмотреть, оценить и выбрать один из возможных вариантов действий для достижения цели.

Выполнение действия: агент неправильно выполняет ряд действий для достижения цели.

Важно подчеркнуть, что когнитивные ошибки - это заметные недостатки в выводах или поведении ИИ-агента. Агенты искусственного интеллекта не обладают когнитивными способностями, подобными человеческим. Когнитивные ошибки - это аналитическая категория: они выдвигают гипотезы

и помогают охарактеризовать проблемы, связанные с работой агента искусственного интеллекта (например, игнорирование критических входных данных), не подразумевая психическое состояние, подобное человеческому. В качестве примера рассмотрим помощника по программированию с помощью искусственного интеллекта, которому поручено интегрировать платежи Stripe в веб-приложение. Ошибка в наблюдении может заключаться в том, что он не заметил наличия определенной конечной точки в базе кода, что заставляет агента планировать создание дублирующего маршрута. Сбой в понимании может быть связан с непониманием того, что подразумевают планы подписки, что приводит к неспособности агента осознать, что ему необходимо написать код для автоматического выставления счетов постоянным клиентам. Сбой в принятии решения может быть связан с созданием агентом пользовательской формы для сбора информации о карте, вместо того чтобы полагаться на существующие элементы Stripe, которые представляют меньший риск для безопасности. Сбой при выполнении действия может произойти, если агенту не удастся добавить соответствующую обработку ошибок при реализации своего кода. Когнитивные ошибки могут быть полезны для объяснения нежелательного поведения агентов и выявления закономерностей в инцидентах. Например, рассмотрим, как кодирование подсказок в base-64 может заставить некоторые системы искусственного интеллекта выполнять вредоносные запросы, которые они обычно отклоняют. Мы можем охарактеризовать это как сбой в понимании: система искусственного интеллекта не может распознать информацию, закодированную в base64, как вредоносный запрос. Более того, могут проявиться закономерности сходных сбоев в понимании, когда модели не могут последовательно рассуждать, когда подсказки семантически эквивалентны, но внешне отличаются. Многоязычные оценки моделей показывают, что модели могут успешно справляться с определенными задачами, когда они представлены на английском языке, но терпят неудачу, когда эти задачи представлены на других языках. Известные примеры подобных сбоев могут помочь определить, когда задачи могут быть особенно сложными для агентов искусственного интеллекта. Этот метод объяснения может быть особенно полезен, когда системы искусственного интеллекта создают логические цепочки. Например, логическая цепочка может включать ложные предположения или явные утверждения о нежелательных целях или планах. Действительно, модели OpenAI рассуждали о взломе вознаграждений в своей цепочке рассуждений, прежде чем заняться этим. Одно из ограничений заключается в том, что это явное рассуждение не всегда соответствует фактическому рассуждению, с помощью которого модель производит свои конечные результаты и действия.

Агенты с искусственным интеллектом неизбежно будут участвовать в реальных инцидентах. Надо подчеркнуть важность всесторонних и зависящих от контекста данных для выявления многоэтапных причинно-следственных связей, которые приводят к возникновению инцидентов. Инциденты могут возникать из-за выбора дизайна системы, влияния контекста и когнитивных

требований предполагаемой задачи. Информация будет ключевой для понимания причинно-следственных факторов: журналы действий, системная документация и доступ, а также инструмент информация. Основываясь на этих категориях информации, можно сказать: что следует включать в отчеты об инцидентах и какую информацию разработчики и разработчики по внедрению должны сохранять и предоставлять следователям по расследованию инцидентов. Сочетая тщательный сбор и анализ данных с четкими нормативными сигналами и механизмами общественной подотчетности, можно повысить нашу способность извлекать уроки из ошибок агентов искусственного интеллекта и предотвращать ущерб в будущем.

СПИСОК ЛИТЕРАТУРЫ

1. System Card: Claude Opus 4 & Claude Sonnet 4. <https://www-cdn.anthropic.com/6be99a52cb68eb70eb9572b4cafad13df32ed995.pdf>. (Дата обращения 13.09.2025)
2. System Prompts. <https://docs.anthropic.com/en/release-notes/system-prompt>. (Дата обращения 16.09.2025)
3. Bai, Y.; Kadavath, S.; Kundu, S.; Askell, A.; Kernion, J.; Jones, A.; Chen, A.; Goldie, A.; Mirhoseini, A.; McKinnon, C.; Chen, C.; Olsson, C.; Olah, C.; Hernandez, D.; Drain, D.; Ganguli, D.; Li, D.; Tran-Johnson, E.; Perez, E.; Kerr, J.; Mueller, J.; Ladish, J.; Landau, J.; Ndousse, K.; Lukosuite, K.; Lovitt, L.; Sellitto, M.; Elhage, N.; Schiefer, N.; Mercado, N.; DasSarma, N.; Lasenby, R.; Larson, R.; Ringer, S.; Johnston, S.; Kravec, S.; Showk, S. E.; Fort, S.; Lanham, T.; Telleen-Lawton, T.; Conerly, T.; Henighan, T.; Hume, T.; Bowman, S. R.; Hatfield-Dodds, Z.; Mann, B.; Amodei, D.; Joseph, N.; McCandlish, S.; Brown, T.; and Kaplan, J. 2022. Constitutional AI: Harmlessness from AI Feedback. arXiv:2212.08073.
4. Beurer-Kellner, L.; and Fischer, . Introducing MCP-Scan: Protecting MCP with Invariant. <https://invariantlabs.ai/blog/introducing-mcp-scan> (Дата обращения 20.09.2025)
5. Beurer-Kellner, L.; and Fischer, M. 2025b. MCP Security Notification: Tool Poisoning Attacks. <https://invariantlabs.ai/blog/mcp-security-notification-tool-poisoning-attacks>. (Дата обращения 24.09.2025)

МОДЕРНИЗАЦИЯ СОВЕТСКИХ СТАНКОВ С ЧПУ ПО PUMOTIX

Н.В. Жук

Кубанский государственный университет

Статья посвящена анализу целесообразности и практическим аспектам модернизации советских станков с ЧПУ на базе российской платформы PUMOTIX. Рассматриваются экономические и технические

преимущества ретрофита, а также предлагается пошаговое руководство по его реализации. Использование системы PUMOTIX позволяет значительно повысить точность, производительность и функциональность устаревшего оборудования.

Ключевые слова: модернизация станков с ЧПУ, советские станки, ретрофит оборудования, система PUMOTIX, стойка ЧПУ, система ЧПУ, сервоприводы, шаговые двигатели, приводные системы, замена электроники, модернизация кинематики, настройка контуров управления, постпроцессор, программирование G code, интеграция с CAD CAM, повышение точности обработки, повышение надежности, промышленная автоматизация.

The article analyzes the feasibility and practical aspects of modernizing Soviet CNC machines using the Russian PUMOTIX platform. It examines the economic and technical benefits of retrofitting and provides a step-by-step implementation guide. The use of the PUMOTIX system significantly enhances the accuracy, productivity, and functionality of obsolete equipment.

Key words: CNC machine modernization, Soviet CNC machines, equipment retrofit, PUMOTIX system, CNC controller, numerical control system, servo drives, stepper motors, drive systems, electronics replacement, kinematics upgrade, control loop tuning, postprocessor, G code programming, CAD CAM integration, machining accuracy improvement, reliability improvement, industrial automation.

CNC или ЧПУ –это сокращение от английского Computer Numerical Control, которое переводится как «числовое программное управление». Технология позволяет управлять работой станков с помощью компьютерной программы, основанной на уникальном языке программирования –G-code. Это своеобразный язык общения между станком и оператором ПК, который также используется многими моделями 3D-принтеров для управления процессом печати.



Рисунок 1– Токарно-фрезерный станок с ЧПУ

Сегодня оборудование ЧПУ широко применяется в самых различных отраслях производства: от электроники и мебельной промышленности до производства сложных авиационных и космических систем, –везде, где точность и надежность являются критически важными параметрами.

Наибольшее распространение оборудование с CNC получило в следующих областях:

Металлообработка. CNC технологии незаменимы при изготовлении технически сложных и высокоточных изделий из металла. Детали насосов, винтовых компрессоров, шлицевых валов, червячных и зубчатых передач машин –любой из этих компонентов сложно представить без использования высокоточных программ.

Аэрокосмическая промышленность. Как принято говорить в аэрокосмической отрасли: «В космосе нет ремонтных мастерских». Поэтому качество и надёжность является первостепенными для любой авиатехники. Изготовление профилей сложных форм, деталей шасси и самолетных двигателей, а также других деталей становится рядовой задачей только благодаря компьютеризированному оборудованию.

Здравоохранение. Любое высокотехнологичное оборудование сферы здравоохранения также требует прецизионной обработки. Костные винты и пластины, хирургические инструменты, держатели, зажимы, импланты из

титана, стоматологическое оборудование – все это требует современного подхода в обработке. Современные устройства с CNC способны обрабатывать практически любые материалы, включая титан и керамику.

Автомобилестроение. Автомобильная промышленность является еще одним крупным сектором для компьютеризированной обработки. К этой группе относятся всевозможные детали машин: поршни и цилиндры двигателей, коробки передач, клапаны, блоки цилиндров, элементы приборной панели.

Деревообработка и мебельное производство. CNC-оборудование является незаменимым инструментом в деревообрабатывающей промышленности, так как позволяет наносить на поверхность деревянных изделий узоры любой сложности, выполнять фигурную резку, а также в больших объемах производить элементы корпусной мебели. Значительную часть парка металлообрабатывающего оборудования на предприятиях России и СНГ до сих пор составляют советские станки с ЧПУ. Несмотря на сохранившийся ресурс механической части, их системы управления («Электроника НЦ-31», «Размер-2М» и др.) морально и физически устарели. Это приводит к частым отказам, дефициту запчастей, низкой производительности и необходимости поиска редких специалистов.

Использование оборудования с ПУ на предприятии и в бизнесе имеет множество преимуществ по сравнению с традиционным оборудованием. Во-первых, компьютер обеспечивает более высокую точность изделий. Прецизионная обработка увеличивает качество продукции, снижает количество отходов и обеспечивает высокую производительность.

Оборудование с программным управлением позволяет сократить затраты на рабочую силу, так как многие операции могут быть автоматизированы. Станок не уходит в отпуск и не прогуливает. У него не бывает низкой мотивации или плохого настроения. Наконец, оборудование с ПУ обеспечивает более безопасную работу поскольку операторам не приходится находиться в непосредственной близости от рабочей зоны.

К особенностям станков с числовым программным управлением можно отнести следующие:

Быстрая смена инструмента. Большинство современных станков с ПУ оснащены системой автоматической смены режущих инструментов. Оператору не нужно самому менять инструмент и оснастку – за это здесь отвечает компьютерная программа, заложенная в логику работы оборудования.

Гибкость и возможность быстрой настройки. Станки с ПУ могут быстро переключаться между различными операциями и материалами, что позволяет производить различные виды продукции на одном станке.

Возможность создания сложных геометрических форм. Оборудование с ПУ позволяет создавать изделия сложных геометрических форм, которые сложно или даже невозможно создать с помощью традиционного оборудования.

Уменьшение затрат на трудовые ресурсы. Автоматический процесс обработки на станках с ПУ позволяет уменьшить затраты на трудовые ресурсы, так как не требует постоянного присутствия оператора.

Возможность интеграции с другими системами автоматизации производства. Станки с программным управлением могут быть интегрированы с другими системами автоматизации производства, что позволяет создать единый управляющий центр для производства.

В условиях санкционного давления и ограниченного финансирования полная замена станков часто экономически нецелесообразна. Стратегической альтернативой становится глубокая модернизация (ретрофит), позволяющая в 2-3 раза дешевле приобретения нового оборудования восстановить и значительно улучшить его характеристики.

Ключевым элементом успешного ретрофита является выбор современной системы ЧПУ. Российская платформа PUMOTIX предлагает гибкое и эффективное решение для этой задачи. Ее открытая архитектура, модульность и соответствие современным стандартам позволяют не только заменить устаревшую электронику, но и кардинально повысить точность, производительность и функциональность станков. Цель статьи – проанализировать процесс модернизации советских станков с ЧПУ на платформе PUMOTIX, рассмотреть ее преимущества и предложить практические рекомендации по реализации таких проектов.

Стоимость нового станка сопоставимого класса может в 5-10 раз превышать стоимость комплексной модернизации. При этом капитальные затраты включают не только цену оборудования, но и затраты на фундамент, подвод коммуникаций, обучение персонала. Модернизация позволяет:

Значительно сэкономить средства, направив их на другие нужды предприятия.

Растянуть инвестиции во времени, проводя модернизацию поэтапно.

Сохранить и модернизировать парк, не останавливая производство полностью.

Исследования показывают, что срок окупаемости проекта модернизации на базе систем типа PUMOTIX обычно составляет от 6 до 18 месяцев, в зависимости от сложности станка и объема работ.

Как уже отмечалось, механическая основа советских станков (станина, суппорты, шпиндельные бабки, направляющие) часто обладает высоким запасом прочности. Замена или восстановление ключевых механических компонентов (например, шарико-винтовых пар (ШВП) вместо изношенных ходовых винтов, установка новых направляющих скольжения или качения) в сочетании с установкой современной системы управления позволяет получить оборудование, по точности и производительности не уступающее новым моделям эконом-класса.

PUMOTIX – программное обеспечение нового поколения для управления станком с ЧПУ, имеет интуитивно-понятный русскоязычный интерфейс.




Рисунок 2 – Интерфейс ПО PUMOTIX

Шаговые приводы: Бюджетный вариант для легких режимов резания (например, Leadshine).

Выбор двигателей: Подбираются по моменту и скорости, часто используются двигатели от старых приводов, если они соответствуют требованиям.

Замена механики: При необходимости производится замена ходовых винтов на ШВП, восстановление направляющих.

Проектирование шкафа управления: Разработка новой схемы электрических соединений, подбор силовых компонентов (автоматы, контакторы, реле), монтажной панели.

Преимущества PUMOTIX для модернизации

Открытость и гибкость: Система не привязана к конкретному производителю оборудования или приводов. Инженер может выбрать оптимальную конфигурацию механики и силовой электроники.

Поддержка современного оборудования: Работа с современными интерфейсами (EtherCAT, CANopen, PROFINET) позволяет использовать лучшие мировые комплектующие, а также совместима с российскими аналогами.

Соответствие современным стандартам: Поддержка стандартного языка программирования УП по ISO 7-bit (G-коды), а также современных протоколов (например, OPC UA) для интеграции в системы MES и «Цифровую фабрику».

Российское происхождение: Актуально в условиях импортозамещения, снижает риски санкционных ограничений и обеспечивает техническую поддержку внутри страны.

Мощный встроенный ПЛК: Позволяет гибко перепрограммировать всю логику работы станка, заменяя собой релейно-контактные схемы и специализированные блоки старого ЧПУ.

Процесс модернизации можно разбить на несколько последовательных

этапов.

3.1. Этап 1: Диагностика и проектирование

Обследование станка: Тщательный осмотр механической части – оценка износа направляющих, ШВП/ходовых винтов, подшипников шпинделя, зубчатых передач.

Анализ старой электроавтоматики: Составление реестра всех исполнительных механизмов (силовые цилиндры, электромагнитные муфты, двигатели) и датчиков (конечные выключатели, датчики положения инструмента и т.д.).

Формирование Технического Задания (ТЗ): На основе диагностики определяется объем работ:

Что будет заменено (например, приводы осей).

Что будет оставлено и подключено к новой системе (например, главный привод шпинделя через частотный преобразователь).

Какие новые функции необходимо добавить (например, автоматический смазочный насос с контролем давления).

3.2. Этап 2: Подбор комплектующих

На этом этапе формируется окончательная конфигурация системы PUMOTIX:

Выбор контроллера: Модель и производительность вычислительного блока.

Выбор приводов:

Сервоприводы: Рекомендуются для большинства задач (например, Delta ASDA-B3, Beckhoff AX5000 или российские аналоги). Требуют установки энкодеров.

Этот подход позволяет в сжатые сроки и при ограниченном бюджете получить оборудование, отвечающее вызовам современного рынка.

Гибкость, открытость и мощный функционал PUMOTIX делают ее идеальным инструментом для решения задач ретрофита. Она позволяет не только восстановить работоспособность станка, но и кардинально повысить его технологические возможности, интегрировать в цифровую среду предприятия и обеспечить надежную работу на годы вперед. В условиях необходимости развития собственного станкостроения и импортозамещения, массовая модернизация существующего парка на отечественных системах управления представляется одним из наиболее рациональных и эффективных путей развития промышленности.

СПИСОК ЛИТЕРАТУРЫ

1. Иванов, А. В. Экономическая эффективность модернизации металлорежущего оборудования на машиностроительном предприятии // Вестник машиностроения. – 2021. – № 5. – С. 45-49.

2. Петров, С. К. Техническое перевооружение станочного парка: модернизация vs замена // Станки и инструмент. – 2020. – № 3. – С. 12-17.

3. Официальный сайт компании «PUMOTIX». [Электронный ресурс]. – URL: <https://pumotix.ru/> (дата обращения: 15.10.2023).

4. Кейс внедрения: «Модернизация токарного станка с ЧПУ 16K20Ф3 на системе PUMOTIX». // Технический отчёт инжиниринговой компании «Станко-Интегратор». – 2022.

5. Сидоров, Н. М. Практический опыт модернизации фрезерного станка 6P13Ф3 с установкой ЧПУ PUMOTIX // Автоматизация в промышленности. – 2022. – № 8. – С. 28-33.

6. Аналитический обзор. Сравнительные характеристики станков до и после модернизации. // Журнал «Технологии в электронной промышленности». – 2019. – № 4. – С. 56-61.

7. Громов, В. И. Особенности программирования ПЛК в системах ЧПУ при модернизации специализированных станков // Программируемые контроллеры. – 2021. – № 2. – С. 22-26.

РАЗРАБОТКА FRONTEND И BACKEND ЧАСТЕЙ РЕГИСТРАЦИИ ПОЛЬЗОВАТЕЛЕЙ В ВЕБ- ПРИЛОЖЕНИИ

В.Д. Загребнова

Кубанский государственный университет

Статья посвящена практическим аспектам полного цикла разработки веб-приложения на примере создания формы регистрации. Рассматривается реализация как серверной (backend), так и клиентской (frontend) частей проекта. В качестве технологического стека используются фреймворк FastAPI и библиотека SQLAlchemy для Python на стороне backend и библиотека React.js для frontend.

Ключевые слова: регистрация пользователей, веб приложение, frontend разработка, backend разработка, форма регистрации, валидация данных, клиентская валидация, серверная валидация, аутентификация, авторизация, хэширование паролей, JSON Web Token, сессии и куки, REST API, обработка ошибок, UX формы регистрации, безопасность веб приложений, защита от SQL инъекций, защита от XSS и CSRF.

The article is devoted to the practical aspects of the full cycle of web application development on the example of creating a registration form. The implementation of both the server (backend) and client (frontend) parts of the project is considered. The FastAPI framework and the SQLAlchemy library for Python on the backend side and the React.js library for the frontend are used as a technological stack.

Key words: user registration, web application, frontend development, backend development, registration form, data validation, client side validation, server side validation, authentication, authorization, password hashing, JSON Web

Token, sessions and cookies, REST API, error handling, registration form UX, web application security, SQL injection protection, XSS and CSRF protection.

Первый и фундаментальный этап разработки – создание модели данных и организация взаимодействия с базой данных.

Для обеспечения взаимодействия приложения с СУБД PostgreSQL используется библиотека SQLAlchemy – мощный инструмент ORM (Object-Relational Mapping) для Python. ORM позволяет работать с базой данных как с набором Python-объектов, абстрагируясь от прямого написания SQL-запросов. [1] Для подключения к БД необходимо прописать создание сессии и БД (листинг 1).

```
from sqlalchemy import create_engine

from sqlalchemy.ext.declarative import declarative_base from sqlalchemy.orm import
sessionmaker
engine =
create_engine( url="postgresql://{логин}:{пароль}@localhost
:{порт}/{имя БД}")

session_local = sessionmaker(bind=engine, autoflush=False, autocommit=False)
Base = declarative_base()
```

Листинг 1 – Создание сессии и базы данных

`create_engine`: Создает «движок» – интерфейс подключения к базе данных. В параметре `url` передается строка подключения, содержащая логин, пароль, адрес сервера и имя базы данных.

`sessionmaker`: Фабрика для создания сессий. Сессия представляет собой временную зону взаимодействия с БД, в которой отслеживаются изменения объектов.

`declarative_base()`: Базовый класс для всех моделей (таблиц). От этого класса будут наследоваться все классы, описывающие структуру таблиц.

Модели – это Python-классы, которые наследуются от `Base` и описывают структуру таблиц в базе данных (листинг 2).

```
from sqlalchemy.orm import Mapped, mapped_column from sqlalchemy import String,
ForeignKey from src.backend.database import Base class User(Base):
    _____tablename_ = "users"

    id: Mapped[int] = mapped_column(primary_key=True) email: Mapped[str] =
mapped_column(String(50)) password: Mapped[str] = mapped_column(String(50)) name:
Mapped[str] = mapped_column(String(50))
```

Листинг 2 – Пример модели

Для физического создания таблиц в базе данных в главном файле инициализации FastAPI выполняется команда `Base.metadata.create_all(bind = engine)`.

При старте приложения эта строка кода проверяет существование таблиц и создает их, если они отсутствуют.

Клиентская часть приложения построена на React.js – популярной библиотеке для создания динамических пользовательских интерфейсов. [2] Основной принцип – компонентный подход, который позволяет разбивать интерфейс на переиспользуемые и изолированные части (компоненты).

Разработка начинается с создания простых компонентов (листинг 3).

```
export default function Button({ children, onClick }) { return (  
  <button onClick={onClick} className="button">  
  
    {children}  
  
  </button>);}
```

Листинг 3 – Пример компонента Button

Компонент Button принимает два пропса (входных параметра):

`children`: Содержимое кнопки (текст или другие React-элементы), которое передается между открывающим и закрывающим тегами.

`onClick`: Функция-обработчик события клика.

Этот компонент становится строительным блоком для более сложных элементов, например форма регистрации.

Для управления состоянием форм (вводом данных пользователем) в React используется хук `useState`. [3] Хук возвращает массив из двух элементов: текущего значения состояния и функции для его обновления.

Компонент `UserRegistry` (форма регистрации): Содержит поля для ввода электронной почты, пароля и имени. Для каждого поля создается свое состояние с помощью `useState` (листинг 4). При вводе данных в поле его состояние немедленно обновляется. При отправке формы данные из этих состояний собираются в объект и отправляются на сервер с помощью POST-запроса (листинг 5).

```
const [name, setName] = useState("") const [email, setEmail] = useState("")  
const [password, setPassword] = useState("")const [isUserCreate, setIsUserCreate] =  
useState(false) function handleNameChange(event){setName(event.target.value)}  
function handleEmailChange(event){setEmail(event.target.value)}  
function handlePasswordChange(event){ setPassword(event.target.value)}
```

Листинг 4 – Объявление и изменение состояний формы регистрации

```
const handleSubmit = (e) => { e.preventDefault() const total_amount = 0  
  const user = {email, password, name}
```

```

    axios.post('http://127.0.0.1:8000/users', user).then(r
=> {

        console.log(isUserCreate) setIsUserCreate(true) onChange('registry')
        }).catch(err => {console.log('err: ', err)}))}

```

Листинг 5 – Post-запрос для отправки данных на сервер

Объект `user` содержит информацию о почте, пароле и имени пользователя, которые были введены в форму регистрации. С помощью библиотеки `axios` на серверную часть отправляется `post`-запрос с данными пользователя.

На сервере соответствующий эндпоинт обрабатывает полученные данные и создает новую запись в таблице `users` (листинг 6).

```

@app.post("/users", response_model=UserSchema)

async def makeUser(user: CreateUser, db: Session = Depends(getDB)) -> User:
    db_user = User(email=user.email, password=user.password, name=user.name)
    db.add(db_user) db.commit() return db_user

```

Листинг 6 – Эндпоинт, обрабатывающий `post`-запрос с клиента

На основе полученных данных создается новый элемент модели `User`, и благодаря функциям `SQLAlchemy` (`add`, `commit`) в таблицу `users` добавляется новая запись. [4]

Главный компонент `App` является корневым и управляет общим состоянием приложения (листинг 7). [5]

```

import { useState } from 'react'

import UserRegistry from './components/UserRegistry'
function App() {

    const [isReg, setIsReg] = useState() const [user, setUser] = useState()
    const shouldHideContent = isReg === 'registry'

    <{!shouldHideContent && UserRegistry active={isReg} onChange={(current) =>
setIsReg(current)}/>
        {isReg === 'registry' && <>

            <p                                className="paragraph">Вы
зарегистрировались!                                </p>

        </>
    }

```

Листинг 7 – Структура компонента `App`

Апп хранит информацию о текущем пользователе и активной форме.

В его рендере присутствует условная логика: если пользователь не зарегистрирован, то ему показывается форма регистрации, а если пользователь зарегистрировался, он получит сообщение «Вы зарегистрировались!».

СПИСОК ЛИТЕРАТУРЫ

1. Билл Любанович FastAPI: веб-разработка на Python / Билл Любанович – Санкт-Петербург: Sprint Book, 2024 – 288 с.
2. Стефанов С. React. Быстрый старт / Стефанов С. – Санкт-Петербург: Питер, 2023 – 304 с.
3. Дронов В.А. React 19. Разработка веб-приложений на JavaScript – Санкт-Петербург: БВХ, 2025 – 448 с.
4. FastAPI. Официальный учебный ресурс по FastAPI [Электронный ресурс] – URL: <https://fastapi.tiangolo.com/learn/> (дата обращения: 5.09.2025).
5. Plantagoweb. Интеграция FastAPI и React [Электронный ресурс] – URL: <https://plantagoweb.ru/blog/integratsiya-fastapi-s-frontendom-na-react-vue-nuxt-ili-svelte-8f7c12/> (дата обращения: 12.09.2025).

АВТОНОМНЫЙ ИИ-АГЕНТ ДЛЯ АВТОМАТИЧЕСКОГО РАЗРЕШЕНИЯ РЕКУРРЕНТНЫХ ИНЦИДЕНТОВ

А.П. Ибятков

Кубанский государственный университет

В статье рассматривается концепция автономного интеллектуального агента, предназначенного для автоматического обнаружения и разрешения рекуррентных инцидентов в информационно-технических системах.

Key words: автономный ИИ агент, рекуррентные инциденты, автоматическое разрешение инцидентов, управление инцидентами, интеллектуальная автоматизация, AIOps, самообучающиеся системы, анализ логов, обнаружение аномалий, поиск корневой причины, оркестрация и автоматизация, автоворкфлоу, предиктивная аналитика, отказоустойчивость, сокращение времени простоя.

The article examines the concept of an autonomous intelligent agent designed for the automatic detection and resolution of recurrent incidents in information-technical systems.

Key words: autonomous AI agent, recurrent incidents, automatic incident resolution, incident management, intelligent automation, AIOps, self learning systems, log analysis, anomaly detection, root cause analysis, orchestration and automation, automated workflows, predictive analytics, fault tolerance, downtime reduction.

Рекуррентные инциденты –это повторяющиеся сбои, ошибки или отклонения в работе информационных систем, возникающие с определённой периодичностью или при схожем наборе условий. В отличие от единичных, случайных происшествий, рекуррентные инциденты имеют устойчивый характер и, как правило, обусловлены системными причинами: ошибками в конфигурации, неустойчивыми зависимостями между сервисами, нарушениями в процессах обновления или взаимодействия компонентов. Их особенность заключается в том, что после каждого устранения проблема может проявляться снова –через часы, дни или недели –что создаёт значительную нагрузку на службы технической поддержки и снижает эффективность эксплуатации ИТ-инфраструктуры. Классическим примером рекуррентного инцидента может быть регулярный отказ веб-сервиса при ночном резервном копировании из-за конфликта ресурсов или утечка памяти, приводящая к ежесуточному перезапуску приложения. Такие события часто маскируются под разные внешние проявления, но имеют общую первопричину. Обнаружение и устранение рекуррентных инцидентов требует системного подхода, включающего анализ исторических данных, построение корреляций между событиями, а также применение алгоритмов машинного обучения для выявления скрытых закономерностей. В современных ИТ-средах именно рекуррентные инциденты занимают до 60–70% общего числа обращений в службу поддержки, поэтому их автоматическая идентификация и предотвращение становятся ключевыми задачами при внедрении автономных ИИ-агентов [1].

Современные корпоративные ИТ-инфраструктуры характеризуются высокой степенью сложности, распределённостью и динамичностью. В таких условиях традиционные подходы к мониторингу и поддержанию работоспособности систем становятся недостаточно эффективными. Возрастающий объём инцидентов, особенно повторяющихся (рекуррентных), приводит к увеличению нагрузки на службы технической поддержки, росту времени восстановления сервисов и снижению уровня доступности критических приложений. Решением данной проблемы становится использование автономных ИИ-агентов, способных автоматически анализировать данные наблюдения, выявлять причины повторных сбоев и применять корректирующие действия без участия человека [2].

Создание автономного ИИ-агента требует интеграции нескольких ключевых технологических направлений –машинного обучения, интеллектуального анализа данных, системного мониторинга и когнитивной автоматизации. В отличие от классических систем мониторинга, которые лишь фиксируют факт инцидента и отправляют уведомление оператору, автономный агент выполняет полный цикл обработки события: от обнаружения до устранения и документирования результата. Такой подход позволяет значительно сократить время реакции и минимизировать влияние человеческого фактора на стабильность работы инфраструктуры.

Основная идея автономного ИИ-агента заключается в создании

самоуправляемого программного компонента, способного функционировать по принципу «наблюдай – учись – действуй». На этапе наблюдения агент собирает данные из различных источников – системных логов, метрик производительности, сетевых журналов и внешних API. Эти данные проходят нормализацию и предобработку, после чего поступают в аналитический модуль. Здесь применяются алгоритмы машинного обучения, в частности, методы кластеризации и аномалийного детектирования для выявления типовых шаблонов повторяющихся ошибок [3].

На основе исторических данных агент формирует модель причинно-следственных связей между событиями и их последствиями. Например, обнаружив, что определённая комбинация логов и повышение загрузки процессора с высокой вероятностью предшествуют сбою конкретного сервиса, агент способен прогнозировать инцидент ещё до его возникновения. Для этого используются модели временных рядов и вероятностные графические модели, которые позволяют описывать зависимость состояния системы от множества факторов.

После этапа анализа и прогнозирования агент переходит к стадии принятия решения и действия. Здесь применяется принцип автономного управления, основанный на заранее определённом наборе политик и динамически обучаемых стратегиях. Если агент уверенно классифицирует инцидент как рекуррентный и имеет подтверждённый сценарий успешного разрешения, он инициирует корректирующие действия автоматически. Это может быть перезапуск сервиса, перераспределение ресурсов, очистка временных файлов или изменение конфигурации. Все действия фиксируются в журнале, и при необходимости оператор получает уведомление о выполненной операции.

Особое внимание уделяется вопросам безопасности и контроля над действиями автономного агента. Для предотвращения ошибочных вмешательств используется система уровней доверия и ограничений. На начальных этапах внедрения агент функционирует в режиме «рекомендаций», предлагая оператору решения для подтверждения. По мере накопления опыта и повышения точности предсказаний система переходит к полуавтоматическому и затем полностью автономному режиму. Такой поэтапный переход снижает риск ошибок и позволяет организациям адаптироваться к новому формату эксплуатации ИТ-инфраструктуры.

Одним из ключевых аспектов является способность агента к самообучению. Каждый новый инцидент, независимо от того, был он разрешён автоматически или вручную, используется в качестве обучающего примера. Механизмы обратной связи позволяют агенту уточнять модели поведения и корректировать стратегию действий. Таким образом, по мере эксплуатации агент становится всё более точным и эффективным, постепенно снижая долю нерешённых или ошибочно обработанных событий.

Практическая реализация автономных агентов тесно связана с концепцией AIOps (Artificial Intelligence for IT Operations). В рамках этого

подхода объединяются средства мониторинга, аналитики и автоматизации, а интеллектуальные агенты становятся центральным элементом экосистемы. Их задача – преобразовать огромные потоки событий и метрик в управляемые знания, на основе которых принимаются решения. Использование AIOps позволяет организациям повысить устойчивость ИТ-инфраструктуры, ускорить диагностику инцидентов и оптимизировать использование ресурсов.

Существует несколько архитектурных вариантов построения автономных ИИ-агентов. В наиболее распространённой конфигурации агент включает следующие модули: сбор данных, обработка и нормализация, аналитика и моделирование, принятие решений, выполнение действий и обратная связь. Компоненты взаимодействуют через шину сообщений или событийный брокер (например, Kafka или RabbitMQ), что обеспечивает масштабируемость и отказоустойчивость. Аналитическая часть может быть реализована на основе фреймворков машинного обучения, таких как TensorFlow, PyTorch или отечественные аналоги, например, библиотека CatBoost.

Важным преимуществом является возможность интеграции агента в существующие системы управления инцидентами, например, ServiceNow, Naumen Service Desk или отечественные решения класса ITSM. Это позволяет не только автоматизировать техническую часть устранения неполадок, но и обеспечить полную прослеживаемость всех действий. Таким образом, агент становится не отдельным инструментом, а частью корпоративной экосистемы, работающей по принципу замкнутого цикла: обнаружение – анализ – реакция – обучение.

На практике автономные агенты уже демонстрируют эффективность в ряде областей. В крупных облачных инфраструктурах они используются для автоматического устранения отказов виртуальных машин, балансировки нагрузки и восстановления сервисов после ошибок обновления [4]. В телекоммуникационных сетях подобные агенты помогают поддерживать стабильность каналов связи и оперативно устранять проблемы на уровне оборудования. В производственных системах агенты применяются для анализа событий SCADA и предотвращения сбоев в цепочках управления.

Однако внедрение таких решений требует решения ряда проблем. Основные из них связаны с качеством исходных данных, необходимостью корректной интерпретации моделей и обеспечением прозрачности работы агента. Сложность алгоритмов машинного обучения приводит к эффекту «чёрного ящика», когда оператор не может понять, почему агент принял то или иное решение. Для минимизации этого эффекта применяются методы интерпретируемого ИИ, позволяющие объяснять выводы модели в человеко-понятной форме.

Другим ограничением является зависимость от инфраструктуры и политики организации. Не все компании готовы предоставить автономным системам право изменять конфигурацию или выполнять операции в продуктивной среде. Поэтому успешное внедрение требует, как технической

подготовки, так и организационной зрелости, включая адаптацию процессов DevOps и ITSM.

Перспективы развития автономных ИИ-агентов связаны с интеграцией технологий прогнозного анализа, генеративного ИИ и мультиагентных систем. В будущем можно ожидать появления целых «экосистем агентов», взаимодействующих между собой и коллективно поддерживающих устойчивость сложных распределённых систем. Такие агенты смогут обмениваться знаниями, синхронизировать стратегии и совместно решать задачи оптимизации. Это откроет новые возможности для построения самоорганизующихся цифровых инфраструктур, где роль человека будет постепенно смещаться от оператора к стратегическому наблюдателю и архитектору систем.

Важнейшей задачей при проектировании автономных ИИ-агентов является обеспечение достоверности данных, на которых они обучаются и принимают решения. Даже самый совершенный алгоритм машинного обучения не сможет корректно функционировать при наличии искажений, дубликатов или некорректно размеченных событий. В условиях крупных корпоративных инфраструктур, где источниками информации являются десятки и сотни систем мониторинга, журналов и сервисов, качество данных становится определяющим фактором эффективности агента. Для решения этой проблемы применяются подходы DataOps – методологии, обеспечивающие непрерывную интеграцию, проверку и очистку данных. Автономный агент должен уметь автоматически оценивать доверие к поступающим данным, выявлять несоответствия и исключать шумовые источники. Кроме того, важно внедрять механизмы контекстного анализа – например, сопоставление событий по времени, типу ресурса и критичности. Только при наличии корректного и актуального информационного фона агент способен принимать решения, соответствующие реальной ситуации, и предотвращать ложные срабатывания, которые в противном случае могут привести к дополнительным сбоям или потере производительности.

Отдельного внимания заслуживает вопрос взаимодействия человека и автономного ИИ-агента. Несмотря на высокую степень автоматизации, полностью исключать участие оператора на современном этапе развития технологий нецелесообразно. Роль человека трансформируется – из исполнителя он становится куратором и контролёром системы, обеспечивая надзор, аудит и оценку корректности работы алгоритмов. Разработка интерфейсов взаимодействия с агентом становится ключевым элементом внедрения: человек должен понимать, какие решения и почему были приняты системой, а также иметь возможность вмешаться в процесс в случае непредвиденной ситуации. Поэтому наряду с развитием самих алгоритмов машинного обучения активно развиваются и методы визуализации данных, аналитических панелей и интерактивных отчётов, которые делают поведение ИИ прозрачным и понятным. Концепция Explainable AI (объяснимого искусственного интеллекта) приобретает особое значение именно в

операционном контексте –там, где цена ошибки высока, а доверие к системе формируется через наглядность и предсказуемость её решений.

Кроме того, внедрение автономных ИИ-агентов требует серьёзных изменений в корпоративной культуре и организационных процессах. Для успешной интеграции подобных систем необходимо перестроить традиционные модели взаимодействия между подразделениями ИТ, информационной безопасности и эксплуатации. Возникает новая роль – инженера по ИИ-операциям (AI Operations Engineer), который объединяет компетенции в области DevOps, анализа данных и системного администрирования. Этот специалист отвечает не только за настройку агентов, но и за мониторинг их поведения, оценку эффективности и выявление потенциальных рисков. В организациях, где уже используются элементы AIOps, наблюдается переход от реактивного к проактивному управлению инфраструктурой, когда большинство инцидентов устраняются до того, как они становятся заметными для пользователей. Таким образом, внедрение автономных агентов не просто повышает уровень автоматизации –оно меняет саму философию эксплуатации ИТ, делая её более предсказуемой, гибкой и интеллектуальной.

В заключение следует отметить, что переход к автономным ИИ-агентам является естественным этапом эволюции систем управления ИТ-инфраструктурой. Он позволяет значительно сократить время реакции на инциденты, повысить стабильность сервисов и снизить операционные затраты. Однако ключевым фактором успеха остаётся баланс между автономностью и контролем, между скоростью реакции и прозрачностью решений. Компании, сумевшие правильно внедрить такие системы, получают конкурентное преимущество, выражающееся в повышенной надёжности и устойчивости цифровых сервисов.

СПИСОК ЛИТЕРАТУРЫ

1. Обнаружение инцидентов информационной безопасности на основе технологии нейронных сетей // Журнал «Вопросы кибербезопасности», 2022.
2. Методы машинного обучения в прогнозировании и предотвращении кибератак / Лоцилин А. В., Яриков В. Г., Никишова А. В. // Журнал «НБИ технологии», том 18, выпуск 2, 2024.
3. Модели данных для автоматизации реагирования на инциденты / А. В. Кузнецов и др. // «Безопасность информационных технологий», № 4, 2021, с. 58-67.
4. Сравнительный анализ моделей управления инцидентами информационной безопасности / А. К. Дмина // Международный журнал гуманитарных и естественных наук, выпуск 5-1 (92), 2024.

МЕХАНИЗМЫ МАСШТАБИРОВАНИЯ ОБЛАЧНЫХ БАЗ ДАННЫХ (DBAAS) И ИХ СРАВНЕНИЕ С ON-PREMISE РЕШЕНИЯМИ

Р.В. Кадыков, М.В. Маслевский, Р.Э. Козинцев

Кубанский государственный университет

В статье рассматривается модель Database as a Service (DBaaS), её преимущества – упрощение администрирования, масштабируемость и снижение затрат, а также недостатки – риски потери контроля, зависимость от поставщика и проблемы безопасности. Сравниваются DBaaS и традиционные СУБД, анализируются популярные решения и перспективы развития технологии.

Ключевые слова: DBaaS, Database as a Service, облачные базы данных, СУБД, облачные технологии, масштабируемость, безопасность данных, цифровая трансформация, ИТ-инфраструктура, управление данными.

The article explores the Database as a Service (DBaaS) model, highlighting its advantages—simplified administration, scalability, and cost reduction—and drawbacks, such as data control risks, vendor dependence, and security issues. It also compares DBaaS with traditional DBMS, examining popular solutions and future development prospects.

Key words: DBaaS, Database as a Service, cloud databases, DBMS, cloud technologies, scalability, data security, digital transformation, IT infrastructure, data management.

Облачная СУБД (Database as a Service, DBaaS) – это модель предоставления СУБД в виде управляемого сервиса, развёртываемого в облачных платформах. Пользователь арендует у провайдера базу данных и может создавать инстансы БД через веб-интерфейс или API, не занимаясь установкой и настройкой ОС или СУБД вручную. Поставщик берёт на себя развёртывание кластера, установку ПО, обновления, мониторинг и резервное копирование. В отличие от традиционного on-premises подхода, где организация закупает и поддерживает собственные серверы, в DBaaS оплата идёт по факту использования. Популярные примеры DBaaS – Amazon RDS (MySQL, PostgreSQL), Amazon DynamoDB (NoSQL), Google Cloud SQL и др.

Важным преимуществом облачных СУБД является гибкая поддержка различных механизмов масштабирования. Большинство провайдеров предлагают как вертикальное масштабирование, так и горизонтальное масштабирование, позволяющее распределять нагрузку между несколькими узлами. При этом масштабирование может выполняться как вручную администратором через консоль управления, так и автоматически – при достижении определённых пороговых значений нагрузки. Это обеспечивает стабильную работу приложений без необходимости заранее закладывать избыточные мощности.

Помимо этого, DBaaS-сервисы активно используют дополнительные механизмы повышения производительности и отказоустойчивости: репликацию данных в разные зоны доступности, партиционирование и шардинг таблиц, а также встроенные механизмы кластеризации. Эти функции реализуются на уровне платформы и прозрачны для пользователя, что снижает требования к квалификации персонала и упрощает сопровождение. В результате компании могут сосредоточиться на разработке приложений и бизнес-логике, а не на решении инфраструктурных задач, связанных с поддержкой масштабируемости и отказоустойчивости СУБД.

Облачные СУБД могут разворачиваться двумя основными способами: во-первых, как виртуальная машина (IaaS), куда администратор загружает образ ОС с СУБД и настраивает её самостоятельно; во-вторых, как полностью управляемый сервис (DBaaS/PaaS), когда провайдер сразу разворачивает кластер по заданным параметрам без участия пользователя. Любой из подходов поддерживает и традиционные реляционные СУБД (Oracle, MS SQL, PostgreSQL, MySQL и др.), и NoSQL-решения (Cassandra, MongoDB, DynamoDB и т.п.). При выборе стоит учесть требования: реляционные БД традиционно фокусируются на транзакциях ACID и SQL запросах, а NoSQL-модели (ключ-значение, документы, графы) изначально оптимизированы для горизонтального масштабирования и высокой нагрузки.

В облаке используются те же методы масштабирования, что и на локальных серверах, но значительно автоматизированные и гибкие. Вертикальное масштабирование (scale-up) означает добавление ресурсов (CPU, RAM, хранилища) к одному узлу. Это просто и прозрачно («увеличил размер инстанса»), но ограничено физическими возможностями сервера и быстро становится дорогостоящим. На практике высокомоощные виртуалки имеют «потолок» по процессорам/памяти, а цена растёт быстрее, чем производительность [1]. Горизонтальное масштабирование (scale-out) предполагает распределение нагрузки между несколькими узлами. В распределённых СУБД используются разные подходы:

Репликация: создание копий данных на нескольких серверах (мастер – слейв или мульти-мастер). Основной сервер принимает записи, а копии обслуживают чтения. Это увеличивает устойчивость (при сбое мастера слейвы могут переключиться на запись) и ускоряет операции чтения. Однако всегда есть задержки синхронизации (асинхронная репликация) и риск рассинхронизации данных между узлами.

Партиционирование (секционирование): разбиение больших таблиц на логические части по какому-то критерию (временная метка, география, тип данных). При этом при запросе система может обращаться лишь к нужным партициям, что ускоряет обработку и облегчает архивацию устаревших данных. Минусы – необходимость сложной схемы разбиения и усложнённых операций при запросах, затрагивающих несколько секций одновременно.

Шардинг: более радикальное разделение, когда данные одной большой таблицы распределяются между разными физическими серверами. Это

решение обеспечивает практически неограниченную горизонтальную масштабируемость и позволяет географически разместить данные для оптимизации доступа. Минусы шардинга – очень сложная архитектура, проблемы согласованности при запросах «между шардами» и сложность разработки (нужно точно определить стратегию шардирования и логику запросов).

Таблица 1 - иллюстрация основных подходов к масштабированию в облачных СУБД

Механизм	Описание	Преимущества	Ограничения
Вертикальное	Увеличение ресурсов одного узла (CPU, RAM, диск)	Простота реализации; сохраняется строгая согласованность и привычная модель работы	Физические пределы сервера; быстро растущая стоимость сверхпроизводительного железа
Репликация	Поддержание идентичных копий БД на нескольких узлах (мастер-слейв или мульти-мастер)	Повышенная отказоустойчивость и производительность чтений; быстрый переключатель при сбое	Возможна рассинхронизация копий; задержки при репликации изменений
Партицирование	Разделение больших таблиц на логические части по критерию (дата, регион и т.д.)	Существенное ускорение запросов за счёт работы только с релевантными сегментами; упрощённое удаление старых данных	Усложнённые транзакции при пересечении нескольких партиций; повышенная сложность администрирования
Шардинг	Горизонтальное распределение данных по разным серверам (каждый сервер хранит часть таблицы)	Практически неограниченная масштабируемость; распределение нагрузки географическая дистрибуция данных	Сложность архитектуры и разработки; обеспечение консистентности при перекрестных запросах

Помимо вышеперечисленных, многие облачные СУБД поддерживают автомасштабирование – автоматическое добавление и удаление экземпляров по расписанию или при росте нагрузки. Такие функции («auto-scaling» в AWS,

Azure и др.) позволяют подстраиваться под пиковые нагрузки без ручного вмешательства. Стоит отметить, что классические реляционные СУБД исторически задумывались для работы на одном крупном сервере и масштабируются преимущественно «вверх». В современных облачных решениях они всё чаще получают возможности аналогичны NoSQL (репликация, шардинг) – однако гибкая горизонтальная масштабируемость остаётся главным преимуществом NoSQL-моделей [2].




Рисунок 1 – Облачная БД

Ниже, в таблице 2, приведено сравнение ключевых параметров облачных баз данных (DBaaS) и традиционных локальных (on-premises) решений:

Таблица 2 – сравнение ключевых параметров облачных БД

Параметр	Облачная СУБД (DBaaS)	Локальная СУБД (On-Premises)
Развёртывание	Быстрое: кластер готов за минуты без покупки собственного оборудования	Медленное: закупка и настройка серверов требует недель/месяцев
Администрирование	Минимальное: провайдер сам ставит патчи, обновления, бэкапы	Высокое: всю работу (установка, обновления, резервное копирование) выполняет внутренняя ИТ-команда
Масштабирование	Автоматическое масштабирование (вертикальное/горизонтальное) через интерфейс	Ручное: требует закупки новых серверов или установки дополнительного железа; масштаб ограничен заранее выделенными ресурсами
Надёжность и отказоустойчивость	Очень высокая: данные хранятся в защищённых дата-центрах с резервными каналами питания, сетями и дисками; провайдеры гарантируют SLA $\approx 99.9\%$ и автоматический фейловер	Зависит от усилий организации: для аналогичного уровня требуется дублированное оборудование и резервные копии на уровне компании

Таблица 2 – сравнение ключевых параметров облачных БД

Стоимость	Модель OPEX – плата за фактически используемые ресурсы (pay-as-you-go); минимальные CAPEX	Высокий первоначальный CAPEX (оборудование и
-----------	---	--

		лицензии), предсказуемые постоянные расходы на обслуживание
Безопасность и контроль	Данные хранятся у стороннего провайдера, требуется доверие к его политикам безопасности market.cnews.ru; часть задач безопасности (изоляция, шифрование) берёт на себя провайдер	Полный контроль над данными и инфраструктурой; независимость от внешних сервисов, но ответственность за защиту лежит на компании
Зависимость	Привязка к API и сервисам конкретного провайдера – сложность миграции («lock-in»); надёжность зависит от выбранного провайдера	Нет зависимости от внешних партнёров, но решения ограничены собственными возможностями и временем обновления

DBaaS имеет ряд преимуществ:

- Быстрое развертывание и гибкость. Создать новый инстанс БД в облаке можно за считанные минуты, без проведения подготовки железа и установки СУБД. Это ускоряет тестирование и запуск приложений: при необходимости за пару кликов выделяются дополнительные узлы или увеличиваются ресурсы;

- Минимум рутинного администрирования. Обновления СУБД, патчи безопасности, настройка резервного копирования, мониторинг и обслуживание инфраструктуры полностью выполняются провайдером. Администратор фокусируется на данных и логике приложения, а не на обслуживании ОС;

- Масштабируемость по требованию. Облачные СУБД легко масштабируются – ресурсы можно увеличить как вертикально (выделить более мощные VM или узлы), так и горизонтально (добавить реплики/шарды) через интерфейс или API. Горизонтальное масштабирование особенно просто реализовать за счёт готовых облачных механизмов, которые уже сделаны для вас (автодеплой дополнительных серверов при росте нагрузки);

- Высокая доступность и надёжность. Дата-центры облачных провайдеров избыточно защищены от отказов: резервное электропитание,

дублированные линии связи и геораспределённая инфраструктура. Большинство DBaaS-сервисов предлагают автоматический failover: при выходе из строя главного узла моментально включается резервная копия. Регулярные бэкапы и репликация на уровне сервиса обеспечиваются по принципу SLA.

Экономия CAPEX и предсказуемый OPEX. Нет необходимости закупать собственные серверы и СХД: инфраструктура арендуется по потребности. Для стартапов и проектов малого масштаба это избавляет от крупных единовременных(лишних для компании) расходов. Оплата «по факту» позволяет точно прогнозировать затраты: при росте нагрузки организация платит только за дополнительную мощность. Кроме того, облако обычно предлагает оборудование высокого класса, труднодоступное на локальном рынке (например, специализированные SSD NVMe, GPU), по более доступной цене.

DBaaS также имеет ряд недостатков:

Безопасность и конфиденциальность. Данные и бэкапы хранятся у стороннего провайдера, что требует ему доверия. Физические ЦОД защищены надёжнее, чем большинство локальных серверных, однако сам факт передачи контроля вызывает беспокойство. При этом стоит помнить: и локальные СУБД при подключении к интернету подвержены атакам. Для надёжной защиты в облаке необходимо дополнительно настраивать шифрование, управлять доступом и внимательно следить за политиками безопасности;

Постоянные операционные затраты (OPEX). Регулярная оплата облака со временем может превысить разовую покупку собственного оборудования. Для проектов с предсказуемой нагрузкой и длительным сроком жизни иногда выгоднее инвестировать в своё ЦОД. В противном случае фиксированные ежемесячные расходы на DBaaS (особенно при резервировании мощностей 24/7) могут оказаться выше, чем амортизация локальных ресурсов [3];

Зависимость от провайдера (vendor lock-in). Использование специфических API и механизмов конкретного облачного сервиса усложняет переход на другую платформу или обратно на локальную инфраструктуру. Ошибочный выбор ненадёжного провайдера чреват простоем и потерей данных: при отказе сервиса могут быть затруднения с восстановлением или переносом базы. Хотя большинство надёжных вендоров позволяют экспортировать данные и реплики, риск привязки к одному поставщику остаётся [4].

Подытожим: облачные СУБД (DBaaS) представляют собой мощный инструмент для современных приложений и аналитики, сочетая удобство, масштабируемость и сниженные CAPEX. При выборе конкретного облачного решения важно учесть цели проекта: какие модели данных нужны (SQL или NoSQL), какие объёмы и темпы роста данных, требования к отказоустойчивости и безопасности. Преимущества DBaaS – скорость развёртывания, эластичное масштабирование и минимальное администрирование – особенно ценны для быстрорастущих и распределённых

сервисов. Вместе с тем стоит тщательно анализировать риски: обеспечивать должный уровень шифрования и контроля доступа, сопоставлять долгосрочные расходы, а также планировать резервные сценарии (например, мультиоблачную архитектуру) для снижения зависимости от одного провайдера.

Таким образом, DBaaS можно рассматривать как стратегическое решение, способное ускорить развитие цифровых сервисов и повысить их конкурентоспособность на рынке. Однако ключ к успешному применению этой технологии заключается в грамотном выборе модели масштабирования (вертикальной или горизонтальной), учёте требований к согласованности данных (ACID против BASE), а также в способности компании выстраивать баланс между удобством облака и уровнем контроля, присущим on-premise-инфраструктуре.

В долгосрочной перспективе облачные СУБД будут играть всё более важную роль в бизнес-экосистемах, поскольку позволяют организациям оперативно реагировать на рост нагрузки, быстро внедрять новые сервисы и интегрироваться с инструментами аналитики и искусственного интеллекта. Тем не менее, окончательное решение должно приниматься на основе глубокого анализа: для одних компаний приоритетом станет гибкость и скорость облака, для других – предсказуемость и полный контроль, которые обеспечивают локальные развертывания.

Следовательно, будущее за гибридными и мультиоблачными стратегиями, где DBaaS будет использоваться наряду с локальными базами данных, а организации смогут извлекать преимущества обеих моделей, минимизируя их недостатки.

Кроме того, нельзя забывать о развитии нормативно-правовой базы и отраслевых стандартов, которые всё активнее регулируют вопросы хранения и обработки данных в облаке. Компании, работающие с персональными или финансовыми данными, должны учитывать соответствие решения требованиям законодательства (GDPR, HIPAA, ФЗ-152 и др.), что также влияет на выбор между облачной и локальной СУБД. Этот фактор делает вопрос безопасности и соответствия нормативам не менее важным, чем технические аспекты масштабируемости или производительности.

Наконец, важным направлением остаётся интеграция DBaaS с экосистемами DevOps и CI/CD. Возможность автоматизировать развертывание, масштабирование и мониторинг баз данных в составе конвейеров разработки и доставки программного обеспечения значительно ускоряет вывод продукта на рынок. Таким образом, DBaaS становится не просто инструментом хранения данных, а частью более широкой стратегии цифровой трансформации, где скорость и гибкость напрямую определяют успех бизнеса.

СПИСОК ЛИТЕРАТУРЫ

1. What is database as a service (DBaaS)? // URL: <https://www.techtarget.com/searchdatamanagement/definition/database-as-a-service> (дата обращения: 15.09.2025).
2. Relational Databases Are Not Designed For Scale // URL: <https://www.progress.com/blogs/relational-databases-scale> (дата обращения: 17.09.2025).
3. Стратегии масштабирования баз данных: опыт ITGLOBAL.COM и SimpleOne // URL: <https://itglobal.com/ru-ru/company/blog/strategii-masshtabirovaniya-baz-dannyh-opyt-itglobal-com-i-simpleone> (дата обращения: 17.09.2025).
4. DBaaS: что такое облачные базы данных, их преимущества и недостатки // URL: https://market.cnews.ru/articles/2022-11-30_dbaas_что_такое_oblachnye_bazy_dannyh (дата обращения: 20.09.2025)

МЕТОДЫ ОПТИМИЗАЦИИ ЭТАПА ПОИСКА И ИЗВЛЕЧЕНИЯ (RETRIEVAL) В RAG- АРХИТЕКТУРЕ ДЛЯ ПОВЫШЕНИЯ РЕЛЕВАНТНОСТИ ОТВЕТОВ

В.В. Капустин

Кубанский государственный университет

В этой работе анализируются ключевые методы этапа поиска и извлечения информации в архитектуре RAG, описаны современные подходы к оптимизации, а также углублённые методы индексации и поиска в векторных пространствах. Делается вывод о том, что комбинирование нескольких методов оптимизации позволяет преодолеть ограничения наивной RAG-архитектуры и значительно повысить качество работы системы в целом.

Ключевые слова: RAG архитектура, этап поиска и извлечения, оптимизация retrieval, векторный поиск, эмбединги, семантический поиск, гибридный поиск (BM25 и векторный), ранжирование документов, reranking, размер и стратегия чанкинга, отбор и фильтрация контекста, уменьшение шума в контексте, индексация и обновление индекса, метрики релевантности (MRR, nDCG), персонализация выдачи, оценка качества ответов с участием человека.

This paper analyzes key methods of the information search and retrieval phase of the RAG architecture, describes modern optimization approaches, and advanced methods for indexing and searching in vector spaces. It concludes that combining several optimization methods can overcome the limitations of the naive RAG architecture and significantly improve the overall performance of the system.

Key words: RAG architecture, retrieval stage optimization, vector search, embeddings, semantic search, hybrid search (BM25 and vector), document ranking, reranking, chunk size and chunking strategy, context selection and filtering, noise

reduction in context, index creation and maintenance, relevance metrics (MRR, nDCG), personalized retrieval, human in the loop evaluation.

Архитектура RAG (Retrieval-Augmented Generation) стала де-факто стандартом для построения интеллектуальных систем, которые должны предоставлять точные и фактологически проверенные ответы на основе корпоративных или специализированных знаний [1-4]. Однако эффективность всей RAG-системы напрямую зависит от качества работы её первого этапа – Retrieval. Если на данном этапе извлекаются нерелевантные или неполные фрагменты текста (чанки), то даже самая совершенная языковая модель (LLM) не сможет сгенерировать корректный ответ, что приводит к галлюцинациям и значительному снижению пользовательского доверия.

«Мусор на входе – мусор на выходе» – это правило в полной мере применимо к RAG. Таким образом, оптимизация этапа извлечения информации является не просто одним из направлений улучшения, а фундаментальной задачей, от решения которой зависит успех всей системы. Цель данной статьи – провести системный обзор и анализ современных методов оптимизации этапа Retrieval. В работе ставится задача классифицировать эти методы, описать их принципы действия и оценить их вклад в повышение релевантности извлекаемых данных.

Базовая, или «наивная», реализация RAG часто страдает от ряда системных проблем на этапе извлечения:

Низкая релевантность чанков: Разбиение текста на фрагменты фиксированной длины (символьный или токенный чанкинг) без учёта его семантической структуры приводит к тому, что в один чанк попадает разнородная информация, а контекст разрывается на границе предложения или абзаца.

Семантическая неоднозначность: Пользовательский запрос и релевантный документ могут использовать разную лексику для описания одного понятия (проблема лексического разрыва). Чисто лексический поиск (например, по ключевым словам) в этом случае не срабатывает.

Потеря глобального контекста: Небольшие чанки, оптимизированные для поиска, могут не содержать достаточной информации для понимания общей сути документа, что критично для сложных запросов.

Жёсткость поисковой системы: Использование только одного типа поиска (векторного или ключевого) ограничивает возможности системы и не позволяет гибко адаптироваться к разнообразию пользовательских запросов [2].

Преодоление этих ограничений требует применения более совершенных методов, которые рассматриваются ниже.

Эффективное разбиение текста – основа качественного поиска.

Приведём примеры разбиения текста, их плюсы и минусы.

Семантический чанкинг: в отличие от наивного, этот метод разбивает текст на границах смысловых единиц. Используются алгоритмы,

чувствительные к границам предложений, пунктуации и тематическим переходам. Например, рекурсивное разбиение текста с помощью разделителей (абзацы, заголовки) позволяет создавать чанки с целостным смыслом.

Иерархический чанкинг: Данный подход предполагает создание многоуровневой структуры. Мелкие чанки (например, отдельные предложения) используются для точного поиска, а крупные (абзацы, разделы) предоставляются LLM для восстановления полного контекста после первичного извлечения. Это решает проблему потери глобального контекста.

Чанкинг на основе графов знаний: Наиболее сложный, но и наиболее эффективный для структурированных доменов метод. Текст преобразуется в граф, где узлы – это сущности, а рёбра – связи между ними. Поиск затем осуществляется по подграфам, что позволяет извлекать не просто фрагменты текста, а целостные факты и их взаимосвязи.

Комбинирование сильных сторон разных поисковых парадигм позволяет нивелировать их слабые стороны.

Плотный (векторный) поиск (Dense Retrieval): Осуществляется с помощью моделей эмбедингов (в дипломной работе используется ai-forever/FRIDA). Он эффективен для поиска по смыслу, но может пропускать точные лексические совпадения.

Разреженный (лексический) поиск (Sparse Retrieval): Классические методы, такие как BM25, отлично справляются с поиском по ключевым словам и точным совпадениям терминов.

Гибридный подход: Результаты двух поисков объединяются. Наиболее распространённый метод – взвешенное суммирование скоринг-функций.

(Reciprocal Rank Fusion – RRF). Это позволяет системе находить документы, которые релевантны как по смыслу, так и по конкретным терминам запроса [3].

Пример формирования эмбедингов и добавления в базу данных представлен в листинге 1:

```
@log_execution
def _create_embeddings(chunks):
    tokenizer = AutoTokenizer.from_pretrained("ai-forever/FRIDA")
    model = T5EncoderModel.from_pretrained("ai-forever/FRIDA")
    embeddings = []
    for chunk in tqdm(chunks):
        inputs = tokenizer(chunk, return_tensors="pt", padding=True, truncation=True,
                           max_length=512)
        with torch.no_grad():
            outputs = model(**inputs)
            embedding = outputs.last_hidden_state.mean(dim=1)
    embeddings.append(embedding.numpy())
    return np.vstack(embeddings) @log_execution
def _create_vector_db(embeddings, chunks):
    client = chromadb.PersistentClient(path="./data")
    collection = client.create_collection('outer_wilds_wiki')
    collection.add(embeddings=embeddings, documents=chunks,
```

```

        ids=[f'chunk_{i}' for i in range(len(chunks))]
    )

```

Листинг 1 – Пример формирования эмбеддингов и добавления в базу данных

Дополнительная стадия обработки результатов первичного поиска крайне важна для RAG-систем, поскольку при поступлении зашумленных данных на вход retriever не сможет создать корректные эмбеддинги, что не позволит сформулировать корректный ответ.

Принцип работы: после того как гибридный или векторный поиск возвращает топ-N (например, 100) кандидатов, более точная, но и более вычислительно затратная модель-переранжировщик (cross-encoder) заново оценивает релевантность каждого чанка относительно запроса [3].

Преимущества: Модели-переранжировщики, такие как «bge-reranker» или «Cohere Rerank», рассматривают запрос и чанк совместно, что позволяет достичь высокой точности. Это «финальный штрих», который отсеивает оставшиеся шумы и выставляет наиболее релевантные чанки на первое место перед отправкой в LLM.

Компромисс: Использование re-ranker'a увеличивает задержку системы, поэтому на практике его применяют для относительно небольшого набора кандидатов.

Fine-tuning на доменных данных: Предобученные модели эмбеддингов часто не оптимальны для узкоспециализированных предметных областей (медицина, юриспруденция, инженерия). Дообучение такой модели на корпусе текстов из целевой области позволяет получать эмбеддинги, которые лучше отражают семантику специализированной терминологии.

Использование инструктивных эмбеддингов (Instructional Embeddings): Современные модели (например, «ai-forever/FRIDA») могут принимать не только текст, но и инструкцию к нему (например, "paraphrase:"). Это позволяет более гибко управлять процессом векторизации в зависимости от задачи.

Для измерения успешности применённых методов оптимизации необходимы объективные метрики, ориентированные именно на этап извлечения:

Hit Rate (Частота попадания): Процент запросов, для которых хотя бы один релевантный документ находится среди топ-K результатов.

Mean Reciprocal Rank (MRR – Среднее обратное ранговое место): Учитывает не только факт попадания, но и позицию первого релевантного документа в ранжированном списке. Чем выше MRR, тем лучше система выставляет релевантные чанки на первое место.

Оптимизация этапа Retrieval в RAG-архитектуре является многоуровневым процессом, не имеющим универсального «серебряного пули». Наибольший эффект достигается при комбинировании нескольких методов: применение семантического или иерархического чанкинга закладывает основу для качественных данных, гибридный поиск обеспечивает

высокий recall, а переранжирование – точность финального набора контекста [2, 3].

Дальнейшее развитие методов оптимизации видится в направлениях агентных подходов, когда система может итеративно уточнять поисковый запрос, активного обучения для автоматического улучшения моделей эмбедингов и более тесной интеграции со структурированными данными и графами знаний. Таким образом, этап Retrieval продолжает оставаться активной областью исследований, от прогресса в которой зависит реализация всего потенциала RAG-систем для создания по-настоящему интеллектуальных и точных ассистентов [5].

СПИСОК ЛИТЕРАТУРЫ

1. Lewis, P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks // Advances in Neural Information Processing Systems. – 2020. – Vol. 33. – Режим доступа: URL: https://proceedings.neurips.cc/paper_files/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html (дата обращения: 23.10.2025).
2. Часть 1. Обзор подходов RAG // Хабр. – Режим доступа: URL: <https://habr.com/ru/articles/893650/> (дата обращения: 23.10.2025).
3. Advanced RAG Optimization: Guide to Improving Retrieval-Augmented Generation System // Medium. – Режим доступа: URL: <https://medium.com/@sulbha.jindal/advanced-rag-optimization-guide-to-improving-retrieval-augmented-generation-system-5992275b9cbc> (дата обращения: 23.10.2025).
4. Генерация, дополненная поиском // Википедия. – Режим доступа: URL: https://ru.wikipedia.org/wiki/Генерация,_дополненная_поиском (дата обращения: 23.10.2025).

СОВРЕМЕННАЯ ВЕБ-РАЗРАБОТКА: ОСНОВЫ, ИСПОЛЬЗУЕМЫЕ ТЕХНОЛОГИИ И АРХИТЕКТУРА

Ю. А. Клещевич

Кубанский государственный университет

В этой работе изучаются основы теории веб-разработки и актуальные на данный момент технологии, которые используются в создании веб-приложений.

Ключевые слова: современная веб разработка, фронтенд, бэкенд, HTML, CSS, JavaScript, фреймворки React и Vue, одностраничные приложения, серверная разработка, Node.js, REST API, GraphQL, микросервисная архитектура, клиент серверная архитектура, архитектура SPA и SSR, DevOps практики, контейнеризация, CI/CD, безопасность веб приложений, производительность и масштабируемость.

This paper examines the fundamentals of web development theory and the current technologies used in creating web applications.

Key words: modern web development, frontend, backend, HTML, CSS, JavaScript, React and Vue frameworks, single page applications, server side development, Node.js, REST API, GraphQL, microservices architecture, client server architecture, SPA and SSR architecture, DevOps practices, containerization, CI/CD, web application security, performance and scalability.

Веб-разработка – это обширная и динамичная область, которая стоит за каждым сайтом и приложением, которые мы видим в интернете. От простой страницы-визитки до сложных высоконагруженных веб-приложений, таких как социальные сети, банковские системы или интерактивные карты – всё это результат работы веб-разработчиков. Технически, веб-разработка – это процесс создания, сопровождения и постоянного совершенствования веб-сайтов и веб-приложений. Она включает в себя множество взаимосвязанных аспектов: программирование клиентской и серверной логики, проектирование отказоустойчивой архитектуры, работу с базами данных, обеспечение безопасности, тестирование, развёртывание на серверах и мониторинг производительности.

Клиентская часть – это всё, что пользователь видит, слышит и с чем взаимодействует в своём браузере: кнопки, текст, изображения, меню, анимации, видео. Frontend-разработчик отвечает не только за визуальную привлекательность, но и за удобство использования (UX – User Experience), отзывчивость (Responsiveness) на разных устройствах (от смартфонов до широкоформатных мониторов) и производительность (чтобы страницы загружались быстро и плавно скроллились).

Ключевые технологии Frontend:

1) HTML (HyperText Markup Language) – это фундаментальный язык разметки, который создает семантическую структуру контента. Он определяет, где находится заголовок (<h1>), параграф текста (<p>), изображение (), ссылка (<a>) или форма для ввода (<form>). Можно сказать, что HTML – это скелет или несущий каркас веб-страницы. Современный подход к HTML подразумевает использование семантических тегов (<header>, <nav>, <main>, <section>, <article>, <footer>), которые не только несут смысловую нагрузку, но и улучшают SEO (поисковую оптимизацию) и доступность (Accessibility) для людей с ограниченными возможностями [1].

2) CSS (Cascading Style Sheets) – это язык стилей, который "оживляет" структурный каркас HTML. Он описывает, как элементы должны отображаться: их цвет, размер, шрифт, расположение на странице, анимации и адаптацию под разные экраны. CSS отвечает за весь дизайн и визуальное восприятие веб-приложения. Современный CSS предлагает мощные инструменты, такие как Flexbox и CSS Grid для создания сложных, гибких макетов, а также встроенную поддержку анимаций и трансформаций.

3) JavaScript (JS) – это высокоуровневый язык программирования, который добавляет интерактивность статичной странице. С его помощью можно:

- Реагировать на действия пользователя (нажатие кнопки, прокрутку, ввод текста, перемещение курсора).
- Динамически изменять содержимое, структуру и стили страницы без её перезагрузки.
- Работать с мультимедиа, включая графику и аудио, вплоть до создания сложных игр прямо в браузере.
- Управлять браузерным API (например, Geolocation API, Web Storage, Canvas).

Сегодня редко пишут на "чистом" HTML, CSS и JS. Используются фреймворки и библиотеки, которые ускоряют и упрощают разработку:

1) Фреймворки и библиотеки: React, Vue.js, Angular – это не просто библиотеки, а целые экосистемы для построения сложных пользовательских интерфейсов. Они используют концепцию компонентного подхода, когда интерфейс разбивается на переиспользуемые, независимые блоки (компоненты). Это значительно ускоряет разработку, упрощает тестирование и поддержку кода. React, разработанный Facebook, доминирует на рынке благодаря своей гибкости и огромному сообществу.

2) Препроцессоры и инструменты для CSS: SASS/SCSS, Less, Styled-Components – это надстройки над CSS, которые добавляют возможности переменных, вложенности селекторов, функций (миксинов) и модульности. Это делает код стилей более структурированным, легким для чтения и поддержки.

3) Сборщики и инструменты для разработки: Webpack, Vite, Parcel – это инструменты, которые автоматизируют процесс сборки проекта. Они комбинируют множество мелких файлов JS и CSS в оптимизированные бандлы, применяют транспиляцию (например, преобразуют современный JS в версию, понятную старым браузерам, с помощью Babel), минифицируют код, обрабатывают статические assets (изображения, шрифты) и запускают сервер для разработки. Vite, например, известен своей чрезвычайно высокой скоростью сборки благодаря использованию нативных ES-модулей.

Серверная часть – это "мозг" и "двигатель" приложения, скрытый от глаз пользователя. Когда пользователь входит в свой аккаунт, делает поисковый запрос, покупает товар или просто переходит по ссылке, его браузер отправляет HTTP-запрос на сервер. Backend-приложение, работающее на этом сервере, обрабатывает запрос, выполняет необходимую бизнес-логику (например, проверяет корректность данных, применяет сложные алгоритмы, рассчитывает скидки), взаимодействует с базой данных, формирует ответ и отправляет его обратно клиенту (обычно в формате JSON или HTML).

Ключевые компоненты серверной части:

1) Сервер: это либо физический компьютер, либо виртуальная машина (VPS), либо контейнер (Docker), который постоянно подключён к интернету и

на котором работает программное обеспечение (веб-сервер, такое как Nginx или Apache, и само backend-приложение).

2) Язык программирования на стороне сервера: backend можно писать на множестве языков, у каждого есть свои сильные стороны и ниши:

- JavaScript (Node.js) – позволяет использовать один язык как на фронтенде, так и на бэкенде, что упрощает разработку для fullstack-инженеров. Идеален для высокопроизводительных I/O операций.

- Python – ценится за простой и читаемый синтаксис, а также за мощные фреймворки с богатой экосистемой библиотек для Data Science и AI.

- PHP – исторически самый распространённый язык для веба, который продолжает активно развиваться (после выхода версий 7.x и 8.x).

- Java – часто используется в крупных, высоконагруженных корпоративных проектах благодаря своей надежности, производительности и многопоточности.

- C# – популярен в экосистеме Microsoft.

- Go (Golang) – относительно молодой язык от Google.

3) Фреймворки: как и во Frontend, здесь используются фреймворки, которые предоставляют готовую структуру приложения, "из коробки" решают типовые задачи (маршрутизацию, аутентификацию, валидацию данных, кеширование) и следуют определенным архитектурным шаблонам (чаще всего MVC – Model-View-Controller). Примеры: Express.js (для Node.js), Django и Flask (для Python), Laravel и Symfony (для PHP), Spring Boot (для Java), ASP.NET Core (для C#) [2].

База данных – это организованное, централизованное хранилище всей информации приложения: данные пользователей, товары, статьи, заказы, логи действий и т.д. Правильный выбор и проектирование базы данных критически важны для производительности, масштабируемости и надежности приложения.

Основные типы баз данных:

1) Реляционные (SQL): Данные хранятся в строго структурированных таблицах (сущностях), состоящих из строк и столбцов. Таблицы связаны между собой отношениями (relations), что обеспечивает целостность данных и позволяет выполнять сложные запросы с помощью языка SQL (Structured Query Language). Этот подход обеспечивает надежность и предсказуемость, следует принципам ACID (Atomicity, Consistency, Isolation, Durability). Примеры: PostgreSQL (самый продвинутый open-source вариант), MySQL (самый популярный), MariaDB, Microsoft SQL Server. [3]

2) Нереляционные (NoSQL): Данные хранятся в более гибких форматах, не требующих строгой схемы. Это дает гибкость и легкость горизонтального масштабирования (добавление новых серверов). Основные виды NoSQL БД:

- Документные: Данные хранятся в виде документов, похожих на JSON (MongoDB, Couchbase). Хороши для каталогов товаров, пользовательских профилей.

- Ключ-значение: Простейший тип, идеален для кеширования и сессий

(Redis, Memcached).

- Колоночные: Оптимизированы для обработки огромных объемов данных и аналитических запросов (Cassandra, ClickHouse).

- Графовые: Специализируются на хранении и анализе связей между данными (Neo4j). Идеальны для социальных сетей, рекомендательных систем.

На практике часто используется комбинация разных типов БД в одном проекте (полиглотное хранение) в зависимости от конкретных задач.

Существуют различные роли в разработке веб-приложений:

- 1) Frontend-разработчик: Специализируется на создании видимой части сайта. Должен не только глубоко знать JS, HTML, CSS и фреймворки, но и иметь хорошее чувство дизайна и понимать основы доступности.

- 2) Backend-разработчик: Работает с серверной логикой, базами данных, архитектурой приложения, API, безопасностью и производительностью серверной части.

- 3) Fullstack-разработчик: Универсальный специалист, который умеет работать как с Frontend, так и с Backend. Это очень востребованная специализация, особенно в стартапах и небольших командах, где требуется широкая экспертиза.

- 4) DevOps-инженер: Специалист, который находится на стыке разработки и эксплуатации. Он автоматизирует процессы сборки, тестирования, развёртывания (CI/CD – Continuous Integration / Continuous Deployment) и мониторинга приложений, чтобы обеспечить их быстрое, надежное и стабильное функционирование. Работает с облачными платформами (AWS, Google Cloud, Azure), контейнеризацией (Docker, Kubernetes) и системами мониторинга.

Git - это обязательный инструмент для любого разработчика. Он позволяет:

- 1) Отслеживать все изменения в коде с возможностью отката к любой предыдущей версии.

- 2) Эффективно работать в команде, объединяя изменения от разных разработчиков.

- 3) Создавать "ветки" (branches) для экспериментальной разработки или работы над новыми функциями без риска для основного кода.

- 4) Хранить резервную копию проекта вместе с его историей. Сервисы вроде GitHub, GitLab или Bitbucket предоставляют хостинг для Git-репозиторий и мощные инструменты для совместной работы (code review, issue tracking).

Ключевые концепции и преимущества Git:

- 1) Распределенная система: в отличие от централизованных систем, каждый разработчик имеет на своем компьютере полную копию репозитория со всей историей изменений. Это обеспечивает надежность и позволяет работать автономно.

- 2) Коммиты (Commits): каждое сохраненное изменение в Git называется коммитом. Коммит представляет собой "снимок" состояния проекта в

определенный момент времени и содержит информацию о том, что было изменено, а также сообщение автора, поясняющее цель изменений.

3) Ветвление и слияние (Branching & Merging): ветвление – одна из самых мощных возможностей Git. Разработчики могут создавать изолированные среды для разработки новых функций или исправления ошибок, не затрагивая основную ветку (часто называемую `main` или `master`). После завершения работы ветка может быть слита обратно, объединяя все изменения.

4) Code Review: системы типа GitHub или GitLab предоставляют удобные инструменты для проверки кода (Pull Request или Merge Request). Коллеги могут просматривать изменения, оставлять комментарии и предлагать улучшения до того, как код попадет в основную ветку, что значительно повышает качество кода.

5) Необходимый навык: знание Git и умение работать с ним через командную строку или GUI-клиенты является обязательным требованием для практически любой вакансии в веб-разработке. Понимание основных workflow (таких как Git Flow или GitHub Flow) является стандартом для современных команд [4].

Архитектурные подходы:

1) Одностраничные приложения (SPA): Приложения, которые динамически обновляют содержимое страницы без её полной перезагрузки (Gmail, Facebook). Обеспечивают плавный, нативный пользовательский опыт. Часто строятся на React, Vue.js, Angular.

2) Серверный рендеринг (SSR): Техника, при которой страница генерируется на сервере и отправляется клиенту в готовом HTML. Это улучшает SEO и первоначальную скорость загрузки. Next.js (для React) и Nuxt.js (для Vue) – популярные фреймворки, реализующие SSR.

3) Микросервисная архитектура: Вместо одного большого "монолитного" приложения создается набор небольших, слабо связанных и независимо развертываемых сервисов. Каждый сервис отвечает за свою бизнес-функцию. Это повышает отказоустойчивость, упрощает масштабирование и позволяет командам работать независимо.

4) API (Application Programming Interface): Это контракт между клиентом и сервером, набор правил, определяющий, как они могут общаться. REST API и GraphQL – два популярных стиля построения API. Backend предоставляет API, а Frontend (будь то веб-браузер, мобильное приложение или умные часы) использует его для получения и отправки данных.

Веб-разработка – это не просто написание кода. Это творческий и логический процесс создания цифровых продуктов, которые используются миллионами людей. Это область, которая никогда не стоит на месте: постоянно появляются новые языки, фреймворки, инструменты и архитектурные парадигмы (такие как `serverless`, `edge computing`). Успех в веб-разработке сегодня требует не только глубоких технических знаний, но и готовности к непрерывному обучению, умения работать в команде и

понимания бизнес-задач, стоящих за техническими решениями.

СПИСОК ЛИТЕРАТУРЫ

1. HTML – Язык гипертекстовой разметки: [Электронный ресурс] – URL: <https://ru.wikipedia.org/wiki/HTML> (дата обращения 19.11.2023)
2. Веб-фреймворк – Каркас веб-приложений: [Электронный ресурс] – URL: <https://ru.wikipedia.org/wiki/Веб-фреймворк> (дата обращения 19.11.2023)
3. PostgreSQL: Документация: [Электронный ресурс] – URL: <https://www.postgresql.org/docs/> (дата обращения 19.11.2023)
4. Git – О системе контроля версий: [Электронный ресурс] – URL: <https://git-scm.com/doc> (дата обращения 19.11.2023).

ВЛИЯНИЕ ПРЕДОБРАБОТКИ ТЕКСТА НА ТОЧНОСТЬ КЛАССИФИКАЦИИ ДЛЯ ЗАДАЧ ПСИХОЛОГИЧЕСКОГО ПРОФИЛИРОВАНИЯ

Е.С. Криворучко

Кубанский государственный университет

В данной работе рассматривается влияние различных методов предобработки текста на качество автоматической классификации психологических характеристик. Описаны основные этапы предобработки: токенизация, лемматизация, стемминг, удаление стоп-слов. На основе анализа существующих исследований показано, что выбор метода предобработки может изменить точность классификации на 10-15%.

Ключевые слова: предобработка текста, очистка текстовых данных, токенизация, лемматизация, стемминг, удаление стоп слов, нормализация текста, обработка эмодзи и смайлов, векторизация текста, мешок слов, TF IDF, модели распределенных представлений, точность классификации, психологическое профилирование, анализ личности, автоматический анализ текстов, машинное обучение в психологии, оценка качества моделей.

This paper examines the impact of various text preprocessing methods on the quality of automatic classification of psychological characteristics. The main preprocessing stages are described: tokenization, lemmatization, stemming, and stop word removal. Based on the analysis of existing research, it is shown that the choice of preprocessing method can change classification accuracy by 10-15%.

Key words: text preprocessing, text data cleaning, tokenization, lemmatization, stemming, stop word removal, text normalization, emoji and emoticon handling, text vectorization, bag of words, TF IDF, distributed representations, classification accuracy, psychological profiling, personality analysis, automated text analysis, machine learning in psychology, model quality evaluation.

Современные системы анализа текста используются в том числе и для определения психологических характеристик человека по его письменной речи. Перед применением нейросетевых алгоритмов текст необходимо предобработать – преобразовать из начального и хаотичного вида в структурированный формат.

Качество предобработки напрямую влияет на точность финальной модели. Неправильный выбор методов может снизить точность на 10-20%, даже если использовать продвинутую нейросеть.

Предобработка текста – это последовательность операций по преобразованию исходного хаотичного текста в структурированный формат, пригодный для анализа нейросетевыми алгоритмами [1, 2]. Качественная предобработка напрямую влияет на точность финальной модели и может улучшить результаты классификации на 10-20% [3, 4].

Токенизация является разбиением текста на отдельные элементы (токены): слова, предложения или символы [1]. Это первый и обязательный этап обработки любого текста, поскольку алгоритмы машинного обучения работают с дискретными единицами, а не с непрерывными строками [2].

Существует несколько подходов к токенизации: пословная – разбиение по пробелам (самая распространенная), по предложениям – для анализа синтаксиса, посимвольная – для работы с опечатками и новыми словами

Для задач обработки естественного языка чаще всего используется пословная токенизация, реализованная в библиотеках NLTK, spaCy, или встроенных методах Python типа `'split()'` [6, 7].

Приведение всех символов к нижнему регистру позволяет уменьшить размер словаря и устранить дублирование слов, отличающихся только регистром [2,6]. Например, слова “Привет”, “привет” и “ПРИВЕТ” будут восприниматься моделью как три разных токена, хотя несут одинаковый смысл.

Однако приведение к нижнему регистру может привести к потере контекста в некоторых случаях, например, когда имена собственные или аббревиатуры несут смысловую нагрузку. Для большинства задач классификации эта потеря незначительна по сравнению с выигрышем в размере словаря [2].

Стоп-слова – это частотные служебные слова (союзы, предлоги, частицы), которые встречаются в большинстве текстов и не несут специфической смысловой нагрузки: “и”, “в”, “на”, “из”, “или”, “что”. Их удаление позволяет сократить размерность данных и сфокусироваться на значимых словах.

Стандартные списки стоп-слов доступны в библиотеках NLTK и spaCy для различных языков, включая русский. Однако важно понимать, что универсального списка не существует – выбор стоп-слов зависит от конкретной задачи.

Стемминг (stemming) – это процесс отсечения окончаний и суффиксов для приведения слова к его основе (стему). Алгоритм работает по формальным

правилам, не учитывая морфологию языка, поэтому основа может не быть реальным словом.

Наиболее распространен алгоритм Портера (Porter Stemmer), для русского языка адаптирован SnowballStemmer. Главное преимущество стемминга – скорость работы, так как он основан на простых правилах отсечения. Недостаток – высокая частота ошибок из-за агрессивного обрезания и невозможности различить омонимы.

Лемматизация (lemmatization) – это приведение слова к его словарной форме (лемме) с учетом морфологии языка [2,6]. В отличие от стемминга, лемматизация использует словари и морфологический анализ, поэтому результат всегда является корректным словом.

Для русского языка существуют специализированные инструменты: pymorphy2, mystem, встроенные модели spaCy. Лемматизация работает медленнее стемминга, но обеспечивает значительно более высокое качество результатов, особенно для морфологически сложных языков, таких как русский.

Психологическое профилирование на основе текста требует особого подхода к предобработке, так как многие элементы, традиционно считающиеся “шумом”, на самом деле несут важную психологическую информацию.

В стандартной предобработке знаки препинания обычно удаляются как нерелевантные [7]. Однако для психологического анализа они критически важны:

Восклицательные знаки указывают на повышенную эмоциональность, импульсивность, могут свидетельствовать о высоком нейротизме или экстраверсии. Многоточия часто ассоциируются с неуверенностью, недосказанностью, тревожностью или рефлексией. Вопросительные знаки в избытке могут говорить о неопределенности, поиске ответов, открытости опыту.

Стандартные списки стоп-слов содержат элементы, психологически значимые для профилирования:

Отрицательные частицы (“не”, “ни”, “никогда”, “нет”) являются маркерами защитных механизмов личности по Фрейду, таких как отрицание и вытеснение. Их удаление приведет к потере информации о способах психологической защиты. Местоимения (“я”, “мы”, “они”, “ты”) указывают на фокус внимания и социальную ориентацию личности. Модальные слова (“должен”, “обязан”, “могу”, “хочу”, “нужно”) отражают внутренние мотивы и ценности.

Рекомендация: создавать кастомный список стоп-слов для каждой задачи психологического профилирования, исключая из него психологически значимые элементы.

При стандартной предобработке эмоционально окрашенные слова могут быть искажены или удалены. Однако именно они являются ключевыми маркерами психологических характеристик:

Интенсификаторы (“очень”, “крайне”, “ужасно”, “невероятно”) усиливают эмоциональный окрас и указывают на высокий нейротизм или эмоциональную лабильность. Оценочная лексика (“прекрасный”, “отвратительный”, “восхитительный”) отражает эмоциональное отношение и может быть индикатором черт Big Five.

Стандартная лемматизация приводит все формы глагола к инфинитиву, что приводит к потере модальной информации. Для психологического анализа важно различать: “Должен был” и “хотел бы” – разные мотивационные установки. “Сделал” и “хотел сделать” – различие между действием и намерением.

Важно использовать, например, теговую разметку части речи (POS-tagging) перед лемматизацией для сохранения грамматических характеристик.

Для оценки влияния различных методов предобработки на точность классификации был проведен эксперимент на примере текста с психологическими маркерами [3, 4].

В качестве тестового образца был взят текст: "Я не хочу никуда идти. Чувствую тревогу и усталость. Не могу справиться с этим."

Задача состояла в определении уровня нейротизма. Текст содержит характерные маркеры высокого нейротизма: отрицания ("не хочу", "не могу"), эмоциональную лексику ("тревогу", "усталость") и указания на беспомощность.

Этапы обработки:

Текст обрабатывался следующими методами (рисунок 1):




Рисунок 1 – поэтапная обработка текста для психологического профилирования

– Токенизация и очистка. Исходный текст был разбит на 14 токенов и приведен к нижнему регистру с удалением знаков препинания.

– Удаление стоп-слов (стандартный список). При использовании типового списка стоп-слов из библиотеки NLTK количество токенов сократилось до 8. Однако при этом были удалены критически важные элементы – отрицания "не" и местоимение "я". Это привело к искажению смысла: вместо "не хочу" и "не могу" в обработанном тексте остались только "хочу" и "могу", что изменило семантику на противоположную.

– Кастомный список стоп-слов. Был создан модифицированный список, исключающий психологически значимые элементы ("не", "я", "мы", "никуда"). Результат составил 11 токенов с полным сохранением важной информации.

– Лемматизация. На финальном этапе слова были приведены к базовой форме ("хочу" к "хотеть", "могу" к "мочь"), что позволило модели лучше обобщать данные.

Ниже представлен упрощенный код эксперимента (Листинг 1):

```
# Базовые списки
stop_words_standard = {'и', 'в', 'не', 'я', 'с', 'о', 'из', 'для', 'мы', 'на'}
stop_words_custom = stop_words_standard - {'не', 'я', 'мы'}
text = "Я не хочу никуда идти. Чувствую тревогу и усталость. Не могу справиться с этим."

# Обработка
clean_text = re.sub(r'[^\w\s]', "", text).lower()
tokens = clean_text.split()

tokens_standard = [w for w in tokens if w not in stop_words_standard]
tokens_custom = [w for w in tokens if w not in stop_words_custom]
print(f"Исходное количество: {len(tokens)} токенов")
print(f"Стандартная обработка: {len(tokens_standard)} токенов")
print(f"Кастомная обработка: {len(tokens_custom)} токенов")
```

Листинг 1 – Код на Python по предобработке экспериментального текста

Для оценки эффективности было использовано два показателя: степень сокращения данных и сохранность психологических маркеров. Маркерами считались отрицания (вес x2) и эмоциональная лексика.

Полученные результаты приведены в таблице 1:

Таблица 1 – Сравнительный анализ методов предобработки текста

Метод	n	Δn (%)	Сохр.	К_инф	Оценка
Базовая токенизация	14	–	1,00	1,00	Эталон
Токенизация + lowercase	14	0	1,00	1,00	Приемлемо

Стандартные стоп-слова	8	-43	0,33	0,23	Неприемлемо
Кастомизированные стоп-слова	11	-21	1,00	1,27	Рекомендуется
Лемматизация	11	-21	1,00	1,27	Оптимально

Где:

n – количество токенов;

Δn – относительное изменение, %;

Сохран. – сохранность маркеров (доля);

$K_{\text{инф}}$ – коэффициент информативности;

Оценка – пригодность для психопрофилирования.

Стандартная обработка дала сокращение на 43%, но количество маркеров упало с 6 до 2 – потеря 67% значимой информации. Кастомный подход сократил данные на 21% при полном сохранении всех маркеров. Лемматизация дополнительно улучшила качество за счет нормализации словоформ.

Согласно литературным данным, подобные оптимизации могут повышать точность классификации на 15-20%. В проведенном эксперименте разница между стандартным и кастомным подходом составила примерно 40% точности.

Эксперимент показал, что применение стандартных методов без учета специфики задачи может значительно ухудшить результаты анализа. Для психологического профилирования необходим индивидуальный подход к выбору удаляемых элементов – сохранение отрицаний, местоимений и эмоционально окрашенных слов является критически важным.

Рекомендуемая последовательность обработки: токенизация, далее – приведение к нижнему регистру, кастомное удаление стоп-слов и лемматизация [1, 2, 3]. Такой подход обеспечивает оптимальный баланс между сокращением размерности данных и сохранением психологически значимой информации.

СПИСОК ЛИТЕРАТУРЫ

1. Основы Natural Language Processing для текста / Хабр Электронный ресурс. – 2020. – URL: <https://habr.com/ru/companies/Voximplant/articles/446738/> (дата обращения: 12.09.2025).
2. Учебник под микроскопом. Часть 2. Предобработка текста / Хабр Электронный ресурс. – 2025. – URL: <https://habr.com/ru/articles/953582/> (дата обращения: 12.09.2025).
3. 4 главных метода предобработки текста в NLP с Python / Python School Электронный ресурс. – 2020. – URL: <https://python-school.ru/blog/nlp/nlp-text-preprocessing/> (дата обращения: 14.09.2025).

4. Хотин Д.Ю., Иванова Г.С. Сравнительный анализ методов векторизации текста для задач классификации // Инженерный вестник. – 2025. – № 10. – URL: <https://www.xn—8sbemprclcwd3bmt.xn—p1ai/article/15374> (дата обращения: 11.09.2025).

5. Двойникова А.А., Кондратенко К.О. Влияние предобработки текста на качество классификации // Научно-технический вестник ИТМО. – 2023. – URL: <http://pribor.ifmo.ru/file/article/22407.pdf> (дата обращения: 13.09.2025).

6. Обработка естественного языка / Викиконспекты Электронный ресурс. – URL: https://neerc.ifmo.ru/wiki/index.php?title=Обработка_естественного_языка (дата обращения: 13.09.2025).

7. Что такое векторизация текста в NLP и какая она бывает / Хабр Электронный ресурс. – 2024. – URL: <https://habr.com/ru/articles/820159/> (дата обращения: 12.09.2025).

СРАВНИТЕЛЬНЫЙ АНАЛИЗ ПОДХОДОВ К РАЗРАБОТКЕ ПОЛЬЗОВАТЕЛЬСКОГО ИНТЕРФЕЙСА В КРОССПЛАТФОРМЕННЫХ МОБИЛЬНЫХ ПРИЛОЖЕНИЯХ: REACT NATIVE И FLUTTER

А.К. Муртазаев

Кубанский государственный университет

В статье проводится сравнительный анализ подходов к разработке пользовательского интерфейса в кроссплатформенных мобильных приложениях с использованием фреймворков React Native и Flutter. Рассмотрены основные концепции, инструменты и критерии выбора между этими двумя популярными решениями.

Ключевые слова: кроссплатформенная мобильная разработка, пользовательский интерфейс, React Native, Flutter, декларативный UI, нативный рендеринг, виджеты и компоненты, производительность интерфейса, анимации и плавность, дизайн системы и стилизация, адаптивный дизайн, UX мобильных приложений, горячая перезагрузка, архитектурные подходы, управление состоянием, интеграция с нативными модулями.

This article provides a comparative analysis of approaches to user interface development in cross-platform mobile apps using the React Native and Flutter frameworks. It examines the key concepts, tools, and criteria for choosing between these two popular solutions.

Key words: cross platform mobile development, user interface, React Native, Flutter, declarative UI, native rendering, widgets and components, UI performance, animations and smoothness, design system and styling, adaptive design, mobile app UX, hot reload, architectural approaches, state management, native modules integration.

В современном мире мобильные приложения играют ключевую роль в различных сферах жизни, от коммуникации и развлечений до бизнеса и образования. Разработка мобильных приложений для различных платформ, таких как iOS и Android, требует значительных ресурсов, включая время, деньги и квалифицированных разработчиков. Кроссплатформенная разработка, позволяющая создавать приложения, которые работают на нескольких платформах из одной кодовой базы, стала привлекательной альтернативой, предлагая значительную экономию ресурсов и ускорение процесса разработки.

Кроссплатформенные фреймворки предоставляют разработчикам инструменты и библиотеки, необходимые для создания мобильных приложений, которые могут быть развернуты на различных операционных системах. Это позволяет компаниям охватить более широкую аудиторию, используя одну команду разработчиков и единую кодовую базу, что значительно снижает затраты на разработку и поддержку приложений. Однако, выбор подходящего кроссплатформенного фреймворка является критически важным решением, которое может существенно повлиять на успех проекта.

На рынке существует множество кроссплатформенных фреймворков, каждый из которых имеет свои особенности, преимущества и недостатки. Выбор оптимального решения требует тщательного анализа и оценки различных факторов, таких как производительность, доступность библиотек, простота использования и поддержка сообщества. Неправильный выбор фреймворка может привести к увеличению сроков разработки, снижению производительности приложения и ухудшению пользовательского опыта.

React Native и Flutter являются двумя из самых популярных и востребованных кроссплатформенных фреймворков для разработки мобильных приложений. React Native, разработанный Facebook, использует JavaScript и React для создания пользовательских интерфейсов, используя нативные компоненты платформы. Это позволяет разработчикам создавать приложения, которые выглядят и ощущаются как нативные, при этом используя знакомые инструменты и технологии веб-разработки.

Flutter, разработанный Google, использует язык программирования Dart и собственный движок рендеринга для создания высокопроизводительных и визуально привлекательных приложений. Концепция "Everything is a widget" во Flutter позволяет разработчикам создавать сложные пользовательские интерфейсы, используя широкий набор готовых виджетов и гибкие возможности кастомизации [1].

Настоящая статья посвящена сравнительному анализу подходов к разработке пользовательского интерфейса в кроссплатформенных мобильных приложениях с использованием React Native и Flutter. В статье будут рассмотрены такие аспекты, как декларативный подход к UI, используемые компоненты/виджеты, стилизация, навигация и другие важные факторы,

влияющие на разработку пользовательского интерфейса. Целью статьи является предоставление разработчикам информации, необходимой для принятия обоснованного решения при выборе фреймворка для разработки кроссплатформенных мобильных приложений.

Подход к разработке UI в React Native

React Native предлагает разработчикам декларативный подход к созданию пользовательских интерфейсов, основанный на использовании компонентов. Этот подход позволяет описывать желаемое состояние UI, а React Native автоматически обновляет интерфейс при изменении данных. Это упрощает разработку и поддержку, особенно в сложных приложениях с большим количеством интерактивных элементов.

В основе UI React Native лежат компоненты – независимые, переиспользуемые блоки, из которых строится интерфейс приложения. Компоненты могут быть простыми элементами, такими как кнопки или текстовые поля, или сложными составными частями, объединяющими несколько других компонентов. React Native предоставляет базовый набор компонентов, готовых к использованию, а также позволяет создавать собственные компоненты для реализации специфических задач.

Для описания структуры компонентов React Native часто используется JSX – расширение синтаксиса JavaScript, позволяющее встраивать HTML-подобные элементы непосредственно в код JavaScript. JSX упрощает визуальное представление структуры UI и делает код более читаемым и понятным [2].

React Native предлагает набор основных компонентов, необходимых для создания большинства UI:

- View: Базовый контейнер, аналогичный элементу `<div>` в HTML. Используется для группировки и позиционирования других компонентов.
- Text: Компонент для отображения текста. Позволяет настраивать шрифт, размер, цвет и другие параметры текста.
- Image: Компонент для отображения изображений. Поддерживает различные форматы изображений и позволяет настраивать их размеры и масштабирование.
- ScrollView: Компонент для создания прокручиваемого контента, когда содержимое не помещается на экране.
- TextInput: Компонент для ввода текста пользователем. Предоставляет различные возможности для настройки ввода, такие как валидация, маски и автозаполнение.
- Button: Компонент для создания кнопок. Позволяет задавать текст, цвет и обработчик нажатия.

Стилизация компонентов в React Native осуществляется с помощью системы стилей, аналогичной CSS. Стили определяются в объектах JavaScript и применяются к компонентам. React Native поддерживает большинство CSS-свойств, что позволяет создавать привлекательные и современные интерфейсы. Для удобства организации стилей рекомендуется использовать

StyleSheet.create, который позволяет создавать именованные стили и переиспользовать их в различных компонентах.

Для навигации между экранами в React Native часто используются библиотеки, такие как React Navigation. React Navigation предоставляет удобный API для управления стеком экранов, переходов между ними и передачи данных между экранами. Он поддерживает различные типы навигации, такие как стековая навигация, таб-навигация и навигация с выдвижной панелью.

Подход React Native к разработке UI имеет свои преимущества и недостатки.

Преимущества:

- Использование JavaScript/TypeScript: Знакомый язык программирования для многих веб-разработчиков, что упрощает переход к мобильной разработке.

- Декларативный подход: Упрощает разработку и поддержку UI, делая код более предсказуемым и понятным.

- Переиспользование кода: Возможность переиспользования большей части кода между iOS и Android платформами.

- Hot Reloading: Возможность мгновенного просмотра изменений в UI без пересборки приложения, что значительно ускоряет процесс разработки.

Недостатки:

- Необходимость работы с нативными компонентами: в некоторых случаях может потребоваться написание нативного кода для реализации специфических функций или оптимизации производительности.

- JavaScript Bridge: Обмен данными между JavaScript и нативным кодом может создавать узкие места в производительности, особенно в сложных приложениях с большим количеством данных.

- Зависимость от сторонних библиотек: Использование большого количества сторонних библиотек может привести к проблемам с совместимостью и усложнить процесс обновления приложения.

В целом, React Native предоставляет мощный и гибкий инструмент для разработки кроссплатформенных мобильных приложений с нативным пользовательским интерфейсом. Однако, при выборе React Native следует учитывать его особенности и недостатки, чтобы принять обоснованное решение.

Подход к разработке UI во Flutter

Flutter, разработанный Google, предлагает инновационный подход к созданию пользовательских интерфейсов для мобильных, веб и десктоп приложений. Ключевой особенностью Flutter является принцип "Everything is a widget", означающий, что любой элемент интерфейса, от простой кнопки до сложной анимации, представляет собой виджет.

Виджеты являются строительными блоками Flutter UI. Они описывают, как должен выглядеть и вести себя определенный элемент интерфейса. Flutter предоставляет широкий набор готовых виджетов, таких как:

- Text: Для отображения текста. Позволяет настраивать шрифт, размер, цвет, стиль и другие параметры текста.
- Image: Для отображения изображений. Поддерживает различные форматы изображений, включая сетевые изображения и изображения из локального хранилища.
- Row и Column: Для организации виджетов в горизонтальном и вертикальном направлениях соответственно. Позволяют создавать сложные макеты с гибким управлением расположением элементов.
- Container: Универсальный виджет для добавления отступов, границ, фона и других визуальных эффектов к своим дочерним виджетам.
- Scaffold: Базовый виджет для создания структуры экрана приложения, включающей AppBar (верхняя панель), Body (основное содержимое) и BottomNavigationBar (нижняя панель навигации).
- Button: Для создания кнопок с различными стилями и обработчиками нажатий.

Flutter использует декларативный подход к разработке UI, аналогичный React Native. Разработчик описывает желаемое состояние UI, а Flutter автоматически перерисовывает экран при изменении данных. Это упрощает разработку и поддержку, особенно в сложных приложениях с динамическим контентом.

Стилизация виджетов во Flutter осуществляется с помощью свойств виджетов и тем. Каждый виджет имеет набор свойств, позволяющих настраивать его внешний вид. Например, виджет Text имеет свойства style для настройки шрифта, размера, цвета и других параметров текста, а виджет Container имеет свойства color, padding, margin и decoration для настройки фона, отступов, границ и других визуальных эффектов [3].

Темы во Flutter позволяют определять общие стили для всего приложения. Темы содержат информацию о цветах, шрифтах, стилях кнопок и других элементах интерфейса. Использование тем позволяет создавать единообразный и согласованный внешний вид приложения.

Для навигации между экранами во Flutter используется виджет Navigator. Navigator управляет стеком экранов и предоставляет методы для перехода на новые экраны, возврата на предыдущие экраны и передачи данных между экранами. Flutter также предоставляет готовые виджеты для создания различных типов навигации, таких как BottomNavigationBar и Drawer.

Подход Flutter к разработке UI имеет свои преимущества и недостатки.

Преимущества:

- Everything is a widget: Гибкий и мощный подход, позволяющий создавать сложные и кастомизированные интерфейсы.
- Производительность: Flutter использует собственный движок рендеринга Skia, что обеспечивает высокую производительность и плавную анимацию.

- Hot Reload: Мгновенное отображение изменений в UI без пересборки приложения, что значительно ускоряет процесс разработки.
- Богатый набор готовых виджетов: Flutter предоставляет широкий набор готовых виджетов, упрощающих создание интерфейсов.
- Кроссплатформенность: Возможность создания приложений для мобильных, веб и десктоп платформ из одной кодовой базы.

Недостатки:

- Dart: Использование языка Dart может потребовать времени на изучение для разработчиков, знакомых с другими языками программирования.
- Большой размер приложения: Приложения Flutter часто имеют больший размер, чем нативные приложения или приложения, разработанные с использованием других кроссплатформенных фреймворков.
- Экосистема: Экосистема Flutter еще не так развита, как экосистема React Native, что может означать меньшее количество доступных библиотек и инструментов.

В целом, Flutter предоставляет мощный и современный инструмент для разработки кроссплатформенных пользовательских интерфейсов с высокой производительностью и гибкостью. Однако, при выборе Flutter следует учитывать его особенности и недостатки, чтобы принять обоснованное решение.

Сравнение подходов и выбор фреймворка

React Native и Flutter представляют собой два мощных и популярных фреймворка для разработки кроссплатформенных мобильных приложений. Оба фреймворка позволяют создавать приложения для iOS и Android из единой кодовой базы, что значительно упрощает и ускоряет процесс разработки. Однако, они используют разные подходы к разработке UI и имеют свои сильные и слабые стороны.

Критерии сравнения:

Для сравнения React Native и Flutter рассмотрим следующие критерии:

- Язык программирования: React Native использует JavaScript/TypeScript, в то время как Flutter использует Dart.
- Архитектура: React Native использует JavaScript bridge для взаимодействия с нативными компонентами, в то время как Flutter использует собственный движок рендеринга Skia.
- Производительность: Flutter обычно демонстрирует более высокую производительность благодаря собственному движку рендеринга и компиляции AOT.
- UI-компоненты: React Native использует нативные компоненты платформы, в то время как Flutter предоставляет свой собственный набор виджетов.
- Стилизация: React Native использует систему стилей, аналогичную CSS, в то время как Flutter использует свойства виджетов и темы.

- Навигация: Оба фреймворка предоставляют инструменты для навигации между экранами, но React Navigation является более популярным решением для React Native, а Navigator – для Flutter.

- Скорость разработки: Оба фреймворка поддерживают Hot Reload, что значительно ускоряет процесс разработки.

- Простота изучения: JavaScript/TypeScript может быть более знакомым для веб-разработчиков, что упрощает изучение React Native. Dart может потребовать времени на изучение для разработчиков, не знакомых с этим языком.

- Гибкость: Flutter предоставляет большую гибкость в настройке UI благодаря принципу "Everything is a widget".

- Экосистема: React Native имеет более развитую экосистему с большим количеством доступных библиотек и инструментов.

- Размер приложения: Приложения Flutter обычно имеют больший размер, чем приложения React Native.

Когда использовать React Native:

- Если у вас уже есть опыт разработки на JavaScript/TypeScript и вы хотите быстро начать разрабатывать мобильные приложения.

- Если вам важна возможность переиспользования кода между веб- и мобильными приложениями.

- Если вам необходимо использовать нативные компоненты платформы для достижения максимальной производительности или использования специфических функций.

- Если размер приложения имеет критическое значение.

Когда использовать Flutter:

- Если вам важна высокая производительность и плавность анимации.

- Если вам нужна большая гибкость в настройке UI и возможность создания уникальных визуальных эффектов.

- Если вы готовы изучить новый язык программирования (Dart).

- Если вы разрабатываете приложение с нуля и не ограничены существующей кодовой базой.

- Если вам важна кроссплатформенность на различных платформах (мобильные, веб, десктоп).

На основании всего вышесказанного можно сделать следующий вывод. Выбор между React Native и Flutter зависит от конкретных требований и целей проекта. Оба фреймворка являются мощными инструментами для разработки кроссплатформенных мобильных приложений, но они имеют разные сильные и слабые стороны. При выборе фреймворка необходимо учитывать такие факторы, как опыт команды разработчиков, требования к производительности, гибкость UI и размер приложения. Тщательный анализ этих факторов поможет принять обоснованное решение и выбрать фреймворк, который наилучшим образом подходит для вашего проекта.

СПИСОК ЛИТЕРАТУРЫ

1. Банцеров, В. Кроссплатформенная разработка мобильных приложений на React Native / В. Банцеров. – М.: ДМК Пресс, 2018. – 432 с. – ISBN: 978-5-97060-620-5.
2. Зинченко, И. SMM. Руководство по продвижению в социальных сетях / И. Зинченко, Д. Ткаченко, В. Савельева. – Москва: Издательство «Альпина Паблишер», 2023. – 304 с. – ISBN: 978-5-9614-7484-2.
3. Харахаш, В. М. Flutter. Кроссплатформенная разработка мобильных приложений / В. М. Харахаш. – Санкт-Петербург: БХВ-Петербург, 2021. – 384 с. – ISBN: 978-5-9775-6702-7.

АНАЛИЗ РАЗРАБОТКИ И ОПТИМИЗАЦИИ СИСТЕМНЫХ ПРОМПТОВ ДЛЯ УПРАВЛЕНИЯ ПОВЕДЕНИЕМ LLM В RAG-СИСТЕМАХ

М.Л. Нечепорук

Кубанский государственный университет

В данной работе рассматривается ключевая проблема современных RAG (Retrieval-Augmented Generation) систем – управление поведением Large Language Models (LLM) через системные промпты. Проведен анализ структуры и функций системных промптов, выявлены основные проблемы их проектирования. Предложена методология поэтапной разработки и оптимизации промптов. Рассмотрены практические аспекты интеграции оптимизированных промптов в рабочую цепочку RAG-системы.

Ключевые слова: системные промпты, инженерия подсказок, RAG системы, большие языковые модели LLM, управление поведением модели, инструкции и ограничения, форматирование запросов, структура промпта, контекст и извлеченные документы, роль системного сообщения, предотвращение галлюцинаций, согласованность тональности и стиля, оценка качества ответов, A/B тестирование промптов, оптимизация промптов, человеческая разметка и обратная связь, безопасность и этические ограничения.

This paper addresses a key challenge in modern RAG (Retrieval-Augmented Generation) systems – controlling Large Language Model (LLM) behavior through system prompts. The analysis examines the structure and functions of system prompts, identifying the main challenges in their design. A methodology for the step-by-step development and optimization of prompts is proposed. Practical aspects of integrating optimized prompts into the operational pipeline of a RAG system are also considered.

Key words: system prompts, prompt engineering, RAG systems, large language models LLM, model behavior control, instructions and constraints, query formatting, prompt structure, context and retrieved documents, system message role,

hallucination mitigation, tone and style consistency, answer quality evaluation, A/B testing of prompts, prompt optimization, human feedback and annotation, safety and ethical constraints.

Современные большие языковые модели (LLM) демонстрируют впечатляющие способности в области генерации и понимания текста. Однако их применение в задачах, требующих работы с актуальными, предметно-ориентированными или проверяемыми данными, сталкивается с фундаментальными ограничениями: наличие у модели знаний, актуальных лишь на момент ее обучения ("разрез знаний"), и склонность к "галлюцинациям" – генерации правдоподобной, но фактически неверной информации [1]. Ответом на эти вызовы стала архитектура RAG (Retrieval-Augmented Generation), которая сочетает в себе модель генерации с внешним механизмом доступа к данным.

Ядро RAG-системы составляет следующий конвейер: пользовательский запрос направляется в модуль поиска (retriever), который извлекает релевантные документы из векторной базы знаний или иного хранилища. Затем извлеченные документы и исходный запрос объединяются в специально сформированный промпт (контекстный промпт), который подается на вход LLM (рис. 1). Задача модели – синтезировать конечный ответ, опираясь исключительно или преимущественно на предоставленный контекст, а не на свои внутренние знания [2].

Целью данной работы является систематический анализ процесса разработки и оптимизации системных промптов для RAG-систем, рассмотрение лучших решений, методологий тестирования и критериев оценки их эффективности.

Системный промпт в RAG-системе выполняет функцию мета-инструктора, который готовит модель к обработке специфического типа задач. Его основная цель – "сообщить" модели, что ее ответ должен быть строго детерминирован предоставленным контекстом, и задать рамки этого ответа.




Рисунок 1 – Схема архитектуры RAG

Можно выделить несколько ключевых компонентов, которые входят в структуру эффективного системного промпта:

1 **Определение роли и личности (Role-Playing):** Модели присваивается конкретная роль, которая настраивает ее на соответствующий стиль коммуникации. Например: "Ты – помощник-аналитик в крупной IT-компании. Твоя задача – отвечать на вопросы сотрудников на основе предоставленной внутренней документации". Это сужает пространство возможных ответов и делает поведение модели более предсказуемым.

2 **Явное указание контекста и источника данных:** Четкая инструкция о том, что является источником истины. Ключевые фразы: "Отвечай ТОЛЬКО на основе предоставленных ниже документов", "Если ответа нет в контексте, не придумывай его, а сообщи, что информации недостаточно". Этот блок напрямую борется со склонностью модели к галлюцинациям.

3 **Инструкции по формату ответа:** для последующей автоматической обработки ответа критически важно соблюдение структуры. Промпт может явно требовать: "Предоставь ответ в формате JSON с полями 'answer' и 'confidence_level'", "Используй маркированные списки для перечисления пунктов", "Начинай каждый ответ с краткого резюме".

4 **Ограничения и запреты:** Прямое указание на недопустимые действия. Например: "Не упоминай, что ты – ИИ-модель", "Не используй информацию, которая не содержится в предоставленных документах", "Избегай субъективных оценок и придерживайся фактов".

5 **Общая тональность и стиль:** Указания на желаемый стиль общения: "Будь вежлив и краток", "Используй профессиональный язык", "Объясняй сложные понятия простыми словами".

Эмпирические наблюдения и анализ существующих реализаций позволяют выделить ряд распространенных ошибок, снижающих эффективность RAG-систем.

Перегруженность и противоречивость. Стремление предусмотреть все возможные сценарии приводит к созданию чрезмерно длинных и сложных промптов. Модель может "потерять" ключевые инструкции среди второстепенных или столкнуться с внутренними противоречиями (например, "будь креативным" и "строго придерживайся фактов" без четкого контекста применения) [1,3].

Недостаточная конкретность. Использование размытых формулировок. Инструкция "отвечай точно" менее эффективна, чем "отвечай, цитируя дословно фрагменты из предоставленных документов". Модели лучше работают с конкретными, измеримыми командами.

Игнорирование "силы краев" (Edge Cases). Промпт не содержит четких инструкций для обработки запросов вне контекста, абсурдных или провокационных вопросов. Это приводит к тому, что модель начинает импровизировать, нарушая принципы RAG.

Неучет особенностей конкретной LLM. Разные модели (GPT, Llama, Claude и др.) имеют различную чувствительность к структуре промпта, длине

контекстного окна и формулировкам инструкций. Промпт, идеально работающий с одной моделью, может быть неэффективен с другой. [3]

Отсутствие явного разделения системной инструкции и пользовательского ввода. В некоторых реализациях системный промпт и пользовательский запрос с контекстом сливаются в один текст, что может запутать модель. Четкое разделение (например, через специальные теги `system`, `user`) является хорошей практикой [2,4].

Неадаптивность. Статический промпт, не учитывающий специфику предметной области или типа запроса. Например, промпт для ответов на технические вопросы из базы знаний может плохо подходить для генерации маркетинговых текстов на основе тех же данных.

Разработка эффективного системного промпта – это итеративный процесс, сочетающий в себе технику подсказок (`prompt engineering`) и эмпирическое тестирование [2]. Предлагается следующий поэтапный подход.

Этап 1. Декомпозиция целей и требований. Прежде чем писать код, необходимо формализовать требования к поведению модели.

- Какая основная задача? (Ответить на вопрос, обобщить документ, извлечь сущности).

- Каковы источники данных? (Техническая документация, новостные статьи, код).

- Каков желаемый формат вывода? (Текст, JSON, XML, HTML).

- Каковы критерии успеха? (Фактическая точность, соответствие формату, отсутствие галлюцинаций).

Этап 2. Создание базового прототипа промпта. На основе декомпозиции создается первоначальная версия промпта по принципу "от простого к сложному". Рекомендуются начинать с минимального набора ключевых инструкций:

- Роль.

- Главная задача.

- Действие при отсутствии информации.

- Базовое требование к формату.

Этап 3. Итеративная оптимизация и "отладка" промпта. Это основной и наиболее трудоемкий этап. Он заключается в прогоне через систему набора тестовых запросов (фактических, пограничных, абсурдных) и анализе ошибок. Для каждой ошибки вносится точечное изменение в промпт [5].

Проблема: Модель признает отсутствие информации, но затем все равно пытается ответить.

Решение: Четко прописать условную логику: "ЕСЛИ в контексте есть информация для ответа, ТО... ИНАЧЕ скажи 'Информация не найдена' и остановись".

Проблема: Несоблюдение формата.

Решение: Привести конкретный пример (`Few-Shot Learning`): "Вот пример ответа в нужном формате: ...". Это один из самых мощных приемов.

Проблема: Слишком многословные или слишком краткие ответы.

Решение: Добавить инструкции по объему: "Ответ должен быть не длиннее 3 предложений" или "Дай развернутый ответ с примерами из контекста".

Этап 4. Формализация и документирование. После достижения удовлетворительных результатов финальная версия промпта формализуется, а все принятые решения (почему была добавлена та или иная фраза) документируются. Это критически важно для поддержки и развития системы в будущем.

Разработанный системный промпт интегрируется в рабочую цепочку RAG-системы. На практике промпт часто представляет собой шаблонную строку в коде, куда динамически подставляются извлеченные документы и пользовательский вопрос.

Для объективной оценки эффективности промпта необходимо создать эталонный набор данных, включающий:

- разнообразные пользовательские запросы (простые, сложные, составные).

- соответствующие им релевантные документы из базы знаний.

- эталонные ответы, подготовленные человеком-экспертом.

Допустимо использование метрик, не требующих эталонных ответов:

- средняя длина ответа. Позволяет контролировать многословность.

- частота ответов "Информация не найдена". Показывает, насколько хорошо модель справляется с неопределенностью.

- соответствие формату. Процент ответов, которые могут быть корректно спаршены целевым парсером (например, JSON).

Системный промпт в RAG-архитектуре – это не просто набор пожеланий к модели, а сложный инструмент управления, от качества которого напрямую зависит надежность и практическая ценность всей системы. Как показал проведенный анализ, его разработка – это сложная инженерная задача, требующая глубокого понимания как принципов работы LLM, так и специфики предметной области.

Дальнейшее развитие этой области видится в создании автоматизированных систем для оптимизации промптов, а также в более тесной интеграции логики промптов с самим процессом семантического поиска, когда системная инструкция может динамически адаптироваться в зависимости от характера извлеченного контекста и типа пользовательского запроса. Уже сегодня очевидно, что мастерское владение инструментом системного промпта является одним из ключевых навыков для разработчика, стремящегося создавать не просто "умные", но и надежные, предсказуемые и безопасные ИИ-приложения.

СПИСОК ЛИТЕРАТУРЫ

1 Шолле Ф. Глубокое обучение на Python / Ф. Шолле – Санкт-Петербург: Питер, 2021. – 400 с. – ISBN 978-5-4461-0770-4.

- 2 Берриман Д., Циглер А. Промт-инжиниринг для LLM: Искусство построения приложений на основе больших языковых моделей / J. Berriman, A. Zeigler – Москва: Питер, 2026. – 288 с. – ISBN 978-601-12-3473-3.
- 3 Фостер Д. Генеративное глубокое обучение: Как не мы рисуем картины, пишем романы и музыку : 2-е изд. / Д. Фостер – Москва: Питер, 2024. – 448 с. – ISBN 978-601-08-3729-4.
- 4 Гудфеллоу Я. Глубокое обучение / Я. Гудфеллоу, И. Бенджио, А. Курвилл – Москва: ДМК Пресс, 2018. – 652 с. – ISBN 978-5-97060-618-6.
- 5 Скляр Д. RAG (Retrieval Augmented Generation) – простое и понятное объяснение [Электронный ресурс]. – Режим доступа: URL: <https://habr.com/ru/articles/779526/> (дата обращения: 19.09.2025).

АВТОМАТИЗАЦИЯ БИЗНЕС-ПРОЦЕССОВ С ИСПОЛЬЗОВАНИЕМ ПЛАТФОРМЫ 1С

Ю.Д. Носовский, Б.Л. Осипов
Кубанский государственный университет

В статье рассматриваются теоретические и практические аспекты автоматизации бизнес-процессов с использованием платформы 1С:Предприятие. Описаны преимущества внедрения автоматизированных систем управления, особенности архитектуры и функциональности платформы 1С, а также её роль в цифровой трансформации предприятий. Приведены примеры успешного использования решений 1С в различных сферах деятельности. Особое внимание уделено интеграции с современными технологиями – искусственным интеллектом, облачными сервисами и большими данными. Показано, что 1С становится не только инструментом учёта, но и центром интеллектуального управления бизнесом.

Ключевые слова: автоматизация бизнес процессов, платформа 1С, 1С:Предприятие, моделирование бизнес процессов, регламентация процессов, BPM, ERP система, управленческий учет, оперативный учет, интеграция с внешними системами, документооборот, маршрутизация задач, бизнес логика, настройка прав доступа, отчетность и аналитика, оптимизация трудозатрат, цифровая трансформация организации.

The article examines the theoretical and practical aspects of business process automation using the 1С:Enterprise platform. It describes the advantages of implementing automated management systems, the architecture and functionality of the 1С platform, and its role in the digital transformation of enterprises. Examples of successful implementations of 1С solutions in various industries are provided. Special attention is given to integration with modern technologies such as artificial intelligence, cloud services, and big data. The study demonstrates that 1С is evolving from an accounting tool into an intelligent business management center.

Key words: business process automation, 1С platform, 1С:Enterprise,

business process modeling, process standardization, BPM, ERP system, management accounting, operational accounting, integration with external systems, document workflow, task routing, business logic, access control, reporting and analytics, workload optimization, digital transformation of the organization.

В условиях стремительного развития цифровых технологий и постоянного роста конкуренции компании всё чаще сталкиваются с необходимостью пересмотра своих бизнес-процессов. Для сохранения устойчивого положения на рынке организациям требуется оперативно принимать управленческие решения, обеспечивать высокое качество обслуживания клиентов и эффективно использовать ресурсы. Решением этой задачи становится автоматизация бизнес-процессов, которая позволяет минимизировать влияние человеческого фактора, ускорить обработку информации и создать единое информационное пространство [1].

В последние десятилетия автоматизация бизнес-деятельности стала не просто инструментом оптимизации, но и стратегическим направлением развития компаний [2]. Без использования современных цифровых решений уже невозможно обеспечить прозрачность работы, конкурентоспособность и долгосрочную устойчивость.

Особое место среди инструментов автоматизации занимает платформа 1С:Предприятие – программный комплекс, который широко используется в России и странах СНГ [3]. Его популярность объясняется доступностью, гибкостью и адаптацией под национальные стандарты бухгалтерского, налогового и управленческого учета. На сегодняшний день 1С внедряется как в малом бизнесе, так и на крупных производственных предприятиях, обеспечивая управление финансами, персоналом, логистикой, продажами и производством.

Цель данной статьи – рассмотреть теоретические основы автоматизации бизнес-процессов, проанализировать возможности платформы 1С:Предприятие, выделить преимущества и проблемы её внедрения, а также привести практические примеры использования в различных сферах деятельности.

Теоретические основы автоматизации бизнес-процессов. Современная экономика характеризуется высокой динамичностью и зависимостью успеха предприятий от эффективности внутренних процессов. Под бизнес-процессом понимается последовательность взаимосвязанных действий, направленных на достижение конкретного результата и создание ценности для клиента [2]. В основе автоматизации лежит процессный подход к управлению, при котором организация рассматривается как совокупность взаимосвязанных процессов, объединённых общими целями и ресурсами.

Главная цель автоматизации – обеспечение непрерывного и контролируемого движения информации и ресурсов внутри организации [3]. Автоматизация делает возможным устранение избыточных операций, сокращение времени выполнения задач и повышение точности

управленческих решений. В условиях растущей сложности управления, особенно в крупных компаниях с территориально распределённой структурой, автоматизация становится неотъемлемым элементом устойчивого развития.

В мировой практике используются различные концепции автоматизации: ERP-системы предназначены для комплексного управления ресурсами предприятия; CRM – для построения долгосрочных отношений с клиентами; BPM – для моделирования, анализа и совершенствования процессов; RPA – для роботизации рутинных операций [4]. Сочетание этих подходов позволяет создавать гибкие цифровые экосистемы, в которых данные циркулируют между подразделениями в режиме реального времени.

Важным аспектом является интеграция информационных потоков. Отдельно автоматизированные процессы не дают эффекта, если между ними отсутствует взаимодействие. Только комплексная система, охватывающая все уровни – от операционного до стратегического, – способна обеспечить полноценный управленческий цикл. В этом контексте автоматизация становится не только технологическим, но и организационным проектом, требующим пересмотра корпоративных стандартов и процедур.

Платформа 1С:Предприятие. Платформа 1С:Предприятие занимает уникальное положение на российском рынке программного обеспечения [4]. Она является универсальной основой для создания специализированных решений, охватывающих все ключевые направления деятельности предприятий. С момента своего появления в начале 1990-х годов система прошла путь от инструмента бухгалтерского учёта до полноценной среды для управления бизнесом.

Одной из особенностей 1С является открытая архитектура, позволяющая настраивать систему под конкретные потребности компании без необходимости привлечения зарубежных решений [4]. Многоуровневая структура платформы поддерживает как файловый режим для небольших организаций, так и клиент-серверную архитектуру для крупных предприятий. Современные версии включают веб-клиент, мобильные приложения и облачные сервисы, что делает возможной работу с системой из любой точки мира.

Функциональность платформы охватывает все области управления – финансы, бухгалтерию, персонал, продажи, производство, склад, логистику, документооборот. [4] Особое внимание уделяется интеграции с государственными информационными системами – налоговой службой, Росстатом, Пенсионным фондом, что обеспечивает соблюдение всех нормативных требований.

1С активно развивается в направлении облачных технологий. Использование облачных версий (1С:Fresh, 1С:Cloud) позволяет компаниям отказаться от затрат на серверное оборудование, повысить мобильность сотрудников и ускорить процесс внедрения. Развитие мобильных приложений и интеграция с электронными сервисами делает платформу современным инструментом цифровой экономики.

В отличие от западных аналогов, таких как SAP, Oracle или Microsoft Dynamics, 1С отличается более низкой стоимостью владения, простотой внедрения и адаптацией под российское законодательство. Её гибкость позволяет создавать индивидуальные решения для отраслей – от сельского хозяйства и логистики до машиностроения и медицины.

Автоматизация ключевых направлений деятельности. Важнейшим направлением автоматизации является финансово-бухгалтерская деятельность [1]. С помощью 1С компании получают возможность полностью автоматизировать учет хозяйственных операций, расчёт налогов и формирование отчетности по стандартам РСБУ и МСФО. Это обеспечивает сокращение времени на закрытие отчетных периодов и повышение прозрачности финансового состояния предприятия. Использование встроенных аналитических инструментов позволяет отслеживать движение денежных потоков, контролировать дебиторскую и кредиторскую задолженность, прогнозировать финансовые результаты.

В сфере управления персоналом автоматизация охватывает весь жизненный цикл сотрудника – от найма до увольнения [5]. Система 1С:Зарплата и управление персоналом обеспечивает кадровое делопроизводство, расчет заработной платы, премий и отпусков, автоматическую подготовку отчетности в государственные органы. В современных версиях реализованы инструменты для оценки эффективности работы сотрудников, планирования обучения и карьерного роста, анализа текучести кадров. Это превращает 1С в элемент системы управления человеческим капиталом.

В области продаж и маркетинга 1С выполняет функции CRM-системы [5]. Она позволяет вести клиентскую базу, управлять сделками, договорами, платежами и маркетинговыми кампаниями. Использование аналитических модулей помогает формировать прогнозы спроса, анализировать эффективность каналов продаж и выявлять наиболее прибыльные направления.

В логистике и управлении запасами 1С обеспечивает полный контроль над движением материальных ценностей [6]. Система поддерживает адресное хранение, штрихкодирование, учет серий и партий, что значительно упрощает процессы инвентаризации и планирования поставок. Интеграция с транспортными компаниями и складскими терминалами делает возможным оперативное управление цепочками поставок.

Производственные предприятия активно используют возможности конфигурации 1С:ERP [5]. Система поддерживает планирование загрузки мощностей, управление производственными заказами, расчет себестоимости и анализ затрат. Благодаря интеграции с бухгалтерией и складом обеспечивается сквозное управление от закупки сырья до реализации готовой продукции. Использование системы позволяет повысить производительность, сократить запасы и снизить издержки.

Внедрение 1С:Предприятие обеспечивает организациям значительное повышение эффективности деятельности. Система способствует снижению операционных расходов, ускорению документооборота, повышению точности расчётов и прозрачности процессов. Руководители получают возможность принимать управленческие решения на основе актуальных данных, что особенно важно в условиях быстроменяющейся экономической среды.

Дополнительным преимуществом является возможность масштабирования и интеграции с другими информационными системами, включая банковские сервисы, онлайн-кассы, системы электронного документооборота и внешние аналитические платформы. Поддержка облачных технологий и мобильного доступа обеспечивает гибкость работы и адаптацию к современным условиям удалённого взаимодействия.

Однако внедрение автоматизированных систем часто сопровождается рядом трудностей. Наибольшие проблемы возникают при адаптации персонала к новым условиям работы, при необходимости переноса данных из старых систем и при изменении устоявшихся бизнес-процессов. Кроме того, стоимость комплексного внедрения может быть значительной для крупных компаний, а для малых предприятий требуется тщательный выбор конфигурации, чтобы избежать избыточного функционала.

Эффективное внедрение требует предварительного анализа бизнес-процессов, поэтапного перехода на новую систему и проведения обучения сотрудников. Наилучшие результаты достигаются, когда внедрение рассматривается не как ИТ-проект, а как стратегическое изменение всей организации, направленное на повышение эффективности и качества управления.

Практические примеры внедрения. Рассмотрим несколько примеров успешного внедрения решений 1С в российских организациях. В крупной торговой сети до автоматизации заказы клиентов фиксировались вручную, что приводило к ошибкам и задержкам при формировании накладных. После внедрения системы 1С:Управление торговлей время обработки заказов сократилось почти вдвое, а количество ошибок при учете запасов уменьшилось более чем на 70 процентов. Руководство получило возможность в режиме реального времени контролировать запасы и анализировать эффективность продаж.

На производственном предприятии, специализирующемся на выпуске машиностроительной продукции, внедрение системы 1С:ERP позволило оптимизировать производственные процессы. В результате удалось сократить себестоимость продукции на 8 процентов, снизить уровень незавершенного производства и повысить точность планирования загрузки оборудования. Дополнительно система обеспечила интеграцию с бухгалтерией и складом, что улучшило финансовую дисциплину и контроль затрат.

В сфере государственного управления использование решений 1С:Документооборот позволило перейти на электронное согласование документов, сократить время рассмотрения обращений граждан и повысить

прозрачность административных процедур. Благодаря автоматизации документооборота повысилась исполнительская дисциплина, а объем бумажных документов был сокращен более чем на половину.

Таким образом, практика показывает, что внедрение платформы 1С оказывает комплексное положительное влияние на эффективность, управляемость и устойчивость предприятий.

Перспективы развития автоматизации на платформе 1С. Современные тенденции развития платформы 1С направлены на глубокую интеграцию с технологиями искусственного интеллекта, аналитикой больших данных и роботизацией [7]. В будущих версиях планируется широкое применение нейросетевых алгоритмов для прогнозирования спроса, автоматического распознавания документов и оптимизации логистических цепочек. Развитие интеллектуальных ассистентов в 1С позволит пользователям взаимодействовать с системой на естественном языке, получая аналитику в реальном времени.

Особое внимание уделяется облачным технологиям и SaaS-модели (Software as a Service) [7]. Это позволяет предприятиям снижать капитальные затраты и быстрее внедрять новые решения. Одновременно платформа активно развивает API-интерфейсы для интеграции с внешними сервисами – банками, маркетплейсами, платёжными системами и электронными площадками.

На государственном уровне курс на импортозамещение и цифровой суверенитет придаёт платформе 1С особое значение. Она становится основой национальных информационных систем, обеспечивающих управление экономикой, промышленностью и социальной сферой [8]. Развитие облачных региональных центров обработки данных на базе 1С позволит создавать распределённые цифровые экосистемы, обеспечивающие непрерывное функционирование предприятий в любых условиях.

Важным направлением становится разработка мобильных решений и веб-платформ, которые позволят руководителям контролировать основные показатели бизнеса с любых устройств. Появление технологий машинного обучения в модулях аналитики 1С создаёт возможность перехода от реактивного к предиктивному управлению, когда система сама рекомендует оптимальные действия на основе анализа данных.

Таким образом, платформа 1С эволюционирует из учётной системы в интеллектуальный центр управления предприятием, способный обеспечить полный цикл цифровой трансформации бизнеса.

Автоматизация бизнес-процессов является важнейшим инструментом повышения конкурентоспособности современных компаний. Она позволяет не только сократить издержки и ускорить работу сотрудников, но и создать основу для стратегического развития.

Платформа 1С:Предприятие занимает лидирующие позиции на российском рынке благодаря своей гибкости, доступности и адаптации под

национальные стандарты. Она успешно применяется в компаниях любого масштаба – от малого бизнеса до крупных корпораций.

Несмотря на определенные трудности внедрения, такие как высокие затраты или сопротивление персонала, преимущества автоматизации значительно перевешивают недостатки. Правильный подход к внедрению, обучение сотрудников и использование типовых решений позволяют компаниям получать ощутимый экономический эффект.

В перспективе развитие 1С будет связано с расширением облачных сервисов, мобильных приложений, интеграцией с искусственным интеллектом и большими данными. Всё это делает платформу не просто учетной системой, а полноценным инструментом цифровой трансформации бизнеса.

СПИСОК ЛИТЕРАТУРЫ

1. Афанасьев, В. В. Автоматизация бизнес-процессов предприятия. – М.: Инфра-М, 2020. – 352 с. [1]
2. Репин, В. В., Елиферов, В. Г. Процессный подход к управлению. Моделирование бизнес-процессов. – М.: Манн, Иванов и Фербер, 2019. – 368 с. [2]
3. Харингтон, Дж. Оптимизация бизнес-процессов. Улучшение качества и производительности. – М.: Альпина Паблишер, 2018. – 280 с. [3]
4. Официальный сайт фирмы «1С». <https://1c.ru> (дата обращения: 29.09.2025). [4]
5. Дьяков, С. В. ERP-системы: теория и практика внедрения. – СПб.: Питер, 2021. – 416 с. [5]
6. Мескон, М. Х., Альберт, М., Хедоури, Ф. Основы менеджмента. – М.: Вильямс, 2020. – 672 с. [6]
7. Балашова, Е. С. Информационные технологии в управлении организацией. – М.: Юрайт, 2021. – 298 с. [7]
8. Советов, Б. Я., Паклин, Н. Б. Информационные системы и технологии в экономике. – М.: Финансы и статистика, 2022. – 412 с.

СРАВНИТЕЛЬНЫЙ АНАЛИЗ PWA И НАТИВНЫХ ПРИЛОЖЕНИЙ ДЛЯ ЗАДАЧ МОНИТОРИНГА ЗДОРОВЬЯ НА МОБИЛЬНЫХ УСТРОЙСТВАХ

Д.В. Нудьга

Кубанский государственный университет

В статье проводится комплексный сравнительный анализ двух подходов к разработке мобильных приложений – прогрессивных веб-приложений (PWA) и нативных приложений – в контексте задач мониторинга здорового образа жизни.

Ключевые слова: PWA, прогрессивные веб приложения, нативные мобильные приложения, мониторинг здоровья, мобильные устройства, сенсоры смартфона, фитнес трекинг, интеграция с носимыми устройствами, офлайн режим, push уведомления, доступ к аппаратным функциям, производительность, энергопотребление, UX и UI, пользовательский опыт, безопасность медицинских данных, конфиденциальность, шифрование, соответствие требованиям GDPR и HIPAA, кроссплатформенность, обновление через браузер, публикация через магазины приложений.

The article provides a comprehensive comparative analysis of two approaches to mobile app development – progressive web apps (PWA) and native apps – on the ninth task of a healthy lifestyle.

Key words: PWA, progressive web applications, native mobile applications, health monitoring, mobile devices, smartphone sensors, fitness tracking, wearable devices integration, offline mode, push notifications, access to hardware features, performance, battery consumption, UX and UI, user experience, medical data security, privacy, encryption, GDPR and HIPAA compliance, cross platform support, browser based updates, app store distribution.

Современный рынок мобильных приложений для мониторинга здоровья демонстрирует устойчивый рост. По данным статистики, только в 2024 году совокупные доходы глобального рынка приложений для питания достигли отметки в 5,4 млрд доллара, а к 2028 году этот показатель должен вырасти до 8,29 млрд доллара. Такая динамика объясняется глобальной популяризацией осознанного отношения к здоровью и развитием мобильных технологий.

Перед разработчиками, создающими решения для здоровья, стоит сложный выбор технологического стека. Долгое время доминирующей парадигмой являлась разработка нативных приложений – программ, созданных специально для конкретной операционной системы (iOS или Android). Однако с развитием веб-технологий появилась жизнеспособная альтернатива – Прогрессивные Веб-Приложения (PWA), которые представляют собой гибрид между веб-сайтами и мобильными приложениями.

Актуальность данного сравнительного анализа обусловлена необходимостью выбора оптимального подхода к разработке приложений для мониторинга здоровья, который должен учитывать баланс между производительностью, доступностью, стоимостью разработки и безопасностью работы с конфиденциальными данными.

Прогрессивные веб-приложения – это веб-приложения, созданные с использованием современных веб-технологий, но функционирующие и воспринимаемые пользователем как нативные приложения. Ключевой особенностью PWA является их способность работать на любом устройстве с совместимым браузером, что обеспечивает истинную кроссплатформенность [1].

С технической точки зрения, PWA характеризуются следующими компонентами:

- Service worker – скрипты, выполняемые в фоновом режиме и обеспечивающие офлайн-функциональность путем кэширования критически важных ресурсов;
- Web App Manifest – JSON-файл, содержащий метаданные о приложении (название, иконки, цвет темы), позволяющий установить его на главный экран устройства;
- Обязательное использование HTTPS – гарантия безопасности передаваемых данных [2].

Нативные приложения – это программное обеспечение, разработанное специально для конкретной операционной системы с использованием определенных языков программирования и инструментов. Для iOS такими языками являются Swift или Objective-C, для Android – Java или Kotlin [3].

Ключевые характеристики нативных приложений:

- Прямой доступ к аппаратным API устройства (камера, GPS, датчики, акселерометр);
- Высокая производительность благодаря оптимизации под конкретную платформу;
- Распространение через магазины приложений (App Store, Google Play);
- Полная интеграция с операционной системой и ее сервисами.

Для задач мониторинга здоровья, где часто требуется интеграция со специализированным оборудованием, нативный подход традиционно считается более предпочтительным.

Сравнительный анализ по ключевым критериям:

1) Производительность

Нативные приложения демонстрируют безусловное преимущество в производительности. Поскольку они компилируются в машинный код, оптимальный для конкретной процессорной архитектуры и ОС, это обеспечивает максимальную скорость отклика, плавную анимацию и минимальное энергопотребление [4].

PWA зависят от производительности JavaScript-движка браузера. Хотя современные движки (V8 в Chrome, JavaScriptCore в Safari) достаточно оптимизированы, они добавляют слой абстракции, что приводит к несколько большим задержкам. Однако для большинства задач мониторинга здоровья (отображение статистики, графиков, журналов питания) эта разница может быть практически незаметна для пользователя.

2) Доступ к аппаратным API

Нативные приложения имеют прямой и неограниченный доступ ко всем аппаратным API через официальные SDK. Примером успешной реализации является приложение "Умный мониторинг здоровья", которое автоматически передает измерения с тонометров и глюкометров через Bluetooth в дневник самонаблюдения.

PWA имеют ограниченный доступ к аппаратным возможностям через стандартизированные Web API. Главным ограничением PWA является зависимость от поддержки этих API в браузерах, которая не всегда одинакова, особенно в Safari.

3) Стоимость и время разработки

PWA существенно выигрывают по экономическим показателям. Разработка единой кодовой базы, работающей на всех платформах, сокращает как временные, так и финансовые затраты. По оценкам экспертов, создание PWA обходится на 30-50% дешевле, чем разработка отдельных нативных приложений для iOS и Android.

Нативная разработка требует создания как минимум двух версий приложения (для iOS и Android) с использованием разных языков программирования и инструментов. Это означает двойные затраты времени и ресурсов. В большинстве случаев приходится нанимать отдельные команды разработчиков для каждой платформы.

4) Безопасность и конфиденциальность

Безопасность – критически важный аспект для приложений с мониторингом здоровья, работающих с конфиденциальными данными.

Нативные приложения могут реализовывать надежные меры безопасности и использовать платформенные механизмы шифрования. Они также проходят строгую проверку перед публикацией в магазинах приложений, что добавляет им надежности.

PWA используют HTTPS и Service worker для безопасной передачи данных. Обеспечение соответствия PWA необходимым стандартам безопасности является критически важным для приложений, работающих с конфиденциальной информацией.

5) Функциональность в офлайн-режиме

Нативные приложения традиционно имеют более развитые возможности офлайн-работы благодаря прямому доступу к файловой системе устройства.

Медицинские приложения, такие как дневники питания или трекеры симптомов, могут хранить данные локально и синхронизировать их при восстановлении соединения.

PWA используют Service worker и Cache API для кэширования критически важных ресурсов и данных. Это позволяет пользователям получать доступ к ключевым функциям приложения даже без подключения к интернету, что особенно важно для регионов с нестабильной связью.

7) Распространение и обновления

Нативные приложения распространяются через магазины приложений (App Store, Google Play), что обеспечивает им высокую видимость и доверие пользователей. Однако процесс публикации и обновления требует времени и должен соответствовать строгим требованиям платформ [5].

PWA распространяются непосредственно через веб-браузеры, что устраняет барьеры для пользователей. Обновления PWA происходят

автоматически без участия пользователя, так как при загрузке всегда используется последняя версия с сервера.

Одним из показательных примеров успешного внедрения PWA в медицинской сфере является опыт нью-йоркской офтальмологической группы. Они разработали PWA для взаимодействия с пациентами и рассылали SMS с ссылкой на приложение. Результаты показали, что все пациенты использовали исключительно PWA, которая обеспечивала быструю аутентификацию по одноразовому паролю из SMS.

Другим успешным кейсом является региональный медицинский провайдер, внедривший PWA для управления назначениями и последующими наблюдениями. Приложение позволяло пациентам записываться, переносить или отменять приемы, получать доступ к своей медицинской истории и персонализированные рекомендации по здоровью. В результате было зафиксировано существенное снижение количества неявок на приемы и повышение удовлетворенности пациентов.

На основе проведенного анализа можно сформулировать следующие рекомендации по выбору между PWA и нативным подходом для разработки приложений мониторинга здоровья.

Прогрессивные веб-приложения являются предпочтительным выбором в следующих сценариях:

- Ограниченный бюджет и сроки разработки – когда необходимо быстро выпустить продукт на рынок с минимальными затратами;
- Широкая целевая аудитория – когда важно обеспечить доступность приложения для пользователей разных платформ без увеличения затрат на разработку;
- Простое распространение – когда необходимо быстро делиться приложением через ссылки без прохождения сложных процессов публикации в магазинах приложений.

Нативная разработка оправдана в следующих случаях:

- Высокие требования к производительности – для приложений, работающих в реальном времени с данными датчиков (ЭКГ, мониторинг глюкозы);
- Интенсивное использование возможностей устройства – когда необходимо глубоко интегрироваться с аппаратными возможностями смартфона или специализированных медицинских устройств;
- Монетизация через магазины приложений – когда планируется использовать встроенные платежные системы App Store или Google Play

Проведенный сравнительный анализ PWA и нативных приложений для задач мониторинга здоровья демонстрирует, что оба подхода имеют свои стратегические преимущества и области применения.

PWA предлагают экономическую эффективность, кроссплатформенность и быстроту развертывания, что делает их идеальным решением для приложений с широкой аудиторией, ограниченным бюджетом

и нечастным использованием. Они особенно эффективны для контент-ориентированных решений, телемедицины и простых трекеров здоровья.

Нативные приложения остаются безусловными лидерами в сегменте высокопроизводительных решений, требующих глубокой интеграции с аппаратными возможностями устройств. Они незаменимы для сложных медицинских систем, работающих в реальном времени с данными датчиков и специализированного оборудования.

Вердикт заключается в том, что выбор технологического подхода должен определяться конкретными задачами и требованиями проекта. Для многих организаций оптимальной стратегией может стать гибридный подход: начинать с PWA для быстрого выхода на рынок и проверки гипотез, а затем развивать нативную версию для углубленной функциональности.

СПИСОК ЛИТЕРАТУРЫ

1. PWA против нативного приложения: что вам больше подходит? // ASO World. – 2023. – URL: <https://asoworld.com/ru/blog/progressive-web-app-pwa-vs-native-app-which-suits-you-better/> (дата обращения: 29.09.2025).
2. Прогрессивное веб-приложение (PWA) в здравоохранении // ARISWEB. – 2023. – URL: <https://arisweb.ru/progressivnoe-veb-prilozhenie-pwa-v-zdravoohranenii/> (дата обращения: 19.09.2025).
3. Progressive Web Apps (PWA) vs Native – Which is Better? // CrustLab. – 2024. – URL: <https://crustlab.com/blog/pwa-vs-native-comparison/> (дата обращения: 24.09.2025).
4. Progressive Web Apps (PWAs) vs. Native Mobile Health Applications // Emorphis Health. – 2023. – URL: <https://emorphis.health/blogs/progressive-web-apps-native-mobile-health/> (дата обращения: 22.09.2025).
5. 12 Best Healthcare Apps for Patients // HP Tech Takes. – 2021. – URL: <https://www.hp.com/us-en/shop/tech-takes/best-healthcare-apps-for-patients> (дата обращения: 19.09.2025).

ВЫБОР МЕЖДУ СИНХРОННЫМ И АСИНХРОННЫМ СТИЛЕМ РАЗРАБОТКИ ВЕБ-ПРИЛОЖЕНИЙ НА ПРИМЕРЕ ЯЗЫКА ПРОГРАММИРОВАНИЯ PYTHON

И. А. Остриков

Кубанский государственный университет

Статья посвящена сравнению синхронного и асинхронного стилей программирования в веб-разработке. Рассмотрены особенности блокирующего и неблокирующего выполнения, их влияние на производительность и параллелизм в обработке запросов. Описаны типичные сценарии применения, преимущества и ограничения каждого подхода, а также факторы выбора между ними с учётом нагрузки, экосистемы и

квалификации команды. Приведены примеры кода на Django (синхронный) и FastAPI (асинхронный) и проведён анализ современных веб-фреймворков и серверных интерфейсов WSGI и ASGI.

Ключевые слова: синхронная разработка, асинхронная разработка, веб приложения на Python, модель ввода вывода, блокирующие и неблокирующие операции, *asyncio*, *event loop*, многопоточность, multiprocessing, WSGI, ASGI, Django, Flask, FastAPI, производительность веб сервера, масштабируемость, конкурентные запросы, задержки ответа, выбор архитектурного стиля, профили нагрузки

The article focuses on comparing synchronous and asynchronous programming styles in web development. It covers the characteristics of blocking and non-blocking execution and their impact on request handling performance and concurrency. Typical use cases, advantages, and limitations of each approach are discussed, along with key criteria for choosing between them considering workload, ecosystem, and team expertise. Code examples using Django (synchronous) and FastAPI (asynchronous) are provided, accompanied by an analysis of current web frameworks and server interfaces WSGI and ASGI.

Key words: synchronous development, asynchronous development, Python web applications, input output model, blocking and non blocking operations, *asyncio*, *event loop*, multithreading, multiprocessing, WSGI, ASGI, Django, Flask, FastAPI, web server performance, scalability, concurrent requests, response latency, architectural style choice, workload profiles.

Актуальность исследования различий между синхронным и асинхронным стилями программирования обусловлена ростом требований к производительности и масштабируемости современных веб-приложений. В условиях высокой нагрузки на серверную инфраструктуру важно выбирать архитектурный подход, обеспечивающий эффективное использование ресурсов при минимальной задержке обработки запросов. Традиционные синхронные решения, несмотря на простоту и предсказуемость, демонстрируют ограниченную производительность при I/O-нагрузке, что приводит к поиску альтернативных неблокирующих моделей исполнения.

```
from django.http import JsonResponse
import time

def get_data(request):
    time.sleep(1) # блокирующая операция: поток ждёт 1 секунду
    data = {"result": "OK"}
    return JsonResponse(data)
```

Листинг 1 – Пример синхронного кода на Django

В данном примере каждый вызов функции `get_data` блокирует поток на одну секунду, из-за чего последующие запросы ожидают освобождения

воркера. При высокой нагрузке это приводит к росту задержек и снижению отзывчивости системы [2].

Ключевое различие между синхронным (blocking) и асинхронным (non-blocking) стилями заключается в механизме взаимодействия с длительными операциями ввода-вывода. В синхронном подходе выполнение операций осуществляется последовательно: поток блокируется на время ожидания результата, что снижает общую пропускную способность системы. Асинхронный подход, напротив, позволяет приостанавливать выполнение задачи и возвращать управление циклу событий (event loop), обеспечивая обработку других запросов без создания дополнительных потоков. Таким образом, асинхронная модель позволяет одному потоку эффективно обслуживать сотни соединений, что особенно актуально для микросервисов и приложений реального времени [1].

Синхронный стиль программирования характеризуется последовательным выполнением операций, когда каждая функция завершается полностью перед началом следующей. При выполнении длительных операций, таких как запросы к базе данных или чтение файлов, поток блокируется до завершения операции, что приводит к простаиванию ресурсов при высокой I/O-нагрузке. Синхронный код отличается линейной логикой, легко читается и отлаживается, а также демонстрирует широкую совместимость с существующими библиотеками и инфраструктурой. Однако для обслуживания большого числа одновременных соединений требуется создание множества потоков или процессов, что увеличивает накладные расходы на ресурсы и снижает масштабируемость.

Асинхронный стиль программирования основан на концепции событийного цикла и корутин. Вместо блокировки потока при ожидании операции ввода-вывода асинхронная функция передаёт управление обратно циклу событий, который переключается на выполнение других задач. После завершения операции цикл возвращается к приостановленной задаче и продолжает её выполнение. Это обеспечивает значительное повышение эффективности при I/O-bound нагрузках.

Асинхронный код использует корутины, определяемые с помощью `async def`, и оператор `await`. При вызове `await` поток не простаивает, а продолжает обработку других запросов, что позволяет обслуживать большое количество соединений в рамках одного процесса. В этом подходе увеличивается сложность программирования: необходимо явно управлять асинхронными функциями, корректно обрабатывать исключения и использовать библиотеки, совместимые с `asyncio`. Асинхронные фреймворки, такие как FastAPI и Starlette, реализуют модель ASGI (Asynchronous Server Gateway Interface), обеспечивая поддержку WebSocket, HTTP/2 и неблокирующих операций [1].

```
from fastapi import FastAPI
import asyncio
```

```

app = FastAPI()

@app.get("/data")
async def get_data():
    await asyncio.sleep(1) # неблокирующая операция: цикл может заняться другими
    задачами
    return {"result": "OK"}

```

Листинг 2 – Пример асинхронного кода на FastAPI

Во время выполнения `await asyncio.sleep(1)` сервер не блокируется и может обрабатывать другие запросы. Таким образом достигается высокая отзывчивость и пропускная способность системы [3].

Сравнение синхронного и асинхронного подходов показывает, что первый обеспечивает простоту реализации, линейную логику и широкую совместимость с библиотеками и инфраструктурой, но ограничен в масштабируемости при высокой I/O-нагрузке. Асинхронный подход позволяет эффективно обрабатывать большое количество одновременных соединений и повышает пропускную способность, однако требует использования асинхронных библиотек, знаний о цикле событий и внимательной обработки исключений. Выбор конкретного стиля зависит от характера нагрузки, требований к масштабируемости и квалификации команды. Синхронные решения остаются актуальными для CPU-bound задач и проектов с умеренной нагрузкой, тогда как асинхронные оправданы для высоконагруженных I/O-bound приложений, микросервисов и систем реального времени [4, 5].

Асинхронность не является универсальным решением. Её главное преимущество проявляется в I/O-bound задачах (ожидание сети, диска, БД). Если же внутри асинхронной функции выполняется длительная CPU-bound задача (сложные вычисления, обработка изображений, machine learning), она блокирует весь цикл событий.

Рассмотрим пример из Листинга 2, если заменить `asyncio.sleep(1)` (неблокирующее I/O-ожидание) на `time.sleep(1)` (блокирующая операция, имитирующая CPU-нагрузку):

```

@app.get("/cpu-bound")
async def get_data_bad():
    time.sleep(1) # ОШИБКА: Это заблокирует весь event loop!
    return {"result": "CPU work done"}

```

Листинг 3 – Неправильное использование асинхронного кода в FastAPI

В этом случае один такой запрос "заморозит" весь воркер, и тысячи других клиентов, обслуживаемых этим воркером, перестанут получать ответы. Это катастрофично для производительности.

Правильное решение – вынести блокирующую (CPU-bound) задачу из основного потока (event loop) в отдельный пул потоков, используя

`asyncio.to_thread` (в Python 3.9+) или `loop.run_in_executor` [6]:

Выбор между синхронным и асинхронным стилями фундаментально влияет на архитектуру развертывания (deployment) и требования к инфраструктуре. Традиционные WSGI-приложения (Django, Flask) развертываются с использованием серверов, таких как Gunicorn, который использует модель pre-fork worker. В этой модели Gunicorn запускает несколько рабочих процессов (воркеров), и каждый воркер синхронно обрабатывает один запрос за раз. Для достижения высокой конкурентности при I/O-нагрузке (например, 1000 одновременных пользователей) требуется запустить большое количество воркеров (например, $2 * \text{число_ядер_CPU} + 1$), что пропорционально увеличивает потребление оперативной памяти [5].

ASGI-приложения (FastAPI), напротив, используют серверы вроде Uvicorn, которые работают на основе событийного цикла [7]. Uvicorn часто запускается под управлением Gunicorn, но с использованием специального класса воркера (`uvicorn.workers.UvicornWorker`). В такой конфигурации достаточно запустить небольшое число воркеров (часто равное числу ядер CPU), поскольку каждый воркер асинхронно обрабатывает тысячи одновременных соединений. Это позволяет добиться значительно более высокой пропускной способности и эффективности использования памяти при I/O-нагрузках, но требует, чтобы весь код внутри воркера был неблокирующим.

Помимо развертывания, критическим фактором является зрелость экосистемы. Асинхронный код требует, чтобы каждая I/O-операция (запрос к БД, HTTP-вызов, чтение файла) была асинхронной. Если в `async def` функции FastAPI вызвать стандартную блокирующую библиотеку (например, `requests`), весь событийный цикл будет заблокирован, что сведет на нет все преимущества асинхронности. Разработчики вынуждены использовать `asyncio.to_thread` для выноса таких вызовов в отдельный поток [6] или искать "async-native" альтернативы (например, `httpx` вместо `requests`). Это усложняет разработку и отладку, а также требует от команды глубокого понимания `asyncio`, `contextvars` и инструментов вроде `pytest-asyncio`.

В конечном счете, современная веб-разработка на Python движется не к полной замене синхронного подхода асинхронным, а к их интеллектуальной гибридизации. Новые проекты (особенно микросервисы), ориентированные на высокую I/O-нагрузку (API-шлюзы, чаты, стриминг), получают немедленную выгоду от FastAPI и ASGI [1, 4]. В то же время, монолитные приложения с умеренной нагрузкой и сложной бизнес-логикой по-прежнему выигрывают от стабильности, предсказуемости и богатой экосистемы Django. Появление асинхронных возможностей в самом Django стирает эту грань, позволяя разработчикам применять асинхронность точечно, там, где она действительно необходима, не переписывая все приложение [2].

СПИСОК ЛИТЕРАТУРЫ

- 1 Конкурентность и `async / await` - FastAPI // FastAPI. – URL:

- <https://fastapi.tiangolo.com/ru/async/> (дата обращения: 15.09.2025)
- 2 Конкурентность и async / await - FastAPI // FastAPI. – URL: <https://fastapi.tiangolo.com/ru/async/> (дата обращения: 15.09.2025)
- 3 Поддержка асинхронного режима | Документация Django 5.2 // Django.fun. – URL: <https://django.fun/docs/django/5.2/topics/async/> (дата обращения: 15.09.2025)
- 4 Почему асинхронный Python не такой популярный? // Хабр. – URL: <https://habr.com/ru/articles/943878/> (дата обращения: 15.09.2025)
- 5 Django vs FastAPI в 2025 году: какой фреймворк выбрать? // Tproger. – URL: <https://tproger.ru/articles/django-vs-fastapi-v-2025-godu--kakoj-frejmwork-vybrat-> (дата обращения: 15.09.2025)
- 6 Running in Threads // Python 3.12 documentation: asyncio. – URL: <https://docs.python.org/3/library/asyncio-task.html#running-in-threads> (дата обращения: 15.09.2025)
- 7 Uvicorn: The lightning-fast ASGI server // Uvicorn. – URL: <https://www.uvicorn.org/> (дата обращения: 15.09.2025)

СИСТЕМА РАЗВИТИЯ НАВЫКОВ СОТРУДНИКОВ (SKILLTRACKER)

Д.С. Павлов

Кубанский государственный университет

В статье рассматривается система развития навыков сотрудников SkillTracker – инновационный инструмент для мониторинга, оценки и планирования профессионального роста персонала. Обосновывается актуальность системного подхода к развитию компетенций, описываются основные функции и компоненты SkillTracker, этапы внедрения и практические примеры использования. Особое внимание уделено применению искусственного интеллекта для персонализации обучения, прогнозирования дефицитов навыков и автоматизации оценки. Подчеркивается значимость SkillTracker для повышения эффективности, мотивации и конкурентоспособности компаний.

Ключевые слова: развитие навыков сотрудников, управление компетенциями, система SkillTracker, матрица компетенций, оценка навыков, индивидуальные планы развития, корпоративное обучение, LMS интеграция, обучение в рабочем процессе, персонализированные траектории обучения, soft skills, hard skills, аналитика обучения, KPI развития персонала, профиль компетенций, оценка 360, управление талантами.

The article discusses the SkillTracker employee skills development system, an innovative tool for monitoring, evaluating, and planning staff professional growth. The relevance of a systematic approach to competence development is substantiated, the main functions and components of SkillTracker, the stages of implementation

and practical use cases are described. Special attention is paid to the use of artificial intelligence to personalize learning, predict skill deficits, and automate assessment. The importance of SkillTracker for increasing the efficiency, motivation and competitiveness of companies is emphasized.

Key words: employee skill development, competence management, SkillTracker system, skills matrix, skills assessment, individual development plans, corporate training, LMS integration, learning in the flow of work, personalized learning paths, soft skills, hard skills, learning analytics, employee development KPIs, competency profile, 360 degree feedback, talent management.

В современном мире динамичных бизнес-процессов и высоких требований к качеству работы организаций, развитие персонала становится одним из ключевых факторов успеха. Компетенции и навыки сотрудников напрямую влияют на эффективность, инновационность и конкурентоспособность компании. Однако управление развитием навыков – процесс сложный, требующий системного подхода и использования современных инструментов.

Система развития навыков сотрудников SkillTracker – это инновационный инструмент для мониторинга, оценки и планирования профессионального роста работников на основе их компетенций. В данной статье мы подробно рассмотрим, что такое SkillTracker, как она работает, какие преимущества дает бизнесу, и как внедрить подобную систему в организации [1].

Технологии развиваются с большой скоростью, профессии трансформируются, а требования к специалистам постоянно растут. Компании сталкиваются с необходимостью непрерывного обучения персонала, чтобы поддерживать высокий уровень эффективности и адаптивности. В таких условиях традиционные методы обучения и оценки часто оказываются недостаточными.

Сфокусированное развитие навыков позволяет повысить производительность, удовлетворенность сотрудников и снизить уровень текучести. Понимание и управление компетенциями становится базой для успешного планирования карьерного роста и развития бизнеса в целом.

1 Система SkillTracker: возможности и преимущества для развития персонала

Что такое SkillTracker?

SkillTracker – это комплексная и многофункциональная система, разработанная для эффективной оценки, отслеживания и всестороннего развития профессиональных навыков сотрудников организации. Эта система объединяет широкий спектр возможностей, направленных на оптимизацию управления компетенциями персонала и повышение общего уровня квалификации коллектива [2].

В первую очередь, SkillTracker обеспечивает сбор детальных данных о текущих навыках и компетенциях работников, что позволяет создать полное

представление о текущем состоянии профессионального потенциала компании. Далее система проводит оценку уровня владения этими навыками с использованием разнообразных методик и инструментов, включая тестирование, опросы и обратную связь, что обеспечивает объективную и разностороннюю оценку возможностей каждого сотрудника.

Кроме того, SkillTracker позволяет строить индивидуальные планы развития для каждого работника, учитывая его уникальные потребности, карьерные цели и бизнес-задачи компании. Система также осуществляет постоянный мониторинг прогресса в обучении и развитии, что позволяет своевременно корректировать планы и повышать эффективность обучения. В завершение, SkillTracker предоставляет инструменты аналитики и отчетности, предназначенные для руководства и подразделений HR, которые получают доступ к ключевой информации для принятия обоснованных решений, планирования кадровой политики и повышения общей эффективности работы организации. Таким образом, данная система становится важным инструментом для стратегического управления человеческими ресурсами и обеспечения устойчивого развития компании.

Основные компоненты системы SkillTracker включают несколько ключевых модулей, обеспечивающих всестороннюю поддержку процессов развития сотрудников [3].

Первый компонент – база навыков и компетенций, представляющая собой обширный каталог, включающий как специфичные, так и универсальные навыки, необходимые для выполнения различных ролей внутри компании. Этот каталог служит фундаментом для точной оценки и планирования развития персонала.

Второй компонент – модули оценки, которые включают различные методы и инструменты, такие как тесты, опросы, 360-градусная обратная связь и самооценка, позволяющие получить объективную и многогранную картину компетенций каждого сотрудника.

Третий компонент – планирование развития, предоставляющий инструменты для создания, управления и контроля как индивидуальных, так и групповых планов обучения, что способствует целенаправленному и системному развитию навыков.

Четвертый важный компонент – интеграция с корпоративными системами, обеспечивающая связность SkillTracker с другими информационными платформами организации, такими как LMS (Learning Management System), HRIS (Human Resource Information System) и системами отчетности, что позволяет эффективно обмениваться данными и автоматизировать управление процессами развития персонала.

Вместе эти компоненты формируют мощную и гибкую систему, адаптируемую под потребности различных организаций.

SkillTracker функционирует на платформе с веб-доступом, доступен через десктоп и мобильные устройства. Используются технологии искусственного интеллекта и машинного обучения для адаптивной оценки и

рекомендаций по обучению.

2 Этапы внедрения и перспективы развития SkillTracker с применением искусственного интеллекта

Преимущества внедрения SkillTracker для сотрудников включают персонализированное обучение, ориентированное на реальные потребности, ясность карьерных перспектив и целей, а также удовлетворение от профессионального роста и получения новых знаний.

Для руководства и HR система предоставляет объективную информацию о текущем уровне квалификации работников, возможность выявления дефицитов навыков и планирования развития, увеличение вовлеченности персонала и сокращение текучести, поддержку решений по продвижению, ротации и назначению на проекты. Для компании в целом SkillTracker обеспечивает конкурентное преимущество за счет компетентного и адаптивного коллектива, снижение затрат на внеплановое обучение и подбор персонала, а также улучшение качества услуг и продукции.

Этапы внедрения системы SkillTracker включают следующие стадии.

Первый этап – анализ потребностей и постановка целей. Цель этого этапа – определить, как система сможет наилучшим образом удовлетворить потребности организации в управлении развитием компетенций и персонала. В рамках этого этапа проводится определение стратегических целей развития персонала, выявление проблемных областей и недостатков текущей системы обучения, анализ ключевых бизнес-процессов для понимания наиболее востребованных навыков, идентификация необходимых компетенций для различных ролей, выявление ограничений и постановка конкретных целей внедрения. Результатом становится четкое понимание задач и целей системы.

Второй этап – выбор и настройка системы. Цель – подобрать оптимальную платформу для развития навыков и подготовить её для работы в организации. Включает анализ рынка решений, выбор системы с учётом масштабов и требований, настройку базы навыков и компетенций, конфигурацию интерфейсов и модулей, интеграцию с другими системами (LMS, HRIS, ERP) и настройку аналитики и отчетности. Результат – адаптированная к организации корпоративная версия системы, готовая к тестированию.

Третий этап – обучение пользователей. Его цель – обеспечить всех участников проекта необходимыми знаниями и навыками для эффективного использования системы. Действия включают разработку обучающих материалов, проведение тренингов для HR и руководителей, обучение сотрудников и организацию поддержки. Результатом становятся компетентные и мотивированные пользователи.

Четвёртый этап – запуск пилотного проекта. Цель – тестирование системы в ограниченной среде для выявления и устранения проблем. Выполняются выбор и запуск тестовой группы, сбор обратной связи и анализ результатов. Результатом подтверждается эффективность системы и выявляются доработки.

Пятый этап – полномасштабное развертывание. Его цель – внедрить систему в организацию и обеспечить её устойчивое развитие. Действия включают расширение использования на все подразделения, информирование и мотивацию сотрудников, поддержку и обновления системы, мониторинг эффективности и создание постоянной культуры развития.

Итогом становится интегрированная система, способствующая постоянному развитию и эффективности работы организации.

Практические кейсы:

Применения системы SkillTracker показывают её эффективность в различных отраслях. В компании А, специализирующейся на IT-разработке, система активно используется для оценки технических компетенций программистов и менеджеров проектов. Благодаря SkillTracker была выявлена существенная нехватка навыков управления Agile-проектами, что привело к организации специализированного обучающего курса. После его проведения значительно повысилась общая эффективность команд, улучшились процессы разработки и управления проектами стало более слаженным.

В компании Б, работающей в промышленном производстве, SkillTracker помог автоматизировать учет квалификаций работников, что позволило соблюдать строгие нормативы безопасности и повысить качество выпускаемой продукции. Использование системы обеспечило прозрачность в управлении персоналом, своевременное обновление навыков сотрудников и снижение рисков, связанных с несоответствием квалификации требованиям производства. В обоих случаях внедрение SkillTracker способствовало существенному повышению производительности и качества работы.

Технические и организационные рекомендации включают необходимость регулярного обновления базы навыков с учетом изменений технологий и требований рынка. Важно обеспечить прозрачность и простоту интерфейса системы, чтобы максимально повысить вовлеченность пользователей. Также рекомендуется интегрировать SkillTracker с другими корпоративными инструментами для повышения общей эффективности работы и упрощения процессов управления развитием персонала [4].

Возможные сложности при внедрении системы SkillTracker включают сопротивление сотрудников и руководителей изменениям, которое эффективно преодолевается посредством коммуникации и обучения. Недостаток ресурсов для реализации проекта можно сгладить путем поэтапного запуска и использования пилотных проектов. Технические трудности с интеграцией системы требуют качественной технической поддержки и предварительного аудита существующей инфраструктуры для успешного внедрения, и эксплуатации.

Перспективы развития системы SkillTracker связаны с активным внедрением технологий искусственного интеллекта и расширением функциональных возможностей для более точного и эффективного управления развитием персонала. Во-первых, повышение персонализации за счет ИИ позволит создавать индивидуальные планы развития, анализируя

уникальные профильные данные каждого сотрудника – его текущие навыки, карьерные цели, предпочтения и историю обучения, чтобы рекомендовать наиболее подходящие курсы, тренинги и проекты. Кроме того, внедрение адаптивного обучения позволит автоматически подстраивать содержание и сложность программ под уровень знаний работника, что обеспечит оптимальный прогресс и высокую мотивацию к обучению [5].

Во-вторых, система получит возможности проактивного прогнозирования дефицитов навыков. Искусственный интеллект будет анализировать внутренние и внешние рыночные тренды, выявляя потенциальные дефициты еще на ранних стадиях. На основе текущих проектов, изменений бизнес-стратегии и технологических новшеств SkillTracker сможет предсказывать необходимые компетенции в будущем и своевременно инициировать обучение сотрудников, снижая время подготовки к новым требованиям и повышая конкурентоспособность компании.

В-третьих, автоматизация оценки и обратной связи станет ключевым элементом развития. ИИ будет использоваться для объективной оценки навыков на основе тестов, выполнения рабочих задач и анализа результатов, а также для постоянного предоставления персонализированных рекомендаций, учитывая динамику профессионального роста сотрудников.

Четвертая перспективная область – повышение эффективности менеджмента развития персонала. Искусственный интеллект сможет автоматически сегментировать и кластеризовать сотрудников по уровням развития и потребностям, что позволит направлять целенаправленные инициативы. Также будет автоматизировано планирование образовательных программ, распределение бюджета и ресурсов, что оптимизирует управление развитием.

Наконец, расширение аналитических возможностей обеспечит создание комплексных отчетов и визуализаций, предоставляющих руководству детальную картину текущего состояния навыков в компании, выявление пробелов и потенциальных рисков. Отслеживание индивидуального прогресса каждого сотрудника повысит прозрачность процессов и мотивацию персонала к постоянному развитию. Таким образом, дальнейшее развитие SkillTracker обеспечит более интеллектуальное, эффективное и гибкое управление кадровым потенциалом компаний.

В заключение можно отметить, что система развития навыков сотрудников SkillTracker представляет собой мощный и современный инструмент для управления человеческими ресурсами, способствующий комплексному и системному подходу к профессиональному развитию сотрудников.

Благодаря внедрению этой системы организации получают возможность существенно повысить уровень мотивации и вовлеченности персонала, что напрямую отражается на их продуктивности и удовлетворённости работой. SkillTracker помогает не только выявлять и развивать необходимые компетенции, но и поддерживает процессы карьерного роста, что в конечном

итоге способствует достижению стратегических целей компании на всех уровнях. Инвестиции в развитие навыков через использование SkillTracker оправдываются значительным повышением эффективности труда, сокращением текучести кадров и улучшением качества выпускаемой продукции и предоставляемых услуг.

Особенно важно отметить, что в условиях постоянно меняющихся требований рынка и технологического прогресса такие системы становятся залогом устойчивого развития бизнеса. Поэтому рекомендуется всем организациям, стремящимся к долгосрочному росту и конкурентоспособности, рассмотреть вопрос об интеграции эффективных инструментов развития навыков, таких как SkillTracker, в свою HR-практику, что позволит обеспечить стабильное развитие и совершенствование кадрового потенциала.

СПИСОК ЛИТЕРАТУРЫ

1. Ермаков С.С., Быстрова А.В. Анализ исследований роли компьютерных тренажеров в формировании, измерении и совершенствовании навыков командной работы. Журнал экспериментальной психологии, 2024. URL: https://psyjournals.ru/journals/exppsy/archive/2024_n2/Ermakov_Bystrova (дата обращения: 20.09.2025).
2. Digital Practice. Аналитика веб-приложения SkillTracker: оптимизация развития сотрудников. Онлайн-ресурс, 2024. URL: <https://digital-practice.rt.ru> (дата обращения: 24.09.2025).
3. Котенко В.В. Развитие «мягких» навыков обучающихся в условиях программирования. CyberLeninka, 2024. URL: <https://cyberleninka.ru/article/n/razvitie-myagkih-navykov-obuchayuschihsya-pri-izuchenii-programmirovaniya> (дата обращения: 25.09.2025).
4. Фаблинова О.Н. Роль «мягких» навыков в условиях инновационного развития экономики. Экономика и инновации, 2021.
5. Петров Д.В. ИИ и автоматизация оценки навыков сотрудников в современных системах развития персонала. Технологии разработки ПО, 2024.

РАЗРАБОТКА МИКРОСЕРВИСНОЙ ПЛАТФОРМЫ ДЛЯ ХРАНЕНИЯ И ОБРАБОТКИ МЕДИЦИНСКИХ ИЗОБРАЖЕНИЙ

И.А. Пилипенко

Кубанский государственный университет

Статья рассматривает подходы к проектированию и реализации микросервисной платформы, предназначенной для хранения, обработки и визуализации медицинских изображений. Приводятся архитектурные принципы, методы взаимодействия сервисов, использование технологий контейнеризации и балансировки нагрузки. Показано, как подобная

архитектура повышает устойчивость и масштабируемость медицинских ИТ-систем, а также её роль в цифровой трансформации здравоохранения.

Ключевые слова: микросервисная платформа, медицинские изображения, DICOM, PACS, хранение изображений, обработка изображений, сервис ориентированная архитектура, контейнеризация, оркестрация сервисов, масштабируемость, отказоустойчивость, анонимизация медицинских данных, защита персональных данных, шифрование, интеграция с HIS и RIS, стандарты HL7 и FHIR, REST API, машинное обучение для анализа изображений, облачная инфраструктура.

The article presents approaches to the design and development of a microservice platform for storing, processing, and visualizing medical images. It describes architectural principles, interservice communication, and the use of containerization and load balancing. The study demonstrates how such architecture improves reliability and scalability of medical IT systems and supports digital healthcare transformation.

Key words: microservice platform, medical imaging, DICOM, PACS, image storage, image processing, service oriented architecture, containerization, service orchestration, scalability, fault tolerance, medical data anonymization, personal data protection, encryption, integration with HIS and RIS, HL7 and FHIR standards, REST API, machine learning for image analysis, cloud infrastructure.

Развитие цифровых технологий в здравоохранении требует внедрения систем, способных эффективно управлять большими объемами данных, включая медицинские изображения. Традиционные монолитные решения ограничены в масштабируемости и устойчивости, что снижает их эффективность при росте объёмов данных [1].

Микросервисная архитектура позволяет преодолеть эти ограничения, разделяя систему на независимые компоненты, каждый из которых отвечает за конкретную бизнес-функцию. Это повышает гибкость, надёжность и устойчивость всей системы.

Цель данной статьи – рассмотреть теоретические основы микросервисной архитектуры, разработать концепцию платформы для хранения и обработки медицинских изображений и проанализировать её преимущества в медицинской практике [2].

Микросервисная архитектура – это современный подход к построению программных систем, основанный на разделении приложения на автономные сервисы, взаимодействующие между собой по стандартным протоколам. Каждый сервис имеет собственные ресурсы и отвечает за определённый набор функций.

Основные преимущества микросервисной архитектуры:

- модульность и независимость компонентов;
- повышение отказоустойчивости;
- гибкость при обновлениях;
- масштабируемость и простота интеграции с другими системами.

В медицинских информационных системах микросервисы позволяют разделить процессы хранения, анализа, визуализации и обработки изображений, что упрощает сопровождение и развитие системы.

Разрабатываемая платформа включает несколько ключевых сервисов:

1. Сервис хранения данных – основан на S3-совместимом хранилище (MinIO), обеспечивает надёжное хранение больших файлов.
2. Сервис регистрации и метаданных – управляет структурой данных, отслеживает статусы файлов, обеспечивает интеграцию с LIS и PACS.
3. Сервис обработки изображений – реализует конвертацию, извлечение слайдов и нарезку тайлов с использованием OpenSlide и libvips.
4. Сервис визуализации – предоставляет врачам веб-интерфейс для просмотра, масштабирования и аннотирования изображений.
5. Сервис авторизации и аудита – контролирует доступ, ведёт журнал действий пользователей и обеспечивает безопасность данных [3].

Все сервисы разворачиваются в контейнерах Docker и управляются Kubernetes, что гарантирует гибкость и масштабируемость. Для обмена сообщениями используется Kafka, а взаимодействие между сервисами осуществляется через gRPC и REST API.

Пилотное внедрение платформы проведено в лаборатории UNIM. Система успешно обеспечила одновременную обработку более 500 файлов объёмом свыше 100 ГБ в сутки.

Использование кэширования и параллельной обработки позволило сократить время генерации изображений на 40%.

Интерфейс врача интегрирован с реестром медицинских случаев, что позволяет выполнять поиск и визуализацию изображений по идентификаторам пациентов и стёкол.

Система доказала свою устойчивость и возможность масштабирования при росте нагрузки.

В перспективе планируется интеграция с модулями искусственного интеллекта, выполняющими автоматическую классификацию изображений и поиск патологий.

Также ведётся работа над внедрением распределённого хранилища данных с географической избыточностью и модулей для совместной работы исследовательских центров [1].

Развитие облачной версии платформы позволит создавать единую цифровую экосистему здравоохранения, объединяющую медицинские учреждения, исследовательские лаборатории и диагностические центры.

Разработка микросервисной платформы для хранения и обработки медицинских изображений является ключевым направлением цифровизации здравоохранения [4].

Микросервисный подход обеспечивает гибкость, надёжность и масштабируемость, а использование современных технологий обработки изображений – повышение скорости и точности диагностики.

Такие решения создают основу для внедрения искусственного интеллекта и автоматизации диагностических процессов, что ведёт к повышению качества медицинской помощи и эффективности работы врачей.

СПИСОК ЛИТЕРАТУРЫ

- 1 Афанасьев, В. В. Автоматизация бизнес-процессов предприятия. – М.: Инфра-М, 2020. – 352 с.
- 2 Репин, В. В., Елиферов, В. Г. Процессный подход к управлению. Моделирование бизнес-процессов. – М.: Манн, Иванов и Фербер, 2019. – 368 с.
- 3 Харингтон, Дж. Оптимизация бизнес-процессов. Улучшение качества и производительности. – М.: Альпина Паблишер, 2018. – 280 с.
- 4 Официальный сайт фирмы «1С». <https://1c.ru> (дата обращения: 29.09.2025).

ТЕХНОЛОГИЧЕСКИЕ ИННОВАЦИИ ПЛАТФОРМЫ 1С КАК ОСНОВА ДЛЯ ЦИФРОВИЗАЦИИ ПРЕДПРИЯТИЙ

А.Е. Пилюгин, А.М. Усейнов

Кубанский государственный университет

В данной статье проанализированы технологические особенности платформы 1С и то, как они помогают в развитии трансформации современных предприятий.

Ключевые слова: технологические инновации, платформа 1С, 1С:Предприятие, цифровизация предприятий, цифровая трансформация бизнеса, low code платформа, конфигурирование и доработка, встроенный язык 1С, распределенные информационные базы, клиент серверная архитектура, веб клиент, мобильный клиент, интеграция с внешними системами, API и веб сервисы, облачные решения 1С, 1С в SaaS модели, автоматизация бизнес процессов, ERP и CRM системы, аналитика и отчетность.

This article analyzes the technological features of the 1C platform and how they help in the development of the transformation of modern enterprises.

Key words: technological innovations, 1C platform, 1C:Enterprise, enterprise digitalization, business digital transformation, low code platform, customization and configuration, 1C built in language, distributed information databases, client server architecture, web client, mobile client, integration with external systems, APIs and web services, 1C cloud solutions, 1C as SaaS, business process automation, ERP and CRM systems, analytics and reporting.

Цифровая трансформация стала неотъемлемой частью стратегии развития современных предприятий. В условиях быстро меняющегося рынка

и технологических изменений компании стремятся повысить свою гибкость, эффективность и конкурентоспособность. Одним из ключевых инструментов, способствующих этим изменениям, является платформа «1С:Предприятие». Эта система предоставляет предприятиям широкий спектр возможностей для автоматизации бизнес-процессов, интеграции различных систем и анализа данных.

Цель данной статьи – проанализировать технологические особенности платформы 1С, обеспечивающие реализацию принципов цифровой трансформации. Особое внимание будет уделено таким аспектам, как использование управляемых форм, распределённых баз данных, встроенные механизмы аналитики и поддержка мобильных клиентов. Также рассмотрим инновации, повышающие гибкость, масштабируемость и интеграционную совместимость решений [1].

Управляемые формы в платформе 1С представляют собой современный инструмент для создания пользовательских интерфейсов. Они обеспечивают единый стиль и интерфейс, механизмы контроля доступа и защиты данных, гибкость.

Способность обеспечивать единый пользовательский интерфейс для всех сотрудников, работающих с системой 1С упрощает процесс обучения пользователей, делает их взаимодействие с системой более интуитивно понятным и снижает вероятность ошибок при работе с программой. Этот единый подход позволяет легко внедрять обновления, а также быстрее внедрять новых сотрудников в процессы работы с системой.

Единый интерфейс помогает не только улучшить взаимодействие, но и повысить эффективность работы за счёт использования стандартных шаблонов. Это позволяет разработчикам значительно сократить время на проектирование интерфейса для новых приложений или функций, что в свою очередь влияет на скорость реагирования компании на внешние и внутренние изменения.

Гибкость позволяет адаптировать интерфейс под специфические потребности каждого предприятия или даже каждого пользователя. Например, для разных категорий сотрудников можно создавать кастомизированные версии интерфейсов, учитывая их роли и задачи в рамках компании.

Кроме того, управляемые формы поддерживают интеграцию с различными внешними сервисами и системами, что позволяет расширить их функциональные возможности и сделать интерфейсы более универсальными. Это особенно важно для компаний, использующих несколько различных решений для управления бизнес-процессами, потому что с помощью управляемых форм можно обеспечить единый пользовательский интерфейс для взаимодействия с несколькими системами.

Безопасность данных – 1С предоставляют разработчикам широкий набор инструментов для реализации контроля доступа и защиты данных на разных уровнях. Это включает в себя контроль доступа на уровне пользовательских ролей. Каждому пользователю или группе пользователей можно задать

специфичные права доступа к различным частям системы. Например, сотрудники, работающие с финансовыми данными, могут иметь доступ только к тем разделам и данным, которые необходимы для их работы, в то время как другие пользователи могут иметь доступ к информации другого типа. Также Управляемые формы позволяют реализовывать механизмы многоуровневой аутентификации и авторизации, включая биометрические данные, одноразовые пароли и другие современные средства защиты. При работе с управляемыми формами данные могут быть зашифрованы, что обеспечивает их защиту как на стадии передачи, так и на стадии хранения. Все действия пользователей с управляемыми формами могут быть зафиксированы в журналах, что позволяет отслеживать любые изменения в системе и при необходимости проводить аудит безопасности. Это не

Платформа 1С регулярно выпускает обновления, которые включают улучшения интерфейсов, улучшения в области безопасности и повышения эффективности работы. Благодаря управляемым формам обновления системы могут быть быстро и безболезненно внедрены на всех рабочих местах, без необходимости вручную изменять пользовательские интерфейсы. Это позволяет значительно сократить время на адаптацию пользователей к новым возможностям и интерфейсам, что важно для динамично развивающихся компаний.

Также стоит отметить, что управляемые формы дают возможность пользователям настраивать интерфейс в зависимости от текущих потребностей. Например, можно изменять вид отображаемых данных, скрывать или показывать определённые элементы в зависимости от задачи, что значительно повышает удобство работы.

Разработчики, использующие платформу 1С, выигрывают от работы с управляемыми формами, так как они позволяют значительно упростить и ускорить процесс создания новых приложений. Управляемые формы избавляют от необходимости вручную создавать и стилизовать пользовательские интерфейсы, а также заботиться о совместимости между различными устройствами и версиями операционных систем. Это даёт разработчикам возможность сосредоточиться на бизнес-логике и функционале приложений, а не на их визуальном оформлении и настройках.

Распределённые базы данных обеспечивают высокую доступность, масштабируемость и отказоустойчивость системы 1С. Эти особенности критичны для современных предприятий, которым необходимо эффективно управлять большими объёмами данных, обеспечивать бесперебойную работу даже в условиях высокого трафика и нагрузок, а также минимизировать риски потери данных и сбоев в работе системы [2].

Масштабируемость системы – это способность увеличивать ресурсы системы (например, вычислительную мощность или объём хранимых данных) без значительных изменений в архитектуре. Основные аспекты масштабируемости: горизонтальное масштабирование, легкость в управлении большим объёмом данных, гибкость в настройках

Отказоустойчивость – это способность системы продолжать работать в случае возникновения непредвиденных сбоев или поломок. В распределённых базах данных платформа 1С предоставляет несколько механизмов, которые обеспечивают высокую доступность и защиту данных от потерь. В них входит репликация данных, позволяющая в случае сбоя одного из серверов перенаправить запросы на другие доступные сервера, не прерывая работу системы, и балансировка нагрузки, позволяющая равномерно распределять запросы между несколькими серверами.

Локальные узлы для разных функций: Для разных бизнес-процессов можно настроить распределение данных по различным узлам, чтобы каждый узел обслуживал свою определённую задачу. Например, один узел может отвечать за финансовые данные, другой – за данные о клиентских заказах, третий – за информацию о складах. Это снижает конкуренцию за ресурсы на одном сервере и ускоряет обработку запросов.

Снижение задержек, поскольку данные могут храниться и обрабатываться ближе к месту их использования (например, в разных офисах или регионах), время отклика системы сокращается. Это особенно важно для приложений с высокой требовательностью к скорости отклика, таких как системы учёта или CRM-системы.

Одним из значимых преимуществ распределённых баз данных является их способность интегрироваться с внешними системами. Это важная особенность для компаний, которые используют несколько информационных систем, таких как CRM, ERP, и другие, и нуждаются в слаженной работе всех этих систем.

Для эффективного функционирования распределённых баз данных необходимы инструменты для их управления и мониторинга. Платформа 1С предоставляет расширенные возможности для администрирования распределённых баз данных, включая интерфейсы мониторинга и автоматическое управление резервным копированием.

В современном бизнесе мобильность становится одним из решающих факторов для обеспечения высокой эффективности работы сотрудников. Работники, не привязанные к определённому месту, могут оперативно реагировать на изменения, принимать решения на ходу и оставаться в курсе всех актуальных событий [3].

Для эффективного функционирования распределённых баз данных необходимы инструменты для их управления и мониторинга. Системы мониторинга позволяют отслеживать состояние серверов и баз данных, определять их загрузку и наличие сбоев, а также оперативно реагировать на возникающие проблемы. Распределённые базы данных позволяют настроить автоматическое создание резервных копий данных, что даёт дополнительные гарантии безопасности и защищённости информации.

Поддержка работы с мобильными приложениями на различных операционных системах, включая iOS и Android, позволяет обеспечить гибкость и возможность выбора для бизнеса, учитывая специфику

используемых устройств. Разработчики могут настроить мобильную версию приложения с учётом специфики работы компании, предоставив пользователям только те функции, которые необходимы для их работы [4].

Поддержка мобильных клиентов на платформе 1С предоставляет пользователям возможность работать с системой в любое время и в любом месте. Решения для мобильных клиентов 1С применимы в различных сферах бизнеса, от продаж до логистики и обслуживания.

Мобильные приложения могут работать в оффлайн-режиме, что позволяет сотрудникам продолжать работать с данными даже в условиях, когда подключение к сети невозможно.

Мобильные клиенты 1С позволяют торговым представителям работать с заказами, проверять наличие товаров на складе, получать информацию о клиентах, выставлять счета и даже заключать сделки непосредственно в полевых условиях.

Внедрение подходов low-code и no-code разработки позволяют значительно ускорить процесс создания и адаптации приложений под потребности бизнеса. Low-code разработка позволяет создавать и настраивать приложения с минимальным количеством программирования, используя визуальные инструменты и шаблоны. No-code подход предоставляет возможность разрабатывать приложения без написания кода, используя только визуальные редакторы. Данные подходы позволяют бизнес-пользователям самостоятельно создавать необходимые отчёты, формы и рабочие процессы, не тратя времени на написание сложного кода [5].

Высокая интеграционная совместимость с другими системами позволяет эффективно обмениваться данными и работать в едином информационном пространстве с различными внешними решениями. Платформа 1С поддерживает различные стандарты и протоколы для интеграции с внешними системами, такими как XML, JSON, REST API и другие.

Интеграции с облачными решениями обеспечивают широкие возможности для бизнеса. Например, 1С:Облако, которое предоставляет предприятиям возможность использовать все преимущества платформы 1С без необходимости инвестировать в дорогостоящую инфраструктуру. Это решение позволяет пользоваться актуальными версиями программного обеспечения, автоматическими обновлениями и резервным копированием данных без необходимости собственных затрат на серверы и IT-персонал [6].

Облачные решения на платформе 1С позволяют быстро масштабировать инфраструктуру в зависимости от роста бизнеса. Если компания расширяет штат сотрудников или увеличивает объём данных, она может легко увеличить мощности облачной платформы без необходимости в значительных капитальных вложениях. Облачные решения платформы 1С обеспечивают постоянный доступ к данным и приложениям, что значительно повышает мобильность бизнеса.

Инновации контейнеризации и микросервисной архитектуры, которые обеспечивают ещё большую гибкость и адаптивность её решений.

Контейнеризация позволяет создавать изолированные и лёгкие в развертывании среды для приложений. Микросервисы обеспечивают возможность независимой разработки и развертывания различных модулей, что повышает устойчивость и масштабируемость систем [7].

Микро-сервисная архитектура позволяет разделить сложные бизнес-приложения на независимые компоненты, каждый из которых отвечает за отдельную функцию. Микро-сервисы обеспечивают возможность независимой разработки и развертывания различных модулей, что повышает устойчивость и масштабируемость системы.

Контейнеризация позволяет создавать изолированные и лёгкие в развертывании среды для приложений. Это снижает зависимость от конкретных серверов и операционных систем, обеспечивая гибкость при развертывании системы на разных платформах.




Рисунок 1 – Внедренные решения по стране

Управляемые формы на платформе 1С играют ключевую роль в цифровой трансформации предприятий, предоставляя уникальные возможности для улучшения взаимодействия пользователей с системой. Они обеспечивают высокий уровень безопасности данных, упрощают процесс разработки и дают возможность адаптировать интерфейсы под специфические требования бизнеса. Согласно данным, управляемые формы внедрены в 85% проектов, что свидетельствует об их широкой востребованности и эффективности.

Другие технологии платформы также активно применяются на предприятиях: распределённые базы данных внедрены примерно в 70% случаев, что обеспечивает масштабируемость и отказоустойчивость систем.

Мобильные клиенты используются в 60% организаций, поддерживая мобильность и оперативность сотрудников. Технологии low-code и no-code разработки, которые ускоряют создание и адаптацию приложений, присутствуют в 55% проектов. Интеграционные решения и облачные сервисы применяются в 65% внедрений, способствуя единству информационного пространства и гибкости. Контейнеризация и микросервисная архитектура внедрены в 50% случаев, обеспечивая модульность и устойчивость приложений.

Данные проценты отражают текущее состояние цифровой трансформации на базе платформы 1С, демонстрируя ведущую роль управляемых форм, а также постепенный рост интеграционных и современных архитектурных решений, что вместе формирует комплексную и эффективную цифровую инфраструктуру предприятия.

СПИСОК ЛИТЕРАТУРЫ

1. Орлов, В.А., Смирнов, И.В. Цифровая трансформация предприятий на базе платформы «1С:Предприятие». // Вестник информационных технологий. 2023. №4. С. 45-52. URL: <https://izd-mn.com/PDF/06MNNPM21.pdf> (дата обращения: 20.09.2025)
2. Иванов, П.С. Инновационные возможности управляемых форм в 1С и их влияние на бизнес-процессы. // Программные продукты и системы. 2024. Т.26, №2. С. 32-39. URL: https://educonf.1c.ru/conf2024/%D1%82%D0%BE%D0%BC_2_v7.pdf (дата обращения: 21.09.2025)
3. Кузнецов, А.Н. Распределённые базы данных в платформах автоматизации: особенности и применение. // Автоматизация и управление. 2023. №11. С. 67-74. URL: <https://bit.spels.ru/index.php/bit/article/view/1774> (дата обращения: 21.09.2025)
4. Сидоров, М.В. Мобильные клиенты и цифровая трансформация предприятий на примере 1С. // Информационные технологии в экономике. 2022. №9. С. 22-29. URL: <https://cyberleninka.ru/article/n/avtomatizatsiya-biznes-protseessov-s-ispolzovaniem-1s-preimuschestva-i-vozmozhnosti> (дата обращения: 24.09.2025)
5. Петров, Д.В. Низкокодové и безкодové технологии разработки в современной платформе 1С. // Технологии разработки ПО. 2024. №1. С. 14-20.
6. Фролова, Е.В. Интеграция и облачные решения в платформе 1С: тенденции и перспективы. // Облачные вычисления и бизнес. 2023. №6. С. 55-61. URL: <https://1c.ru/rus/partners/konf0623.jsp> (дата обращения: 24.09.2025)
7. Лазарев, С.М. Контейнеризация и микросервисная архитектура в современных корпоративных информационных системах. // Журнал системной архитектуры. 2024. №3. С. 10-16. URL: <https://deckhouse.ru/blog/10-trendov-kontejnerizaczii-kotorye-opredelyat-razvitie-it-infrastruktury-v-2024-godu/> (дата обращения: 24.09.2025)

ТЕНДЕНЦИИ И ПЕРСПЕКТИВЫ 3D-ВИЗУАЛИЗАЦИИ: СТАНДАРТЫ, НЕЙРОСЕТЕВЫЕ МЕТОДЫ И ИНДУСТРИАЛЬНЫЕ ПРАКТИКИ

А.И. Питинов, И.С. Черкунов
Кубанский государственный университет

В данной описываются методы создания реалистичной интерактивной графики. Рассматриваются способы ускорения работы и улучшения качества за счет автоматизации и нейросетей.

Ключевые слова: 3D визуализация, типы 3D контента, графические движки, стандарты 3D форматов, glTF, USD, PBR материалы, фотореалистичный рендеринг, трассировка лучей, нейросетевые методы рендеринга, генерация 3D объектов, восстановление 3D сцены по изображениям, диффузионные модели, нейронные поля освещенности, виртуальная и дополненная реальность, цифровые двойники, индустриальные практики, игровые движки в промышленности, CAD и BIM системы, визуализация для маркетинга и обучения.

This paper describes methods for creating realistic interactive graphics. It examines ways to speed up work and improve quality through automation and neural networks.

Key words: 3D visualization, types of 3D content, graphics engines, 3D format standards, glTF, USD, PBR materials, photorealistic rendering, ray tracing, neural rendering methods, 3D object generation, 3D scene reconstruction from images, diffusion models, neural radiance fields, virtual and augmented reality, digital twins, industrial practices, game engines in industry, CAD and BIM systems, visualization for marketing and training.

3D-визуализация сегодня выступает не только средством демонстрации, но и рабочим инструментом для обучения, проектирования и принятия решений. В учебных тренажерах она помогает быстро показать причинно-следственные связи и последствия действий; в промышленности и цифровых двойниках делает наглядными износ, загрязнение и изменения состояния оборудования; в робототехнике и человеко-машинных интерфейсах обеспечивает читаемую обратную связь о сцеплении, ошибках и рисках. Развитие интерактивного освещения и геометрии в реальном времени, а также появление общих форматов описания сцены и материалов позволяют достигать кинематографического качества без долгих офлайн-просчетов и ускоряют цикл разработки.

Практическая актуальность темы для проектов на игровых движках заключается в снижении доли ручного тюнинга и в повышении переносимости контента между инструментами. Использование согласованных форматов сцены и материалов облегчает совместную работу и воспроизводимость внешнего вида, а веб-рендеринг делает возможной публикацию

интерактивных моделей в браузере без установки клиента. Дополнительный вклад вносят нейросетевые методы, которые помогают улучшать изображение и ускоряют подготовку ассетов при сохранении договоренностей о внешнем виде. Настоящая работа систематизирует эти направления с точки зрения разработчика, фокусируясь на пользе для учебных и прикладных сцен в Unreal Engine и смежных экосистемах.

Под рендерингом в реальном времени понимается формирование изображения с частотой, достаточной для интерактивного управления сценой, при котором освещение, тени и отражения согласованно обновляются при изменении положения камеры и объектов. Целью является достижение визуальной достоверности при сохранении стабильной частоты кадров; при этом приоритет отдается устойчивости изображения в динамике, а не разовым пиковым эффектам. Практически значимым требованием является стабильность визуализации при движении камеры и резких изменениях освещения. Для этого в процессе разработки проводится регулярный просмотр контрольных траекторий с фиксированными ракурсами и скоростями. Оцениваются наличие мерцания теней, «шум» и распад отражений, а также читаемость ключевых деталей сцены. Такой протокол позволяет выявлять регрессии на ранней стадии и подтверждать воспроизводимость результата между сборками.

В целях масштабируемости заранее определяется и документируется иерархия качественных настроек для различных аппаратных конфигураций. На высоком уровне допускаются более точные модели освещения и отражений, на среднем применяются вычислительно умеренные приближения, на базовом сохраняются только те составляющие, которые критичны для понимания происходящего в сцене. Важным считается не набор конкретных опций, а инвариантность смысловых акцентов: визуальные подсказки, зоны риска и следы действий должны оставаться читаемыми на всех уровнях.

Под материалом в контексте 3D-визуализации понимается совокупность оптических свойств поверхности и связанных с ними параметров шейдинга, обеспечивающих воспроизводимый внешний вид объекта при изменении освещения и ракурса. Базовая практика опирается на физически обоснованное описание отражения, в котором энерго-согласованная диффузная и зеркальная составляющие формируются из ограниченного набора параметров. К числу таких параметров обычно относят базовый цвет, характеристику микрошероховатости, долю проводящей компоненты, нормали мелкого рельефа и дополнительные скалярные коэффициенты, отвечающие за окклюзию, прозрачность и толщину слоя. Физически корректное представление материалов сделало поведение поверхностей предсказуемым между редакторами, движками и визуализаторами. Когда для дерева, металла и стекла используются согласованные параметры и текстуры, разработчик меньше времени тратит на ручную подгонку и больше на логику приложения. Отдельное значение имеют переносимые описания материалов. Стандарты

уровня сцены позволяют задавать внешний вид так, чтобы он сохранял смысл при перемещении между инструментами, а не превращался в набор несовместимых узлов.

Общие форматы сцен и обмена моделями решают ключевую задачу переносимости: один и тот же набор объектов, материалов и настроек должен воспроизводиться предсказуемо в разных инструментах подготовки и в целевом приложении. Для этого форматы описывают геометрию, иерархию сцены, трансформации, назначение материалов и сопутствующие метаданные в машиночитаемом и проверяемом виде. Наличие явных соглашений по единицам измерения, ориентации осей и управлению цветом снижает риск расхождений внешнего вида после импорта. Для крупных проектов важна поддержка вариативности и управления версиями. Современные описания сцен позволяют хранить альтернативные конфигурации объектов, переключаемые наборы материалов и уровни детализации, а также фиксировать историю изменений. Такое представление облегчает работу распределенных команд, упрощает сборку разных версий под разные целевые платформы и позволяет подключать различные рендер-бэкенды без переработки исходных данных.




Рисунок 1 – Материалы и внешний вид

В приложениях, ориентированных на доставку ассетов в среде выполнения, приоритетом становятся компактность, скорость загрузки и воспроизводимый внешний вид без ручной правки. Форматы, рассчитанные на исполнение, стремятся к минимальному числу зависимостей и чётко определённым материалам, чтобы исключить «сюрпризы» после импорта на устройство пользователя. В результате сокращается количество ошибок на стыке этапов пайплайна, ускоряется интеграция новых стадий обработки и повышается повторяемость визуального результата.

3D-графика в браузере вышла на уровень, достаточный для учебных, инженерных и демонстрационных задач. Современные веб-интерфейсы позволяют работать напрямую с возможностями видеокарты в окне сайта,

поэтому интерактивные сцены запускаются без установки специализированного ПО и без привязки к операционной системе. Это снимает типовые барьеры: преподаватель открывает модель на лекции, инженер делится результатами визуальной аналитики по ссылке, студент публикует прототип для обратной связи – пользователю нужен только обновлённый браузер. Практическая ценность веб-подхода состоит в простоте распространения и контролируемой среде исполнения. Сборка проекта один раз размещается на сервере и становится одинаково доступной на настольных и мобильных устройствах; обновления доставляются автоматически, а вопросы совместимости решаются централизованно. Для учебных курсов это означает предсказуемый старт лабораторных работ: все участники видят одну и ту же сцену, одни и те же материалы и получают сопоставимые результаты. Для прикладных задач удобно организуется «тонкий клиент»: расчеты и подготовка данных выполняются на сервере, а визуализация и взаимодействие в браузере.

Отдельного внимания требуют вопросы производительности и веса ассетов. Чтобы сцены загружались быстро и работали плавно, используется потоковая подгрузка моделей и текстур, сжатие данных и согласованные форматы обмена. Важна дисциплина бюджета: крупные сетки и текстуры применяются только там, где они действительно влияют на читаемость, остальное заменяется упрощенными представлениями. При этом читаемость подсказок и «следов» действий имеет приоритет над второстепенными эффектами. Такой баланс позволяет сохранить достоинства веб-доставки и добиться устойчивой работы даже на средних устройствах.

Методы машинного обучения заняли устойчивое место в графическом пайплайне, выступая ускорителями и помощниками, а не заменой классическим алгоритмам. На этапе формирования изображения нейронные модели улучшают качество при ограниченном времени рендера: подавляют шум, сглаживают мерцание, восстанавливают детали и повышают видимое разрешение. Это повышает стабильность сцены в движении и помогает удерживать целевую частоту кадров без заметной потери читаемости. Вторая зона применения полуавтоматическая подготовка ассетов. Генеративные подходы ускоряют создание карт материалов, вариаций повреждений и маркировок, экономя время на рутинных операциях. В учебных и исследовательских проектах это особенно полезно: можно быстро собрать несколько версий одной сцены, проверить на них гипотезы и выбрать конфигурацию, которая обеспечивает понятную обратную связь пользователю. При этом сохраняется ключевое требование физическая правдоподобность: материал должен вести себя как материал, а не как декоративная текстура. Этого добиваются сочетанием генеративных методов с правилами PBR и обязательной визуальной валидацией.

В учебных тренажерах современная визуализация делает процесс обучения наблюдаемым и проверяемым. Пользователь видит не только итог, но и ход действий: где возник контакт, к чему привёл неверный приём, на

каком этапе следовало скорректировать усилие. Последовательные подсветки и «следы» взаимодействия упрощают разбор на занятиях и сокращают время до уверенного выполнения типовых операций. В прикладной промышленной практике визуализация помогает выявлять узкие места и согласовывать решения между подразделениями. На 3D-модели удобно показать зоны износа, накопления загрязнений или следов перегрева, оценить влияние операций на соседние узлы и определить приоритеты обслуживания. Использование переносимых материалов и моделей уменьшает объём ручных правок при переходе между инструментами и повышает сопоставимость результатов во времени. В человеко-машинных интерфейсах ценится предсказуемая обратная связь. Чёткие маркеры сцепления, скольжения, перегруза и ошибок позволяют оператору корректировать действия до наступления критического события. Визуальные подсказки проектируются так, чтобы поддерживать внимание в динамике и не перегружать кадр второстепенными эффектами, сохраняя читаемость на разных классах оборудования.

В образовательных и научно-популярных проектах 3D-визуализация делает причинно-следственные связи явными. Сложные явления раскрываются через последовательность понятных кадров и интерактивных шагов, что повышает вовлеченность и качество усвоения материала. Возможность публикации сцен в браузере расширяет аудиторию и упрощает демонстрации в лабораториях и аудиториях без установки дополнительного программного обеспечения. Для аналитики и последующего разбора визуализация предоставляет единый «след» действий и изменений состояния. Накопленные отметки контактов, зон риска и ошибок связываются с временной шкалой, что облегчает восстановление контекста, проверку гипотез и принятие решений. Такой подход повышает доверие к визуальной информации, превращая её из иллюстрации в инструмент обучения, диагностики и управления процессами.

Актуальные исследования направлены на уменьшение разрыва между «идеальным» внешним видом и ограничениями интерактивной производительности. Ведущую роль здесь играют группы NVIDIA Research, Microsoft Research, Intel Graphics Research и AMD Radeon Technologies Group, которые продвигают методы освещения, комбинирующие малое число выборок с устойчивой во времени реконструкцией. Их цель обеспечить стабильные тени и непрямой свет без заметного шума при стандартной частоте кадров; по мере созревания таких подходов снижается потребность в длительной предварительной подготовке сцен и ручной подгонке параметров. В области представления сцены усилия сосредоточены на унификации описаний материалов и процедур их преобразования между инструментами; заметный вклад вносят Pixar / OpenUSD и Adobe Research (совместно с экосистемой MaterialX/OpenPBR) [1]. Формализуются словари свойств и их допустимые диапазоны, а также правила интерпретации карт рельефа, шероховатости и отражения. Прогресс в этих направлениях уменьшает

расхождения внешнего вида при переносе ассетов и делает авторские решения более воспроизводимыми [2].

Для подготовки контента расширяется применение полуавтоматических средств: генерация вариативных текстур и маркировок, восстановление недостающих деталей, ускоренная ретопология и нормализация масштаба. Эти инструменты активно развиваются и в среде разработчиков движков, где инициативы Epic Games (Unreal Engine Graphics) и Adobe Research позволяют снимать значительную часть рутинных операций и сокращать цикл итераций. Параллельно совершенствуется потоковая доставка ассетов и адаптивная подгрузка уровней детализации в веб-среде, что делает интерактивные сцены доступнее без установки клиента на широком спектре устройств. Серьезную силу набирают практики измеримой валидации качества. Эталонные сцены, методики скриншот-регрессии и протоколы сопоставления визуальных результатов между версиями систематизируются и поддерживаются индустриальными и стандартизирующими организациями; здесь важна координация со стороны Khronos Group и сообщества вокруг OpenUSD, а также публикации NVIDIA Research и Microsoft Research, что позволяет фиксировать стабильность конвейера, контролировать побочные эффекты оптимизаций и предметно обсуждать компромиссы между качеством и скоростью [3].

Полная согласованность внешнего вида материалов между разными инструментами и конвейерами остается трудной задачей. Даже при использовании схожих параметризаций по-разному трактуются микрорельеф, шероховатость, энергетический баланс отражения и порядок тонального отображения. Небольшие расхождения на каждом этапе накапливаются и дают заметную разницу в итоговом кадре, особенно на граничных случаях – тонкие плёнки, анизотропия, многослойные покрытия. Крупные и динамические сцены по-прежнему сталкиваются с ограничениями устройств начального уровня и мобильных конфигураций. Потоковая подгрузка геометрии и текстур, использование сжатых форматов и адаптивные уровни детализации заметно улучшают ситуацию, но не устраняют фундаментальные узкие места – ограниченный объём оперативной и видеопамати, невысокую пропускную способность подсистем хранения и ограниченный бюджет вычислений на кадр. Поддержание стабильной частоты кадров в таких условиях неизбежно требует управляемых компромиссов: приходится уменьшать точность и глубину глобального освещения, упрощать материалы с тяжёлой зеркальной составляющей, сокращать интенсивность постобработки и аккуратно перераспределять бюджет между подсистемами. Это, в свою очередь, влияет на единообразие пользовательского опыта: одна и та же сцена выглядит и ощущается по-разному на разных классах оборудования, и разработчикам приходится заранее проектировать «лестницу качества», чтобы сохранять читаемость ключевых подсказок при любом профиле производительности.

Недостаточно зрелыми остаются и метрики качества, которые учитывают особенности человеческого восприятия. Формальные показатели частота кадров, время на кадр, суммарная стоимость проходов, статические метрики ошибок изображения важны для технической диагностики, но они почти не отражают «когнитивную читабельность» сцены: насколько быстро оператор замечает визуальную подсказку, отличает штатный режим от аварийного, удерживает внимание на нужных элементах при движении камеры и изменении освещения [4].




Рисунок 2 – Метрики качества визуализации

Отсутствие согласованных протоколов таких испытаний затрудняет сопоставление альтернативных решений и делает обсуждение компромиссов между качеством и скоростью менее предметным. По сути, индустрии не хватает стандартных сценариев тестирования с фиксированными траекториями, наборами освещения и контрольными раскадровками, а также порогов восприятия, на которые можно опираться при принятии инженерных решений [5].

Рассмотренные в работе направления показывают, что индустрия 3D-визуализации последовательно движется к согласованной экосистеме, в которой внешний вид и структура сцены описываются переносимыми средствами, а интерактивная картинка достигает уровня, достаточного для учебных, инженерных и демонстрационных задач. Унификация представления материалов и сцен снижает зависимость результата от конкретного инструмента подготовки, облегчает совместную работу и делает возможной воспроизводимость визуального эффекта в среде выполнения без длительного ручного тюнинга. Это принципиально важно там, где визуализация выступает не только средством иллюстрации, но и рабочим инструментом – в тренажерах, системах технадзора, робототехнических

интерфейсах и образовательных средах. Доступность реалистичного освещения в реальном времени меняет подход к проектированию сцен: акцент смещается с предварительного запекания и локальных «хаков» на управление бюджетом и устойчивость изображения в движении. При таком подходе сцену можно быстрее собирать, модифицировать и проверять на типовых траекториях камеры и наборе освещающих условий. Практическая ценность состоит в сокращении цикла итераций и в предсказуемом качестве на разных классах оборудования при сохранении читабельности ключевых подсказок и «следов» действий. Тесная интеграция с веб-средой расширяет аудиторию и упрощает распространение интерактивных материалов. Веб-доставка снижает порог входа для обучающихся и специалистов смежных профилей, а единые форматы обмена делают возможным повторное использование ассетов в настольных приложениях и в браузере без ухудшения воспринимаемого качества. На стороне подготовки контента заметную роль играют полуавтоматические инструменты и нейронные методы, которые снимают часть рутины, ускоряют проверку гипотез и, при соблюдении оговоренных правил PBR и управления цветом, сохраняют физическую правдоподобность результата. Одновременно сохраняется ряд ограничений, которые определяют зону ответственности разработчика [6].

В совокупности эти факторы формируют устойчивый вектор развития на ближайшую перспективу: визуализация становится инфраструктурной технологией для обучения, диагностики и поддержки решений. Её ценность определяется не только эстетикой изображения, но и прозрачностью пайплайна, переносимостью данных и ясностью визуальной коммуникации. При последовательном выполнении этих условий 3D-сцены перестают быть «картинкой» и превращаются в надежный инструмент, который помогает быстрее обучать, точнее анализировать и увереннее действовать в реальных задачах [7].

СПИСОК ЛИТЕРАТУРЫ

1. OpenUSD. Официальная документация. [Электронный ресурс]. URL: <https://openusd.org> (дата обращения: 30.09.2025).
2. Pixar. USD Glossary & Overview. [Электронный ресурс]. URL: <https://graphics.pixar.com/usd/docs/index.html> (дата обращения: 30.09.2025).
3. Khronos Group. glTF 2.0 Specification. [Электронный ресурс]. URL: <https://registry.khronos.org/glTF/specs/2.0/glTF-2.0.html> (дата обращения: 30.09.2025).
4. ISO/IEC 12113:2022. Information technology – glTF™ 2.0 format specification. [Электронный ресурс]. URL: <https://www.iso.org/standard/81083.html> (дата обращения: 30.09.2025).
5. Academy Software Foundation. MaterialX Specification. [Электронный ресурс]. URL: <https://materialx.org/> (дата обращения: 30.09.2025).

6. Academy Software Foundation. OpenPBR: A Physically-Based Material Model. [Электронный ресурс]. URL: <https://academysoftwarefoundation.github.io/OpenPBR/> (дата обращения: 30.09.2025).

7. W3C. WebGPU (Working Draft). [Электронный ресурс]. URL: <https://www.w3.org/TR/webgpu/> (дата обращения: 30.09.2025).

ИССЛЕДОВАНИЕ ВОЗМОЖНОСТИ УЛУЧШЕНИЯ КАЧЕСТВА ИЗОБРАЖЕНИЯ ПОЛУЧАЕМОГО ВИДЕОПОТОКА С ПОМОЩЬЮ АЛГОРИТМА МАШИННОГО ОБУЧЕНИЯ YOLO

В.В. Порозов

Кубанский Государственный университет

В работе исследуется возможность улучшения качества видеопотока с помощью алгоритма YOLO. Рассматривается влияние разрешения, шумов и артефактов на точность распознавания объектов, а также использование методов восстановления изображений для повышения эффективности детектирования.

Ключевые слова: YOLO, видеопоток, улучшение качества изображения, детектирование объектов, машинное обучение, нейронные сети.

This paper explores the possibility of improving video stream quality using the YOLO algorithm. The impact of resolution, noise, and artifacts on object recognition accuracy is considered, as well as the use of image restoration methods to improve detection efficiency.

Key words: YOLO, video stream, improvement of image quality, object detection, machine learning, neural networks.

Современные системы компьютерного зрения становятся неотъемлемой частью технологий обработки визуальной информации. Камеры и сенсоры используются в самых разных областях – от систем видеонаблюдения и беспилотных транспортных средств до медицинской диагностики и промышленной автоматизации. Для автоматического анализа видеопотоков применяются нейронные сети, способные в реальном времени распознавать и классифицировать объекты. Одним из наиболее известных и эффективных алгоритмов такого типа является YOLO (You Only Look Once).

Однако точность работы нейронных сетей во многом зависит от качества входных данных. Видеопотоки нередко содержат шум, артефакты, низкое разрешение или размытость, что значительно снижает достоверность детектирования. Особенно это заметно при работе с уличными камерами, дронами или видеопотоками, полученными в сложных условиях освещения. В связи с этим исследование методов улучшения качества изображения перед подачей на вход YOLO является актуальной задачей современной науки и

техники.

Целью данной работы является исследование возможности улучшения качества видеопотока с помощью алгоритмов машинного обучения и оценка их влияния на точность детектирования объектов нейронной сетью YOLO.

Для достижения цели были поставлены следующие задачи:

- 1) Изучить архитектуру и принципы работы YOLOv8;
- 2) Проанализировать влияние качества изображения на точность распознавания;
- 3) Рассмотреть современные алгоритмы повышения качества изображений;
- 4) Провести эксперимент по обработке видеопотока с применением алгоритмов суперразрешения и фильтрации;
- 5) Сравнить результаты детектирования до и после улучшения качества видео.

YOLO (You Only Look Once) – это семейство сверточных нейронных сетей, предназначенных для детектирования объектов на изображениях и в видеопотоках в режиме реального времени. Алгоритм был предложен Джозефом Редмоном в 2015 году и стал прорывом в области компьютерного зрения. В отличие от более ранних подходов, таких как R-CNN и Fast R-CNN, YOLO рассматривает задачу детектирования как регрессию от изображения к координатам объектов и их классам, выполняя анализ за один проход нейросети [1].

Главное преимущество метода заключается в том, что нейросеть одновременно выполняет выделение признаков, классификацию и локализацию объектов, что обеспечивает высокую скорость обработки и возможность работы с видеопотоком в реальном времени. Этот принцип однократной обработки (single-shot detection) позволил YOLO стать базой для множества современных систем видеоаналитики.

С момента появления первой версии YOLO архитектура неоднократно улучшалась.

YOLOv1 (2015) выполняла детектирование в одной сетке 7×7 и демонстрировала высокую скорость, но страдала от потери точности при обнаружении мелких объектов.

YOLOv3 реализовала многоуровневое детектирование и использовала архитектуру Darknet-53.

YOLOv4 включила современные улучшения (Mish, CSPDarknet, PAFNet).

YOLOv5 перешла на PyTorch и добавила новые методы аугментации данных.

YOLOv8 – актуальная версия, использующая безъякорный (anchor-free) подход и оптимизированные блоки C2f, обеспечивающие стабильность и скорость работы.

YOLOv8 состоит из трёх ключевых блоков:

Backbone – отвечает за извлечение признаков из изображения. В этой части используется модифицированная архитектура CSPDarknet с

улучшенными блоками C2f, что повышает эффективность обучения и уменьшает количество параметров.

Neck – объединяет признаки с разных уровней глубины. Здесь применяется структура PAN-FPN, позволяющая улучшить качество детектирования объектов разных размеров.

Head – выполняет финальное предсказание координат и классов объектов. YOLOv8 отказалась от фиксированных “якорей” (anchor boxes), что делает детектирование более универсальным и устойчивым к изменениям масштаба.

Такое разделение позволяет YOLOv8 эффективно анализировать изображение, извлекать информативные признаки и выполнять точное прогнозирование с минимальной задержкой [2].

YOLOv8 обладает высокой скоростью и гибкостью. Модель может автоматически подстраивать разрешение входного изображения, использовать встроенные методы аугментации данных (например, Mosaic и MixUp) и работать с различными аппаратными ускорителями – от видеокарт до мобильных процессоров.

Для оценки качества работы модели применяются метрики:

Precision – доля правильных предсказаний среди всех найденных объектов;

Recall – доля найденных объектов среди всех существующих на изображении;

mAP (mean Average Precision) – усреднённая точность по всем классам.

Высокие значения этих метрик указывают на способность сети распознавать объекты корректно, минимизируя ложные срабатывания. Для видеопотока также важен показатель FPS (frames per second), который характеризует скорость обработки кадров. YOLOv8 способна достигать 50–60 FPS на видеокартах среднего уровня, что делает её пригодной для систем реального времени [3].

К основным преимуществам YOLO относятся:

высокая скорость и возможность работы в реальном времени;

универсальность и лёгкость обучения на новых данных;

компактность архитектуры и поддержка оптимизированных версий для мобильных устройств.

Среди ограничений можно отметить снижение точности при детектировании мелких или размытых объектов и зависимость результата от качества исходного изображения. Однако постоянное развитие архитектуры и использование новых технологий обучения позволяют существенно минимизировать эти недостатки.

Качество видеопотока является одним из ключевых факторов, определяющих эффективность работы нейронных сетей при распознавании объектов. Низкое разрешение, шумы, неравномерное или слабое освещение, сильное сжатие и размытие кадров могут приводить к потере важных признаков и усложнять корректное определение объектов. Для алгоритма

YOLO это особенно критично, поскольку он обрабатывает изображение на уровне относительно небольших фрагментов, а потеря текстурных и контурных деталей значительно затрудняет точное выделение границ объектов [4].

Типичные искажения видеопотока включают:

Шум и артефакты сжатия – приводят к ложным контурам, искажают текстуры и могут вызывать ошибки при выделении признаков;

Размытость – снижает контраст и размывает мелкие объекты, делая их практически незаметными для модели;

Неравномерное освещение – создаёт блики, тени и резкие переходы яркости, что сбивает классификацию и снижает точность;

Падение разрешения – уменьшает количество пикселей, содержащих полезную информацию, и приводит к потере деталей, особенно на дальних планах.

В связи с этим особую важность приобретает этап предобработки видеопотока, включающий методы устранения шума, повышения резкости, выравнивания освещённости и суперразрешения. Применение таких методов позволяет восстановить потерянные детали, повысить чёткость изображения и, как следствие, значительно улучшить качество распознавания объектов нейросетью. Особенно это важно в системах видеонаблюдения, автономных транспортных средствах и других приложениях, где точность анализа видеопотока напрямую влияет на безопасность и надёжность работы системы.

Существует широкий спектр методов повышения качества изображения. Они подразделяются на традиционные и основанные на машинном обучении.

Классические методы включают:

медианную и гауссову фильтрацию;

выравнивание гистограммы (Histogram Equalization);

алгоритмы повышения резкости и устранения шума (Unsharp Masking, Bilateral Filtering).

Современные нейросетевые подходы включают использование генеративно-сопоставительных сетей (GAN) и сверточных автоэнкодеров. Среди них наиболее популярны:

SRGAN – сеть, восстанавливающая высокое разрешение изображений из низкого;

ESRGAN (Enhanced SRGAN) – улучшенная версия, сохраняющая текстурные детали и структуру;

DeblurGAN – алгоритм, устраняющий размытие с помощью генеративной модели;

DnCNN – сверточная сеть, обученная на устранение шумов различных типов.

Эти алгоритмы позволяют не только повысить визуальное качество, но и улучшить детектирование объектов за счёт восстановления важных признаков.

Для проверки гипотезы был проведён эксперимент с видеопотоком,

содержащим объекты городской сцены: пешеходов, автомобили и здания. Обработка выполнялась в два этапа:
1) исходный видеопоток анализировался YOLOv8 без изменений;
2) кадры предварительно улучшались с помощью ESRGAN и медианной фильтрации.

В ходе эксперимента использовались метрики mAP@0.5, Precision и Recall. Для обучения и оценки применялись данные из открытого набора COCO и собственные видеозаписи с камер наблюдения. Обработка проводилась на GPU NVIDIA RTX 3060 с использованием библиотеки Ultralytics YOLOv8.

Результаты показали, что после предобработки видеопотока значение mAP увеличилось с 0.61 до 0.74, а Precision вырос с 0.76 до 0.85. Количество ложных срабатываний снизилось на 12%, а скорость обработки уменьшилась незначительно – с 47 до 42 кадров в секунду.

Проведённые эксперименты подтвердили, что качество входного видеопотока оказывает существенное влияние на точность распознавания объектов. YOLO эффективно выделяет крупные объекты даже на низкокачественных кадрах, однако при наличии размытия и шумов точность падает. Применение ESRGAN позволило восстановить мелкие детали и улучшить контрастность изображения, что повысило стабильность работы детектора.

Особенно заметен эффект при анализе мелких объектов (например, дорожных знаков или пешеходов на дальнем плане). После предобработки YOLO начала корректно определять их даже в сложных условиях освещения. Это подтверждает, что внедрение нейросетевых алгоритмов улучшения изображений перед детектированием повышает качество анализа сцены без необходимости модифицировать архитектуру самой YOLO.

Результаты исследования могут быть применены в следующих областях:

Системы видеонаблюдения – улучшение качества изображения позволяет повысить точность идентификации лиц и номеров автомобилей;

Беспилотный транспорт – повышение надёжности восприятия дорожной обстановки при плохих погодных условиях;

Медицинская визуализация – улучшение качества снимков до анализа позволяет точнее определять патологические изменения;

Робототехника и промышленный контроль – повышение точности распознавания дефектов или объектов.

В будущем перспективным направлением является создание единой модели, совмещающей YOLO с блоком автоматического улучшения изображений, обученным совместно с детектором. Такой подход позволит системе самостоятельно подстраиваться под условия видеосъёмки в реальном времени [5].

В ходе исследования была проведена работа по анализу влияния качества видеопотока на точность работы алгоритма YOLO. Рассмотрены существующие методы предобработки изображений и проведён эксперимент

с использованием ESRGAN и медианной фильтрации. Полученные результаты подтвердили, что улучшение качества изображения позволяет увеличить точность детектирования на 15–20%, не снижая существенно производительность системы.

Таким образом, интеграция алгоритмов повышения качества изображений с системами детектирования объектов является перспективным направлением развития компьютерного зрения. В дальнейшем планируется разработка комбинированных моделей, способных выполнять улучшение и распознавание изображений в едином процессе.

СПИСОК ЛИТЕРАТУРЫ

1. Redmon J., Farhadi A. YOLOv3: An Incremental Improvement. arXiv, 2018.
2. Wang C.Y. et al. YOLOv8 Documentation. Ultralytics, 2023.
3. Xintao Wang et al. ESRGAN: Enhanced Super-Resolution Generative Adversarial Networks, 2018.
4. Купын О., Чурилов А., DeblurGAN: Устранение размытия движения с помощью условных генеративных сетей. CVPR, 2018.
5. Гусев В.А., Панов А.Н. Обработка и анализ изображений: учебное пособие. М.: БХВ-Петербург, 2017.

ИССЛЕДОВАНИЕ ВОЗМОЖНОСТИ УЛУЧШЕНИЯ КАЧЕСТВА ИЗОБРАЖЕНИЯ ПОЛУЧАЕМОГО ВИДЕОПОТОКА С ПОМОЩЬЮ АЛГОРИТМА МАШИННОГО ОБУЧЕНИЯ СВЕРТОЧНЫЕ НЕЙРОННЫЕ СЕТИ (CNN)

С.Е. Пояс

Кубанский государственный университет

В данной статье рассматривается актуальная проблема повышения качества видеопотоков в условиях ограниченной пропускной способности каналов передачи данных и низкого качества исходного видеосигнала. Проводится анализ традиционных методов улучшения изображения и обосновывается преимущество подходов на основе глубокого обучения, в частности, сверточных нейронных сетей (CNN). Исследуются архитектуры CNN, наиболее применимые для задач супер-разрешения, удаления артефактов сжатия и снижения шума. Рассматривается комплексный подход к обработке видеопотока в реальном времени, включая выделение кадров, их обработку нейросетевой моделью и последующую сборку. Приводятся результаты экспериментального сравнения эффективности классического алгоритма бикубической интерполяции и CNN-модели SRCNN на тестовом наборе данных. Показано, что использование CNN позволяет достичь значительного улучшения как объективных метрик качества (PSNR,

SSIM), так и субъективного визуального восприятия.

Ключевые слова: видеопоток, качество изображения, улучшение качества видео, сверточные нейронные сети, CNN, суперразрешение, восстановление изображения, шумоподавление, удаление артефактов сжатия, стабилизация видео, предобработка и постобработка кадров, обучение по парам изображений, архитектуры SRCNN и EDSR, метрики качества PSNR и SSIM, обработка в реальном времени, оптимизация вычислительной сложности, компьютерное зрение

This article addresses the current problem of improving the quality of video streams under conditions of limited bandwidth of data transmission channels and low quality of the source video signal. The analysis of traditional image enhancement methods is carried out and the advantage of approaches based on deep learning, in particular, convolutional neural networks (CNN), is substantiated. CNN architectures most applicable for super-resolution, compression artifact removal and noise reduction tasks are investigated. An integrated approach to real-time video stream processing, including frame extraction, their processing by a neural network model and subsequent assembly, is considered. The results of an experimental comparison of the effectiveness of the classical bicubic interpolation algorithm and the SRCNN CNN model on a test dataset are presented. It is shown that the use of CNN allows for significant improvement in both objective quality metrics (PSNR, SSIM) and subjective visual perception.

Key words: video stream, image quality, video quality enhancement, convolutional neural networks, CNN, super resolution, image restoration, denoising, compression artifact removal, video stabilization, frame preprocessing and postprocessing, paired image training, SRCNN and EDSR architectures, PSNR and SSIM quality metrics, real time processing, computational optimization, computer vision

Современный мир характеризуется экспоненциальным ростом объема передаваемых видеоданных. Это связано с повсеместным распространением видеоконференцсвязи, систем видеонаблюдения, стриминговых платформ и сервисов пользовательского контента. Однако передача видео высокого разрешения требует значительных пропускных способностей каналов связи. Для решения этой проблемы повсеместно используются алгоритмы сжатия с потерями, такие как H.264/AVC, HEVC и другие. Несмотря на свою эффективность, эти алгоритмы при высоких коэффициентах сжатия приводят к появлению артефактов: блочности, размытости, ступенчатости границ и др.

Кроме того, источником видеопотока часто являются камеры с неидеальными характеристиками, что приводит к наличию шумов, низкому разрешению и недостаточной резкости. Традиционные методы улучшения качества изображения, такие как билинейная и бикубическая интерполяция, фильтрация Винера и др., обладают рядом недостатков. Они, как правило, являются линейными и не учитывают семантику сцены, что приводит к излишнему размытию деталей и неспособности эффективно восстановить

высокочастотную информацию.

В последнее десятилетие методы машинного обучения, и в частности, глубокого обучения, произвели революцию в области компьютерного зрения. Сверточные нейронные сети (Convolutional Neural Networks – CNN) показали выдающиеся результаты в таких задачах, как классификация изображений, детекция объектов и семантическая сегментация. Их способность автоматически извлекать иерархические признаки из данных делает их исключительно подходящими и для задач восстановления и улучшения изображений.

Целью данного исследования является анализ возможности и эффективности применения сверточных нейронных сетей для улучшения качества изображения в видеопотоке в реальном или близком к реальному времени.

Прежде чем перейти к рассмотрению нейросетевых подходов, необходимо кратко охарактеризовать классические методы.

Интерполяция: Методы вроде ближайшего соседа, билинейной и бикубической интерполяции являются самыми простыми для увеличения разрешения. Они вычисляют значения новых пикселей на основе взвешенных средних значений окружающих пикселей. Недостаток – сильное размытие текстур и краев объектов.

Фильтрация на основе моделей: Такие методы, как фильтр Винера или алгоритм Ричардсона-Люси, используют математическую модель процесса деградации изображения (размытия, зашумленности) [1]. Их эффективность сильно зависит от точности априорного знания параметров деградации, что на практике часто недостижимо.

Методы, основанные на словарях: Эти подходы (например, метод разреженного кодирования) используют заранее обученные пары словарей для низко- и высококачественных патчей изображений. Хотя они показывали лучшие результаты, чем интерполяция, их производительность ограничена размером словаря и вычислительной сложностью.

Общим недостатком традиционных методов является их неадаптивность. Они не «учатся» на данных и применяют одни и те же правила ко всем типам изображений, независимо от их содержания.

Сверточные нейронные сети – это специальный тип искусственных нейронных сетей, предназначенный для обработки данных с сеточной структурой, таких как изображения. Их ключевые особенности включают:

Локальные связи и разделение весов: Каждый нейрон в сверточном слое связан только с небольшой областью предыдущего слоя, а веса свертки (ядро) используются совместно для всей обрабатываемой области. Это drastically снижает количество параметров по сравнению с полносвязными сетями и позволяет сети эффективно выявлять локальные паттерны (края, текстуры), инвариантные к положению.

Иерархия признаков: Последовательность сверточных слоев позволяет сети строить иерархию признаков – от простых краев и углов на начальных

слоях до сложных объектов и текстур на глубоких слоях [2].

Задача супер-разрешения (Super-Resolution – SR) заключается в восстановлении изображения высокого разрешения (HR - High Resolution) из его версии низкого разрешения (LR - Low Resolution).

SRCNN (Super-Resolution Convolutional Neural Network): Одна из первых и наиболее влиятельных архитектур. Она реализует простой трехэтапный процесс:

Извлечение патчей и представление: Низкокачественное изображение интерполируется (например, бикубически) до нужного размера. Затем сверточный слой извлекает локальные патчи и представляет их в виде feature maps.

Нелинейное отображение: Несколько сверточных слоев отображают эти feature maps в представления для высококачественного изображения. Это ядро сети, где происходит сложное нелинейное преобразование.

Реконструкция: Последний сверточный слой комбинирует предсказания для восстановления финального изображения HR.

SRCNN продемонстрировала значительное превосходство над традиционными методами по метрикам PSNR и SSIM.

FSRCNN (Fast Super-Resolution CNN): Развитие SRCNN, ориентированное на ускорение обработки. Ключевые отличия: использование исходного изображения LR без предварительной интерполяции (дешилинговая структура – deconvolution layer на выходе), уменьшение размерности feature maps и большее количество сверточных слоев малого размера.

ESPCN (Efficient Sub-Pixel CNN): Данная архитектура вводит концепцию субпиксельного сверточного слоя (sub-pixel convolution layer). Сеть извлекает признаки из изображения LR, а на последнем этапе производится переупорядочивание feature maps для непосредственного формирования изображения HR. Это позволяет значительно ускорить процесс.

GAN-подходы (Generative Adversarial Networks): Для задач, где важна не только точность пикселей, но и визуальное восприятие, используются состязательные сети (например, SRGAN). Генератор (CNN) создает изображения HR, а дискриминатор пытается отличить их от реальных фотографий. Это позволяет генерировать более реалистичные и резкие текстуры, хотя метрики PSNR могут быть ниже.

Архитектуры, используемые для супер-разрешения, часто могут быть адаптированы и для других задач улучшения качества, таких как удаление артефактов сжатия (AR-CNN - Artifact Reduction CNN) и шума (DnCNN - Denoising CNN). Принцип остается схожим: сеть обучается отображать искаженное изображение на его чистую версию.

Обработка видеопотока в реальном времени предъявляет строгие требования к производительности алгоритма. Прямое применение CNN к каждому кадру может быть слишком затратным. Рассмотрим возможные архитектурные решения:

Поточная обработка по кадрам (Frame-by-Frame): Самый простой подход. Видеопоток разбивается на отдельные кадры, каждый кадр независимо обрабатывается CNN, после чего кадры собираются обратно в поток. Недостаток: временная согласованность между кадрами не учитывается, что может приводить к мерцанию и артефактам в динамических сценах.

Использование временной информации: Более продвинутые подходы используют несколько последовательных кадров для улучшения текущего. Сеть (часто с 3D-свертками или рекуррентными блоками типа LSTM/GRU) анализирует движение объектов и использует информацию из соседних кадров для более точного восстановления деталей. Примеры архитектур: EDVR, RBPN. Этот подход значительно эффективнее, но и более требователен к вычислительным ресурсам [3].

Оптимизация для развертывания: Для работы в реальном времени необходима оптимизация модели:

Квантизация: Сведение точности весов с 32-битных чисел с плавающей запятой к 8-битным целым числам.

Прунинг (Обрезка): Удаление малозначимых весов и связей из сети.

Использование специализированных аппаратных ускорителей: Графические процессоры (GPU), тензорные процессоры (TPU), нейропроцессоры (NPU).

Блок-схема предлагаемой системы может выглядеть следующим образом:

Модуль приема: Получает видеопоток (например, по RTSP).

Декодер: Декодирует поток в последовательность кадров (например, из H.264 в YUV или RGB).

Буфер кадров: Сохраняет несколько последовательных кадров для временного анализа (если используется).

Модуль улучшения на основе CNN: Обрабатывает одиночный кадр или группу кадров обученной нейросетевой моделью.

Кодер: Кодировывает улучшенные кадры обратно в требуемый формат.

Модуль передачи: Отправляет улучшенный видеопоток потребителю.

Для демонстрации эффективности подхода было проведено сравнительное тестирование классического метода бикубической интерполяции и модели SRCNN

Набор данных: Использовался стандартный датасет Set5.

Методы сравнения: Билинейная интерполяция, бикубическая интерполяция, SRCNN

Метрики качества: Пиковое отношение сигнала к шуму (PSNR) и Структурное сходство (SSIM).

Коэффициент масштабирования: x2, x3.

Результаты оценки на тестовом наборе данных представлены в Таблице 1.

Таблица 1. Сравнение методов супер-разрешения (метрика PSNR, дБ)

Метод	Масштаб x2	Масштаб x3
Билинейная интерполяция	31,52	28,76
Билинейная интерполяция	32,19	29,31
SRCNN	34,01	30,89

Таблица 2. Сравнение методов супер-разрешения (метрика SSIM)

Метод	Масштаб x2	Масштаб x3
Билинейная интерполяция	0,909	0,822
Билинейная интерполяция	0,926	0,841
SRCNN	0,947	0,873

Как видно из таблиц, модель SRCNN демонстрирует устойчивое превосходство над традиционными методами интерполяции по обоим метрикам. При увеличении масштаба в 2 раза прирост PSNR составляет около 1,8 дБ, что визуально соответствует значительному повышению резкости и детализации.

Визуальный анализ результатов подтверждает данные метрики. Изображения, обработанные бикубической интерполяцией, выглядят размытыми, особенно в областях с сложными текстурами и контрастными границами. В то же время, изображения, восстановленные с помощью SRCNN, сохраняют более четкие края и восстанавливают потерянные детали, что свидетельствует о способности сети обобщать и предсказывать высокочастотную информацию на основе обученных паттернов.

В ходе проведенного исследования была подтверждена высокая эффективность использования сверточных нейронных сетей для улучшения качества видеопотока [4]. Показано, что CNN-подходы превосходят классические методы как по объективным метрикам качества (PSNR, SSIM), так и по субъективному визуальному восприятию.

Ключевыми преимуществами CNN являются:

Способность к нелинейному отображению: Сети могут моделировать сложные взаимосвязи между низкокачественным и высококачественным представлениями изображения.

Адаптивность и обучение на данных: CNN не используют фиксированные ядра, а обучаются на большом наборе примеров, что позволяет им эффективно работать с разнообразным контентом.

Учет семантики: Глубокая иерархия признаков позволяет сети «понимать» содержание сцены, что помогает в восстановлении структурно сложных объектов.

Основными вызовами на пути практической реализации систем

улучшения видео на основе CNN в реальном времени остаются высокие вычислительные затраты и необходимость учета временной согласованности кадров. Перспективы дальнейших исследований видятся в разработке более легковесных и эффективных архитектур нейронных сетей, использовании методов обучения с подкреплением для адаптивного выбора стратегии обработки, а также в активном внедрении аппаратных ускорителей для обеспечения требуемой производительности.

СПИСОК ЛИТЕРАТУРЫ

1. Гудфеллоу Я., Бенджио И., Курвилль А. Глубокое обучение. – М.: ДМК Пресс, 2022. – 652 с.
2. Дэнге Л., Ван Чж., Чэнь Ю. Сверточные нейронные сети для задач супер-разрешения изображений // Информационные технологии и вычислительные системы. – 2020. – № 3. – С. 45-58.
3. Кричевский В.Е., Лыткин С.Е. Сравнительный анализ алгоритмов глубокого обучения для восстановления и увеличения разрешения изображений // Труды СПИИРАН. – 2021. – Т. 20. – № 4. – С. 89-112.
4. Осипов А.В., Петровский А.А. Применение глубоких нейронных сетей для улучшения качества видео в системах видеонаблюдения // Научно-технический вестник информационных технологий, механики и оптики. – 2019. – Т. 19. – № 3. – С. 512-520.

СОВРЕМЕННЫЕ ТЕХНОЛОГИИ ВИРТУАЛЬНОЙ РЕАЛЬНОСТИ: ИСПОЛЬЗОВАНИЕ В РЕАЛЬНОЙ ЖИЗНИ И УЧЕБНОМ ПРОЦЕССЕ

Э.Э. Самадинов

Кубанский государственный университет

В этой работе анализируются актуальные разработки в области виртуальной реальности (VR), затрагиваются их технические и физические принципы. Основной фокус сделан на использовании VR-технологий в разных сферах – от промышленности и медицины до искусства, а также на их растущей роли в образовании. На основе современных тенденций прогнозируется преобразующее влияние VR на подготовку специалистов для высокотехнологичных областей.

Ключевые слова: виртуальная реальность, VR технологии, иммерсивная среда, шлем виртуальной реальности, контроллеры движения, полнотеловый трекинг, образовательные VR приложения, виртуальные лаборатории, симуляторы для обучения, профессиональная подготовка, обучение навыкам высокой опасности, медицинские тренажеры, корпоративное обучение, игровые и развлекательные сценарии, реабилитация и терапия, пользовательский опыт, киберболезнь, требования к оборудованию.

This paper analyzes current developments in the field of virtual reality (VR),

touches upon their technical and physical principles. The main focus is on the use of VR technologies in various fields, from industry and medicine to art, as well as their growing role in education. Based on current trends, the transformative impact of VR on the training of specialists for high-tech fields is predicted.

Key words: virtual reality, VR technologies, immersive environment, virtual reality headset, motion controllers, full body tracking, educational VR applications, virtual labs, training simulators, professional training, high risk skills training, medical simulators, corporate training, gaming and entertainment use cases, rehabilitation and therapy, user experience, cybersickness, hardware requirements.

Сегодня цифровое и физическое пространства все теснее переплетаются. Технологии виртуальной реальности, еще недавно бывшие фантастикой, становятся неотъемлемой частью нашей жизни, превращаясь из дорогого развлечения в эффективный инструмент для профессиональной деятельности, учебы и творчества. Будучи студентом физтеха, я постоянно сталкиваюсь со сложными физическими явлениями и инженерными задачами, которые сложно понять только по плоским схемам и уравнениям. В этом случае VR предлагает совершенно новые пути для понимания сложных концепций.

Цель работы – не просто описать существующие технологии, а изучить их базовые принципы и определить самые перспективные направления для их внедрения, в первую очередь в образовании, где качество усвоения материала сильно зависит от наглядности и вовлечения. Как же устроены современные системы VR? Чтобы оценить возможности виртуальной реальности, нужно понимать, из чего она состоит. Сегодня VR-система – это комплекс взаимосвязанных компонентов [1-3].

Основу VR-гарнитуры составляют дисплеи. В отличие от обычных мониторов, здесь применяют два экрана высокой четкости – для каждого глаза отдельно, что создает стереоскопическую картинку. Современные шлемы используют OLED- или LCD-матрицы с частотой обновления 90-120 Гц, что очень важно для уменьшения задержек и предотвращения так называемой «киберболезни». Разрешение 4K и выше на глаз стало нормой, что позволяет убрать «эффект сетки».

Система отслеживания движений отвечает за определение местоположения и поворотов пользователя в пространстве. Есть два основных метода:

Внешние датчики: Специальные базовые станции испускают ИК-излучение и сканируют комнату. Такой подход дает высочайшую точность и минимальные задержки, что идеально для тренажеров и научных задач.

Внутренние камеры: Камеры на самом шлеме анализируют окружающую обстановку, создавая ее 3D-модель. Этот способ более мобилен и удобен для дома, а его точность постоянно улучшается благодаря новым алгоритмам.

Устройствами управления являются контроллеры. Контроллеры – это основной способ взаимодействия с виртуальным миром. Сегодня они

снабжены системой отслеживания, вибромоторами, а в новых моделях – даже датчиками, чувствующими сжатие пальцев. Ведутся разработки систем тактильной обратной связи, которые позволяют «ощущать» виртуальные предметы.

Создание реалистичного и плавного стереоизображения требует огромных вычислительных мощностей. Помимо мощных видеокарт, здесь помогают специальные технологии, например, “foveated rendering”. Она использует отслеживание взгляда, чтобы рендерить в высоком качестве только ту область, куда смотрит пользователь, а остальное – с меньшим, что сильно разгружает систему.

Сфера применения VR давно вышла за пределы игр. Примером могут стать производство и инженерия [4].

Инженеры могут собрать и проверить 3D-модель сложного устройства до его изготовления. Это помогает находить ошибки на ранних этапах, экономя значительные средства.

Специалист из одного города может в VR подключиться к коллеге на объекте, видеть то же, что и он, и накладывать подсказки прямо в его поле зрения, помогая с ремонтом.

Также VR могут использовать в медицине.

Студенты-медики могут тренироваться на виртуальных пациентах, отрабатывая сложные операции без риска. Некоторые системы дают тактильные ощущения, имитируя прикосновение к тканям.

Восстановление: VR-среды делают реабилитацию более интересной, превращая упражнения в игру. Например, пациент с травмой руки может собирать виртуальные объекты, а система отслеживает прогресс [5].

Психология: Под наблюдением врача пациент помещается в ситуацию, которая вызывает страх, и учится справляться с ней в безопасной обстановке.

Для строителей виртуальная реальность тоже упрощает работу. Архитекторы и заказчики могут «походить» по будущему дому или району до начала стройки. Это помогает оценить удобство планировки, освещение и вовремя внести изменения.

Для цифровых выставок художники создают интерактивные произведения, а музеи оцифровывают коллекции, позволяя всем желающим «посетить» Лувр или Эрмитаж из дома. Также можно воссоздавать древние города, позволяя людям прогуляться по улицам прошлого.

Обучение – это, пожалуй, самое перспективное направление. VR превращает пассивное получение знаний в активное погружение.

Изучая физику в VR можно увидеть силовые поля, наблюдать за поведением молекул, ставить опыты в условиях невесомости или вакуума.

Используя современные игровые движки, вполне реально создать реалистичную среду для различных опытов.

В данный момент мной активно разрабатывается лаборатория физических экспериментов в VR. Проект создаётся на игровом движке Unreal Engine 5 от компании Epic Games и уже содержит такие эксперименты как

маятник для проверки абсолютного упругого соударения шаров с отслеживанием углов наклона шаров и скоростью перед столкновением и комната визуализации явления Броуновского движения с возможностью регулировки температуры среды.

Химики могут безопасно смешивать любые реактивы и наблюдать за реакциями на микроуровне. Можно создавать сложные молекулы в 3D.

Биологи вместо изучения учебника путешествуют внутри тела. Студенты могут изучать анатомию органов, видеть, как работают системы организма.

VR идеален для отработки навыков в реалистичных, но безопасных условиях. Например, в авиации VR-тренажеры становятся доступной альтернативой дорогим авиасимуляторам.

МЧС и армия могут использовать виртуальную реальность для отработки действий в ЧС, что позволяет тренировать реакцию и стрессоустойчивость.

Технические профессионалы могут обучаться работе со сложным оборудованием до допуска к реальным машинам.

История оживает с современными технологиями. Вместо чтения о сражении можно оказаться на поле боя. Изучая древние языки, можно погрузиться в атмосферу того времени.

VR дает уникальные возможности детям с ОВЗ. Ребенок с ограниченной подвижностью может побывать в любой точке мира, а управление взглядом позволяет работать в VR тем, кто не может пользоваться руками.

Несмотря на прогресс, есть еще много сложностей, например, нужны мощные компьютеры, время работы от батареи ограничено, у некоторых людей возникает дискомфорт при использовании. Так же не хватает хороших образовательных программ, их создание дорого и сложно.

Технологии виртуальной реальности быстро развиваются, превращаясь из развлечения в важный инструмент для науки, промышленности и образования. Их главная сила – в возможности дать человеку опыт, который раньше был невозможен: взаимодействие с абстрактными понятиями и сложными системами.

Для студентов технических специальностей, VR – это будущая рабочая среда, инструмент для исследований и площадка для создания новых технологий. Уже сейчас во многих вузах, включая КУБГУ есть лаборатории, где студенты не только используют VR, но и разрабатывают для него новые решения.

Внедрение VR в образование – это вопрос времени. И то, насколько быстро мы, новое поколение инженеров, сможем освоить и улучшить эти технологии, определит будущее подготовки кадров для высокотехнологичных отраслей. Следующая задача – создание удобных и доступных образовательных платформ, которые позволят использовать VR в учебе повсеместно.

СПИСОК ЛИТЕРАТУРЫ

1. DTF // История развития виртуальной реальности: [Электронный ресурс]. – Режим доступа: URL: <https://dtf.ru/gameindustry/206605-proshloe-i-budushee-vr-industrii> (дата обращения: 15.09.2025).
2. Valve Corporation // SteamVR Developer Documentation: Valve Index Hardware Overview [Электронный ресурс]. – Режим доступа: URL: https://partner.steamgames.com/doc/steamvr/hardware/valve_index (дата обращения: 15.09.2025).
3. Что такое виртуальная реальность [Электронный ресурс]. – Режим доступа: URL: <https://skyeng.ru/magazine/wiki/it-industriya/chto-takoe-virtualnaia-realnost> (дата обращения: 17.09.2025).
4. Геймификация учебного процесса: как VR и AR проникает в образование [Электронный ресурс]. – Режим доступа: URL: <https://habr.com/ru/companies/sberbank/articles/927242/> (дата обращения: 19.09.2025).
5. VR в медицине: лечение фобий и реабилитация с помощью виртуальной реальности [Электронный ресурс]. – Режим доступа: URL: <https://medgorod-clinic.ru/stati/vr-v-meditsine--lechenie-fobiy-i-reabilitatsiya-s-pomoshchyu-virtualnoy-realnosti> (дата обращения: 19.09.2025)

ПРОЕКТИРОВАНИЕ И РЕАЛИЗАЦИЯ СИСТЕМЫ БЕЗОПАСНОГО ВЫПОЛНЕНИЯ АВТОМАТИЗИРОВАННЫХ СЦЕНАРИЕВ С ИСПОЛЬЗОВАНИЕМ ANSIBLE

Д.А. Саркисян

Кубанский государственный университет

Статья посвящена разработке комплексной методологии построения эффективной, безопасной и масштабируемой ИТ-инфраструктуры. Предлагаемый подход интегрирует инструменты автоматизации (Ansible), технологии виртуализации (KVM, Proxmox VE), платформы управления контейнерами (Kubernetes) и решения для сетевой безопасности (межсетевые экраны FortiGate) в единый framework, основанный на жизненном цикле разработки сети (NDLC).

Ключевые слова: автоматизация ИТ-инфраструктуры, Ansible, виртуализация, Kubernetes, KVM, сетевая безопасность, FortiGate, отказоустойчивость, DevOps, IaC.

The article is devoted to the development of a comprehensive methodology for building an efficient, secure, and scalable IT infrastructure. The proposed approach integrates automation tools (Ansible), virtualization technologies (KVM, Proxmox VE), container management platforms (Kubernetes), and network security solutions (FortiGate firewalls) into a single framework based on the Network Development Lifecycle (NDLC).

Key words: automation of IT infrastructure, Ansible, virtualization, Kubernetes, KVM, network security, FortiGate, fault tolerance, DevOps, IaC.

Компьютерные сети играют решающую роль в поддержке бизнес- и организационных операций, где доступность и надежность являются критически важными факторами для поддержания производительности и операционной эффективности [1]. Однако современные ИТ-инфраструктуры сталкиваются с рядом проблем, включая необходимость защиты данных от несанкционированного доступа и кибератак при одновременном обеспечении оптимальной производительности системы. Ручные процессы управления серверами и сетями часто требуют много времени, подвержены ошибкам и плохо масштабируются. Кроме того, потребность в высокой доступности сервисов требует решений, которые минимизируют риск сбоев и повышают уровень автоматизации.

Такие технологии, как межсетевые экраны (например, FortiGate) для многоуровневой защиты, отказоустойчивая кластеризация для обеспечения непрерывности обслуживания и виртуализация для снижения затрат и повышения эффективности, являются ключевыми направлениями для решения этих задач. В частности, контейнеризация и платформы управления, такие как Kubernetes, предлагают улучшенную масштабируемость и изоляцию сервисов [2].

Данное исследование направлено на восполнение этого пробела путем разработки и внедрения комплексного подхода, объединяющего автоматизацию на основе Ansible, виртуализацию KVM, управление контейнерами с помощью Kubernetes и усиление сетевой безопасности с помощью межсетевых экранов FortiGate [3]. Целью является создание эффективной, безопасной и масштабируемой ИТ-инфраструктуры.

В данном исследовании применяется подход, сочетающий проектирование, внедрение и экспериментальное тестирование. В качестве методологической основы используется жизненный цикл разработки сети (NDLC), который включает этапы анализа, проектирования, моделирования, прототипирования, внедрения, мониторинга и управления. Этот метод применяется для проектирования, тестирования и внедрения автоматизации серверов на основе Ansible в системах Ubuntu Server [4].

Данные собираются путем наблюдения, тестирования производительности до и после автоматизации, а также анализа системных журналов. В качестве инструментов исследования используется серверное оборудование и программное обеспечение, включая Ansible, Docker, Kubernetes, а также инструменты мониторинга Prometheus и Grafana. Анализ данных проводится количественно путем сравнения времени развертывания, эффективности использования ресурсов, сетевой задержки и уровня безопасности системы.

Была разработана сетевая топология с двумя интернет-провайдерами для обеспечения отказоустойчивости. Для преодоления уязвимостей,

связанных с прерыванием соединения, была реализована механизм маршрутизации при отказе. Это обеспечивает автоматическое переключение на резервного провайдера в случае сбоя основного канала, тем самым повышая надежность и доступность сети [5].

Для усиления безопасности был настроен межсетевой экран FortiGate. Конфигурация включала настройку интерфейсов WAN и LAN, создание статических маршрутов и политик трафика, что позволяет эффективно управлять сетевым трафиком и обеспечивать безопасное подключение внутренней сети к Интернету [6].

Управление серверной инфраструктурой было автоматизировано с помощью Ansible, который выступал в роли контроллера. Процесс включал установку SSH-соединения с узлами, клонирование репозитория из GitLab, содержащих скрипты для развертывания стека LAMP и Docker, и последующее развертывание приложений с использованием Kubernetes [7]. Мониторинг активности серверов и сетевых служб осуществлялся для обеспечения стабильности работы.

Виртуализация была реализована на платформе Proxmox VE, которая поддерживает как полную (KVM), так и контейнерную виртуализацию. Три серверных узла были объединены в кластер, что позволило централизованно управлять ими и использовать Ansible для автоматизированного развертывания и миграции виртуальных машин между узлами [8].

Для размещения приложений, таких как WordPress, использовалась контейнеризация. Процесс включал развертывание WordPress и MySQL в виде контейнеров, настройку служб Kubernetes и использование NGINX в качестве обратного прокси-сервера и балансировщика нагрузки для обеспечения стабильного и безопасного доступа.

Сравнение производительности физических серверов и серверов, виртуализированных с помощью KVM, показало следующие результаты:

1. Время загрузки: У виртуализированных серверов время загрузки сократилось на 28% по сравнению с физическими.
2. Загрузка ЦП: Использование процессора на виртуализированных серверах снизилось на 12,5%, что указывает на более эффективное использование ресурсов.
3. Дисковый ввод-вывод: Производительность дискового ввода-вывода у виртуализированных серверов снизилась на 10%, что может быть связано с накладными расходами гипервизора, но остается в приемлемых пределах.

Проведенное исследование демонстрирует эффективность предложенного комплексного подхода к построению современной ИТ-инфраструктуры.

Инструмент автоматизации Ansible доказал свою эффективность в заранее спроектированной среде, обеспечивая более быстрое и эффективное развертывание и конфигурацию по сравнению с ручными методами.

Подход с использованием Ansible является ресурсоэффективным, так как не требует установки специальных агентов на управляемые узлы, а потребление полосы пропускания минимально [9].

Виртуализация на основе KVM обеспечила значительные преимущества в скорости загрузки и эффективности использования процессора, хотя было отмечено незначительное снижение производительности дискового ввода-вывода, требующее дальнейшей оптимизации.

На основе полученных результатов для будущих исследований рекомендуется:

1. Провести более глубокую оптимизацию виртуализации для повышения производительности дискового ввода-вывода.
2. Исследовать интеграцию Ansible с другими инструментами оркестровки, такими как Terraform, для создания более комплексной системы управления инфраструктурой.
3. Провести испытания в крупномасштабных производственных средах для проверки отказоустойчивости и масштабируемости предложенного решения.

СПИСОК ЛИТЕРАТУРЫ

1. Ислами, М. Роль компьютерных сетей в поддержке бизнес-операций / М. Ислами, А. Муса, Р. Ламсани // Информационные технологии в бизнесе. – 2020. – № 3(45). – С. 12–18.
2. Пратама, Р. Контейнерная виртуализация как основа изоляции сервисов / Р. Пратама, Т. Харияди // Современные проблемы информатики и вычислительной техники. – 2021. – № 4(52). – С. 45–52.
3. Путро, С. Проблемы и возможности виртуализации на основе Kubernetes / С. Путро, Б. Супоно // Программная инженерия. – 2022. – Т. 13, № 1. – С. 31–39.
4. Харияди, Т. Реализация Ansible для управления конфигурацией виртуальных частных серверов / Т. Харияди, М. Марзуки // Автоматизация и ИТ. – 2020. – № 2(28). – С. 22–29.
5. Кристантио, А. Оптимизация серверов с использованием технологий виртуализации / А. Кристантио // Научный вестник информационных технологий. – 2023. – № 1(15). – С. 77–85.
6. Риана, Л. Обеспечение сетевой безопасности с помощью межсетевых экранов нового поколения / Л. Риана, М. Ридха // Вопросы кибербезопасности. – 2021. – № 5(12). – С. 60–67.
7. Виджая, А. Эффективность технологий виртуализации и контейнеризации в снижении затрат на ИТ-инфраструктуру / А. Виджая, М. Абдуррохим, Т. Тугийоно, Р. Румандан // Экономика и управление в отраслях ИТ. – 2023. – № 1(18). – С. 44–55.
8. Викаксоно, Д. Многоуровневая защита с использованием межсетевых экранов FortiGate / Д. Викаксоно, Ф. Видиасари // Защита информации. – 2022. – № 4(41). – С. 25–33.

9. Ялестиа, Н. Решения для обеспечения высокой доступности сервисов в корпоративной среде / Н. Ялестиа, К. Чандравати, Т. Харияди // Корпоративные информационные системы. – 2021. – № 2(34). – С. 15–23.

СРАВНИТЕЛЬНЫЙ АНАЛИЗ ФРЕЙМВОРКОВ FASTAPI И FLASK ДЛЯ РАЗРАБОТКИ ВЫСОКОПРОИЗВОДИТЕЛЬНОГО БЕКЕНД- СЕРВИСА НА PYTHON

Е.И. Сафиулина

Кубанский государственный университет

Данная статья посвящена сравнительному анализу двух ключевых инструментов для разработки API: традиционного микрофреймворка Flask и современного, асинхронного фреймворка FastAPI.

Ключевые слова: FastAPI, Flask, веб фреймворки на Python, высокопроизводительный бекенд сервис, REST API, асинхронная обработка запросов, asyncio, ASGI, WSGI, типизация и аннотации типов, автоматическая генерация документации OpenAPI и Swagger, сериализация и валидация данных, Pydantic, производительность и масштабируемость, микросервисная архитектура, сравнительный анализ, время отклика, потребление ресурсов сервера.

This article provides a comparative analysis of two key tools for API development: the traditional Flask microframework and the modern, asynchronous FastAPI framework.

Key words: FastAPI, Flask, Python web frameworks, high performance backend service, REST API, asynchronous request handling, asyncio, ASGI, WSGI, type hints and static typing, automatic OpenAPI and Swagger documentation, data serialization and validation, Pydantic, performance and scalability, microservices architecture, comparative analysis, response time, server resource consumption.

На современном этапе развития информационных технологий скорость и масштабируемость бэкенд-сервисов являются критическими факторами успеха любого веб-приложения. Язык программирования Python занял лидирующие позиции в области анализа данных и разработки API. Однако, высокая популярность Python привела к появлению множества фреймворков для бэкенда, что ставит разработчиков перед необходимостью выбора оптимального инструмента, напрямую влияющего на производительность и архитектуру конечного продукта.

Flask – это минималистичный микрофреймворк для веб-разработки на Python, следующий философии «батарейки не включены». Это означает, что он предоставляет разработчикам лишь базовое ядро, оставляя свободу выбора дополнительных компонентов, от работы с базами данных до валидации форм.

Flask построен на синхронной модели WSGI (Web Server Gateway Interface). Этот подход подразумевает последовательную обработку запросов, где каждый поток блокируется на время выполнения операций ввода-вывода, таких как запросы к базе данных или внешним API. Это делает Flask удобным для небольших приложений, но создает ограничения по производительности при высокой нагрузке [1].

Маршрутизация в Flask декларативная – маршруты объявляются с помощью декораторов, что интуитивно понятно и легко читается. Также Flask использует концепцию контекста запроса, которая делает такие объекты, как `request` и `session`, глобально доступными в пределах обрабатываемого запроса. Это упрощает код, но требует понимания механики работы.

Ключевым преимуществом Flask является не его внутренняя функциональность, а зрелость и богатство экосистемы. Для решения практически любой задачи существует проверенная библиотека: Flask-SQLAlchemy для ORM, Flask-WTF для форм, Flask-Login для аутентификации и другие. Это позволяет разработчику собрать идеальный для проекта «конструктор».

FastAPI – это современное, высокопроизводительное решение, которое стало ответом на ограничения традиционных синхронных фреймворков. Его основной фокус – на скорости разработки и высокой производительности. FastAPI работает на основе спецификации ASGI (Asynchronous Server Gateway Interface), которая является современным преемником WSGI. ASGI позволяет приложению работать асинхронно с помощью синтаксиса `async/await`. Это означает, что во время выполнения длительной операции ввода-вывода поток не блокируется, а переключается на обработку следующего запроса. В результате FastAPI демонстрирует производительность, сопоставимую с такими высокоскоростными платформами, как Node.js и Go.

В отличие от Flask, где типизация и валидация данных являются опциональными и требуют сторонних библиотек, FastAPI интегрирует библиотеку Pydantic в свою основу. Pydantic позволяет разработчику объявлять структуру данных с помощью стандартных аннотаций типов Python. Это обеспечивает автоматическую валидацию входящих данных и строгую типизацию, что минимизирует ошибки времени выполнения.

Одним из самых лучших преимуществ FastAPI является автоматическая генерация интерактивной документации OpenAPI. Просто объявив типы данных для входных и выходных параметров, разработчик получает готовую документацию по маршрутам `/docs` (Swagger UI) и `/redoc`. Это кардинально сокращает время на поддержку API и взаимодействие с фронтенд-разработчиками.

Ключевые преимущества FastAPI: высочайшая производительность, скорость разработки, встроенная валидация на основе типов, автоматическая документация и современный синтаксис `async/await` [2].

Наиболее критичное различие между фреймворками заключается в их архитектурном подходе к обработке запросов: синхронном и асинхронном.

Flask, основанный на WSGI, использует синхронную модель обработки запросов: каждый запрос занимает отдельный поток, который блокируется при операциях ввода-вывода. При росте числа одновременных подключений это приводит к быстрому исчерпанию ресурсов и ограничивает пропускную способность.

FastAPI, построенный на ASGI, реализует асинхронную модель. При операциях ввода-вывода поток не блокируется, а переключается на обработку других запросов. Это позволяет эффективно обслуживать тысячи соединений в одном потоке, что обеспечивает многократное преимущество в производительности для высоконагруженных систем.

Что касается валидации данных и типизация - этот аспект критически важен для надёжности API, и здесь проявляется одно из главных функциональных различий фреймворков.

Flask не имеет встроенной системы валидации. Разработчик должен вручную реализовывать логику проверки входящих данных или использовать сторонние библиотеки, такие как Marshmallow. Это увеличивает объём кода, необходимого для каждой конечной точки, и повышает риск ошибок. FastAPI интегрирован с библиотекой Pydantic, которая использует стандартные аннотации типов Python. FastAPI автоматически проверяет и преобразует входящие данные на соответствие объявленным Pydantic-схемам, обеспечивая строгую типизацию данных на всём пути. Это значительно повышает надёжность и безопасность API, минимизируя ошибки времени выполнения. В то время как Flask требует дополнительных трудозатрат и кода для обеспечения целостности данных, FastAPI предлагает встроенное, элегантное и автоматизированное решение, которое резко ускоряет процесс разработки надежных API.

Третий ключевой аспект – это трудозатраты на создание и поддержание актуальной технической документации.

Flask не имеет встроенных инструментов для генерации документации. Разработчик вынужден полагаться на сторонние расширения, такие как Flask-RESTX, или создавать документацию вручную. Любое изменение в коде API требует ручного обновления документации, что часто приводит к рассинхронизации между кодом и его описанием, замедляя разработку фронтенда и интеграцию со сторонними сервисами. FastAPI радикально решает эту проблему, используя информацию из аннотаций типов и Pydantic-схем. Он автоматически генерирует интерактивную документацию, соответствующую стандартам OpenAPI, которая всегда актуальна, интерактивна и стандартизирована. В то время как Flask требует дополнительных усилий и инструментов для создания документации, FastAPI предлагает готовое, интегрированное решение.

Flask является лучшим выбором в следующих случаях:

- Для очень малых проектов, прототипов или традиционных веб-приложений (не API), где важен минимализм ядра.

- Для разработчиков, которые только начинают осваивать бэкенд и хотят иметь полный контроль над каждым подключаемым модулем [3].

FastAPI – это идеальный инструмент для современных, высокопроизводительных сервисов:

- Для систем, где критична скорость, асинхронность и высокая пропускная способность при работе с операциями ввода-вывода.

- Для проектов, где данные должны быть строго типизированы и валидированы, что минимизирует ошибки.

Для наглядного сравнения характеристик представлена таблица (Листинг 1), где систематизированы основные критерии выбора.

Таблица 1 – Сравнительная таблица фреймворков Flask и FastAPI

Критерий	Flask	FastAPI
Сложность / Легковесность	Простота, минимализм ядра	Современные, высокопроизводительные сервисы
Тип задач	CPU-Bound задачи, традиционные веб-приложения	Высоконагруженные API, I/O-Bound задачи
Асинхронность	Минимальный выигрыш	Критична скорость, высокая пропускная способность

Таблица 1 (продолжение)

Документация API	Требует дополнительных усилий и инструментов	Готовое, интегрированное решение (автоматизация)
Типизация данных	Менее строгая	Строгая типизация и валидация данных
Использование	Малые проекты, прототипы, обучение	Data Science, микросервисы, высоконагруженные API
Приоритет	Простота и гибкость	Производительность и автоматизация процессов

СПИСОК ЛИТЕРАТУРЫ

1. Shalabh Aggarwal Flask Framework Cookbook: Enhance your Flask skills with advanced techniques and build dynamic, responsive web applications, 3rd Edition / [Aggarwal S.](#) – UK, Packt Publishing – 2023. – 318 с – ISBN 978-1-80461-110-4

2. Билл Любанович FastAPI веб-разработка на Python / Любанович Б. – USA, O'Reilly Media – 2024. – 280 с – ISBN 978-1-098-13550-8
3. Мурат Дурмус Практическое введение в основные библиотеки и фреймворки Python / Дурмус М. – USA, Murat Durmus – 2023. -173 с - ISBN 979-8385699681

ОБРАЗОВАНИЕ В НОГУ СО ВРЕМЕНЕМ: ИНТЕРАКТИВНЫЙ ПОРТАЛ МЕНЯЕТ ЖИЗНЬ БУДУЩИХ СТУДЕНТОВ

А.А. Тищенко

Кубанский государственный университет

Эта работа посвящена запуску уникального образовательного портала, разработанного преподавателями и студентами Физико-технического факультета Московского технического университета имени Н.Э. Баумана. Данный ресурс представляет собой новую страницу в истории российского образования благодаря своей многофункциональности, удобному интерфейсу и возможности интеграции виртуальных сред в учебный процесс.

Ключевые слова: образовательный портал, электронная база знаний, дистанционное обучение, интеграция виртуальных сред, современное образование, инновационные технологии, академическое развитие, учебно-методический комплекс, интерактивное взаимодействие.

This work is dedicated to the launch of a unique educational portal developed by faculty members and students of the Faculty of Physics and Technology at the Bauman Moscow State Technical University. This resource represents a new chapter in the history of Russian education due to its versatility, user-friendly interface, and ability to integrate virtual environments into the learning process.

Key words: educational portal, electronic knowledge base, distance learning, integration of virtual environments, modern education, innovative technologies, academic development, educational and methodological complex, interactive interaction.

Недавно преподавательский коллектив Физико-технического факультета Московского технического университета имени Н.Э. Баумана представил уникальный проект – интерактивный портал, предназначенный для кардинального улучшения образовательных возможностей абитуриентов. Данная инициатива стала результатом дипломной работы студентов старших курсов Владимира Алексеева и Анастасии Смирновой, которые предложили свежую концепцию интеграции учебного процесса и виртуальной среды.

Традиционно подготовка к поступлению и последующему освоению учебной программы считалась трудоемким процессом, требующим больших усилий от будущих студентов. Трудности возникали вследствие нехватки актуальной информации, недостатка квалифицированного сопровождения и

низкой мотивации. Многие учащиеся тратили значительную часть времени на поиски необходимой литературы, ожидание консультаций и попытки самостоятельного освоения теоретического материала.

Новый портал радикально меняет восприятие учебного процесса. Портал аккумулирует в одном месте всю необходимую информацию о факультетах, программах обучения, расписаниях занятий, лабораторных практикумах и дополнительных занятиях. Электронная база знаний обеспечивает мгновенный доступ к актуальным материалам, даёт возможность получать персональные рекомендации и поддерживает обратную связь с преподавателем.

Одно из ключевых преимуществ портала – его многофункциональность. Учащиеся получают доступ к широкому спектру учебных пособий, лекционным материалам и мультимедийным урокам. Каждый студент может вести собственный электронный журнал успеваемости, формировать расписание занятий и просматривать динамику результатов. Особенностью портала является интегрированная система дистанционного обучения, позволяющая ученикам готовиться к сессии дистанционно и проводить репетиторские занятия онлайн.

Кроме того, предусмотрена удобная система диагностики знаний учащихся посредством специализированных тестов и практических упражнений. Таким образом, студенты смогут заблаговременно выявить свои слабые стороны и целенаправленно подтянуть отстающие дисциплины.

Особое внимание разработчики уделили эргономичности и привлекательности сайта. Портал оснащён удобным и интуитивно понятным интерфейсом, который доступен каждому пользователю независимо от уровня компьютерной грамотности. Сайт предусматривает адаптивную версию для мобильных устройств, что делает его использование комфортным и эффективным в любых обстоятельствах.

Сам портал удобно сегментирован на тематические блоки, где собраны учебные пособия, практические задания, календарь мероприятий и интерактивные викторины. Отдельный раздел посвящён научной деятельности студентов, где публикуются лучшие студенческие проекты, статьи и доклады, представленные на всероссийских конкурсах и олимпиадах.

Первые месяцы функционирования портала показали впечатляющие результаты. Почти четыре сотни зарегистрированных пользователей высоко оценили преимущества ресурса, отмечая легкость подачи документов, удобство составления индивидуального плана обучения и своевременность уведомлений о предстоящих мероприятиях. Многие отметили резкое уменьшение нервного напряжения накануне экзаменационной сессии и повысили свою успеваемость.




Рисунок 1 – Раздел с расписанием мобильного приложения портала

Пример использования образовательного портала учениками:

Шаг 1: Вход в систему

Ученик заходит на образовательный портал, вводит свой логин и пароль, подтверждает, что он не робот, и нажимает кнопку входа. Процесс входа занимает считанные секунды, после чего ученик попадает в свой личный кабинет.

Шаг 2: Просмотр расписания

На главной странице личного кабинета ученик видит своё расписание уроков на ближайшую неделю. Например, на вторник запланированы уроки математики, физики и информатики. Рядом с каждым предметом указана аудитория и время начала урока.

Шаг 3: Проверка домашних заданий

Ученик может проверить домашнее задание по любому предмету прямо на портале. Домашние задания представлены в виде ссылок на электронные учебники или PDF-файлы, которые можно скачать и распечатать. Также доступна функция отправки выполненного домашнего задания преподавателю через портал.

Шаг 4: Участие в онлайн-тестировании

По итогам прохождения урока учитель назначает тестирование. Ученик выбирает нужный предмет и приступает к выполнению теста. Вопросы появляются последовательно, а после завершения теста сразу выводится результат с указанием правильных и неправильных ответов.

Шаг 5: Обратная связь с учителем

Если у ученика возникают вопросы по уроку или домашнему заданию, он может задать их непосредственно на портале. Ответ учителя поступает в виде сообщения в личном кабинете, а также отправляется на указанный учеником e-mail.

Шаг 6: Использование дополнительных сервисов

Помимо основных функций, портал предоставляет дополнительные сервисы, такие как просмотр новостей университета, участие в форумах и чатах, а также доступ к электронным ресурсам библиотеки.

Шаг 7: Оценка успеваемости

В специальном разделе ученик может просмотреть свою успеваемость по каждому предмету, сравнить её с результатами предыдущих семестров и получить рекомендации по улучшению результата.

Использование образовательного портала упрощает жизнь учеников, повышая эффективность обучения и облегчая взаимодействие с преподавателями. Портал является неотъемлемой частью учебного процесса, помогая ученикам достигать высоких результатов и уверенно двигаться вперед.

Заведующий кафедрой информатики и вычислительной техники, профессор Владислав Дмитриев отметил: «Мы уверены, что созданный нами портал позволит будущим студентам обрести уверенность в собственных силах и гармонично влиться в академическую среду университета». Научное сообщество восприняло новинку восторженно, отмечая высокое качество исполнения и прогрессивность самой идеи.

Директор департамента по образованию Минпросвещения РФ Александр Сергеев подчеркнул: «Подобные образовательные платформы демонстрируют яркий пример гармоничного сочетания новейших технологий и традиций отечественного образования. Мы гордимся нашими молодыми учеными и студентами, чьё стремление к совершенствованию достойно восхищения».

Сегодня рассматриваются варианты распространения проекта на другие факультеты университета и потенциально – на ведущие высшие учебные заведения России. Российские ученые и преподаватели считают, что данная технология способна совершить настоящий прорыв в подготовке кадров и способствовать улучшению общего уровня образования.

В заключение отметим, что интерактивный портал Физико-технического факультета МГУ им. Н.Э. Баумана стал яркой страницей в истории отечественного образования. Он демонстрирует мощный потенциал технологического прорыва и открывает блестящие перспективы для эффективного усвоения знаний и карьерного роста будущих инженеров и учёных.

СПИСОК ЛИТЕРАТУРЫ

1. Власова В.Н. Цифровизация непрерывного образования как фактор повышения эффективности образовательного процесса // Непрерывное образование в России. – 2020. – С. 72-76.
2. Воскрекасенко О.А., Мендова Н.С. Использование дистанционного обучения в высшей школе: преимущества и недостатки // Современные наукоемкие технологии. – 2020. – № 9. – С. 111-115.
3. Григорьев С.Г., Гриншкун В.В., Краснова Г.А. Основные принципы и методики использования системы порталов в учебном процессе // Интернет-порталы: содержание и технологии. – 2005.
4. Напалкова И.Г. Использование образовательных порталов при подготовке студентов в вузе // Научная статья. – 2009.
5. Тихонова Л.П. Об актуальности внедрения современных цифровых технологий в образование // Вестник Череповецкого государственного университета. – 2019. – № 1. – С. 203-221.

ОЦЕНКА ПРИМЕНИМОСТИ ИСПОЛЬЗОВАНИЯ СОВРЕМЕННЫХ ОТКРЫТЫХ МАЛОВЕСЯЩИХ ЯЗЫКОВЫХ МОДЕЛЕЙ НА МИКРОКОМПЬЮТЕРАХ RASPBERRY PI

В.Н. Значко, Н.А. Томашевский, В.А. Елькин

Кубанский государственный университет

Статья посвящена актуальной проблеме развертывания искусственного интеллекта на устройствах с ограниченными вычислительными ресурсами. В качестве альтернативы требовательным к ресурсам большим языковым моделям рассматриваются открытые маловесящие LLM. Основная цель исследования – комплексная оценка применимости таких моделей на платформе Raspberry Pi. В работе систематизируются и оцениваются ключевые характеристики моделей: скорость обработки запросов, адекватность ответов и стабильность работы на Raspberry Pi 4b и 5b.

Ключевые слова: маловесные языковые модели, открытые LLM, квантованные модели, Raspberry Pi, микрокомпьютеры, локальный инференс, ограниченные вычислительные ресурсы, одноплатные компьютеры, оптимизация памяти, энергоэффективность, специализированные фреймворки, аппаратное ускорение, использование GPU и NPU, edge вычисления, приватность данных, офлайн обработка текста, оценка производительности, задержка отклика, качество ответов модели.

The article is devoted to the urgent problem of deploying artificial intelligence on devices with limited computing resources. Open low-weight LLMs are considered as an alternative to resource-demanding large language models. The main purpose of the study is a comprehensive assessment of the applicability of such models on

the Raspberry Pi platform. The paper systematizes and evaluates the key characteristics of the models.: query processing speed, adequate responses, and stable performance on Raspberry Pi 4b and 5b.

Key words: lightweight language models, open source LLMs, quantized models, Raspberry Pi, single board computers, local inference, limited computing resources, memory optimization, energy efficiency, specialized frameworks, hardware acceleration, GPU and NPU usage, edge computing, data privacy, offline text processing, performance evaluation, response latency, model answer quality.

Современные большие языковые модели (LLM) произвели поистине революционный скачок в области искусственного интеллекта, однако их эксплуатация традиционно связана со значительными вычислительными затратами и требовательностью к ресурсам. Развёртывание подобных интеллектуальных систем становится возможно только с использованием тяжелого серверного оборудования.

Альтернатива большим моделям - открытые маловесящие языковые модели, насчитывающие от сотен миллионов до нескольких миллиардов параметров. Использование таких моделей открывает новые перспективы для внедрения ИИ-функционала на микрокомпьютеры, что позволит создать децентрализованные, энергоэффективные и не зависящие от облачных сервисов интеллектуальные системы. Микрокомпьютеры Raspberry Pi, являясь одной из самых популярных платформ для прототипирования и периферийных вычислений, широко используемые в робототехнике, представляют собой идеальный полигон для испытания применимости таких моделей в реальных условиях.

Цель данной работы – систематизировать и оценить возможности современных маловесящих языковых моделей при их запуске на Raspberry Pi. В фокусе исследования находятся такие ключевые аспекты, как скорость обработки запросов, адекватность и полезность ответов в различных сценариях использования, общая стабильность работы. Проведённый анализ позволит сформировать четкие рекомендации по выбору оптимальной модели под конкретный микрокомпьютер.

Для исследования были взяты следующие маловесящие модели:

- 1) Gemma 3:4b / 1b / 270m – представители семейства Gemma 3 от Google. Созданы для таких задач, как анализ, чат, классификация текста и т.д. [1];
- 2) Qwen2.5:3b / 1.5b / 0.5b - представители семейства Qwen2.5 от Alibaba, универсальные многоязычные модели, созданы для общего общения, решения задач и работы с текстом [2];
- 3) Qwen2.5-Coder:7b / 3b / 1.5b / 0.5b - специализированные версии моделей семейства Qwen2.5 для программирования [3];
- 4) SmolLM:1.7b / 360m / 135m – представители семейства SmolLM от Microsoft, созданы с целью достичь максимальной производительности при минимальном размере;

5) SmolLM2:1.7b / 360m / 135m – относятся к семейству SmolLM2 от Microsoft, созданы с упором на эффективность и работу на маломощных устройствах;

6) Reader-LM:1.5b / 0.5b – представители семейства Reader-LM, специализированные модели, ориентированные на понимание длинных контекстов. Созданы для задач, где нужно задавать вопросы по большому документу.

Для исследования отбирались модели, отличающиеся наибольшей производительностью вместе с малым весом. Тестирование языковых моделей проводилось на Raspberry Pi 5b и Raspberry Pi 4b. На микрокомпьютеры установлена операционная система Debian GNU/Linux 12 (bookworm), версия ядра Linux 6.12.25+rpt-rpi-v8. [4, 5]

```
1 prompt:
2 You are controlling a robot and need to decide the direction and necessity of movement to complete a task.
3
4 Based on the task and the object data, decide where to move and if movement is needed.
5 Task: Проедь вперед на 20см.
6
7 What action will you take?
8 If no movement or rotation is needed, say ONLY "#SKIP"
9
10 movement.move(FORWARD / BACKWARD / STOP, distance)
11 movement.turn(angle)
12
13 Only parameters were received.
14 NO COMMENTS, ONLY PARAMETERS
```

Рисунок 1 – Пример промпта для языковой модели

Языковые модели, запускаемые на Raspberry Pi, будут исследоваться в следующем контексте: микрокомпьютер является управляющим центром робота с камерой со встроенным компьютерным зрением, а также получает задание от пользователя-человека на русском языке. Информация с камеры об объектах, которые смогла определить система компьютерного зрения, передается в формате json (список объектов с их показателями). На вход языковой модели приходит промпт, объясняющий ситуацию, в которой находится микрокомпьютер, а также непосредственно задачу на русском языке, полученную от человека. Пример одного из промптов представлен на рисунке 1. Языковая модель должна решить задание, но ответить по шаблону, предоставляемому в промпте. Всего было подготовлено 6 промптов, для каждой языковой модели промпт отрабатывал 2 раза.

Подробные результаты исследования и промпты можно найти по адресу <https://github.com/tomatik-beep/model-research-on-raspberry.git>.

Ниже представлена таблица 1, которая отражает статистику по запуску моделей на Raspberry Pi 4b.

Таблица 1 – Сравнение моделей при запуске на Raspberry Pi 4b

Модель	Процент успеха	Среднее время ответа (сек.)	Следование формату %
reader-lm:0.5b	0,0%	66,7	0,0%
gemma3:270m	33,3%	16,6	33,3%
smollm2:135m	0,0%	19,3	0,0%

smollm:135m	33,3%	19,7	33,3%
qwen2.5:0.5b	33,3%	18,3	66,7%
qwen2.5-coder:0.5b	33,3%	17,5	33,3%
gemma3:1b	33,3%	18,2	33,3%
smollm2:360m	0,0%	19,8	0,0%
smollm:360m	0,0%	26,5	0,0%
reader-lm:1.5b	0,0%	25,8	0,0%
qwen2.5:1.5b	33,3%	21,6	33,3%
qwen2.5-coder:1.5b	50,0%	19,5	66,7%
smollm2:1.7b	33,3%	36,5	33,3%
smollm:1.7b	33,3%	42,8	33,3%
qwen2.5:3b	66,7%	23,4	100,0%
qwen2.5-coder:3b	66,7%	23,5	100,0%
gemma3:4b	66,7%	26,5	66,7%
qwen2.5-coder:7b	83,3%	29,9	100,0%

На микрокомпьютере Raspberry Pi 4b нейросети сталкиваются с невысоким быстродействием. В среднем распознавание вопроса и создание ответа на один промпт занимает 20-30 секунд, что очень критично и делает

В таблице 2 представлена статистика по языковым моделям, где на самых верхних позициях модели, показывающие наилучшие результаты для Raspberry Pi 4b.

Таблица 2 – Оценка работы языковых моделей для Raspberry Pi 4b

Модель	Успешность	Анализ проблем
qwen2.5-coder:7b	83,3	Наиболее стабилен, редко ошибается
qwen2.5:3b	66,7	Стабилен в простых задачах
gemma3:4b	66,7	Редко галлюцинирует
qwen2.5-coder:3b	66,7	Стабилен в базовых задачах, но не точен

Таблица 2 (продолжение)

qwen2.5-coder:1.5b	50,0	частые ошибки в сложных задачах
qwen2.5:0.5b	33,3	Частые галлюцинации, нестабильные ответы
qwen2.5:1.5b	33,3	Случайные ответы, непонимание формата
smollm2:1.7b	33,3	Иногда верно, но часто галлюцинирует
smollm:1.7b	33,3	Избыточность, несоответствие формату
smollm:135m	33,3	Генерирует код вместо параметров
gemma3:1b	33,3	Случайные ответы, нестабильность
gemma3:270m	33,3	Непонимание задачи, галлюцинации

qwen2.5-coder:0.5b	33,3	Галлюцинации, нестабильность, случайность
smollm2:360m	16,7	Случайные ответы, нестабильность
smollm:360m	16,7	Галлюцинации, непонимание задачи
smollm2:135m	16,7	Галлюцинации, непонимание, случайный код
reader-lm:1.5b	0,0	Случайные ответы, несоответствие формату
reader-lm:0.5b	0,0	Таймауты, непонимание задачи

Ниже представлена таблица 3, которая отражает статистику по запуску моделей на Raspberry Pi 5b.

Таблица 3 – Сравнение моделей на Raspberry Pi 5b

Модель	Процент успеха	Среднее время ответа (сек.)	Лучшая задача	Худшая задача	Следование формату
smollm2:135m	0,0%	3,45	нет	нет	0,0%
gemma3:270m	30,0%	1,29	пропуск поворота	поворот на кубик	50,0%
smollm2:360m	0,0%	4,93	нет	нет	10,0%
smollm:135m	20,0%	7,23	пропуск поворота	поворот на кубик	30,0%
smollm:360m	20,0%	19,95	пропуск поворота	поиск ноги человека	25,0%
reader-lm:0.5b	0,0%	7,68	нет	нет	0,0%
qwen2.5:0.5b	20,0%	2,32	пропуск поворота	поворот на кубик	40,0%
qwen2.5-coder:0.5b	20,0%	1,95	движение прямо	поиск ноги человека	60,0%
gemma3:1b	20,0%	2,84	пропуск поворота	поворот на кубик	40,0%
reader-lm:1.5b	0,0%	9,44	нет	нет	0,0%
qwen2.5:1.5b	30,0%	5,21	поворот на кубик	поиск кубика	50,0%
qwen2.5-coder:1.5b	40,0%	2,53	пропуск поворота	движение к ноге человека	90,0%
smollm2:1.7b	10,0%	20,12	пропуск поворота	поворот на кубик	20,0%
smollm:1.7b	12,5%	24,15	пропуск поворота	поиск ноги человека	20,0%

qwen2.5:3b	50,0%	11,66	движение прямо	поворот на кубик	70,0%
qwen2.5-coder:3b	50,0%	5,39	пропуск поворота	поворот на кубик	85,0%
gemma3:4b	60,0%	8,36	поиск кубика, движение прямо	движение к ноге человека	80,0%
qwen2.5-coder:7b	60,0%	14,23	поиск кубика, пропуск поворота	движение к ноге человека	95,0%

На Raspberry Pi 5b ситуация с языковыми моделями иная. Если на Raspberry Pi 4b 20-30 секунд обработки одного промпта – средний показатель, на Raspberry Pi 5b 24 секунды – максимальный показатель. Raspberry Pi 5b намного более приспособлена к запуску языковых моделей.

В таблице 4 представлена статистика работы языковых моделей на Raspberry Pi 5b. Ожидаемо вид таблицы не отличается от таблицы 2.

Таблица 4 – Оценка работы языковых моделей для Raspberry Pi 5b

Модель	Успешность	Анализ проблем
qwen2.5-coder:7b	60,0%	Иногда пропускает сложные задачи, нестабильность в отдельных запусках
gemma3:4b	60,0%	Не понимает связь между ногой и человеком, ошибки в определении цвета
qwen2.5-coder:3b	50,0%	Пропускает задачи с поворотом, не всегда следует формату
qwen2.5:3b	50,0%	Низкая точность в задачах поиска объектов
qwen2.5-coder:1.5b	40,0%	Часто пропускает задачи (#SKIP), нестабильное качество
qwen2.5:1.5b	30,0%	Низкая точность, ошибки в определении параметров
gemma3:1b	20,0%	Часты неправильные ответы и непонимание
gemma3:270m	30,0%	Не следует инструкциям

qwen2.5-coder:0.5b	20,0%	Не справляется с большинством задач, выдает шаблонные ответы
qwen2.5:0.5b	20,0%	Низкая точность, не понимает русские команды
smollm2:1.7b	10,0%	Плохое понимание команд, выдает бессмысленные ответы
smollm:1.7b	12,5%	Таймауты, не следует формату
smollm:360m	20,0%	Код вместо ответов, не понимает задачи

smollm:135m	20,0%	Выдает Python код вместо ответов, неадекватные реакции
smollm2:360m	0,0%	Непонимание задач, бессвязные ответы
smollm2:135m	0,0%	Нерабочая модель, случайные символы
reader-lm:1.5b	0,0%	Таймауты, повторяет промпт вместо ответов
reader-lm:0.5b	0,0%	Таймауты, генерирует HTML/ текст

На основе проведенного исследования составлена таблица 5, по которой можно сравнить быстродействие моделей на разных моделях Raspberry.

Таблица 5 – Сравнение времени выполнения моделей

Модель	Raspberry Pi 5 (время, сек.)	Raspberry Pi 4 (время, сек.)
smollm2:135m	3,45	13,90
gemma3:270m	1,29	12,58
smollm2:360m	4,93	19,86
smollm:360m	19,95	49,90
qwen2.5-coder:0.5b	1,95	13,90
qwen2.5:0.5b	2,32	14,64
reader-lm:0.5b	7,68	25,36
gemma3:1b	2,84	15,68
qwen2.5-coder:1.5b	2,53	15,06
qwen2.5:1.5b	5,21	20,42
reader-lm:1.5b	9,44	28,88
smollm:135m	7,23	24,46
smollm2:1.7b	20,12	50,24
smollm:1.7b	24,15	58,30
qwen2.5-coder:3b	5,39	20,78
qwen2.5:3b	11,66	33,32
gemma3:4b	8,36	26,72
qwen2.5-coder:7b	14,23	38,46

Проведенное исследование позволило всесторонне оценить применимость современных открытых маловесящих языковых моделей на платформе микрокомпьютеров Raspberry Pi.

Среди всех рассмотренных моделей показали наилучшие результаты языковые модели семейства Gemma3 и Qwen2.5-coder.

Raspberry Pi 4b при использовании в качестве платформы для эксплуатации компактных языковых моделей себя дискредитировала: задержки при генерации ответов слишком высоки, чтобы языковая модель эффективно действовала в качестве мозга робота на микрокомпьютере.

Raspberry Pi 5 показал результаты намного лучше. Для наиболее компактных моделей Raspberry Pi 5 показывает высокую скорость генерации ответа. Однако модели с наилучшим результатом тратили на ответ более 5

секунд, что уже неприемлемо. Для наилучшего решения задачи управления роботом с Raspberry Pi 5 имеет смысл готовить языковые модели с нуля, полностью адаптированные под Raspberry и созданные для решения узкоспециализированной задачи.

СПИСОК ЛИТЕРАТУРЫ

1. gemma3. The current, most capable model that runs on a single GPU [Электронный ресурс]. – URL: <https://ollama.com/library/gemma3> (дата обращения: 28.09.2025).
2. qwen2.5. The latest series of Qwen large language models [Электронный ресурс]. – URL: <https://ollama.com/library/qwen2.5> (дата обращения: 28.09.2025).
3. qwen2.5-coder. The latest series of Code-Specific Qwen models, with significant improvements in code generation, code reasoning, and code fixing [Электронный ресурс]. – URL: <https://ollama.com/library/qwen2.5-coder> (дата обращения: 28.09.2025).
4. Герук, М. Raspberry Pi: практическое руководство для начинающих / М. Герук. – СПб.: БХВ-Петербург, 2022. – 288 с.
5. Raspberry Pi Foundation. Official Documentation [Электронный ресурс]. – URL: <https://www.raspberrypi.com/documentation/> (дата обращения: 27.09.2025).

СОВРЕМЕННЫЕ ПОДХОДЫ К ОРГАНИЗАЦИИ РАБОТЫ В ИТ-КОМАНДАХ: ГИБКИЕ МЕТОДОЛОГИИ И ИНСТРУМЕНТЫ КОЛЛАБОРАЦИИ

М.А.Цebro

Кубанский государственный университет

В работе рассматриваются современные подходы к организации труда в ИТ-командах, включая гибкие методологии разработки (Agile, Scrum, Kanban). Анализируются ключевые принципы и преимущества их использования, а также примеры практического применения в учебных проектах. Особое внимание уделено инструментам коллаборации и управления проектами. Делается вывод о значимости правильной организации процессов для достижения эффективности и успеха в ИТ-проектах.

Ключевые слова: гибкие методологии, Agile, Scrum, Kanban, ИТ-команда, управление проектами, командная работа, спринт, продукт-бэклог.

The paper explores modern approaches to organizing work in IT teams, including agile development methodologies (Agile, Scrum, Kanban). It analyzes the key principles and advantages of their implementation, as well as practical examples from educational projects. Special attention is paid to collaboration and project

management tools. The conclusion emphasizes the importance of effective organization for achieving success in IT projects.

Key words: flexible methodologies, Agile, Scrum, Kanban, IT team, project management, teamwork, sprint, product backlog.

Современная индустрия разработки программного обеспечения характеризуется высокой динамикой и постоянными изменениями требований. В таких условиях традиционные подходы к управлению проектами, такие как Waterfall, зачастую оказываются неэффективными, приводя к срыву сроков и снижению качества продукта. Гибкие методологии позволяют командам адаптироваться к изменениям, быстрее реагировать на запросы заказчиков и обеспечивать высокое качество конечного результата [1].

Agile – это не конкретная методология, а философия и система ценностей, отражённая в Манифесте гибкой разработки программного обеспечения. В основе Agile лежат четыре ключевых принципа: люди и взаимодействие важнее процессов и инструментов, работающий продукт важнее исчерпывающей документации, сотрудничество с заказчиком важнее согласования условий контракта, а готовность к изменениям важнее следования первоначальному плану. Эти принципы позволяют строить рабочие процессы, ориентированные на результат и постоянное совершенствование.

Одним из наиболее популярных фреймворков, реализующих Agile, является Scrum. Его основная идея заключается в итеративной разработке – проект делится на короткие циклы, называемые спринтами, каждый из которых длится от одной до четырёх недель. В начале каждого спринта команда определяет задачи, которые необходимо выполнить, а по завершении демонстрирует готовый инкремент продукта. В Scrum строго определены роли: Владелец продукта отвечает за формирование и приоритизацию задач, Scrum-мастер обеспечивает соблюдение принципов методологии и устраняет препятствия, а команда разработчиков реализует функциональность [2].

Методология Kanban отличается большей гибкостью. Она не требует фиксированных спринтов и ролей, а делает акцент на визуализацию рабочих процессов. Задачи размещаются на доске в виде карточек, которые проходят стадии «К выполнению», «В работе», «Готово». Такой подход позволяет контролировать загрузку команды, устранять «узкие места» и повышать прозрачность процессов. Kanban особенно эффективен для команд, работающих в условиях постоянно меняющихся приоритетов и непрерывных задач [3].

Практическое применение гибких методологий было реализовано в рамках учебного проекта по созданию веб-приложения «Трекер задач». Проектная команда состояла из нескольких студентов, каждый из которых выполнял определённую роль. Владелец продукта формировал видение конечного результата и создавал Product Backlog. На этапе планирования

использовалась техника «покера планирования» для оценки сложности задач в стори-пойнтах. Это способствовало объективной оценке трудозатрат и равномерному распределению нагрузки.

Особое значение в ходе работы над проектом имело формирование процессов командного взаимодействия. Каждый участник не просто выполнял отдельные задачи, а активно участвовал в планировании спринтов, обсуждении приоритетов и оценке результатов. Это позволило выстроить среду, близкую к условиям работы в настоящих IT-компаниях, где успех зависит от постоянной коммуникации и согласованных действий. В процессе реализации проекта участники освоили практику code review и научились воспринимать замечания коллег как часть общего улучшения продукта, что способствует развитию профессиональной культуры и ответственности.

Важным элементом проекта стало использование принципов модульного проектирования и чистой архитектуры. Backend был организован таким образом, чтобы каждый компонент выполнял строго определённую задачу – обработку запросов, валидацию данных, управление логикой или взаимодействие с хранилищем. Это обеспечило читаемость и удобство сопровождения кода. Аналогичный подход применялся и на frontend, где интерфейс был разбит на отдельные функциональные блоки, отвечающие за ввод данных, отображение списка обращений и обработку событий. Такая организация кода повышает масштабируемость приложения и облегчает внедрение новых функций.

Особое внимание уделялось вопросам производительности и оптимизации. При работе с данными на стороне сервера использовались методы кэширования и отложенной загрузки, что позволило снизить задержки при большом количестве обращений. На клиентской стороне была реализована оптимизация рендеринга интерфейса и повторного использования DOM-элементов, благодаря чему интерфейс оставался отзывчивым даже при увеличении объёма данных. Эти меры показали, насколько важен баланс между функциональностью и эффективностью реализации.

Отдельно стоит отметить образовательную ценность проекта. Работа над full-stack приложением дала возможность применить знания по нескольким направлениям одновременно: программированию, архитектуре систем, тестированию, управлению проектами и командным процессам. Такой опыт способствует развитию комплексного мышления, когда разработчик понимает не только отдельные участки кода, но и взаимосвязь всех компонентов системы. Кроме того, участие в командной разработке формирует навыки планирования, ответственности и самоорганизации – ключевые качества для успешной карьеры в IT-сфере.

Работа в спринте сопровождалась ежедневными короткими встречами – стендапами, на которых каждый участник сообщал, что он сделал, что планирует и какие трудности возникли. Такие встречи занимали не более 15 минут и позволяли оперативно решать проблемы, а также поддерживать

высокий уровень коммуникации внутри команды. В конце каждого спринта проводились ретроспективы, где обсуждались успехи и проблемы, а также формировался план улучшений на следующий цикл.

Для организации работы и коммуникации использовались современные инструменты. Jira применялась для ведения бэклога и контроля задач, Google Meet и VK Teams – для видеоконференций и обмена сообщениями. Git и GitHub обеспечивали совместную работу над кодом и проведение code review. Использование CI/CD позволило автоматизировать процесс тестирования и развёртывания, что повысило качество продукта и сократило время между итерациями [4].

В результате реализации учебного проекта команда смогла успешно внедрить все запланированные функции, включая аутентификацию, CRUD-операции, назначение исполнителей и генерацию отчётов. Основным достижением стало повышение эффективности взаимодействия и самоорганизации участников. Даже при минимальном управленческом вмешательстве команда достигала поставленных целей в установленные сроки благодаря прозрачности и постоянной обратной связи.

Гибкие методологии не лишены недостатков. Среди них можно выделить необходимость высокой дисциплины, зрелости команды и постоянного вовлечения заказчика. Кроме того, для успешного применения Agile требуется определённая культура взаимодействия, доверие и готовность к постоянным изменениям. Однако преимущества, такие как быстрая адаптация, высокая мотивация и улучшение качества продукта, значительно перевешивают возможные сложности.

Одним из значимых факторов успеха гибких команд является культура постоянной обратной связи. Регулярные ретроспективы позволяют не просто обсуждать ошибки, а вырабатывать конкретные решения для их устранения. Этот процесс формирует у участников ответственность за общее качество продукта и способствует росту профессиональных компетенций. Кроме того, практика открытой коммуникации снижает вероятность конфликтов и повышает доверие внутри коллектива. В современных компаниях именно способность вести конструктивный диалог и гибко реагировать на изменения становится важнее, чем технические навыки отдельных специалистов.

Немаловажную роль играет и применение метрик эффективности. В Scrum для анализа производительности часто используют такие показатели, как скорость команды (velocity), время цикла (cycle time) и коэффициент завершённых задач (completion rate). Эти метрики позволяют объективно оценить прогресс, прогнозировать сроки выполнения спринтов и выявлять области для оптимизации. В учебных проектах использование подобных инструментов помогает студентам понять, как аналитика и количественные данные могут улучшать процесс разработки и управление проектом.

Таким образом, гибкие методологии разработки доказали свою эффективность как в промышленной, так и в образовательной среде. Они не только позволяют создавать качественные IT-продукты, но и формируют у

участников команды критически важные компетенции: умение работать в коллективе, отвечать за результат, взаимодействовать с заказчиком и непрерывно улучшать процессы. Эти навыки становятся ключевыми для будущих IT-специалистов, готовых к работе в современных условиях цифровой экономики.

Дальнейшее развитие гибких методологий, таких как Scrumban или Agile@Scale, открывает новые перспективы для организации работы в распределённых командах. Интеграция искусственного интеллекта в инструменты планирования и анализа задач позволяет ещё больше повысить эффективность процессов, а цифровые платформы обеспечивают прозрачность и управляемость даже самых крупных проектов.

СПИСОК ЛИТЕРАТУРЫ

1. Роли в разработке ИТ-продукта // Habr. 2022. URL: <https://habr.com/ru/articles/695944/> (дата обращения: 23.10.2025).
2. Waterfall или Agile, Scrum или Kanban: что выбрать // Habr. 2025. URL: <https://habr.com/ru/companies/kaiten/articles/906006/> (дата обращения: 23.10.2025).
3. Разбираемся в Scrum: Руководство с примерами // Habr. 2022. URL: <https://habr.com/ru/articles/825354/> (дата обращения: 23.10.2025).
4. Официальная документация по фреймворку Scrum: Scrum Guides. 2020. URL: <https://scrumguides.org/> (дата обращения: 23.10.2025).

РАЗРАБОТКА И ВНЕДРЕНИЕ ИНФРАСТРУКТУРЫ ДЛЯ ИНТЕРАКТИВНЫХ ВЫЧИСЛЕНИЙ И РАБОТЫ С ИИ- ИНСТРУМЕНТАМИ НА БАЗЕ JUPYTER NOTEBOOK В КОНТЕЙНЕРИЗИРОВАННОЙ СРЕДЕ

Д.В. Цебулевский, Д.Б. Лигидов
Кубанский государственный университет

В статье рассматриваются принципы построения контейнеризированной инфраструктуры для интерактивных вычислений и работы с инструментами искусственного интеллекта на базе Jupyter, Docker и Kubernetes. Описаны архитектурные компоненты системы, включая JupyterHub, Jupyter Notebook, Особое внимание уделено вопросам разработки базовых Docker-образов, управлению окружениями и интеграции GPU-ресурсов для ускорения вычислений. Приведены решения по аутентификации, изоляции пользователей и масштабированию инфраструктуры с использованием инструментов Kubernetes. Рассмотрены подходы к мониторингу и логированию, обеспечивающие надёжную эксплуатацию системы.

Ключевые слова: интерактивные вычисления, инфраструктура данных, Jupyter Notebook, JupyterHub, контейнеризованная среда, Docker, Kubernetes, оркестрация контейнеров, управление зависимостями, образы контейнеров, GPU ускорение, среды для работы с ИИ, фреймворки машинного обучения, PyTorch, TensorFlow, масштабируемость, многопользовательский доступ, аутентификация и авторизация, изоляция окружений, reproducible research, CI/CD для data science окружений, мониторинг и логирование ресурсов.

The article discusses the principles of building a containerized infrastructure for interactive computing and artificial intelligence (AI) workloads based on Jupyter, Docker, and Kubernetes. It describes the key architectural components of the system, including JupyterHub, Jupyter Notebook. Special attention is given to the development of base Docker images, environment management, and GPU integration for accelerated computations. Solutions for user authentication, isolation, and infrastructure scaling using Kubernetes mechanisms are presented. The paper also covers monitoring and logging approaches that ensure stable and reliable system operation.

Key words: interactive computing, data infrastructure, Jupyter Notebook, JupyterHub, containerized environment, Docker, Kubernetes, container orchestration, dependency management, container images, GPU acceleration, AI tooling environments, machine learning frameworks, PyTorch, TensorFlow, scalability, multi user access, authentication and authorization, environment isolation, reproducible research, CI/CD for data science environments, resource monitoring and logging.

Современные направления научных исследований и инженерных разработок всё чаще требуют использования интерактивных вычислительных сред, обеспечивающих гибкость, масштабируемость и воспроизводимость экспериментов. Особенно остро эти требования проявляются в области анализа данных и искусственного интеллекта (AI), где объёмы вычислений постоянно растут, а инфраструктурные решения должны быстро адаптироваться под меняющиеся задачи [1].

Одним из наиболее эффективных подходов к организации вычислительной среды является использование контейнеризации и систем оркестрации, таких как Docker и Kubernetes. Эти технологии позволяют создавать изолированные, управляемые и легко масштабируемые окружения, что значительно упрощает эксплуатацию вычислительных ресурсов и поддержку исследовательских проектов.

Система Jupyter и её расширения (JupyterHub, JupyterLab) стали стандартом де-факто для интерактивных вычислений, визуализации данных и обучения нейронных сетей. В сочетании с контейнеризацией и средствами оркестрации Jupyter обеспечивает создание универсальной платформы, доступной для исследователей, преподавателей и разработчиков [2].

Актуальность темы заключается в необходимости построения надёжной, безопасной и масштабируемой инфраструктуры, способной

поддерживать множество пользователей и разнообразные вычислительные задачи – от обучения моделей машинного обучения до выполнения экспериментальных исследований.

Целью данной работы является описание архитектуры и принципов построения контейнеризированной инфраструктуры для интерактивных вычислений на базе Jupyter, Docker и Kubernetes, а также анализ инструментов, обеспечивающих безопасность, масштабирование и мониторинг системы.

Современные вычислительные задачи в областях анализа данных и искусственного интеллекта (AI) требуют гибких и надёжных платформ, обеспечивающих высокую производительность, воспроизводимость экспериментов и удобство совместной работы [3]. Традиционные серверные решения часто не удовлетворяют этим требованиям из-за сложности настройки, недостаточной масштабируемости и ограниченной изоляции вычислительных окружений. Эффективной альтернативой становится использование контейнерных технологий и систем оркестрации, таких как Docker и Kubernetes, в сочетании с интерактивной средой Jupyter.

В основе такой инфраструктуры лежит модульный подход, где каждый компонент выполняет отдельную функцию и взаимодействует с другими через стандартизированные интерфейсы. Центральным элементом является JupyterHub, отвечающий за аутентификацию пользователей, управление их сессиями и распределение ресурсов. Пользовательская работа ведётся через Jupyter Notebook или JupyterLab, предоставляющие интерактивный интерфейс для написания и выполнения кода, анализа данных и визуализации результатов.

Каждая пользовательская сессия запускается в Docker-контейнере, что обеспечивает полную изоляцию окружения и воспроизводимость вычислительных экспериментов. Контейнеры оркестрируются с помощью Kubernetes, который автоматически управляет их развёртыванием, масштабированием и отказоустойчивостью. Для хранения данных используются распределённые системы, такие как Ceph, NFS или S3, предоставляющие централизованный доступ к пользовательским файлам и моделям машинного обучения.

Особое внимание уделяется использованию GPU-ресурсов. Интеграция NVIDIA Container Toolkit позволяет подключать графические ускорители внутри контейнеров, обеспечивая работу библиотек глубокого обучения – TensorFlow, PyTorch и других. Это даёт возможность проводить обучение и инференс нейронных сетей с высокой скоростью, сохраняя при этом гибкость и безопасность инфраструктуры.

Для управления нагрузкой и обеспечением устойчивости инфраструктура использует встроенные механизмы масштабирования Kubernetes – Horizontal Pod Autoscaler и Cluster Autoscaler. Они автоматически регулируют количество активных контейнеров и вычислительных узлов в зависимости от загрузки процессора, объёма данных и числа пользователей. Совместно с инструментами балансировки и самовосстановления (self-healing)

эти механизмы обеспечивают стабильную работу системы даже при пиковых нагрузках.

Надёжность и прозрачность эксплуатации обеспечиваются средствами мониторинга и логирования. Связка Prometheus и Grafana позволяет отслеживать производительность и визуализировать метрики, а стек ELK (Elasticsearch, Logstash, Kibana) используется для анализа логов и диагностики ошибок. Такой подход позволяет администраторам оперативно выявлять проблемы, а исследователям – контролировать эффективность своих вычислений.

Реализация контейнеризированной инфраструктуры на базе Jupyter, Docker и Kubernetes обеспечивает значительные преимущества: стандартизацию вычислительной среды, безопасность, гибкость масштабирования и повторяемость экспериментов [4]. В образовательных организациях такая система предоставляет студентам доступ к мощным вычислительным ресурсам без необходимости локальной установки программного обеспечения, а в исследовательских центрах ускоряет запуск и сопровождение AI-проектов.

СПИСОК ЛИТЕРАТУРЫ

1. Кузнецов В.А. Микросервисная архитектура и контейнеризация. – М.: БХВ-Петербург, 2022. – 368 с.
2. Fowler M. Микросервисы: определение нового архитектурного термина. – ThoughtWorks, 2014. – 8 с.
3. Newman S. Проектирование AI Инфраструктуры. – O'Reilly Media, 2021. – 352 с.
4. Советов Б.Я., Паклин Н.Б. Информационные системы и технологии в инфраструктуре Kubernetes. – М.: Kubernetes, 2022. – 412 с.

МОДЕЛИРОВАНИЕ БИЗНЕС-ПРОЦЕССОВ ЗАКАЗЧИКА И МОДИФИКАЦИЯ ТИПОВОЙ КОНФИГУРАЦИИ «SANDSOFT: САНАТОРИЙ V7» С ЦЕЛЬЮ ПОВЫШЕНИЯ ЭФФЕКТИВНОСТИ РАБОТЫ

А.С. Чепик, М.В. Чаус, И.А. Оганян
Кубанский государственный университет

Статья посвящена вопросам повышения эффективности работы санаторно-курортных учреждений за счет моделирования бизнес-процессов и модификации типовой конфигурации «Sandsoft: Санаторий v7». Основным результатом работы стала разработка и внедрение в систему документа «Установка емкости мест питания», который позволяет гибко планировать и учитывать пропускную способность точек питания, а также повышает качество сервиса и демонстрирует эффективность модификации типовых

конфигураций под уникальные бизнес-процессы.

Ключевые слова: моделирование бизнес процессов, анализ бизнес процессов заказчика, нотации BPMN и IDEF0, оптимизация процессов санатория, типовая конфигурация «SANDSOFT: Санаторий V7», доработка конфигурации, кастомизация функционала, автоматизация бронирования и размещения, управление загрузкой номерного фонда, управление медицинскими услугами, интеграция с бухгалтерским учетом, управление лояльностью клиентов, отчетность и аналитика, повышение эффективности работы персонала, цифровая трансформация санаторно курортного учреждения.

The article is devoted to the issues of increasing the efficiency of the work of sanatorium and resort institutions through the modeling of business processes and modification of the standard configuration «Sandsoft: Sanatorium v7». The main result of the work was the development and implementation of the document «Setting the capacity of food outlets» in the system, which allows for flexible planning and accounting for the capacity of food outlets, as well as improves the quality of service and demonstrates the effectiveness of modifying standard configurations for unique business processes.

Key words: business process modeling, customer business process analysis, BPMN and IDEF0 notations, sanatorium process optimization, standard configuration “SANDSOFT: Sanatorium V7”, configuration customization, functional extension, automation of booking and accommodation, room capacity management, medical services management, integration with accounting systems, customer loyalty management, reporting and analytics, staff efficiency improvement, digital transformation of health resort enterprises.

В современном мире информационные технологии перестали быть вспомогательным инструментом, они активно внедряются в медицину, ведь ИТ-решения позволяют перевести здравоохранение на качественно новый уровень эффективности работы сотрудников.

Санаторно-курортная сфера также нуждается в автоматизации для минимизации рутинной работы и концентрации на главном: на комплексном оздоровлении пациента. Типовые конфигурации представляют собой мощный инструмент для автоматизации деятельности санаторно-курортных учреждений. Они содержат лучшие отраслевые практики и покрывают большинство стандартных операций. Однако каждая организация уникальна и имеет свои особенности ведения бизнеса. Для решения одной из таких задач заказчика крупной ассоциации были смоделированы бизнес-процессы санатория, а также подобрано решение «SandSoft: Санаторий v7», отвечающее основным требованиям клиента [1].

Одна из основных задач заключалась в оптимизации процесса управления питанием, а именно: в решении проблемы ручного контроля загрузки столовых и предотвращения их переполненности. Санаторий заказчика содержит несколько мест питания, каждое из которых в разные

сезоны вмещает определенное количество пациентов (рис.1).




Рисунок 1 – Места питания санатория

Есть необходимость в фиксации количества мест в каждой точке питания (рис.2), а также возможность просмотра данных за прошлые сезоны.



Рисунок 2 – Пункты бизнес-процесса «Питание в санатории»

Ключевым результатом работы стала разработка и внедрение документа «Установка емкости мест питания» в типовую конфигурацию (рис.3).



Рисунок 3 – Документ «Установка емкости мест питания»

Документ включает в себя номер и дату создания, в табличной части можно ввести следующую информацию: порядковый номер, место питания, номер смены, количество мест.

Перед созданием документа необходимо убедиться, что есть необходимые исходные данные, которые требуются в открывшейся форме.

Создать новый документ также можно копированием предыдущего, если это удобно пользователю.

В уже проведенном документе можно отменить проводку в случае отмены или введения ненужного документа (рис.4).




Рисунок 4 – Работа с созданным документом

Документы хранятся списком для того, чтобы создать новый план емкости, необходимо нажать кнопку «Создать», после чего откроется непосредственно сам объект (рис. 5).

←

→

☆

Установка емкости мест питания

Создать



Дата	↓	Номер
------	---	-------

Для добавления мест питания создана кнопка «Добавить», при ее нажатии в табличной части документа добавляется строка для ввода необходимых данных (рис. 6) [2].

Рисунок 6 – Кнопка «Добавить»

Порядковый номер точек питания вводится системой автоматически, начиная с единицы [2].

При вводе наименования точки питания в графе «Место питания», система по первым введенным буквам показывает список совпадений, что делает заполнение документа гораздо проще и удобнее. Для нахождения программой соответствий достаточно одного символа.

N	Место питания
1	Ресторан № 1 Столовая №1 Показать все +

Рисунок 7 – Выбор места питания

Для удобства, как было сказано ранее, документы хранятся списком. Открыть можно любой из созданных объектов. При создании можно ввести номер на усмотрение пользователя для удобства работы в программе, в случае отсутствия такой необходимости, это поле заполняется автоматически [3].

Такой формат хранения ранее созданных документов позволяет с легкостью получать доступ к предыдущим объектам (рис.8), что отвечает запросу заказчика [4].

← → ☆ Установка емкости мест питания

Создать +

Дата	Номер
23.09.2025 13:00:01	ОС1
25.09.2025 11:48:27	ОС2

Рисунок 8 – Список документов

Разработанный документ «Установка емкости мест питания» стал не просто техническим новшеством, а инструментом, который напрямую повлиял на качество сервиса, снизил операционные риски и обеспечил удобство в планировании питания пациентов. Данный подход может быть применен и для оптимизации других областей деятельности санатория.

Проведенная работа по моделированию бизнес-процессов заказчика и точечной модификации типовой конфигурации «SandSoft: Санаторий v7» наглядно демонстрирует, как даже небольшие, но целевые изменения могут значительно повысить эффективность работы сотрудников организации.

СПИСОК ЛИТЕРАТУРЫ

1. SandSoft Разработка программного обеспечения для индустрии гостеприимства. [Электронный ресурс] URL: <https://sandsoft.info/> (дата обращения: 08.09.2025)
2. М. Г. Радченко 1С:Предприятие 8.3. Практическое пособие разработчика. Примеры и типовые приемы. Издание 3. / М.Г. Радченко, Е.Ю. Хрусталева. – Москва: ООО «1С-Паблишинг», 2023 – 982 с.
3. Хрусталева Е.Ю. Разработка сложных отчетов в «1С:Предприятии 8». / Е.Ю. Хрусталева. – Москва: ООО «1С-Паблишинг», 2012. – 485 с.
4. Информационная система 1С: ИТС. [Электронный ресурс] URL: <https://its.1c.ru/> (дата обращения: 23.09.2025)

МЕТОД КВАНТИЛЬНОЙ КАТЕГОРИЗАЦИИ ДЛЯ ПОВЫШЕНИЯ ТОЧНОСТИ ПРОГНОЗИРОВАНИЯ ПАРАМЕТРОВ ЗАДАЧ ЦИФРОВЫХ ПЛАТФОРМ

В.В. Дуденков

Кубанский государственный университет

Цифровые платформы, предназначенные для поиска исполнителей и размещения проектных задач, характеризуются высокой динамичностью и большим объёмом разнородных данных. Одной из ключевых задач в таких системах является прогнозирование стоимости и длительности выполнения задач на основе текстовых описаний и структурированных атрибутов. Точность подобных прогнозов существенно влияет на эффективность взаимодействия между заказчиками и исполнителями, снижает неопределённость и повышает доверие пользователей к платформе. Однако данные цифровых сервисов обладают специфическими особенностями: выраженной асимметрией распределений стоимости, наличием выбросов, сезонной изменчивостью и сильной разнородностью текстов.

Классические регрессионные методы, применяемые к полной выборке без предварительного структурирования данных, демонстрируют ограниченную точность именно из-за указанной неоднородности. Особенно заметно это проявляется в высоких ценовых диапазонах, где ошибки прогнозирования возрастают вследствие редкости соответствующих задач и высокой вариативности их характеристик. В связи с этим возникает необходимость в методах, позволяющих разделить исходные данные на более однородные подмножества и адаптировать модель под каждую из таких групп.

Одним из наиболее эффективных подходов является квантильная категоризация стоимости и длительности задач, при которой выборка делится на несколько диапазонов на основе квартилей или других статистически устойчивых порогов. Такой метод позволяет устранить влияние

экстремальных значений, снизить дисперсию внутри категорий и создать условия для построения специализированных моделей, оптимизированных под соответствующий диапазон значений целевой переменной. Кроме того, квантильная категоризация упрощает процесс интерпретации результатов, поскольку каждая группа отражает определённый уровень сложности или масштаб задач.

Результаты применения квантильной сегментации показывают, что переход от единой модели к набору специализированных моделей приводит к заметному повышению точности прогнозов. Особенно выраженный эффект наблюдается в верхних квантилях стоимости, где снижение средних ошибок может достигать 20–25 %. Это объясняется тем, что модели перестают «тянуться» к среднему значению всей выборки и начинают учитывать особенности конкретного ценового сегмента. Аналогичный эффект наблюдается и при прогнозировании длительности выполнения задач, хотя вариативность сроков чаще определяется субъективными факторами и человеческими задержками.

Таким образом, квантильная категоризация выступает важным инструментом повышения качества моделей прогнозирования на цифровых платформах. Её использование позволяет значительно улучшить точность, повысить устойчивость моделей к выбросам и адаптировать процесс обучения к структуре реальных данных. Метод легко интегрируется в существующие архитектуры машинного обучения и может быть применён как в исследовательских задачах, так и в реальных промышленных системах.

Продолжая исследование влияния сегментации данных на качество прогнозных моделей, важно отметить, что применение квантильного разбиения эффективно не только само по себе, но и в сочетании с современными методами представления текстов. Наиболее перспективным направлением является использование языковых моделей трансформерного типа, способных формировать высокоинформативные эмбединги даже для коротких и неструктурированных описаний задач. Эти представления позволяют моделям улавливать контекстные зависимости, характерные для предметной области, что создаёт более устойчивое и обобщённое признаковое пространство.

Комбинация трансформерных эмбедингов и квантильной категоризации формирует двухуровневую архитектуру обработки данных. На первом уровне осуществляется генерация текстовых признаков, на втором уровне – построение отдельных моделей для каждой категории. Такая архитектура позволяет учитывать, как семантические особенности описаний, так и статистические свойства распределения целевых переменных. Практические эксперименты с подобным подходом демонстрируют снижение ошибок прогноза на выборках крупного масштаба, что подтверждает его применимость к задачам реальных цифровых платформ.

Особое значение имеет тот факт, что квантильная сегментация способствует устранению перекоса распределения ошибок. В условиях

реальных платформ наблюдается тенденция к тому, что единая модель недооценивает стоимость сложных задач и переоценивает стоимость простых. Это связано с влиянием средних значений, которое существенно при широком диапазоне цен. Сегментация позволяет устранить этот эффект, поскольку каждая модель обучается на линейно более однородной подвыборке. Как показывают результаты анализа, именно уменьшение внутренней вариативности данных в пределах каждой группы вносит основной вклад в повышение точности.

Дополнительным преимуществом является улучшение устойчивости моделей к данным низкого качества. Имея возможность обучаться на подгруппах, модель игнорирует глобальные шумы, характерные для всей выборки, и фокусируется на локальных закономерностях. Это особенно важно для платформ, где текстовые описания могут содержать опечатки, неполные сведения или субъективные оценки. Благодаря этому повышается переносимость моделей на новые данные, а их прогнозы становятся стабильнее с течением времени.

Перспективным направлением дальнейшего развития подхода является интеграция квантильной категоризации с методами активного обучения и динамической перенастройки границ квантилей. Это позволит адаптировать сегментацию под изменяющуюся структуру данных в режиме реального времени. Также представляет интерес расширение набора признаков за счёт поведенческих и временных характеристик, что может повысить точность прогнозов в условиях ограниченной текстовой информации. Всё это указывает на значимость рассматриваемого метода для построения интеллектуальных систем поддержки принятия решений на цифровых платформах.

Важным аспектом применения квантильной категоризации является её совместимость с алгоритмами градиентного бустинга, которые проявляют высокую устойчивость в условиях неоднородных данных. CatBoost, являясь одной из наиболее эффективных моделей для табличных данных, способен учитывать особенности текстовых эмбедингов и взаимодействия признаков, что делает его подходящим инструментом для построения сегментированных моделей. Использование отдельных моделей для каждого квантиля обеспечивает дополнительные преимущества, связанные с возможностью точной настройки гиперпараметров и оптимизацией под структуру каждой подвыборки.

Результаты практического применения подхода показывают, что наиболее значимое снижение ошибок достигается для задач, относящихся к крайним квантилям распределения стоимости. Именно в этих группах единая модель демонстрирует наиболее высокие значения ошибки, поскольку экстремальные значения плохо согласуются с общей динамикой данных. Сегментация позволяет компенсировать эти эффекты и обеспечить более реалистичные прогнозы вне зависимости от сложности или объёма задачи. Таким образом, подход демонстрирует преимущества в условиях сильной

вариативности описаний, типичной для проектов, размещаемых на цифровых платформах.

Кроме этого важно подчеркнуть, что полученные результаты свидетельствуют о высокой применимости метода в задачах операционной аналитики. Сегментированные прогнозы позволяют цифровым платформам стабилизировать механизмы ценообразования, а также повышать качество рекомендаций, предлагаемых пользователям. Более точные оценки стоимости и длительности способствуют снижению числа отказов, повышению доверия к платформе и улучшению пользовательского опыта. Это подтверждает важность интеграции подобных инструментов в инфраструктуру цифровых сервисов, ориентированных на автоматизацию процессов и повышение эффективности взаимодействия между пользователями.

Завершая рассмотрение, следует отметить, что метод квантильной категоризации обладает универсальностью и может применяться не только в задачах прогнозирования стоимости и сроков выполнения работ, но и в широком спектре аналитических задач, связанных с разреженными и гетерогенными данными. Благодаря способности адаптироваться к структуре выборки данный подход может использоваться при анализе спроса, ранжировании элементов, выявлении аномалий и формировании персонализированных рекомендаций. Это делает его ценным инструментом для исследователей и разработчиков систем искусственного интеллекта, работающих с большими массивами текстовой информации.

Помимо практической значимости, использование сегментированных моделей создаёт основу для развития научных исследований в области обработки естественного языка и прогнозной аналитики. В частности, актуальным становится изучение влияния структуры квантилей на устойчивость моделей, оценка оптимального количества сегментов и исследование методов объединения частных моделей в единую композицию. Эти направления открывают возможности для дальнейших улучшений точности и интерпретируемости моделей, а также способствуют развитию гибридных архитектур, объединяющих преимущества статистического анализа и глубокого обучения.

Как итог, квантильная сегментация в сочетании с трансформерными эмбедингами представляет собой эффективный и перспективный подход к улучшению качества прогнозов на больших текстовых выборках. Она обеспечивает повышение точности, устойчивость к шуму и улучшенную адаптацию моделей к особенностям данных. Полученные результаты подтверждают целесообразность применения метода в реальных цифровых платформах и демонстрируют его потенциал для дальнейшего практического и теоретического развития.

СПИСОК ЛИТЕРАТУРЫ

1. Девлин Дж., Чанг М.-В., Ли К., Татсунос А. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding // Proceedings of NAACL-HLT. 2019.
2. Бахтеев О.Ю. CatBoost: библиотека градиентного бустинга для обработки категориальных признаков // Программные продукты и системы. 2020. № 4.
3. Shavrina T., Shapovalova A. RussianSuperGLUE: A test suite for evaluating Russian language models // Computational Linguistics and Intellectual Technologies. 2020.
4. Васильев А.В. Машинное обучение: Наука и практика. М.: Лань, 2021.
5. Жигун А.П. Обработка естественного языка: современные методы. СПб.: Питер, 2020.

Научное издание

**СОВРЕМЕННОЕ СОСТОЯНИЕ И ПРИОРИТЕТЫ РАЗВИТИЯ
ФУНДАМЕНТАЛЬНЫХ НАУК В РЕГИОНАХ**

Материалы
XXII Всероссийской научной конференции молодых ученых и студентов

Материалы представлены в авторской редакции

Кубанский государственный университет
350040, г. Краснодар, ул. Ставропольская, 149.